

卒業研究報告書

題目

マルチモーダル学習による薬剤鑑別

指導教員

森山 真光 准教授

報告者

23-1-211-0009

呉竹 權人

近畿大学情報学部情報学科

令和 7 年 5 月 22 日提出

概要

薬剤の取り違いや誤服用は医療安全上の重要な課題であり、医療現場や家庭では、薬剤名が記載された外箱や薬袋が失われた場合、または薬剤本体や PTP シートのみが残された場合に、錠剤やカプセルの外観、刻印、包装上の印字など限られた視覚情報を手がかりに薬剤を鑑別する必要がある。本研究では、薬剤画像とテキストプロンプトを入力とし、薬剤名を出力する Vision-Language Model 型の薬剤鑑別手法を検討する。具体的には、オープンソースのマルチモーダル LLM である Qwen3.5 を用い、薬剤画像に対して「この錠剤は何という薬ですか」という質問を与え、正解薬剤名を出力するように LoRA によるファインチューニングを行う。比較対象として、ファインチューニング前の Qwen3.5 および ChatGPT・Gemini などの外部 API 型マルチモーダル AI によるゼロショット識別を用い、薬剤画像データに特化したファインチューニングが薬剤鑑別精度に与える効果を評価する。また、今後の発展的課題として、薬剤データベースを検索して候補薬剤情報を提示する RAG 型手法との比較も検討する。

目次

1	序論	1
1.1	本研究の背景	1
1.2	従来研究と課題	1
1.3	本研究の目的	2
1.4	本報告書の構成	2
2	関連研究	3
2.1	画像特徴・刻印文字を用いた薬剤識別手法	3
2.2	画像特徴とテキスト特徴を用いたマルチモーダル薬剤識別手法	3
2.3	生成 AI・LLM を用いた薬剤識別支援手法	4
2.4	先行研究の整理と本研究の位置づけ	4
3	研究内容	5
3.1	研究テーマの整理	5
3.2	解決策の妥当性	5
3.3	使用モデル：Qwen3.5	6
3.4	提案手法：Qwen3.5 の LoRA ファインチューニング	6
3.5	比較手法	7
3.6	使用データ	7
3.7	評価方法	7
3.8	実験計画	8
4	予備実験	9
4.1	予備実験の目的	9
4.2	使用データと拡張処理	9
4.3	学習設定	9
4.4	単一薬剤による予備学習	10
4.5	Gemini API との比較	10
4.6	全薬剤を対象とした予備学習	11
4.7	誤識別の傾向分析	11
4.8	予備実験から得られた示唆	12
5	結果・考察	13
6	結論・今後の課題	14

1 序論

1.1 本研究の背景

薬剤の取り違いや誤服用は、患者の健康被害につながる医療安全上の重要な問題である。医療現場や家庭では、薬剤名が記載された外箱や薬袋が失われた場合、または薬剤本体や PTP シートのみが残された場合に、錠剤やカプセルの外観、刻印、包装上の印字など限られた視覚情報を手がかりに薬剤を鑑別する必要がある。特に、高齢者が複数の薬剤を長期的に服用する場合や、一包化調剤によって複数の薬剤がまとめられる場合には、薬剤の識別が困難になり、誤服用のリスクが高まる。

従来、薬剤鑑別には薬剤師などの専門知識が必要であり、薬剤データベースを手作業で検索する負担も大きい。また、白色円形の錠剤のように外観が類似する薬剤も多く、画像のみから薬剤を正確に識別することは容易ではない。このような背景から、薬剤画像を用いて自動的に薬剤を識別する研究が行われてきた。

1.2 従来研究と課題

Heo ら [1] は、薬剤識別を認識ステップと検索ステップに分けた深層学習ベースの薬剤識別システムを提案している。YOLOv5 により錠剤表面の刻印文字を検出し、ResNet-32 により形状、色、剤形を認識する。さらに、RNN ベースの文字レベル言語モデルを用いて検出された刻印文字の誤りを補正し、薬剤データベース内の情報との類似度に基づいて候補薬剤を順位付けする。この手法は、薬剤画像に含まれる視覚情報と刻印文字情報を組み合わせて識別する点で有効であり、検索型の構成を採用することで学習に含まれない薬剤への対応も考慮している。一方で、複数の専用モジュールを組み合わせる必要があり、システム構成が複雑である。また、刻印文字を重要な識別手がかりとしているため、刻印が不明瞭な画像や刻印のない薬剤では識別性能が低下する可能性がある。

Rádli ら [3] は、薬剤画像の視覚特徴と薬剤説明テキストから得られるテキスト特徴を組み合わせたマルチモーダルな薬剤認識手法を提案している。この研究は、画像情報だけでなくテキスト情報を利用して薬剤認識を行う点で本研究と近い。一方で、同手法は画像特徴抽出器、テキスト埋め込み、メトリクス学習を個別に設計する構成であり、画像とテキストプロンプトを入力として薬剤名を直接生成する Vision-Language Model 型の手法ではない。

Menaha ら [2] は、Google Gemini を用いた生成 AI ベースの薬剤識別支援システムを提案している。この研究は、マルチモーダル AI を薬剤識別支援に応用している点で本研究と関連する。一方で、同研究は商用クローズドソースモデルを用いたプロンプトベースの手法であり、薬剤画像データを用いてモデル自体をファインチューニングする構成ではない。また、外部 API を利用する場合、薬剤画像を外部サービスに送信する必要がある、プライバシー上の懸念が残る。

以上の課題から、(1) 錠剤本体の外観、刻印、包装上の印字など複数の視覚情報を統合した識別、(2) 外部 API に過度に依存しないローカル動作の可能性、(3) 薬剤画像に特化したファインチューニングによる識別精度の向上、の 3 点を検討する必要がある。

1.3 本研究の目的

本研究では、オープンソースの Vision-Language Model である Qwen3.5 を用い、薬剤画像とテキストプロンプトから薬剤名を出力する薬剤鑑別手法を検討する。具体的には、薬剤画像に対して「この錠剤は何という薬ですか」という質問を与え、正解薬剤名を出力するように LoRA によるファインチューニングを行う。

本研究の目的は、ファインチューニング前の Qwen3.5 および ChatGPT・Gemini などの外部 API 型マルチモーダル AI と比較することで、薬剤画像データに特化したファインチューニングが薬剤鑑別精度に与える効果を検証することである。また、オープンソースモデルを用いることで、薬剤画像を外部 API に送信せず、適切な計算環境を用意すればローカル環境で推論できる薬剤鑑別システムの可能性を示すことを目指す。

なお、本研究におけるマルチモーダル学習とは、薬剤画像を視覚情報として入力し、自然言語による質問文をテキスト情報として与え、薬剤名を応答として生成する Vision-Language Model 型の学習を指す。本報告時点では、テキスト入力は質問文を中心とするが、今後は識別コード、薬剤候補名、形状情報、効能情報などを追加し、より情報量の多い画像・テキスト統合型の鑑別へ拡張することを検討する。

1.4 本報告書の構成

第 2 章では関連研究を整理し、本研究の位置づけを明確にする。第 3 章では提案手法の詳細および実験計画を述べる。第 4 章では実験結果と考察を示す。第 5 章では結論と今後の課題を述べる。

2 関連研究

本研究では以下の 3 本の先行研究を参考文献とし、各手法の概要と限界を整理する。

2.1 画像特徴・刻印文字を用いた薬剤識別手法

Heo ら [1] は、薬剤識別を認識ステップと検索ステップに分けた深層学習ベースの薬剤識別システムを提案した。認識ステップでは、YOLOv5 により錠剤表面の刻印文字を検出し、ResNet-32 により形状、色、剤形を認識する。さらに、RNN ベースの文字レベル言語モデルを用いて、検出された刻印文字の誤りを補正する。検索ステップでは、認識された形状、色、剤形、刻印文字と薬剤データベース内の情報との類似度を計算し、候補薬剤を順位付けする。韓国の薬剤データセット (MFDS) において Top-1 精度 85.6%、米国データセット (NLM) において 74.5% を達成している。

この手法は、薬剤画像に含まれる視覚情報と刻印文字情報を組み合わせて識別する点で有効であり、画像分類ではなく検索型の構成を採用することで、学習に含まれない薬剤への対応も考慮している。

課題

- YOLOv5, ResNet, RNN ベースの言語モデルなど複数のモジュールを組み合わせる必要があり、システム構成が複雑である。
- 刻印文字を重要な識別手がかりとしているため、刻印が不明瞭な画像や刻印のない薬剤では、識別性能が低下する可能性がある。
- 検索型の構成により未知薬剤への対応を考慮している一方で、刻印検出や特徴認識の各モジュールが対象データに依存する可能性がある。

2.2 画像特徴とテキスト特徴を用いたマルチモーダル薬剤識別手法

Rádli ら [3] は、薬剤画像の視覚特徴と薬剤説明文から得られるテキスト特徴を組み合わせたマルチモーダルな薬剤認識手法を提案している。同研究では、EfficientNetV2 をバックボーンとし、RGB 画像、局所特徴、輪郭、テクスチャなど複数の視覚特徴を抽出する。また、薬剤説明文から得られる単語埋め込みを用いて、メトリクス学習における動的マージントリプレット損失 (DMTL) のマージンを決定する。112 クラス・4,480 枚で構成する OGYEIV2 データセットにて Top-1 精度 93.56% を達成している。

この研究は、画像情報だけでなくテキスト情報を利用して薬剤認識を行う点で本研究と近い。

課題

- 画像特徴抽出器、テキスト埋め込み、メトリクス学習を個別に設計する必要がある。
- 画像とテキストプロンプトから薬剤名を直接出力する VLM 型の手法ではない。
- 評価データが特定地域・特定データセットに限定されており、他の薬剤画像への適用可能性は追加検証が必要である。

2.3 生成 AI・LLM を用いた薬剤識別支援手法

Menaha ら [2] は、Google Gemini を用いた生成 AI ベースの薬剤識別支援システムを提案している。同研究は、薬剤画像を入力として、薬剤に関する情報をテキストおよび音声で提示するシステムであり、マルチモーダル AI を薬剤識別支援に応用している点で本研究と関連する。

一方で、同研究は商用クローズドソースモデルを用いたプロンプトベースの手法である。少なくとも同研究では、薬剤画像データを用いてモデル自体をファインチューニングする構成は示されていない。また、外部 API を利用する場合、薬剤画像を外部サービスに送信する必要がある、プライバシー上の懸念が残る。本研究では、オープンソースモデルである Qwen3.5 を用い、ローカル環境で LoRA ファインチューニングを行う点に差異がある。

課題

- 商用クローズドソースモデルであり、当該研究ではモデル自体のファインチューニングは行われていない。
- 外部 API を利用する場合、薬剤画像を外部サービスに送信する必要がある、プライバシー上の懸念が残る。
- 利用コストが高く、継続的な運用において制約が生じる可能性がある。
- プロンプトベースの手法であり、当該研究では対象薬剤への追加学習は示されていない。

2.4 先行研究の整理と本研究の位置づけ

先行研究では、薬剤画像のみを用いる CNN 分類に加え、刻印文字、薬剤説明テキスト、処方情報などを組み合わせるマルチモーダルな薬剤識別手法が提案されている。Heo らの手法は、画像特徴と刻印文字を個別に抽出し、言語モデルで刻印文字を補正することで高精度な薬剤検索を実現している。一方で、複数の専用モジュールを組み合わせる必要がある、システム構成が複雑である。Rádli らの手法は、薬剤画像と薬剤説明テキストを組み合わせる点で本研究と関連するが、画像特徴抽出器とテキスト埋め込みを用いたメトリクス学習であり、薬剤名を直接生成する VLM 型の手法ではない。Menaha らの手法は、生成 AI を薬剤識別支援に用いる点で関連するが、商用モデルを用いたプロンプトベースの手法であり、薬剤画像に特化したファインチューニングを行うものではない。

これらを踏まえ、本研究ではオープンソースの Vision-Language Model である Qwen3.5 を用い、薬剤画像とテキストプロンプトを入力として薬剤名を直接出力する手法を検討する。特に、LoRA によるファインチューニングを行うことで、薬剤画像データに特化したモデルを構築し、ファインチューニング前のモデルおよび外部 API 型マルチモーダル AI との比較を通じて、その有効性を評価する。

表 1 に、先行研究の問題点と本研究での対応を整理して示す。

表 1 従来手法の問題点と本研究の対応

従来手法の問題点	該当研究	本研究での対応
YOLOv5・ResNet・RNN など複数の専用モジュールが必要でシステム構成が複雑	Heo ら [1]	Qwen3.5 単一モデルで画像とテキストプロンプトを統合処理し、構成をシンプルに保つ
画像特徴抽出器・テキスト埋め込み・メトリクス学習を個別に設計する必要がある、エンドツーエンドの学習ではない	Rádli ら [3]	LoRA により Qwen3.5 全体を薬剤画像データに適応させ、エンドツーエンドでファインチューニングする
商用クローズドソースモデルへの依存および薬剤画像の外部送信によるプライバシー懸念	Menaha ら [2]	オープンソースモデルをローカル環境で動作させることで、画像を外部に送信しない構成を目指す
ゼロショットのみで薬剤画像に特化した追加学習が行われておらず、専門的な薬剤識別への適応が不十分	Menaha ら [2]	薬剤画像と正解薬剤名のペアを用いて LoRA ファインチューニングを行い、識別精度を向上させる

3 研究内容

本章では、提案手法の概要と、課題・解決策・評価方法の対応関係を整理したうえで、手法の詳細を述べる。

3.1 研究テーマの整理

本研究の課題，解決策，評価方法の対応を表 2 に示す。

表 2 研究テーマの課題・解決策・評価方法の対応

課題	解決策	評価方法
薬剤名が記載された外箱・薬袋が失われた場合に、錠剤・PTP シートの外観のみから薬剤を識別する必要がある	オープンソース VLM (Qwen3.5-4B) を少数の実画像にデータ拡張を施した小規模データセットで LoRA ファインチューニングし、単一モデルで薬剤鑑別を実現する	Top-1 Accuracy (学習・評価データ分離) で Gemini・ChatGPT のゼロショット識別と比較する
従来手法は複数の専用モジュールを要するか、商用 API に依存しプライバシー懸念がある	オープンソースモデルをローカル環境で動作させることで、薬剤画像を外部サービスに送信しない構成を目指す	外部 API 不使用でのローカル推論が可能かを動作確認する

3.2 解決策の妥当性

提案手法の妥当性を以下の観点から検討する。

- **少数画像での LoRA 有効性**：単一薬剤（メインテート錠 2.5mg）を元画像 6 枚から 11 倍に拡張した 66 枚で学習し、評価用 22 枚すべてで正答した (Top-1 精度 100%)。少数の実画像でもデータ拡張との

組み合わせにより LoRA が有効に機能することを予備実験で確認している。

- **多クラス拡張性**：40 種類の薬剤を対象とした単一モデルの LoRA ファインチューニングにおいても、評価用 814 枚中 799 枚で正答（全体 Top-1 精度 98.2%）を達成しており、薬剤数を増やした場合でも精度を維持できることを確認している。
- **外部 API との比較根拠**：Gemini 2.5 Flash によるゼロショット識別との比較において、LoRA ファインチューニング後の Qwen3.5 が大幅に上回る結果を予備実験で得ており、本実験での比較評価の有効性が示唆されている（4 章参照）。
- **残課題**：回転（±30 度）・水平反転に対する頑健性に課題があり、本実験では学習側の拡張強化または向き揃えの前処理を検討する。

3.3 使用モデル：Qwen3.5

本研究では、画像とテキストを入力できるオープンソースの Vision-Language Model として Qwen3.5 を使用する。Qwen3.5 を選定する理由は、外部 API に依存せずローカル環境で動作させられる可能性があり、LoRA などのパラメータ効率の高い手法によって追加学習が可能であるためである。

Vision-Language Model は画像とテキストプロンプトを同時に入力できるため、薬剤画像に対する質問応答形式で薬剤名を出力するタスクを構成できる。本研究では、この特性を利用し、薬剤画像から薬剤名を出力するように Qwen3.5 を LoRA によりファインチューニングする。

3.4 提案手法：Qwen3.5 の LoRA ファインチューニング

本研究では、薬剤画像とテキストプロンプトを入力し、正解薬剤名を出力するように Qwen3.5 を LoRA によりファインチューニングする。学習データは、薬剤ごとに分類された画像フォルダから作成する。各サブフォルダ名を薬剤名ラベルとし、フォルダ内の画像を入力画像として用いる。

入力プロンプトは「この錠剤は何という薬ですか。薬剤名だけで教えてください。」とし、モデルが正解薬剤名のみを出力するように学習させる。これにより、薬剤画像に対する質問応答形式の薬剤鑑別モデルを構築する。

図 1 に、提案手法の処理フローを示す。




図 1 提案手法の処理フロー：薬剤画像とテキストプロンプトを Qwen3.5 に入力し、LoRA アダプタで薬剤画像データに適応させて薬剤名を出力する

強み

- 薬剤画像データに特化した追加学習により、ゼロショット識別よりも高い識別精度が期待できる。
- 外部 API に依存せず、適切な計算環境を用意すればローカル環境で推論できる。
- 画像と自然言語プロンプトを組み合わせた質問応答形式で薬剤名を出力できる。

課題

- ある程度の量と多様性を持つ学習データが必要である。
- 新たな薬剤クラスを追加する場合、再チューニングまたはデータベース検索との併用が必要となる。
- 包装込み画像を用いる場合、モデルが錠剤本体ではなく包装上の文字やデザインに依存する可能性がある。

3.5 比較手法

提案手法の有効性を検証するため、以下の比較手法を設定する。

- **ファインチューニング前の Qwen3.5**：LoRA 適用前のモデルによるゼロショット識別。
- **ChatGPT**：外部 API 型マルチモーダル AI によるゼロショット識別。
- **Gemini**：外部 API 型マルチモーダル AI によるゼロショット識別。

3.6 使用データ

本研究では、研究用に撮影した薬剤画像を使用する。画像には、錠剤やカプセル本体に加え、PTP シートや包装上の印字が含まれる場合がある。これは、実際の薬剤鑑別において、錠剤本体の色や形状だけでなく、包装上の文字情報や印字も重要な手がかりとなるためである。

ただし、包装情報を含む画像を用いる場合、モデルが錠剤本体ではなく包装上の文字やデザインに依存して薬剤名を予測する可能性がある。そのため、評価時には、包装込み画像と錠剤部分を中心とした画像で性能差を比較し、モデルがどの情報に依存しているかを分析する必要がある。本研究では、包装情報を含む画像をそのまま用いる場合と、錠剤またはカプセル部分を中心に切り出した画像を用いる場合を区別して評価することを検討する。これにより、モデルが包装上の印字に依存しているのか、薬剤本体の色や形状などの外観特徴を利用しているのかを分析する。

3.7 評価方法

評価においては、学習画像と評価画像が重複しないようにデータを分割する。具体的には、各薬剤クラスごとに画像を学習用と評価用に分け、同一画像および極端に類似した連続撮影画像が学習データと評価データの両方に含まれないようにする。これにより、単なる画像の記憶ではなく、薬剤画像に対する識別性能を評価する。評価では、入力画像に対してモデルが出力した薬剤名と正解薬剤名を比較し、識別精度を算出する。主な評価指標として、Top-1 Accuracy を用いる。Top-1 Accuracy は、モデルが最初に出力した薬剤名が正解薬剤名と一致した割合である。また、モデルに上位 3 候補を出力させる実験を行う場合には、Top-3 Accuracy も補助指標として用いる。Top-3 Accuracy を算出する場合は、「可能性の高い薬剤名を 3 件出力してください」という固定プロンプトを用い、上位 3 候補の中に正解薬剤名が含まれるかを判定する。また、包装込み画

像と錠剤部分を中心とした画像を分けて評価することで、包装印字への依存度を分析する。

さらに、誤識別例については、外観が類似している薬剤、包装印字が不明瞭な薬剤、撮影条件が悪い画像などに分類し、誤識別の原因を分析する。

3.8 実験計画

本研究では、以下の手順で実験を進める。

1. 薬剤画像データセットを作成し、薬剤名ラベルを整理する。
2. 各薬剤クラスごとに、画像を学習用、検証用、評価用に分割する。この際、同一画像および極端に類似した連続撮影画像が学習データと評価データの両方に含まれないようにする。
3. ファインチューニング前の Qwen3.5 を用いて、薬剤画像に対するゼロショット識別を行う。
4. 薬剤画像と正解薬剤名のペアを用いて、Qwen3.5 を LoRA によりファインチューニングする。
5. ファインチューニング後のモデルを用いて同一条件で識別実験を行う。
6. ChatGPT・Gemini などの外部 API 型マルチモーダル AI と比較する。
7. 包装込み画像と錠剤部分を中心とした画像で性能差を比較し、包装印字への依存度を分析する。
8. 誤識別例を分析し、薬剤外観、包装印字、撮影条件などが識別精度に与える影響を考察する。

表 3 に実験スケジュールを示す。

表 3 実験スケジュール

フェーズ	期間	内容
先行研究・準備	4～7 月	先行研究調査（論文 3 本以上）、研究課題・解決策・評価方法の整理、薬剤画像撮影・データセット整備
予備実験	5～8 月	単一薬剤 LoRA 予備学習、全 40 薬剤拡張データセット予備学習、誤識別傾向分析・改善方針策定
本実験	9 月	LoRA ファインチューニング（本実験）、Gemini・ChatGPT との比較、誤識別・包装依存度分析
論文執筆・発表	10 月～	卒業論文執筆、発表準備・スライド作成

4 予備実験

本章では、提案手法の有効性を検証するために実施した予備実験の内容と結果を述べる。予備実験では、限られた枚数の実画像とデータ拡張を組み合わせた小規模なデータセットを用い、Qwen3.5 に対する LoRA ファインチューニングの効果を検証した。あわせて、比較対象として外部 API 型マルチモーダル AI である Gemini を用いたゼロショット識別との性能比較も行った。

4.1 予備実験の目的

予備実験では、以下の 3 点を確認することを目的とした。

- 数枚程度の実画像にデータ拡張を施した小規模データセットでも、LoRA ファインチューニングにより実用的な薬剤鑑別精度を達成できるか。
- 単一薬剤での動作確認を踏まえ、40 種類の薬剤に拡張した場合に同等の精度を維持できるか。
- ファインチューニング後の Qwen3.5 が、汎用大規模マルチモーダルモデルである Gemini に対して有意な精度差を示すか。

4.2 使用データと拡張処理

予備実験では、調剤薬局で実際に取り扱われる 40 種類の薬剤を対象とした。各薬剤について、PTP シートの表面と裏面を含む 3~10 枚程度の画像を撮影し、薬剤名でフォルダを分けて保存した。混合薬である一包化薬は単剤識別の対象外として除外した。

学習データと評価データの分離を行うため、各薬剤フォルダごとに画像を学習用 75 %、評価用 25 % の比率でランダム分割した。分割時の乱数シードを 42 に固定することで、同一の分割が再現可能となるようにした。

撮影枚数が限定的であることを補うために、分割後の学習用および評価用の各画像に対して、以下の 11 種類のデータ拡張を適用した。

- 元画像のコピー
- 回転 (+15 度, -15 度, +30 度, -30 度)
- 水平反転
- 明度変更 (0.7 倍, 1.3 倍)
- コントラスト変更 (0.7 倍, 1.3 倍)
- ガウシアンノイズ付加 (標準偏差 10)

1 枚の元画像から 11 枚の拡張画像を生成した結果、学習用合計 2,343 枚、評価用合計 814 枚のデータセットを構築した。

4.3 学習設定

基盤モデルとして Qwen3.5-4B を用い、LoRA によるファインチューニングを行った。主なハイパーパラメータを表 4 に示す。

表 4 LoRA ファインチューニングの設定

パラメータ	値
基盤モデル	Qwen/Qwen3.5-4B
LoRA rank	8
LoRA alpha	16
target modules	q_proj, v_proj
dropout	0.05
エポック数	5
学習率	2e-4
最大画像ピクセル数	768 × 768

入力プロンプトには「この錠剤は何という薬ですか。薬剤名だけで答えてください。」を用い、正解薬剤名のみを出力するように学習させた。評価時には同一のプロンプトでモデルに推論を実行させ、フォルダ名（正解薬剤名）が回答テキストに含まれていれば正解とみなした。薬剤名は半角化および小文字化による簡易正規化を施したうえで一致判定を行った。

4.4 単一薬剤による予備学習

提案手法が機能するかを確認するため、まず単一薬剤「2.5mg メインテート錠」のみを対象とした LoRA ファインチューニングを実施した。学習用 66 枚（元 6 枚を 11 倍に拡張）、評価用 22 枚（元 2 枚を 11 倍に拡張）を用いた。NVIDIA CUDA 環境において学習に要した時間は 15 分 18 秒であり、エポックごとの平均損失は表 5 のとおりであった。

表 5 単一薬剤での学習損失推移

エポック	平均損失
1	0.6757
2	0.0002
3	0.0001
4	0.0001
5	0.0001

2 エポック目以降にほぼ完全に収束しており、評価用 22 枚すべてで正解薬剤名を出力することができた (Top-1 精度 100 %). 明度, コントラスト, 回転, 水平反転, ノイズの全拡張パターンに対して正答しており, 少なくとも単一薬剤の範囲では拡張による分布変化に対して頑健であることが確認できた。

4.5 Gemini API との比較

単一薬剤の評価用 22 枚に対し, Gemini 2.5 Flash を用いたゼロショット識別を行い, LoRA ファインチューニング後の Qwen3.5 と比較した。プロンプトには「この画像に写っている薬剤は何ですか。薬剤名のみを日本語で回答してください。」を用い, 成功判定は「メインテート」と「2.5mg」の両方が回答に含まれる

こととした。

結果は表 6 に示すとおり，LoRA 側が 22 / 22 で 100 %，Gemini 側は 0 / 22 であった。

表 6 2.5mg メインテート錠における LoRA と Gemini の比較

指標	LoRA	Gemini 2.5 Flash
成功数	22 / 22	0 / 22
成功率	100.0 %	0.0 %
平均推論時間	1.1 秒	14.0 秒

Gemini 側の失敗は，無料枠における API リクエスト数の上限超過によるエラー応答が 6 件と，薬剤名の一部（「メインテート」のみ）しか出力されない部分認識，さらに「エンテカビル」「メチコパール」などへの誤認識が混在していた．特に大きな回転を加えた画像で誤認識が多く見られた．なお，Gemini 側の 0 / 22 は無料枠の制約も含むため，クォータ解放後または有料プランでの再評価が望ましい．

4.6 全薬剤を対象とした予備学習

続いて，40 種類すべての薬剤を対象とした単一モデルの LoRA ファインチューニングを行った．学習用 2,343 枚，評価用 814 枚をそのまま用いた．評価結果の全体集計を表 7 に示す．

表 7 全薬剤評価の全体集計

指標	値
対象薬剤数	40 種
評価画像合計	814 枚
成功画像	799 枚
全体 Top-1 精度	98.2 %
100 % 正答薬剤数	28 / 40

40 薬剤中 28 薬剤で 100 % の正答を達成し，残り 12 薬剤に合計 15 枚の誤識別が発生した．誤識別が発生した 12 薬剤の内訳を表 8 に示す．

4.7 誤識別の傾向分析

誤識別された 15 枚を拡張種別ごとに集計したものを表 9 に示す．

誤識別の大部分は，回転（±30 度，-15 度）と水平反転の合計 14 枚であり，文字方向や錠剤シートの上下左右が大きく変化する拡張に対してモデルが脆弱であることが分かった．一方で，明度，コントラスト，ノイズなどの輝度系の変化に対してはほぼ全勝（誤識別 1 件のみ）であり，色や明るさの揺らぎに対しては頑健であった．

また，同一の元画像が複数の拡張で同時に失敗するケースが 3 例観察された（ジャヌビア錠 50mg の IMG_0142，ノルバスク OD 錠 5mg の IMG_0071，パルモディア XR 錠 0.2mg の IMG_0272）．このような元画像はそもそも判別が難しい撮影条件であり，モデル側の問題よりも撮影品質に起因する可能性がある．

誤識別の出力内容は，無関係な単語ではなく別の薬剤名に分類されているケースがほとんどであり，モデル

表 8 誤識別が発生した薬剤と失敗枚数

薬剤名	評価枚数	失敗枚数
アルダクトンA錠 25mg	22	1
エソメプラゾールカプセル 20mg	22	1
エンレスト錠 100mg	22	1
ジャヌビア錠 50mg	22	2
タリージェ OD 錠 5mg	22	1
ノルバスク OD 錠 5mg	22	2
パルモディア XR 錠 0.2mg	22	2
フロセミド錠 20mg	22	1
ムコダイン錠 500mg	22	1
リクシアナ OD 錠 30mg	22	1
レボフロキサシン錠 500mg	11	1
ロスバスタチン錠 2.5mg 「DSEP」	22	1
合計	—	15

表 9 誤識別画像の拡張種別内訳

拡張種別	失敗枚数
回転 +30 度	4
回転 -30 度	4
水平反転	4
回転 -15 度	2
明度 1.3 倍	1
元画像, 回転 +15 度, 明度 0.7 倍, コントラスト 0.7・1.3 倍, ノイズ	0
合計	15

自体は錠剤として認識しているものの、回転や反転で文字が読みにくくなった結果として近い見た目の別薬剤に誤判定していると考えられる。

4.8 予備実験から得られた示唆

予備実験の結果、以下の示唆が得られた。

- LoRA ファインチューニングはわずか数枚程度 of 元画像に対して 11 倍 of データ拡張を施すだけでも、実用的な精度（全体 98.2 %）に到達できる。
- 単一薬剤評価では、Gemini 2.5 Flash が 22 / 22 で識別できなかった画像群に対して、LoRA 適用後の Qwen3.5 は 22 / 22 で正答した。
- 回転に対する頑健性に課題が残るため、本実験では大角度回転を含めた学習側拡張の強化、あるいは推論前に画像の向きを揃える前処理の導入を検討する。
- 同一元画像が複数の拡張で同時に失敗する事例があり、撮影品質と評価方法の見直しが本実験設計の検討課題となる。

本予備実験で得られた知見を踏まえ、第 5 章では本実験の結果と考察を述べる。

5 結果・考察

(本実験実施後に記述予定)

6 結論・今後の課題

（実験実施後に記述予定）

参考文献

- [1] Yejin Heo, Hyunjung Kim, Sungjin Lee, et al. Deep learning-based pill identification with imprint text detection and recognition. *Journal of Medical Internet Research*, 25:e41043, 2023.
- [2] R. Menaha et al. Drug pills identification system using Google Gemini LLM: A generative AI approach. In *Proceedings of the International Conference on Electronics, Robotics and Control Systems (ICERCS)*, 2024.
- [3] Richárd Rádli and László Toka. Metric-based pill recognition with the help of textual and visual cues. *IET Image Processing*, 18(1):1–13, 2024.