

卒業研究報告書

題目

マルチモーダル学習による薬剤鑑別

指導教員

森山 真光 准教授

報告者

23-1-211-0009

呉竹 權人

近畿大学情報学部情報学科

令和7年6月2日提出

概要

薬剤の取り違いや誤服用は医療安全上の重要な課題であり、医療現場や家庭では、薬剤名が記載された外箱や薬袋が失われた場合、または薬剤本体やPTPシートのみが残された場合に、錠剤やカプセルの外観、刻印、包装上の印字など限られた視覚情報を手がかりに薬剤を鑑別する必要がある。本研究では、薬剤画像とテキストプロンプトを入力とし、薬剤名を出力する Vision-Language Model 型の薬剤鑑別手法を検討する。具体的には、オープンソースのマルチモーダル LLM である Qwen3.5 を用い、薬剤画像に対して「この錠剤は何という薬ですか」という質問を与え、正解薬剤名を出力するように LoRA によるファインチューニングを行う。比較対象として、ファインチューニング前の Qwen3.5 および外部 API 型マルチモーダル AI である Gemini によるゼロショット識別を用い、薬剤画像データに特化したファインチューニングが薬剤鑑別精度に与える効果を評価する。41 種類の薬剤を対象とした評価では、ファインチューニング後のモデルが単一薬剤識別で Top-1 精度 98.2% を達成し、ファインチューニング前 (0.9%) および Gemini (80.2%) を大きく上回った。さらに、1 枚の画像に複数の薬剤が写る場合についても、薬剤位置を検出して領域ごとに単剤識別を行う 2 段階構成を提案し、検出器の専用学習により完全一致率 96.0% を達成した。スマートフォン搭載を見据えたモデルサイズ (0.8B/2B/4B) および 4bit 量子化による精度変化の検証も行った。また、薬剤データベースを検索して候補薬剤情報を提示する RAG 型手法については予備実験で比較を行っており、全薬剤規模での比較を今後の発展的課題とする。

目次

1	序論	1
1.1	本研究の背景	1
1.2	本研究の目的	2
1.3	本報告書の構成	2
2	関連研究・関連技術	3
2.1	画像特徴・刻印文字を用いた薬剤識別手法	3
2.2	画像特徴とテキスト特徴を用いたマルチモーダル薬剤識別手法	3
2.3	生成 AI・LLM を用いた薬剤識別支援手法	4
2.4	先行研究の整理と本研究の位置づけ	4
3	提案手法	5
3.1	研究テーマの整理	5
3.2	解決策の妥当性	5
3.3	使用モデル：Qwen3.5	6
3.4	提案手法：Qwen3.5 の LoRA ファインチューニング	6
3.5	複数薬剤同時識別への拡張：検出→単剤分類	7
3.6	比較手法	8
3.7	使用データ	9
3.8	評価方法	9
3.9	実験計画	10
4	実験と結果	11
4.1	実験環境	11
4.2	データセットの構築	12
4.3	学習設定	12
4.4	評価手順	14
4.5	予備実験（単一薬剤メインテート錠）	14
4.6	初期検討：データ拡張なしでの全薬剤学習	15
4.7	単一薬剤識別の結果（本実験）	16
4.8	外部画像での汎化（予備的検証）	17
4.9	複数薬剤同時識別の結果	18
4.10	検出器の専用学習による改善	19
4.11	過検出抑制の検証（負の結果）	20
4.12	軽量化の評価（量子化・モデルサイズ）	21
4.13	誤識別の横断分析	22
4.14	考察	23

5	結論・今後の課題	25
5.1	結論	25
5.2	今後の課題	25
	謝辞	26
	参考文献	27

1 序論

1.1 本研究の背景

薬剤の取り違いや誤服用は、患者の健康被害につながる医療安全上の重要な問題である。世界保健機関（WHO）は、2017年に第3回世界患者安全チャレンジとして「Medication Without Harm」を立ち上げ、投薬に関連する重篤かつ回避可能な健康被害を5年間で50%削減することを世界共通の目標として掲げている[1]。WHOは、こうした投薬に関連する有害事象に世界全体で年間およそ420億ドルの費用が費やされていると報告しており、投薬の安全性確保は一国にとどまらない世界的な課題と位置づけられている。国内においても、日本医療機能評価機構の薬局ヒヤリ・ハット事例収集・分析事業には毎年多数の調剤に関する事例が報告されており、「薬剤取り違い」は上位を占める調剤過誤の一つである[2]。特に、名称や外観が類似した薬剤による取り違いが多く報告されており、薬剤を正確に識別・鑑別することは医療安全上の重要な課題である。

医療現場や家庭では、薬剤名が記載された外箱や薬袋が失われた場合、または薬剤本体やPTPシートのみが残された場合に、錠剤やカプセルの外観、刻印、包装上の印字など限られた視覚情報を手がかりに薬剤を鑑別する必要がある。特に、高齢者が複数の薬剤を長期的に服用する場合や、一包化調剤によって複数の薬剤がまとめられる場合には、薬剤の識別が困難になり、誤服用のリスクが高まる。

従来、薬剤鑑別には薬剤師などの専門知識が必要であり、薬剤データベースを手作業で検索する負担も大きい。実際に末次ら[3]は、持参薬の一包化鑑別が薬剤師にとって時間を要する負担の大きい業務であることを報告している。また、白色円形の錠剤のように外観が類似する薬剤も多く、画像のみから薬剤を正確に識別することは容易ではない。こうした鑑別業務の負担を軽減する手段として、近年ではAIによる画像解析を用いた薬剤識別の自動化が注目されている。同研究[3]は、AI画像解析錠剤識別システムを持参薬の一包化鑑別業務に導入し、鑑別に要する時間を短縮できることに加え、従来は薬剤師が担っていた鑑別業務を薬剤助手へタスク・シフト／タスク・シェアできる可能性を報告している。このことは、薬剤鑑別をモデルによって自動化することが、医療安全の確保と医療従事者の負担軽減の両面で有用であることを示している。このような背景から、薬剤画像を用いて自動的に薬剤を識別する研究が行われてきた。

Heoら[4]は、薬剤識別を認識ステップと検索ステップに分けた深層学習ベースの薬剤識別システムを提案している。YOLOv5により錠剤表面の刻印文字を検出し、ResNet-32により形状、色、剤形を認識する。さらに、RNNベースの文字レベル言語モデルを用いて検出された刻印文字の誤りを補正し、薬剤データベース内の情報との類似度に基づいて候補薬剤を順位付けする。この手法は、薬剤画像に含まれる視覚情報と刻印文字情報を組み合わせて識別する点で有効であり、検索型の構成を採用することで学習に含まれない薬剤への対応も考慮している。一方で、複数の専用モジュールを組み合わせる必要があり、システム構成が複雑である。また、刻印文字を重要な識別手がかりとしているため、刻印が不明瞭な画像や刻印のない薬剤では識別性能が低下する可能性がある。

Rádliら[5]は、薬剤画像の視覚特徴と薬剤説明テキストから得られるテキスト特徴を組み合わせたマルチモーダルな薬剤認識手法を提案している。この研究は、画像情報だけでなくテキスト情報を利用して薬剤認識を行う点で本研究と近い。一方で、同手法は画像特徴抽出器、テキスト埋め込み、メトリクス学習を個別に設計する構成であり、画像とテキストプロンプトを入力として薬剤名を直接生成するVision-Language Model型の手法ではない。

Menahaら[6]は、Google Geminiを用いた生成AIベースの薬剤識別支援システムを提案している。この

研究は、マルチモーダル AI を薬剤識別支援に応用している点で本研究と関連する。一方で、同研究は商用クローズドソースモデルを用いたプロンプトベースの手法であり、薬剤画像データを用いてモデル自体をファインチューニングする構成ではない。また、外部 API を利用する場合、薬剤画像を外部サービスに送信する必要があり、プライバシー上の懸念が残る。

以上の課題から、(1) 錠剤本体の外観、刻印、包装上の印字など複数の視覚情報を統合した識別、(2) 外部 API に過度に依存しないローカル動作の可能性、(3) 薬剤画像に特化したファインチューニングによる識別精度の向上、の 3 点を検討する必要がある。

1.2 本研究の目的

本研究では、オープンソースの Vision-Language Model である Qwen3.5 を用い、薬剤画像とテキストプロンプトから薬剤名を出力する薬剤鑑別手法を検討する。具体的には、薬剤画像に対して「この錠剤は何という薬ですか」という質問を与え、正解薬剤名を出力するように LoRA によるファインチューニングを行う。

本研究の目的は、ファインチューニング前の Qwen3.5 および外部 API 型マルチモーダル AI である Gemini と比較することで、薬剤画像データに特化したファインチューニングが薬剤鑑別精度に与える効果を検証することである。また、オープンソースモデルを用いることで、薬剤画像を外部 API に送信せず、適切な計算環境を用意すればローカル環境で推論できる薬剤鑑別システムの可能性を示すことを目指す。

なお、本研究におけるマルチモーダル学習とは、薬剤画像を視覚情報として入力し、自然言語による質問文をテキスト情報として与え、薬剤名を応答として生成する Vision-Language Model 型の学習を指す。本報告時点では、テキスト入力は質問文を中心とするが、今後は識別コード、薬剤候補名、形状情報、効能情報などを追加し、より情報量の多い画像・テキスト統合型の鑑別へ拡張することを検討する。

1.3 本報告書の構成

2 章では関連研究および関連技術を整理し、本研究の位置づけを明確にする。3 章では提案手法の詳細および実験計画を述べる。4 章では実験結果と考察を示す。5 章では結論と今後の課題を述べる。

2 関連研究・関連技術

本研究では以下の 3 本の先行研究を参考文献とし、各手法の概要と限界を整理する。

2.1 画像特徴・刻印文字を用いた薬剤識別手法

Heo ら [4] は、薬剤識別を認識ステップと検索ステップに分けた深層学習ベースの薬剤識別システムを提案した。認識ステップでは、YOLOv5 により錠剤表面の刻印文字を検出し、ResNet-32 により形状、色、剤形を認識する。さらに、RNN ベースの文字レベル言語モデルを用いて、検出された刻印文字の誤りを補正する。検索ステップでは、認識された形状、色、剤形、刻印文字と薬剤データベース内の情報との類似度を計算し、候補薬剤を順位付けする。韓国の薬剤データセット (MFDS) において Top-1 精度 85.6%、米国データセット (NLM) において 74.5% を達成している。

この手法は、薬剤画像に含まれる視覚情報と刻印文字情報を組み合わせて識別する点で有効であり、画像分類ではなく検索型の構成を採用することで、学習に含まれない薬剤への対応も考慮している。

課題

- YOLOv5, ResNet, RNN ベースの言語モデルなど複数のモジュールを組み合わせる必要があり、システム構成が複雑である。
- 刻印文字を重要な識別手がかりとしているため、刻印が不明瞭な画像や刻印のない薬剤では、識別性能が低下する可能性がある。
- 検索型の構成により未知薬剤への対応を考慮している一方で、刻印検出や特徴認識の各モジュールが対象データに依存する可能性がある。

2.2 画像特徴とテキスト特徴を用いたマルチモーダル薬剤識別手法

Rádli ら [5] は、薬剤画像の視覚特徴と薬剤説明文から得られるテキスト特徴を組み合わせたマルチモーダルな薬剤認識手法を提案している。同研究では、EfficientNetV2 をバックボーンとし、RGB 画像、局所特徴、輪郭、テクスチャなど複数の視覚特徴を抽出する。また、薬剤説明文から得られる単語埋め込みを用いて、メトリクス学習における動的マージントリプレット損失 (DMTL) のマージンを決定する。112 クラス・4,480 枚で構成する OGYEIV2 データセットにて Top-1 精度 93.56% を達成している。

この研究は、画像情報だけでなくテキスト情報を利用して薬剤認識を行う点で本研究と近い。

課題

- 画像特徴抽出器、テキスト埋め込み、メトリクス学習を個別に設計する必要がある。
- 画像とテキストプロンプトから薬剤名を直接出力する VLM 型の手法ではない。
- 評価データが特定地域・特定データセットに限定されており、他の薬剤画像への適用可能性は追加検証が必要である。

2.3 生成 AI・LLM を用いた薬剤識別支援手法

Menaha ら [6] は、Google Gemini を用いた生成 AI ベースの薬剤識別支援システムを提案している。同研究は、薬剤画像を入力として、薬剤に関する情報をテキストおよび音声で提示するシステムであり、マルチモーダル AI を薬剤識別支援に応用している点で本研究と関連する。

一方で、同研究は商用クローズドソースモデルを用いたプロンプトベースの手法である。少なくとも同研究では、薬剤画像データを用いてモデル自体をファインチューニングする構成は示されていない。また、外部 API を利用する場合、薬剤画像を外部サービスに送信する必要があり、プライバシー上の懸念が残る。本研究では、オープンソースモデルである Qwen3.5 を用い、ローカル環境で LoRA ファインチューニングを行う点に差異がある。

課題

- 商用クローズドソースモデルであり、当該研究ではモデル自体のファインチューニングは行われていない。
- 外部 API を利用する場合、薬剤画像を外部サービスに送信する必要があり、プライバシー上の懸念が残る。
- 利用コストが高く、継続的な運用において制約が生じる可能性がある。
- プロンプトベースの手法であり、当該研究では対象薬剤への追加学習は示されていない。

2.4 先行研究の整理と本研究の位置づけ

先行研究では、薬剤画像のみを用いる CNN 分類に加え、刻印文字、薬剤説明テキスト、処方情報などを組み合わせるマルチモーダルな薬剤識別手法が提案されている。Heo らの手法は、画像特徴と刻印文字を個別に抽出し、言語モデルで刻印文字を補正することで高精度な薬剤検索を実現している。一方で、複数の専用モジュールを組み合わせる必要があり、システム構成が複雑である。Rádli らの手法は、薬剤画像と薬剤説明テキストを組み合わせる点で本研究と関連するが、画像特徴抽出器とテキスト埋め込みを用いたメトリクス学習であり、薬剤名を直接生成する VLM 型の手法ではない。Menaha らの手法は、生成 AI を薬剤識別支援に用いる点で関連するが、商用モデルを用いたプロンプトベースの手法であり、薬剤画像に特化したファインチューニングを行うものではない。

これらを踏まえ、本研究ではオープンソースの Vision-Language Model である Qwen3.5 を用い、薬剤画像とテキストプロンプトを入力として薬剤名を直接出力する手法を検討する。特に、LoRA によるファインチューニングを行うことで、薬剤画像データに特化したモデルを構築し、ファインチューニング前のモデルおよび外部 API 型マルチモーダル AI との比較を通じて、その有効性を評価する。

表 1 に、先行研究の問題点と本研究での対応を整理して示す。

表 1 従来手法の問題点と本研究の対応

従来手法の問題点	該当研究	本研究での対応
YOLOv5・ResNet・RNN など複数の専用モジュール が必要でシステム構成が複雑	Heo ら [4]	Qwen3.5 単一モデルで画像とテキストプロンプトを統合処理し、構成をシンプルに保つ
画像特徴抽出器・テキスト 埋め込み・メトリクス学習 を個別に設計する必要がある、 エンドツーエンドの学習ではない	Rádli ら [5]	LoRA により Qwen3.5 全体を薬剤画像データに適応させ、 エンドツーエンドでファインチューニングする
商用クローズドソースモデルへの 依存および薬剤画像の外部送信による プライバシー懸念	Menaha ら [6]	オープンソースモデルをローカル環境で動作させることで、 画像を外部に送信しない構成を目指す
ゼロショットのみで薬剤画像に 特化した追加学習が行われておらず、 専門的な薬剤識別への適応が不十分	Menaha ら [6]	薬剤画像と正解薬剤名のペアを用いて LoRA ファインチューニングを行い、 識別精度を向上させる

3 提案手法

本章では、提案手法の概要と、課題・解決策・評価方法の対応関係を整理したうえで、手法の詳細を述べる。

3.1 研究テーマの整理

本研究の課題，解決策，評価方法の対応を表 2 に示す。

表 2 研究テーマの課題・解決策・評価方法の対応

課題	解決策	評価方法
薬剤名が記載された外箱・薬袋が 失われた場合に、錠剤・PTP シートの 外観のみから薬剤を識別する 必要がある	オープンソース VLM (Qwen3.5-4B) を少数 の実画像にデータ拡張を施した小規模データ セットで LoRA ファインチューニングし、単 一モデルで薬剤鑑別を実現する	Top-1 Accuracy (学習・評価 データ分離) で Gemini のゼロ ショット識別と比較する
従来手法は複数の専用モジュール を要するか、商用 API に依存し プライバシー懸念がある	オープンソースモデルをローカル環境で動作 させることで、薬剤画像を外部サービスに送 信しない構成を目指す	外部 API 不使用でのローカル 推論が可能かを動作確認する

3.2 解決策の妥当性

提案手法の妥当性を以下の観点から検討する。

- **少数画像での LoRA 有効性**：単一薬剤（メインテート錠 2.5mg）を元画像 6 枚から 11 倍に拡張した 66 枚で学習し、評価用 22 枚すべてで正答した (Top-1 精度 100%)。少数の実画像でもデータ拡張との

組み合わせにより LoRA が有効に機能することを予備実験で確認している。

- **多クラス拡張性**：41 種類の薬剤を対象とした単一モデルの LoRA ファインチューニングにおいても、評価用 814 枚中 799 枚で正答（全体 Top-1 精度 98.2%）を達成しており、薬剤数を増やした場合でも精度を維持できることを確認している。
- **外部 API との比較根拠**：Gemini によるゼロショット識別との比較において、LoRA ファインチューニング後の Qwen3.5 が単一薬剤識別（98.2% 対 80.2%）・複数薬剤同時識別（68.8% 対 48.2%）の双方で上回る結果を得ており、特化学習の有効性が示されている（4 章参照）。
- **複数薬剤への拡張可能性**：単剤識別用に学習したモデルをそのまま用い、薬剤位置の検出と領域ごとの単剤識別を組み合わせる 2 段構成（3.5 節）により、再学習なしで複数薬剤の同時識別が可能であることを確認している。さらに検出器を専用学習することで完全一致率 96.0% に到達した。
- **残課題**：回転（± 30 度）・水平反転に対する頑健性に課題があり、学習側の拡張強化または向き揃えの前処理を今後検討する。

3.3 使用モデル：Qwen3.5

本研究では、画像とテキストを入力できるオープンソースの Vision-Language Model として Qwen3.5 を使用する。Qwen3.5 を選定する理由は、外部 API に依存せずローカル環境で動作させられる可能性があり、LoRA などのパラメータ効率の高い手法によって追加学習が可能であるためである。

Vision-Language Model は画像とテキストプロンプトを同時に入力できるため、薬剤画像に対する質問応答形式で薬剤名を出力するタスクを構成できる。本研究では、この特性を利用し、薬剤画像から薬剤名を出力するように Qwen3.5 を LoRA によりファインチューニングする。

3.4 提案手法：Qwen3.5 の LoRA ファインチューニング

本研究では、薬剤画像とテキストプロンプトを入力し、正解薬剤名を出力するように Qwen3.5 を LoRA によりファインチューニングする。学習データは、薬剤ごとに分類された画像フォルダから作成する。各サブフォルダ名を薬剤名ラベルとし、フォルダ内の画像を入力画像として用いる。

入力プロンプトは「この錠剤は何という薬ですか？薬剤名だけで教えてください。」とし、モデルが正解薬剤名のみを出力するように学習させる。これにより、薬剤画像に対する質問応答形式の薬剤鑑別モデルを構築する。

3.4.1 LoRA の定式化

LoRA (Low-Rank Adaptation) は、事前学習済みモデルの重み行列を固定したまま、低ランク行列の積のみを追加学習するパラメータ効率的ファインチューニング手法である。事前学習済みの重み行列を $W_0 \in \mathbb{R}^{d \times k}$ とすると、LoRA 適用後の順伝播は次式で表される。

$$h = W_0 x + \Delta W x = W_0 x + \frac{\alpha}{r} B A x \quad (1)$$

ここで、 $A \in \mathbb{R}^{r \times k}$ 、 $B \in \mathbb{R}^{d \times r}$ は学習対象の低ランク行列、 r はランク、 α はスケール係数である。 W_0 は学習中固定され、 A と B のみが更新されるため、学習対象パラメータ数は全体のごく一部に抑えられる。本研究では $r = 8$ 、 $\alpha = 16$ とし、LLM 部の各 Transformer 層におけるアテンションの問合せ射影 (q_proj)

と値射影 (v_proj) に LoRA を適用する.

3.4.2 学習目的関数

学習は、画像とプロンプトを条件とした正解薬剤名の自己回帰生成として定式化する. 薬剤画像のトークン列を v , 質問プロンプトのトークン列を q , 正解薬剤名のトークン列を $y = (y_1, \dots, y_T)$ とすると, 損失関数は次式の交差エントロピーである.

$$\mathcal{L} = - \sum_{t=1}^T \log p_{\theta}(y_t \mid v, q, y_{<t}) \tag{2}$$

ここで θ は LoRA パラメータ (A, B) である. 損失はプロンプト部分のトークンには課さず (ラベルを -100 としてマスク), 正解薬剤名と文末トークンの部分にのみ課す. これにより, モデルは質問への応答として薬剤名のみを生成するよう学習される.

図 1 に, 提案手法の処理フローを示す.




よ」と質問しても 1 薬剤しか出力できない（この現象は 4 章の実験で定量的に示す）。

そこで本研究では、再学習を行わずに複数薬剤を識別する 2 段構成のパイプラインを提案する。基本的な考え方は、「複数薬剤の識別」を「薬剤位置の検出」と「領域ごとの単剤識別」に分解することである。入力画像 I に対する処理手順をアルゴリズム形式で示す。

1. **検出**：Vision-Language Model のグラウンディング能力を用い、画像 I 中の各薬剤シートの位置を bounding box 集合 $\{b_1, \dots, b_n\}$ ($b_i = (x_1, y_1, x_2, y_2)$) として JSON 形式で出力させる。検出プロンプトには「画像に写っているすべての薬剤（錠剤シート/PTP シート）の位置を検出し、各薬剤の bounding box を JSON で出力してください」を用いる。
2. **切り出し**：各 bounding box b_i を画像の幅・高さの 2% のマージン付きで切り出し、部分画像 I_i を得る。
3. **単剤識別**：各部分画像 I_i に対して、3.4 節の単剤識別モデル（学習済み LoRA）を適用し、薬剤名 $\hat{y}_i$ を得る。
4. **統合**：全領域の識別結果を集合 $\hat{Y} = \{\hat{y}_1, \dots, \hat{y}_n\}$ として統合し、画像に写る薬剤の集合の予測とする。

検出段階には 2 つの構成を用いる。第 1 の構成では、LoRA を無効化した素のベースモデルのゼロショット検出能力を用いる（再学習・追加データ不要）。第 2 の構成では、検出専用の LoRA アダプタを追加学習し、検出精度を高める（4 章で比較する）。後者では、1 つの基盤モデルに識別用 LoRA と検出用 LoRA の 2 つを搭載し、処理段階に応じてアダプタを切り替える。このため、モデル本体のメモリ使用量はほぼ単剤識別時と変わらない。

図 2 に複数薬剤同時識別の処理フローを示す。



また、提案手法の出力形式を確定するための予備実験（4 章）では、上記に加えて以下の方式も比較した。

- **詳細鑑別形式（方法 B）**：薬剤名だけでなく、色・形状・刻印などの鑑別理由を含む詳細な説明を出力するようにファインチューニングする方式。
- **RAG 型（薬剤データベース検索）**：薬剤情報を記述したデータベース（JSON 形式）を検索し、候補薬剤情報を回答に利用する方式。

3.7 使用データ

本研究では、研究用に撮影した薬剤画像を使用する。画像には、錠剤やカプセル本体に加え、PTP シートや包装上の印字が含まれる場合がある。これは、実際の薬剤鑑別において、錠剤本体の色や形状だけでなく、包装上の文字情報や印字も重要な手がかりとなるためである。

ただし、包装情報を含む画像を用いる場合、モデルが錠剤本体ではなく包装上の文字やデザインに依存して薬剤名を予測する可能性がある。本研究では、PTP シートや包装上の印字を含む画像をそのまま使用する。錠剤部分のみを切り出した画像との比較は今後の課題とする。

3.8 評価方法

評価においては、学習画像と評価画像が重複しないようにデータを分割する。具体的には、各薬剤クラスごとに拡張前の元画像単位で学習用と評価用に分け、同一画像および同一の元画像に由来する拡張画像が学習データと評価データの両方に含まれないようにする。これにより、単なる画像の記憶ではなく、薬剤画像に対する識別性能を評価する。評価では、入力画像に対してモデルが出力した薬剤名と正解薬剤名を比較し、識別精度を算出する。

3.8.1 単一薬剤識別の評価指標

主な評価指標として、Top-1 Accuracy を用いる。評価画像数を N 、 i 番目の画像の正解薬剤名を $y^{(i)}$ 、モデルの出力テキストを $\hat{y}^{(i)}$ とすると、Top-1 Accuracy は次式で定義される。

$$\text{Top-1 Accuracy} = \frac{1}{N} \sum_{i=1}^N \mathbf{1} \left[\phi(y^{(i)}) \subseteq \phi(\hat{y}^{(i)}) \right] \quad (3)$$

ここで $\phi(\cdot)$ は Unicode 正規化（NFKC、全角→半角）と小文字化を行う正規化関数、 $\subseteq$ は部分文字列としての包含、 $\mathbf{1}[\cdot]$ は指示関数である。すなわち、正規化後の正解薬剤名が正規化後の出力テキストに含まれていれば正解と判定する。また、モデルに上位 3 候補を出力させる実験では、3 候補のいずれかが正解と一致すれば正解とする Top-3 Accuracy を補助指標として用いる。

3.8.2 複数薬剤同時識別の評価指標

複数薬剤の同時識別では、画像に写る正解薬剤の集合 Y と予測薬剤の集合 $\hat{Y}$ を比較する集合ベースの指標を用いる。画像ごとに適合率（Precision）・再現率（Recall）・F1 スコアを次式で算出し、全評価画像で平均する（マクロ平均）。

$$\text{Precision} = \frac{|\hat{Y} \cap Y|}{|\hat{Y}|}, \quad \text{Recall} = \frac{|\hat{Y} \cap Y|}{|Y|}, \quad \text{F1} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (4)$$

さらに、予測集合が正解集合と過不足なく一致した画像の割合を完全一致率として算出する。

$$\text{ExactMatch} = \frac{1}{N} \sum_{i=1}^N \mathbf{1} \left[\hat{Y}^{(i)} = Y^{(i)} \right] \quad (5)$$

完全一致率は1薬剤でも過剰・不足があれば不正解とする厳しい指標であり、F1スコアは部分的な正解に部分点を与えるバランス指標である。

さらに、誤識別例については、外観が類似している薬剤、包装印字が不明瞭な薬剤、撮影条件が悪い画像などに分類し、誤識別の原因を分析する。

3.9 実験計画

本研究では、以下の手順で実験を進める。

1. 予備実験として、単一薬剤を対象に出力形式（薬剤名のみ／詳細鑑別）および RAG 型・Gemini との比較を行い、提案手法の出力形式を確定する。
2. 薬剤画像データセットを作成し、薬剤名ラベルを整理する。
3. 各薬剤クラスごとに、画像を学習用と評価用に分割する。この際、同一画像が学習データと評価データの両方に含まれないようにする。
4. ファインチューニング前の Qwen3.5 を用いて、薬剤画像に対するゼロショット識別を行う。
5. 薬剤画像と正解薬剤名のペアを用いて、Qwen3.5 を LoRA によりファインチューニングする。
6. ファインチューニング後のモデルを用いて同一条件で識別実験を行う。
7. Gemini (gemini-3.5-flash) と比較する。
8. 複数薬剤の同時識別を「検出→単剤分類」の2段階構成（3.5 節）で評価し、ファインチューニング前の Qwen3.5 および Gemini と同一の評価セットで比較する。
9. 検出器の専用学習（検出用 LoRA）により複数薬剤同時識別の改善を図り、検出が完璧な場合の上限値と比較する。
10. スマートフォン搭載を見据え、4bit 量子化およびモデルサイズ（0.8B / 2B / 4B）による精度の変化を、単一・複数・混在の各評価セットで測定する。
11. 誤識別例を全実験横断で集計・分析し、薬剤外観、包装印字、撮影条件などが識別精度に与える影響を考察する。

表 3 に実験スケジュールを示す。

表 3 実験スケジュール

フェーズ	期間	内容
先行研究・準備	4～5 月	先行研究調査（論文 3 本以上）、研究課題・解決策・評価方法の整理、薬剤画像撮影・データセット整備
予備実験	4～5 月	単一薬剤 LoRA 予備学習（手法比較）、全 41 薬剤拡張データセット学習
本実験	5～6 月	単一薬剤 3 者比較、複数薬剤同時識別（検出→単剤分類・検出器学習）、量子化・モデルサイズ比較、誤識別分析
追加実験	7～9 月	ネット収集画像での汎化評価、実写の複数薬剤検証、軽量 2B モデルの学習・評価
論文執筆・発表	10 月～	卒業論文執筆、発表準備・スライド作成

4 実験と結果

本章では、提案手法の有効性を検証するために実施した実験の内容と結果を述べる。本研究は予備実験（単一薬剤での方式検証）、本実験（41 薬剤での単一・複数識別の 3 者比較）、および追加実験（検出器の専用学習、軽量化評価）の順に進めた。共同研究者による追加実験を可能とするため、入力データの作成手順、処理方法、出力結果を、使用したパラメータとともに記述する。本章に示すすべての数値は、実験実行時に自動出力された結果ファイル（評価サマリー・学習ログ）に基づく。

4.1 実験環境

実験に使用した計算環境を表 4 に示す。学習・評価スクリプトは Python で実装し、Hugging Face Transformers および PEFT ライブラリを用いた。モデルの演算精度は bfloat16 である。

表 4 実験環境

項目	内容
OS	Windows 11
GPU	NVIDIA GeForce RTX 4070 Ti SUPER (VRAM 16GB)
Python	3.10 以上 (uv による仮想環境)
PyTorch	2.10.0 (CUDA 13.0)
transformers	5.5.0
peft	0.18.1
qwen-vl-utils	0.0.14
外部 API	Gemini API (gemini-3.5-flash)

4.2 データセットの構築

4.2.1 元画像の撮影

調剤薬局で実際に取り扱われる薬剤を対象に、2026 年 4 月に薬剤画像を撮影した。各薬剤について、PTP シートの表面と裏面を含む 3～10 枚程度の画像をスマートフォンのカメラで撮影し、薬剤名でフォルダを分けて保存した。フォルダ名（正式な薬剤名・用量を含む）をそのまま正解ラベルとして用いる。混合薬である一包化薬は単剤識別の対象外として除外した。最終的なデータセットは 41 種類の薬剤、元画像合計 287 枚である。薬剤ごとの内訳を表 5 に示す。

表 5 データセットの内訳 (41 薬剤)。学習・評価枚数は 11 種データ拡張適用後の枚数

薬剤名	元	学習	評価	薬剤名	元	学習	評価
2.5mg メインテート錠	8	66	22	トラゼンタ錠 5mg	7	55	22
アルダクトンA錠 25mg	6	44	22	ノルバスク OD 錠 5mg	6	44	22
ウルソ錠 100mg	4	33	11	バイアスピリン錠 100mg	4	33	11
エソメプラゾールカプセル 20mg	7	55	22	バクトラミン配合錠	6	44	22
エンレスト錠 100mg	9	77	22	バルモディア XR 錠 0.2mg	10	88	22
エンレスト錠 200mg	9	77	22	フェブリク錠 10mg	9	77	22
カロナール錠 500mg	6	44	22	フォシーガ錠 10mg	9	77	22
キャブピリン配合錠	9	77	22	フロセミド錠 20mg	6	44	22
クエン酸第一鉄 Na 錠 50mg	6	44	22	ブレドニン錠 5mg	6	44	22
ジャディアンス錠 10mg	6	44	22	ブロマック D 錠 75mg	9	77	22
ジャスピア錠 50mg	9	77	22	ベオーバ錠 50mg	9	77	22
センノシド錠 12mg	9	77	22	ミヤBM錠	4	33	11
タケキャブ錠 10mg	7	55	22	ムコダイン錠 500mg	9	77	22
タケキャブ錠 20mg	4	33	11	メチコパール錠 500μg	4	33	11
タリージェ OD 錠 5mg	6	44	22	メトクロプラミド錠 5mg	4	33	11
ダイアート錠 30mg	10	88	22	メトグルコ錠 250mg	10	88	22
デエビゴ錠 5mg	10	88	22	ランソプラゾール OD 錠 15mg	4	33	11
リクシアナ OD 錠 30mg	9	77	22	レバミピド錠 100mg	6	44	22
レボチロキシン Na 錠 50μg	10	88	22	レボフロキサシン錠 500mg	3	22	11
ロスバスタチン錠 2.5mg 「DSEP」	6	44	22	ロキソプロフェンナトリウム錠 60mg	6	44	22
酸化マグネシウム錠 330mg	6	44	22	合計	287	2,343	814

4.2.2 学習・評価分割

学習データと評価データの分離は、データ拡張を行う前の元画像単位で実施した。各薬剤フォルダごとに、画像ファイル名を辞書順に整列したうえで乱数シード 42 でシャッフルし、先頭 75% を学習用、残り 25% を評価用とした（評価用には最低 1 枚を保証）。シードを固定しているため、同一の元画像集合からは常に同一の分割が再現される。分割を元画像単位で行うため、同一の元画像に由来する拡張画像が学習データと評価データの両方に含まれることはない。

4.2.3 データ拡張

撮影枚数が限定的であることを補うために、分割後の学習用・評価用それぞれの元画像に対して、表 6 に示す 11 種類のデータ拡張を適用し、PNG 形式で保存した。

この結果、学習用 2,343 枚（元 213 枚 × 11）、評価用 814 枚（元 74 枚 × 11）のデータセットを構築した。

4.3 学習設定

基盤モデルとして Qwen3.5-4B を使い、3.4 節で述べた LoRA ファインチューニングを行った。学習に用いたハイパーパラメータを表 7 に示す。

学習サンプルは「ユーザー発話＝薬剤画像＋質問文、アシスタント応答＝正解薬剤名（フォルダ名）＋文末

表 6 データ拡張の種類とパラメータ (1 枚の元画像から 11 枚を生成)

拡張名	種別	処理内容
orig	複製	元画像のコピー
rot±15	回転	±15 度回転 (キャンバス拡張あり, 余白は RGB(128,128,128) で充填)
rot±30	回転	±30 度回転 (同上)
flip_h	反転	水平 (左右) 反転
bright0.7 / 1.3	明度	明度を 0.7 倍 / 1.3 倍に変更
contrast0.7 / 1.3	コントラスト	コントラストを 0.7 倍 / 1.3 倍に変更
noise	ノイズ	平均 0・標準偏差 10 のガウシアンノイズを加算 (画素値は 0~255 にクリップ)

表 7 LoRA ファインチューニングの設定

パラメータ	値
基盤モデル	Qwen/Qwen3.5-4B
LoRA rank r	8
LoRA alpha α	16
target modules	q-proj, v-proj
LoRA dropout	0.05
エポック数	5
最適化手法	AdamW
学習率	2e-4 (固定)
バッチサイズ	1
勾配チェックポイント	有効
演算精度	bfloat16
画像入力ピクセル数	最小 256 × 256, 最大 768 × 768

トークン」のチャット形式で構成し、式 (2) のとおりプロンプト部分のトークンをマスクして応答部分のみに損失を課した。各エポックで学習サンプルの順序をシャッフルした。41 薬剤・2,343 枚での学習に要した時間は 498 分 50 秒 (約 8.3 時間) であり、エポックごとの平均損失は表 8 のとおり単調に減少した。

表 8 全薬剤学習における損失推移 (学習 2,343 枚)

エポック	平均損失
1	0.2470
2	0.0258
3	0.0133
4	0.0058
5	0.0006

4.4 評価手順

評価時には学習時と同一の質問文「この錠剤は何という薬ですか？薬剤名だけで教えてください。」でモデルに推論を実行させ、式 (3) のとおり、NFKC 正規化（全角→半角）および小文字化を施したうえで、正解薬剤名（フォルダ名）が回答テキストに部分文字列として含まれていれば正解と判定した。Top-3 評価では、ビームサーチ（ビーム幅 3）により 3 候補を生成させた。

比較手法の評価条件は次のとおりである。ファインチューニング前の Qwen3.5-4B は、LoRA を適用しない同一の基盤モデルに同一の質問文・同一の評価画像で推論させた。Gemini は `gemini-3.5-flash` を API 経由で使い、プロンプトには「PTP シートに印刷された文字を読み、製品名と用量 (mg/μg) を必ず両方教えてください」を使用した。API のレート制限対策として 1 リクエストごとに 1 秒の待機を挟み、レート超過エラー (429) 発生時には再試行した。正解判定は Qwen 側と同一の正規化・部分一致判定である。

4.5 予備実験（単一薬剤メインテート錠）

本実験に先立ち、単一薬剤「2.5mg メインテート錠」のみを対象として、(1) 出力形式・方式の比較、(2) 少数画像+データ拡張での LoRA 学習の有効性確認を行った。

4.5.1 出力形式・方式の比較

提案手法の出力形式を確定するため、以下の 4 方式をテスト画像 5 枚（メインテート錠 2.5mg）で比較した（2026 年 4 月 26 日実施）。

- **方法 A（薬剤名のみ FT）**：画像に対して薬剤名のみを出力するよう LoRA 学習する方式（3.4 節の提案手法）。
- **方法 B（詳細鑑別 FT）**：薬剤名に加えて色・形状・刻印などの鑑別理由を含む詳細な説明を出力するよう LoRA 学習する方式。
- **RAG 型**：薬剤情報データベース（JSON 形式の薬剤 DB）を検索し、候補薬剤情報を回答に利用する方式。
- **Gemini**：外部 API によるゼロショット識別（当時は `gemini-2.5-flash` を使用）。

結果を表 9 に示す。

表 9 出力形式・方式の比較（テスト画像 5 枚・メインテート錠 2.5mg）

方式	成功数	平均時間/枚	備考
方法 A（薬剤名のみ FT）	5 / 5	0.8 秒	最も高速かつ正確
方法 B（詳細鑑別 FT）	3 / 5	37.4 秒	説明的だが遅く不安定
RAG 型（薬剤 DB 検索）	5 / 5	24.4 秒	正確だが検索処理で低速
Gemini（ゼロショット）	0 / 5	3.4 秒	全滅

方法 A と RAG 型がともに 5/5 で正答したが、推論時間は方法 A が 0.8 秒/枚と約 30 倍高速であったため、以降の全実験では方法 A（薬剤名のみを出力）を採用した。なお、RAG 型は新規薬剤の追加に再学習が不要という利点があり、全薬剤規模での比較は今後の課題とする（5 章）。

4.5.2 拡張データセットでの学習と評価

次に、少数の元画像とデータ拡張の組み合わせで LoRA 学習が機能するかを確認した。元画像 6 枚を 11 種拡張した 66 枚で学習し、元画像 2 枚を 11 種拡張した 22 枚で評価した。学習に要した時間は 15 分 18 秒であり、エポックごとの平均損失は表 10 のとおりであった。

表 10 単一薬剤での学習損失推移

エポック	平均損失
1	0.6757
2	0.0002
3	0.0001
4	0.0001
5	0.0001

2 エポック目以降にほぼ完全に収束し、評価用 22 枚すべてで正解薬剤名を出力した (Top-1 精度 100%)。明度、コントラスト、回転、水平反転、ノイズの全拡張パターンに対して正答した。同一の 22 枚に対する Gemini (gemini-2.5-flash) のゼロショット識別は 0/22 であった (表 11)。ただし Gemini 側の失敗には無料枠の API リクエスト数上限超過によるエラー応答 6 件が含まれるため、この予備実験の比較は参考値であり、本実験 (4.7 節) にて全薬剤・新プロンプトでの再評価を行った。

表 11 2.5mg メインテート錠における LoRA と Gemini の比較 (予備実験・参考値)

指標	LoRA	Gemini 2.5 Flash
成功数	22 / 22	0 / 22
成功率	100.0%	0.0%
平均推論時間	1.1 秒	14.0 秒

4.6 初期検討：データ拡張なしでの全薬剤学習

データ拡張を導入する前の初期検討として、元画像 287 枚のみ (拡張なし) を用いた全薬剤の LoRA 学習を行った (2026 年 5 月 12 日頃実施)。学習設定は本実験と同一 (LoRA rank 8・alpha 16, target modules q_proj・v_proj, 5 エポック, 学習率 $2e-4$) である。

学習損失は初期 3.88 から最終約 0.001 までほぼゼロに低下した。学習枚数が 287 枚と少ないにもかかわらず損失がほぼゼロまで落ちる挙動は、学習データを丸暗記する過学習の兆候であり、未学習画像への汎化は期待できないと判断した。このモデルに対する定量評価は実施せず、撮影枚数の不足を補う対策として 4.2 節の 11 種類のデータ拡張を導入した。すなわち本検討は、提案手法においてデータ拡張が必要である根拠を与えた通過点である。以降の結果はすべて拡張あり (学習 2,343 枚) のモデルによる。

4.7 単一薬剤識別の結果（本実験）

41 薬剤の評価画像 814 枚（撮影＋拡張あり）に対して、提案手法（ファインチューニング後の Qwen3.5-4B）、ファインチューニング前の Qwen3.5-4B、および Gemini の 3 者を同一条件で比較した。結果を表 12 に示す。

表 12 単一薬剤識別の 3 者比較（同一の評価画像 814 枚）

手法	Top-1 精度	成功数
ファインチューニング後 Qwen3.5-4B（提案手法）	98.2%	799 / 814
Gemini（gemini-3.5-flash・ゼロショット）	80.2%	653 / 814
ファインチューニング前 Qwen3.5-4B（ゼロショット）	0.9%	7 / 814

提案手法は 98.2% を達成し、41 薬剤中 29 薬剤で 100% の正答であった。提案手法の薬剤別の成功率を表 13 に示す。

表 13 提案手法（ファインチューニング後 4B）の薬剤別 Top-1 成功率（成功数／評価枚数）

薬剤名	成功／枚数	成功率	薬剤名	成功／枚数	成功率
2.5mg メインテート錠	22/22	100.0%	バルモディア XR 錠 0.2mg	20/22	90.9%
アルダクトンA錠 25mg	21/22	95.5%	フェブリク錠 10mg	22/22	100.0%
ウルソ錠 100mg	11/11	100.0%	フォシーガ錠 10mg	22/22	100.0%
エソメプラゾールカプセル 20mg	21/22	95.5%	フロセミド錠 20mg	21/22	95.5%
エンレスト錠 100mg	21/22	95.5%	ブレドニン錠 5mg	22/22	100.0%
エンレスト錠 200mg	22/22	100.0%	プロマック D 錠 75mg	22/22	100.0%
カロナール錠 500mg	22/22	100.0%	ベオーパ錠 50mg	22/22	100.0%
キャベリン配合錠	22/22	100.0%	ミヤBM錠	11/11	100.0%
クエン酸第一鉄 Na 錠 50mg	22/22	100.0%	ムコダイン錠 500mg	21/22	95.5%
ジャディアンス錠 10mg	22/22	100.0%	メチコパール錠 500μg	11/11	100.0%
ジャスピア錠 50mg	20/22	90.9%	メトクロプラミド錠 5mg	11/11	100.0%
センノシド錠 12mg	22/22	100.0%	メトグルコ錠 250mg	22/22	100.0%
タケキャブ錠 10mg	22/22	100.0%	ランソプラゾール OD 錠 15mg	11/11	100.0%
タケキャブ錠 20mg	11/11	100.0%	リクシアナ OD 錠 30mg	21/22	95.5%
タリージェ OD 錠 5mg	21/22	95.5%	レバミピド錠 100mg	22/22	100.0%
ダイアート錠 30mg	22/22	100.0%	レボチロキシン Na 錠 50μg	22/22	100.0%
デエビゴ錠 5mg	22/22	100.0%	レボフロキサシン錠 500mg	10/11	90.9%
トラゼンタ錠 5mg	22/22	100.0%	ロキソプロフェンナトリウム錠 60mg	22/22	100.0%
ノルバスク OD 錠 5mg	20/22	90.9%	ロスバスタチン錠 2.5mg「DSEP」	21/22	95.5%
バイアスピリン錠 100mg	11/11	100.0%	酸化マグネシウム錠 330mg	22/22	100.0%
バクトラミン配合錠	22/22	100.0%	全体	799/814	98.2%

ファインチューニング前のモデルは 0.9%（7/814）であり、正答した 7 枚はすべてレバミピド錠 100mg であった（同薬剤のみ 31.8%，他の 40 薬剤は 0%）。レバミピドのみ正答できたのは、一般名としての知名度が高く事前学習の知識に含まれていたためと推測される。ファインチューニング前後の差 97.3 ポイントが、薬剤画像特化の追加学習の効果である。

Gemini は 80.2% であり、提案手法が 18.0 ポイント上回った。Gemini は薬剤ごとの差が大きく、提案手法では高精度に識別できる薬剤で大きく精度を落とした（表 14）。

なお、Gemini の評価は当初「薬剤名のみを日本語で答える」旧プロンプトで実施しており、このときの正答率は 44.0%（学習用拡張データ 1,338 枚を対象とした途中中断時点の参考値）であった。プロンプトを「PTP シートの印字を読み、製品名と用量を必ず両方答える」形式（4.4 節）に変更して評価用 814 枚で測り直した結果が 80.2% である。外部 API の性能はプロンプト設計に強く依存することも確認された。

また、提案手法について評価条件を変えた結果を表 15 に示す。

拡張なしの元画像のみでは 100%（74/74）であり、98.2% における失敗 15 枚はすべて拡張によって人工的に変形させた画像に由来する。また、上位 3 候補を提示する Top-3 評価では 99.9%（813/814）に達してお

表 14 Gemini の正答率が低かった薬剤と提案手法との比較（同一評価画像）

薬剤名	Gemini	提案手法 (FT 後 4B)
ロスバスタチン錠 2.5mg 「DSEP」	0.0%	95.5%
パルモディア XR 錠 0.2mg	4.5%	90.9%
ジャヌビア錠 50mg	18.2%	90.9%
メチコパール錠 500 μ g	36.4%	100.0%
エンレスト錠 200mg	45.5%	100.0%
カロナール錠 500mg	45.5%	100.0%

表 15 提案手法（ファインチューニング後 4B）の評価条件別の結果

評価条件	評価画像	精度
撮影＋拡張あり（標準）	814 枚	Top-1 98.2%
拡張なし（元画像のみ）	74 枚	Top-1 100.0%
Top-3 評価（ビーム幅 3）	814 枚	Top-3 99.9% (Top-1 98.3%)

り，Top-1 で誤る場合でも候補提示により実用上の救済が可能である．

誤識別 15 枚は表 13 に示した 12 薬剤で発生した（各薬剤 1～2 枚）．この 15 枚を拡張種別ごとに集計したものを表 16 に示す．

表 16 誤識別画像の拡張種別内訳（提案手法・15 枚）

拡張種別	失敗枚数
回転 +30 度	4
回転 -30 度	4
水平反転	4
回転 -15 度	2
明度 1.3 倍	1
元画像，回転 +15 度，明度 0.7 倍，コントラスト 0.7・1.3 倍，ノイズ	0
合計	15

誤識別の大部分は回転（ ± 30 度， -15 度）と水平反転の合計 14 枚であり，文字方向や錠剤シートの上下左右が大きく変化する拡張に対してモデルが脆弱であることが分かった．一方で，明度・コントラスト・ノイズなどの輝度系の変化に対する失敗は 1 件のみであり，色や明るさの揺らぎに対しては頑健であった．また，同一の元画像が複数の拡張で同時に失敗するケースが 3 例観察され（ジャヌビア錠 50mg，ノルバスク OD 錠 5mg，パルモディア XR 錠 0.2mg の各 1 枚），これらはそもそも判別が難しい撮影条件の画像であり，撮影品質に起因する可能性がある．誤識別の出力内容は無関係な単語ではなくほぼすべて別の薬剤名であり，回転や反転で文字が読みにくくなった結果，近い見た目の別薬剤に誤判定していると考えられる．

4.8 外部画像での汎化（予備的検証）

評価画像が学習画像と同一の撮影環境であることによる過大評価の可能性を確認するため，データセット（4.2 節）とは別の時期に撮影したレバミピド錠 100mg の画像を，回転・明度の拡張を施して 390 枚とし，

提案手法（同一の学習済み LoRA・同一の評価手順）で評価した（2026 年 5 月 21 日実施）。結果は 99.7%（389/390，失敗 1 枚）であり，少なくとも本薬剤については撮影時期が異なっても高精度を維持した．ただし対象が 1 薬剤のみであるため，全薬剤を対象とした別環境画像（Web 収集画像等）での汎化評価は今後の課題である（5 章）．

4.9 複数薬剤同時識別の結果

4.9.1 評価データの作成

1 枚に複数の薬剤が写る評価画像は，評価用 814 枚（学習に未使用）の画像から合成して作成した．合成手順は次のとおりである．（1）各薬剤画像から，画素値の局所標準偏差に基づくテクスチャ検出により薬剤（PTP シート）部分の領域を自動的に切り出す．（2）切り出した薬剤画像を高さ 512px に揃え，異なる薬剤 2 枚または 3 枚を余白なしで横に連結して 1 枚のタイル画像とする．（3）全 41 薬剤が均等に登場するよう，各画像の主薬剤をラウンドロビンで割り当て，残りの 1～2 薬剤をランダムに選択する（乱数シード 42 で固定）．この方法で 2 薬剤 500 枚＋3 薬剤 500 枚の合計 1,000 枚を生成した（各薬剤は各グループに 12～13 回ずつ登場）．各合成画像に写る薬剤の集合は正解ラベルファイル（labels.json）として保存し，採点に用いた．合成には評価用画像のみを使用しているため，学習データのリークはない．

4.9.2 一括質問方式の失敗

まず，合成画像全体をモデルに 1 回提示し「写っている薬をすべて JSON リストで答えよ」と質問する一括質問方式を試みた．表 17 に示すとおり，プロンプトの工夫（必ず複数答えるよう指示，薬剤の個数を提示，領域順の列挙指示，高解像度化）のいずれを加えても完全一致率はほぼ 0% であった．

表 17 一括質問方式の結果（ファインチューニング後 4B）

方式	プロンプトの工夫	完全一致率
手法 1	基準（すべて JSON で答えよ）	≈0%（1/2050）
手法 3	「必ず複数答えよ」と指示	0%
手法 4	写っている個数 n を提示	0%
手法 5	「領域ごとに左から順に」と指示	0%
手法 6	個数提示＋高解像度入力	0%

失敗の原因は，モデルが「1 枚に 1 薬剤」を答えるよう学習されているため，複数の薬剤が写っていても 1 薬剤しか出力しないことであった．

4.9.3 検出→単剤分類方式の結果と 3 者比較

次に，3.5 節の 2 段階構成（検出→単剤分類）を適用した．検出には LoRA を無効化した素のベースモデルのゼロショット検出（検出プロンプトは 3.5 節，入力最大 1280 × 1280 ピクセル）を用い，検出された各領域をマージン 2% 付きで切り出して単剤識別した．

まず先行検証として，学習用画像から同じ手順で合成した生成画像 2,050 枚（各薬剤が 2 薬剤 25 枚＋3 薬剤 25 枚の計 50 回登場）で本方式を評価し，完全一致率 69.6%・F1 85.2% を得た．ただしこの 2,050 枚は学習に使用した画像を合成元とするため評価としては甘い．そこで本評価では，学習に未使用の評価用画像から合成した前述の 1,000 枚を用いた．同一の 1,000 枚で，Gemini およびファインチューニング前の Qwen3.5-4B とも比較した．Gemini は外部 API であり検出→分類のパイプラインを組めないため，一括質問方式（プロ

ンプト「この画像に写っているすべての薬を薬剤名と用量を含めて JSON リストで教えてください」で評価した。ファインチューニング前の Qwen3.5-4B も同様に一括質問方式（「この画像に写っているすべての薬を JSON リストで教えてください」）である。結果を表 18 に示す。

表 18 複数薬剤同時識別の 3 者比較（同一の合成評価画像 1,000 枚）

手法	完全一致率	Recall	Precision	F1
FT 後 4B（検出→単剤分類・提案）	68.8% (688/1000)	85.5%	86.3%	85.6%
Gemini（一括質問）	48.2% (482/1000)	—	—	—
FT 前 4B（一括質問）	0.0% (0/1000)	—	—	—

提案手法の完全一致率は 68.8%（2 薬剤 75.6%，3 薬剤 62.0%）であり，Gemini の 48.2%（2 薬剤 57.2%，3 薬剤 39.2%）を上回った。ファインチューニング前のモデルは完全一致 0%（1 薬剤以上正解した画像でも 3.3%）であった。単剤識別が 98.2% であるのに対し複数同時識別が 68.8% に留まることから，性能低下の主な要因は検出・切り出し段階にあると考えられた。この仮説は次節の実験で検証する。

4.10 検出器の専用学習による改善

4.10.1 評価セットと上限値の診断（検出が完璧な場合）

本節の実験では，評価用 814 枚（学習に未使用）から各薬剤の正解 bounding box 付きで再合成した評価セットを用いた。構成は，標準セット 200 枚（2 薬剤 100 枚＋3 薬剤 100 枚）と，評価用 814 枚を 1 枚ずつ使い切る全部セット 320 枚（2 薬剤 146 枚＋3 薬剤 174 枚）の 2 種類である。

検出段階の改善余地を定量化するため，合成時に保存した正解 bounding box で切り出して単剤識別する「検出が完璧な場合の上限値」を測定した。あわせて合成タイル画像の解像度（タイル高さ）の影響も調べた。結果を表 19 に示す。

表 19 合成解像度別の上限値（正解 bbox 使用）と実機値（素のベース検出）

タイル高さ	上限（正解 bbox）	実機（素のベース検出）
512px	80.0%	—
768px	92.0%	81.5%（200 枚）
1024px	93.5%	—

解像度を 512px から 768px に上げるだけで上限が 80.0% から 92.0% に，実機（素のベース検出）も 68.8% から 81.5% に改善した。したがって（1）入力解像度と（2）検出精度の双方が複数識別のボトルネックであることが確認された。

4.10.2 検出器 LoRA の学習

検出精度を高めるため，検出専用の LoRA アダプタを追加学習した。学習データは，学習用分割の画像（評価用合成画像とは元画像レベルで分離しリークを防止）から，実写に近い条件（薬剤間のすきま，背景余白約 6%，大きさ・位置のばらつき）を加えて合成した複数薬剤画像 500 枚（2 薬剤 200 枚・3 薬剤 200 枚・4 薬剤 100 枚）である。教師信号は，各薬剤の bounding box を 0～1000 に正規化した座標で記述するグラウンディング形式 JSON（`[{"bbox_2d": [x1,y1,x2,y2], "label": "薬剤"}]`）であり，検出プロンプトは推論時

(3.5 節) と同一とした。学習設定は LoRA rank 8・alpha 16, 画像解像度 1024px, 3 エポックで, 平均損失は 0.181 → 0.134 → 0.119 と単調に減少した (所要約 80 分)。

4.10.3 検出器差し替え後の再評価

学習した検出器 LoRA を検出段に差し替え, 同一の合成画像で「上限 (正解 bbox)」「旧検出 (素のベース)」「新検出 (学習した検出器)」を比較した。1 つの基盤モデルに識別 LoRA と検出 LoRA の 2 つを搭載し, 処理段階に応じてアダプタを切り替えた。結果を表 20 に示す。

表 20 検出器学習の効果 (完全一致率, 括弧内は F1)

方式	768px・標準 200 枚	768px・全部 320 枚	1024px・標準 200 枚
上限 (正解 bbox)	92.0% (96.8%)	91.6% (96.9%)	93.5% (97.3%)
旧検出 (素のベース)	81.5% (90.8%)	77.8% (90.4%)	85.5% (93.4%)
新検出 (学習した検出器)	91.0% (96.2%)	88.8% (96.3%)	96.0% (98.4%)
改善 (新 - 旧)	+9.5pt	+10.9pt	+10.5pt

検出器の専用学習により完全一致率は 9.5~10.9 ポイント改善し, 検出起因の損失の約 80~90% を回収した。新検出 (学習した検出器) の薬剤数別の内訳を表 21 に示す。

表 21 新検出 (学習した検出器) の薬剤数別の完全一致率

条件	2 薬剤	3 薬剤
768px・標準 200 枚	92.0% (92/100)	90.0% (90/100)
768px・全部 320 枚	93.8% (137/146)	84.5% (147/174)
1024px・標準 200 枚	97.0% (97/100)	95.0% (95/100)

特に 1024px 設定では全体 96.0% (2 薬剤 97.0%, 3 薬剤 95.0%) に達し, 本研究の複数薬剤同時識別における最高値となった。注目すべきは, 1024px において新検出 (96.0%) が正解 bbox 使用の上限 (93.5%) を上回った点である。これは, 学習した検出器が出力する bounding box が正解 box (タイル全体) よりも薬剤に密着しており, 切り出し品質が高いためである。1024px で新検出が誤った 8 枚はすべて検出ではなく識別段階の取り違い (うち 5 枚がロスバスタチン錠 2.5mg 「DSEP」→クエン酸第一鉄 Na 錠 50mg の誤読) であり, 検出の問題は実質的に解消された。

4.11 過検出抑制の検証 (負の結果)

検出器学習前の誤り分析で観察された過検出 (余分な box の出力) への対策として, (1) 重なり率 (IoU) 0.5 超の box を統合する重複除去 (NMS), (2) 切り出し領域が薬剤か否かを判定する「該当なしゲート」LoRA (薬剤 328 枚・非薬剤 340 枚の計 668 枚で学習) の 2 方式を, 768px・標準 200 枚で検証した。結果を表 22 に示す。

重複除去は除去対象となる重複 box が 0 個であり効果がなかった。該当なしゲートは学習損失が 2 エポック目で 0.0000 まで低下する過学習を起こし, 実際の検出領域 (特にジャディアン錠 10mg) を誤って「該当なし」と判定して正しい薬剤を棄却した結果, 完全一致率が 7.5 ポイント悪化した (Precision は向上せず)。この負の結果から, 過検出は検出器の専用学習の時点で既に解消されており, 後処理による抑制の余地はないことが確認された。

表 22 過検出抑制の検証結果 (768px・標準 200 枚)

方式	完全一致率	F1	Precision
ベース (A-3 新検出・抑制なし)	91.0%	96.2%	96.5%
重複除去 (NMS)	91.0%	96.2%	96.5%
該当なしゲート	83.5%	94.3%	96.5%

4.12 軽量化の評価 (量子化・モデルサイズ)

スマートフォン等の端末搭載を見据え、(1) 学習済み 4B モデルの 4bit 量子化 (NF4 形式+二重量子化、再学習は行わず、学習済み LoRA をそのまま量子化モデルに適用)、(2) モデルサイズの縮小 (0.8B / 2B、いずれも 4B と同一の学習データ・同一の LoRA 設定で学習) による精度の変化を測定した。

評価は 3 条件で行った。単一薬剤は評価用 814 枚 (4.7 節と同一)、複数薬剤は合成評価画像 1,000 枚 (4.9 節と同一・検出→単剤分類方式) である。混在評価は、薬剤数が事前に分からない実運用を模擬するため、単一薬剤の評価画像から 100 枚と複数薬剤の合成画像から 100 枚を抽出・シャッフルした計 200 枚に対し、検出→単剤分類方式で薬剤数を自動判定させて評価した。結果を表 23~25 に示す。

表 23 モデルサイズ・量子化と単一薬剤識別精度 (Top-1, 814 枚)

モデル	非量子化	4bit 量子化	量子化での低下
0.8B	87.3% (711/814)	74.3% (605/814)	-13.0pt
2B	87.2% (710/814)	83.9% (683/814)	-3.3pt
4B	98.2% (799/814)	91.9% (748/814)	-6.3pt

表 24 モデルサイズ・量子化と複数薬剤同時識別精度 (完全一致率, 括弧内は F1, 1,000 枚)

モデル	非量子化	4bit 量子化
0.8B	12.7% (54.1%)	4.6% (33.9%)
2B	30.0% (67.6%)	12.9% (51.7%)
4B	68.8% (85.6%)	55.2% (76.7%)

表 25 単一・複数混在評価 (完全一致率, 括弧内は F1, 単一 100 枚+複数 100 枚)

モデル	非量子化 (単一／複数の内訳)	4bit 量子化 (単一／複数の内訳)
0.8B	38.0%・F1 62.7% (66% / 10%)	26.5%・F1 42.4% (48% / 5%)
2B	48.5%・F1 68.3% (68% / 29%)	40.5%・F1 62.2% (71% / 10%)
4B	68.0% ・F1 80.3% (67% / 69%)	70.0% ・F1 80.4% (72% / 68%)

単一薬剤識別ではモデルサイズによる差が比較的小さい (0.8B でも 87.3%) のに対し、複数薬剤同時識別では 0.8B 12.7%, 2B 30.0%, 4B 68.8% とサイズの影響が極めて大きい。量子化の影響も複数識別の方が大きく (4B で単一 -6.3pt, 複数 -13.6pt), これは検出→分類の 2 段階処理で量子化誤差が領域ごとに累積するためと考えられる。また、量子化による精度低下は薬剤間で一様ではなく、量子化 4B の単一識別ではレ

バミピド錠 100mg (27.3%), メチコバル錠 500 μ g・ロスバスタチン錠 2.5mg 「DSEP」(各 54.5%) など、特定の薬剤に低下が集中した。量子化 4B の複数識別の内訳は 2 薬剤 63.8%・3 薬剤 46.6% (Recall 76.8%・Precision 77.6%) であった。混在評価では 4B のみが単一・複数で均等な精度を示し (67% / 69%), 量子化しても全体精度がほぼ低下しなかった (68.0% → 70.0%, 各 100 枚での誤差範囲)。量子化 4B でも複数識別 55.2% は Gemini の 48.2% を上回っており、端末搭載の候補としては量子化 4B が精度と軽さのバランスで最有力である。なお混在評価は各 100 枚の軽量版であり、数ポイントの差は誤差として傾向の確認に用いる。

4.13 誤識別の横断分析

単一薬剤識別の全 6 条件 (モデルサイズ 3 種 × 量子化の有無) の誤識別を横断的に集計し、誤りの傾向を分析した。条件別の誤識別件数を表 26 に示す (合計 640 件)。

表 26 単一薬剤識別の条件別誤識別件数 (評価 814 枚に対する誤り数)

モデル	非量子化	4bit 量子化
0.8B	103 件	209 件
2B	104 件	131 件
4B	27 件	66 件

(1) 向きの崩れへの脆弱性：誤識別を評価画像の拡張種別ごとに集計した結果を表 27 に示す。回転 (± 15 度・ ± 30 度) 合計 311 件と水平反転 108 件を合わせた 419 件 (全体の約 66%) が、向きが崩れる加工の画像で発生した。明度・コントラスト・ノイズによる失敗は各 30 件台にとどまり、無加工の元画像等での失敗はわずか 12 件であった。通常の向きで撮影された画像にはほぼ失敗しないことを意味する一方、向きが大きく崩れた入力への対策 (学習側拡張の強化または向き補正前処理) が今後の課題である。

表 27 誤識別の拡張種別内訳 (単一識別・全 6 条件の合計)

拡張種別	誤識別件数
回転 -30 度	109
水平反転	108
回転 $+30$ 度	89
回転 -15 度	63
回転 $+15$ 度	50
コントラスト 0.7 倍	39
コントラスト 1.3 倍	38
明度 0.7 倍	35
明度 1.3 倍	34
ノイズ	30
元画像・その他	12

(2) 誤答先の偏り (受け皿薬剤)：よく起きる取り違えの組 (正解→予測) の上位を表 28 に示す。

誤答は特定の薬剤に偏って流れる傾向が見られた。特にデエビゴ錠 5mg とプロマック D 錠 75mg が複数の薬剤からの誤答先になっており、複数識別 (検出→単剤分類) の誤検出でもデエビゴ錠 5mg が 81 件と突出していた (2 位のクエン酸第一鉄 Na 錠 50mg は 20 件)。これらの「受け皿」となる薬剤は白色円形の錠剤であり、外観の手がかりが乏しい場合の既定の答えになっていると考えられる。また複数識別の取りこぼし (写っ

表 28 頻出する取り違えの組（単一識別・全 6 条件の合計・上位 10 組）

取り違え（正解 → 予測）	件数
パルモディア XR 錠 0.2mg → デエビゴ錠 5mg	14
酸化マグネシウム錠 330mg → プロマック D 錠 75mg	13
エンレスト錠 100mg → プロマック D 錠 75mg	12
ミヤBM錠 → バクトラミン配合錠	11
ロスバスタチン錠 2.5mg 「DSEP」 → 2.5mg メインテート錠	11
ジャヌビア錠 50mg → デエビゴ錠 5mg	10
ダイアート錠 30mg → ジャヌビア錠 50mg	10
メチコパール錠 500 μ g → メトグルコ錠 250mg	10
ノルバスク OD 錠 5mg → プロマック D 錠 75mg	9
カロナール錠 500mg → ロキソプロフェンナトリウム錠 60mg	9

ているのに当てられなかった薬剤）は、カロナール錠 500mg（29 件）、ロスバスタチン錠 2.5mg 「DSEP」（22 件）、エンレスト錠 100mg・ロキソプロフェンナトリウム錠 60mg（各 21 件）が上位であり、単一識別の苦手薬剤と重なる。

（3）同名・別用量の取り違え：エンレスト錠 100mg → エンレスト錠 200mg（3 件）、タケキャブ錠 10mg と 20mg の相互取り違え（各 1 件）など、同一製品名で用量のみが異なる薬剤間の取り違えが観察された。件数は少ないが投与量の誤りに直結するため、医療応用上は最も注意すべき誤りであり、用量表示の読み取りを強化する対策が必要である。

（4）量子化・小型化による誤りの増加：表 26 のとおり、単一識別の誤りは 4B 非量子化の 27 件に対し、0.8B 量子化では 209 件と桁が変わる水準で増加した。端末搭載時には、上記の苦手薬剤・受け皿薬剤を重点的に確認する必要がある。

4.14 考察

本章の実験結果から、以下の知見が得られた。

第一に、薬剤画像に特化した LoRA ファインチューニングの効果は決定的である。同一の評価画像 814 枚に対して、ファインチューニング前 0.9% に対しファインチューニング後 98.2%（差 97.3 ポイント）であり、汎用大規模モデルである Gemini（80.2%）も上回った。1 薬剤あたり元画像 3～10 枚という少数データでも、11 種のデータ拡張との組み合わせで実用的な精度に到達できることが示された。データ拡張なしの初期学習が過学習の挙動を示したこと（4.6 節）を踏まえると、少数画像の薬剤鑑別においてデータ拡張は本手法の成立に不可欠な要素である。

第二に、複数薬剤の同時識別は、モデルの再学習ではなく「解き方の分解」で実現できた。一括質問方式はプロンプトをどのように工夫しても 0% であったが、検出→単剤分類の 2 段構成により再学習なしで 68.8% に達し、さらに検出器の専用学習と入力解像度の向上（1024px）により 96.0% まで改善した。検出器学習後の残差はすべて識別段階の取り違えであり、検出の問題は実質的に解消された。一方で過検出抑制の後処理（NMS・該当なしゲート）は効果がなく、検出器そのものの学習が本質的な対策であったことが負の結果からも裏付けられた。

第三に、軽量化のトレードオフが定量化された。単一識別のみであれば小型モデル（量子化 2B で 83.9%）も実用域に近いが、複数識別を含めるなら 4B が必須であり、量子化 4B（単一 91.9%・複数 55.2%）が端末搭載の現実的な選択肢である。

最後に本実験の限界を述べる．評価画像は（外部画像での予備的検証を除き）学習画像と同一環境で撮影したものであり，撮影環境の異なる画像（Web 収集画像等）での汎化性能は未検証である．複数薬剤の評価は合成画像によるものであり，実際に複数の PTP シートを並べて撮影した実写画像での検証も今後必要である．また，回転・反転への脆弱性，同名・別用量の取り違えは未解決の課題として残る．

5 結論・今後の課題

5.1 結論

本研究では、オープンソースの Vision-Language Model である Qwen3.5-4B を薬剤画像で LoRA ファインチューニングし、薬剤画像とテキストプロンプトから薬剤名を直接出力する薬剤鑑別手法を提案・評価した。得られた主な結論は以下のとおりである。

1. **特化学習の有効性**：41 薬剤・評価画像 814 枚の単一薬剤識別において、提案手法は Top-1 精度 98.2% を達成し、ファインチューニング前のモデル (0.9%) および外部 API 型マルチモーダル AI の Gemini (80.2%) を上回った。1 薬剤あたり元画像 3~10 枚という少数データでも、11 種のデータ拡張との組み合わせにより高精度が実現できる。
2. **複数薬剤同時識別の実現**：単剤識別用に学習したモデルを変更せず、「検出→単剤分類」の 2 段構成により複数薬剤の同時識別を実現した (完全一致率 68.8%, Gemini 48.2% を上回る)。さらに検出器 LoRA の専用学習と入力解像度の向上により 96.0% まで改善し、検出段階の課題を実質的に解消した。
3. **軽量化のトレードオフ**：モデルサイズ (0.8B/2B/4B) と 4bit 量子化の影響を単一・複数・混在の 3 条件で定量化した。複数識別にはモデルサイズの影響が極めて大きく、端末搭載には量子化 4B (単一 91.9%・複数 55.2%) が精度と軽さのバランスで最有力である。
4. **ローカル動作**：以上の全評価は Gemini 比較を除きローカル環境 (単一 GPU) で完結しており、薬剤画像を外部サービスへ送信しない薬剤鑑別システムの実現可能性を示した。

5.2 今後の課題

- **別環境画像での汎化評価**：本研究の評価画像は学習画像と同一環境での撮影が中心である。Web から収集した別環境・別個体の画像で全薬剤の評価を行い、撮影環境に依存しない汎化性能を検証する (別時期撮影のレバミピド錠 100mg では 99.7% を確認済み)。
- **実写の複数薬剤画像での検証**：複数薬剤の評価は合成画像によるものであるため、実際に複数の PTP シートを並べて撮影した実写画像で最終検証を行う。
- **向きの崩れへの対策**：誤識別の 66% が回転・水平反転に起因した。学習側での大角度回転拡張の強化、または推論前の向き補正前処理を導入し、効果を比較する。
- **同名・別用量の取り違え対策**：エンレスト錠 100mg と 200mg のような用量違いの取り違えは投与量の誤りに直結する。用量表示の読み取りを強化する学習・プロンプト設計を検討する。
- **軽量モデルの拡充と実機検証**：Qwen3-VL-2B の再学習による「再学習あり 2B」対「量子化のみ 4B」の比較、およびスマートフォン実機でのオンデバイス推論の検証を行う。
- **RAG 型手法との比較**：薬剤データベース検索を併用する RAG 型手法 (予備実験では 5/5 を確認) を全薬剤に拡張し、新規薬剤追加時に再学習が不要であるという利点を含めてファインチューニング型と比較する。

謝辭

参考文献

- [1] World Health Organization. Medication without harm – WHO global patient safety challenge. <https://www.who.int/initiatives/medication-without-harm>, 2017. 2026 年 6 月 2 日閲覧.
- [2] 日本医療機能評価機構. 薬局ヒヤリ・ハット事例収集・分析事業. <https://www.yakkyoku-hiyari.jcqh.or.jp/>. 2026 年 6 月 2 日閲覧.
- [3] 末次王卓, 金澤直子, 正門佳法, 天達菜緒, 副田雪乃, 屋地慶子, 寺蘭英之. AI 画像解析錠剤識別システムの使用による持参薬錠剤一包化鑑別作業の効率化と薬剤助手へのタスク・シフト／タスク・シェアに関する評価. 医療薬学, Vol. 52, No. 5, pp. 273–281, 2026.
- [4] Yejin Heo, Hyunjung Kim, Sungjin Lee, et al. Deep learning-based pill identification with imprint text detection and recognition. *Journal of Medical Internet Research*, Vol. 25, p. e41043, 2023.
- [5] Richárd Rádli and László Toka. Metric-based pill recognition with the help of textual and visual cues. *IET Image Processing*, Vol. 18, No. 1, pp. 1–13, 2024.
- [6] R. Menaha, et al. Drug pills identification system using Google Gemini LLM: A generative AI approach. In *Proceedings of the International Conference on Electronics, Robotics and Control Systems (ICERCS)*, 2024.