

卒業研究報告書

題目

マルチモーダル学習による薬剤鑑別

指導教員

森山 真光 准教授

報告者

23-1-211-0009

呉竹 權人

近畿大学情報学部情報学科

令和 8 年 7 月 30 日提出

概要

薬剤の取り違いや誤服用は、医療安全上の重要な課題である。医療現場や家庭では、薬剤名が記載された外箱や薬袋が失われた場合、または薬剤本体や PTP シートのみが残された場合に、錠剤やカプセルの外観、刻印、包装上の印字といった限られた視覚情報を手がかりに薬剤を鑑別する必要がある。本研究では、薬剤画像とテキストプロンプトを入力とし、薬剤名を出力する Vision-Language Model 型の薬剤鑑別手法を検討する。具体的には、オープンソースの Vision-Language Model である Qwen3.5 を用い、薬剤画像に対して「この錠剤は何という薬ですか」という質問を与え、正解薬剤名を出力するように LoRA によるファインチューニングを行う。比較対象として、ファインチューニング前の Qwen3.5 および外部 API 型マルチモーダル AI である Gemini によるゼロショット識別を用い、薬剤画像データに特化したファインチューニングが薬剤鑑別精度に与える効果を評価する。41 種類の薬剤を対象とした評価では、拡張のない撮影元画像を主指標とし、ファインチューニング後のモデルが全 41 薬剤の 5 分割交差検証で単一薬剤識別 Top-1 精度 $98.6\% \pm 1.5\%$ を達成した。回転・反転等を加えた拡張画像 814 枚に対しても 98.2% を維持し、ファインチューニング前 (0.9%) および外部 API 型の Gemini (拡張画像で 82.3%) を画像変形への頑健性で上回った (拡張のない元画像では Gemini との差は McNemar 検定で有意でなく、統計的に同等であった)。さらに、1 枚の画像に複数の薬剤が写る場合についても、薬剤位置を検出して領域ごとに単剤識別を行う 2 段階構成を提案した。2~3 薬剤を横一列に配置した合成画像 200 枚を用いる 1024px 条件では、検出器の専用学習により完全一致率 96.0% を達成した。スマートフォン搭載を見据えたモデルサイズ (0.8B/2B/4B) および 4bit 量子化による精度変化の検証も行った。加えて、自前撮影とは出典および撮影条件が異なる Web 収集画像 136 枚で 96.3% の正答率を得て、異なる画像条件に対しても一定の汎化性能を示した。データ拡張の倍率のみを変えた対照実験では、拡張なしの 73.0% に対し 11 種拡張で 97.3% となり、データ拡張が精度向上に大きく寄与することを確認した。また、学習対象外の未知薬剤に対して出力候補を学習済み薬剤名一覧と照合するホワイトリスト方式を予備実験として評価し、未知薬剤 17 枚中 12 枚を保留できたが単独では不十分であることを明らかにした。薬剤データベースを検索して候補薬剤情報を提示する RAG 型手法については予備実験で比較を行っており、全薬剤規模での比較を今後の発展的課題とする。

目次

1	序論	1
1.1	本研究の背景	1
1.2	本研究の目的	2
1.3	本報告書の構成	2
2	関連研究・関連技術	3
2.1	画像特徴・刻印文字を用いた薬剤識別手法	3
2.2	画像特徴とテキスト特徴を用いたマルチモーダル薬剤識別手法	3
2.3	生成 AI・LLM を用いた薬剤識別支援手法	4
2.4	先行研究の整理と本研究の位置づけ	4
3	提案手法	5
3.1	研究テーマの整理	5
3.2	解決策の妥当性	6
3.3	使用モデル：Qwen3.5	7
3.4	提案手法：Qwen3.5 の LoRA ファインチューニング	7
3.5	複数薬剤同時識別への拡張：検出→単剤分類	8
3.6	比較手法	10
3.7	使用データ	10
3.8	評価方法	10
3.9	実験計画	11
4	実験と結果	13
4.1	実験環境	13
4.2	データセットの構築	13
4.3	学習設定	15
4.4	評価手順	16
4.5	予備実験（単一薬剤メインテート錠）	16
4.6	初期検討：データ拡張なしでの全薬剤学習	18
4.7	単一薬剤識別の結果（本実験）	18
4.8	外部画像での汎化（予備的検証）	20
4.9	複数薬剤同時識別の結果	20
4.10	検出器の専用学習による改善	22
4.11	軽量化の評価（量子化・モデルサイズ）	23
4.12	Gemini による拡張前の元画像 287 枚の評価	24
4.13	Web 収集画像での汎化評価	25
4.14	回転・反転への対策	26
4.15	学習枚数の感度分析（few-shot 曲線）と表裏・錠数の効果	27

4.16	量子化・モデルサイズの実画像（拡張なし）評価	29
4.17	データ分割の妥当性検証（リーク監査）	29
4.18	5 分割交差検証による頑健性の確認	30
4.19	推論ベンチマーク（メモリ・速度）	31
4.20	根拠説明文の生成可否	32
4.21	考察	32
5	結論・今後の課題	34
5.1	結論	34
5.2	今後の課題	34
	謝辞	36
	参考文献	37

1 序論

1.1 本研究の背景

薬剤の取り違いや誤服用は、患者の健康被害につながる医療安全上の重要な問題である。世界保健機関（WHO）は、2017年に第3回世界患者安全チャレンジとして「Medication Without Harm」を立ち上げ、投薬に関連する重篤かつ回避可能な健康被害を5年間で50%削減することを世界共通の目標として掲げている[1]。WHOは、こうした投薬に関連する有害事象に世界全体で年間およそ420億ドルの費用が生じていると報告しており、投薬の安全性確保は一国にとどまらない世界的な課題と位置づけられている。国内においても、日本医療機能評価機構の薬局ヒヤリ・ハット事例収集・分析事業の2024年年報には、調剤に関するヒヤリ・ハット事例が19,304件報告されている。このうち、調製および鑑査における薬剤取り違いは、異なる成分の取り違いが2,389件、同成分の取り違いが1,841件であり、合計4,230件に上る[2]。また、同機構は外観が類似した内服薬の取り違いを分析テーマとして取り上げており、薬剤を正確に識別・鑑別することは医療安全上の重要な課題である[3]。

医療現場や家庭では、薬剤名が記載された外箱や薬袋が失われた場合、または薬剤本体やPTPシートのみが残された場合に、錠剤やカプセルの外観、刻印、包装上の印字など限られた視覚情報を手がかりに薬剤を鑑別する必要がある。特に、高齢者が複数の薬剤を長期的に服用する場合や、一包化調剤によって複数の薬剤がまとめられる場合には、薬剤の識別が困難になり、誤服用のリスクが高まる。

従来、薬剤鑑別には薬剤師などの専門知識が必要であり、薬剤データベースを手作業で検索する負担も大きい。実際に末次ら[4]は、持参薬の一包化鑑別が薬剤師にとって時間を要する負担の大きい業務であることを報告している。また、白色円形の錠剤のように外観が類似する薬剤も多く、画像のみから薬剤を正確に識別することは容易ではない。こうした鑑別業務の負担を軽減する手段として、近年ではAIによる画像解析を用いた薬剤識別の自動化が注目されている。同研究[4]は、AI画像解析錠剤識別システムを持参薬の一包化鑑別業務に導入し、鑑別に要する時間を短縮できることに加え、従来は薬剤師が担っていた鑑別業務を薬剤助手へタスク・シフト／タスク・シェアできる可能性を報告している。このことは、薬剤鑑別をモデルによって自動化することが、医療安全の確保と医療従事者の負担軽減の両面で有用であることを示している。このような背景から、薬剤画像を用いて自動的に薬剤を識別する研究が行われてきた。

Heoら[5]は、薬剤識別を認識ステップと検索ステップに分けた深層学習ベースの薬剤識別システムを提案している。YOLOv5により錠剤表面の刻印文字を検出し、ResNet-32により形状、色、剤形を認識する。さらに、RNNベースの文字レベル言語モデルを用いて検出された刻印文字の誤りを補正し、薬剤データベース内の情報との類似度に基づいて候補薬剤を順位付けする。この手法は、薬剤画像に含まれる視覚情報と刻印文字情報を組み合わせて識別する点で有効であり、検索型の構成を採用することで学習に含まれない薬剤への対応も考慮している。一方で、複数の専用モジュールを組み合わせる必要があり、システム構成が複雑である。また、刻印文字を重要な識別手がかりとしているため、刻印が不明瞭な画像や刻印のない薬剤では識別性能が低下する可能性がある。

Rádliら[6]は、薬剤画像の視覚特徴と薬剤説明テキストから得られるテキスト特徴を組み合わせたマルチモーダルな薬剤認識手法を提案している。この研究は、画像情報だけでなくテキスト情報を利用して薬剤認識を行う点で本研究と近い。一方で、同手法は画像特徴抽出器、テキスト埋め込み、メトリクス学習を個別に設計する構成であり、画像とテキストプロンプトを入力として薬剤名を直接生成する Vision-Language Model

(画像と文章を同時に入力できるモデル. 以下, VLM と呼ぶ) 型の手法ではない.

Menaha ら [8] は, Google Gemini を用いた生成 AI ベースの薬剤識別支援システムを提案している. この研究は, マルチモーダル AI を薬剤識別支援に応用している点で本研究と関連する. 一方で, 同研究は商用クロードソースモデルを用いたプロンプトベースの手法であり, 薬剤画像データを用いてモデル自体をファインチューニングする構成ではない. 同研究自体がプライバシー上の問題を評価したものではないが, 外部 API 型モデルを利用する構成では薬剤画像を外部サービスに送信するため, ローカル推論と比べてプライバシー保護上の追加対応が必要になる.

以上の課題から, (1) 錠剤本体の外観, 刻印, 包装上の印字など複数の視覚情報を統合した識別, (2) 外部 API に過度に依存しないローカル動作の可能性, (3) 薬剤画像に特化したファインチューニングによる識別精度の向上, の 3 点を検討する必要がある.

1.2 本研究の目的

本研究では, オープンソースの VLM である Qwen3.5 を用い, 薬剤画像とテキストプロンプトから薬剤名を出力する薬剤鑑別手法を検討する. 具体的には, 薬剤画像に対して「この錠剤は何という薬ですか」という質問を与え, 正解薬剤名を出力するように LoRA[?] (追加学習の一手法. ??節) によるファインチューニングを行う.

本研究の目的は, ファインチューニング前の Qwen3.5 および外部 API 型マルチモーダル AI である Gemini と比較することで, 薬剤画像データに特化したファインチューニングが薬剤鑑別精度に与える効果を検証することである. また, オープンソースモデルを用いることで, 薬剤画像を外部 API に送信せず, 適切な計算環境を用意すればローカル環境で推論できる薬剤鑑別システムの可能性を示すことを目指す.

本研究のテーマを課題・解決策・評価方法として要約すると次のとおりである. **課題**は, 外箱や薬袋が失われた状況で, 錠剤・PTP シートの限られた視覚情報のみから薬剤名を特定することである. **解決策**は, オープンソース VLM を薬剤画像と正解薬剤名のペアで LoRA ファインチューニングし, 画像と質問文から薬剤名を直接生成させることである (複数薬剤に対しては薬剤位置の検出と単剤識別の 2 段階構成へ拡張する). **評価方法**は, 学習に用いていない画像に対する Top-1 正答率 (複数薬剤では完全一致率と F1 スコア) を, ファインチューニング前のモデルおよび Gemini と同一の評価画像・同一の判定基準で比較し, 交差検証と統計検定 (McNemar 検定) によって結果の妥当性を確認することである.

なお, 本研究におけるマルチモーダル学習とは, 薬剤画像を視覚情報として入力し, 自然言語による質問文をテキスト情報として与え, 薬剤名を応答として生成する VLM 型の学習を指す. 本報告時点では, テキスト入力は質問文を中心とするが, 今後は識別コード, 薬剤候補名, 形状情報, 効能情報などを追加し, より情報量の多い画像・テキスト統合型の鑑別へ拡張することを検討する.

1.3 本報告書の構成

2 章では関連研究および関連技術を整理し, 本研究の位置づけを明確にする. 3 章では提案手法の詳細および実験計画を述べる. 4 章では実験結果と考察を示す. 5 章では結論と今後の課題を述べる.

2 関連研究・関連技術

本章では、まず薬剤識別に関する 3 本の先行研究について各手法の概要と限界を整理し、次に本研究が用いる要素技術（Vision-Language Model および LoRA）に関する研究を述べたうえで、本研究の位置づけを示す。

2.1 画像特徴・刻印文字を用いた薬剤識別手法

Heo ら [5] は、薬剤識別を認識ステップと検索ステップに分けた深層学習ベースの薬剤識別システムを提案した。認識ステップでは、YOLOv5 により錠剤表面の刻印文字を検出し、ResNet-32 により形状、色、剤形を認識する。さらに、RNN ベースの文字レベル言語モデルを用いて、検出された刻印文字の誤りを補正する。検索ステップでは、認識された形状、色、剤形、刻印文字と薬剤データベース内の情報との類似度を計算し、候補薬剤を順位付けする。学習に用いていない薬剤種に対する検索精度として、韓国の薬剤データセット（MFDS）において Top-1 精度 85.6%、米国データセット（NLM）において 74.5% を達成している。

この手法は、薬剤画像に含まれる視覚情報と刻印文字情報を組み合わせて識別する点で有効であり、画像分類ではなく検索型の構成を採用することで、学習に含まれない薬剤への対応も考慮している。

課題

- YOLOv5, ResNet, RNN ベースの言語モデルなど複数のモジュールを組み合わせる必要があり、システム構成が複雑である。
- 刻印文字を重要な識別手がかりとしているため、刻印が不明瞭な画像や刻印のない薬剤では、識別性能が低下する可能性がある。
- 検索型の構成により未知薬剤への対応を考慮している一方で、刻印検出や特徴認識の各モジュールが対象データに依存する可能性がある。

2.2 画像特徴とテキスト特徴を用いたマルチモーダル薬剤識別手法

Rádli ら [6] は、薬剤画像の視覚特徴と薬剤説明文から得られるテキスト特徴を組み合わせたマルチモーダルな薬剤認識手法を提案している。同研究では、EfficientNetV2 をバックボーンとし、RGB 画像、局所特徴、輪郭、テクスチャなど複数の視覚特徴を抽出する。また、薬剤説明文から得られる単語埋め込みを用いて、メトリクス学習における動的マージントリプレット損失（DMTL）のマージンを決定する。112 クラス・4,480 枚で構成する OGYEIV2 データセットを用いた 5 分割交差検証において、同手法は Top-1 精度 99.23% を報告しており、単語埋め込みを画像埋め込みと併用する同じ著者らの先行研究 [7] で報告された Top-1 精度 93.56% から改善している。

この研究は、画像情報だけでなくテキスト情報を利用して薬剤認識を行う点で本研究と近い。

課題

- 画像特徴抽出器、テキスト埋め込み、メトリクス学習を個別に設計する必要がある。
- 画像とテキストプロンプトから薬剤名を直接出力する VLM 型の手法ではない。
- 評価データが特定地域・特定データセットに限定されており、他の薬剤画像への適用可能性は追加検証

が必要である。

2.3 生成 AI・LLM を用いた薬剤識別支援手法

Menaha ら [8] は、Google Gemini を用いた生成 AI ベースの薬剤識別支援システムを提案している。同研究は、薬剤画像を入力として、薬剤に関する情報をテキストおよび音声で提示するシステムであり、Web から収集した 807 枚の薬剤画像において 95.04% の識別精度を報告している。マルチモーダル AI を薬剤識別支援に応用している点で本研究と関連する。

一方で、同研究は商用クローズドソースモデルを用いたプロンプトベースの手法である。少なくとも同研究では、薬剤画像データを用いてモデル自体をファインチューニングする構成は示されていない。同研究自体がプライバシー上の問題を評価したものではないが、外部 API 型モデルを利用する構成では薬剤画像を外部サービスに送信するため、ローカル推論と比べてプライバシー保護上の追加対応が必要になる。本研究では、オープンソースモデルである Qwen3.5 を使い、ローカル環境で LoRA ファインチューニングを行う点に差異がある。

課題

- 商用クローズドソースモデルであり、当該研究ではモデル自体のファインチューニングは行われていない。
- 外部 API 型モデルを利用する場合、薬剤画像を外部サービスに送信するため、プライバシー保護上の追加対応が必要になる。
- プロンプトベースの手法であり、当該研究では対象薬剤への追加学習は示されていない。

2.4 関連技術：Vision-Language Model と LoRA

本節では、前節までの薬剤識別の先行研究に加えて、本研究の提案手法を構成する 2 つの要素技術に関する研究を整理する。

2.4.1 Qwen-VL 系列の Vision-Language Model

Bai ら [?] は、大規模言語モデル Qwen-LM に視覚エンコーダを接続し、画像とテキストを統合して扱う VLM である Qwen-VL を提案した。Qwen-VL は、画像説明や視覚的質問応答に加えて、画像・キャプション・物体枠 (bounding box) の組を用いた学習により、文章で指した物体の位置を画像中で特定するグラウンディング能力と、画像中の文字を読み取る能力を備える点に特徴がある。このとき bounding box の座標は、画像サイズによらず 0～1000 の範囲に正規化したテキストとして表現される。同系列のより新しい技術報告である Qwen3-VL[?] では、2B/4B/8B/32B の高密度モデルおよび Mixture-of-Experts モデルが提供され、画像・動画を含む幅広いマルチモーダルベンチマークで高い性能が報告されている。

本研究で用いる Qwen3.5 は、これらと同じ Qwen シリーズのオープンソース VLM として公開されているモデルである。本研究の単剤識別は PTP シート上の印字を読み取る能力を、複数薬剤識別の検出段階 (3.5 節) はグラウンディング能力を、それぞれ基盤として利用している。

2.4.2 LoRA によるパラメータ効率の高いファインチューニング

Hu ら [?] は、事前学習済みモデルの重みを固定したまま、低ランク行列のみを追加学習するファインチューニング手法 LoRA (Low-Rank Adaptation) を提案した。同研究では、Transformer の注意機構の重み（クエリ射影 W_q ・値射影 W_v など）に LoRA を適用することで、GPT-3 175B に対して学習対象パラメータ数を約 1 万分の 1、学習時の GPU メモリ使用量を約 3 分の 1 に削減しながら、全パラメータのファインチューニングと同等以上の品質を達成できることが報告されている。また、学習後の低ランク行列は元の重み行列に合成できるため推論時の追加遅延がなく、低ランク行列（アダプタ）の差し替えだけでタスクを切り替えられるという性質を持つ。

本研究では、単一 GPU 環境で薬剤画像への特化学習を実現する手段として LoRA を採用する（3.4 節）。さらに、1 つの基盤モデルに識別用と検出用の 2 つのアダプタを搭載して切り替える複数薬剤識別の構成（3.5 節）にも、このアダプタ差し替えの性質を利用している。

2.5 先行研究の整理と本研究の位置づけ

先行研究では、薬剤画像のみを用いる CNN 分類に加え、刻印文字、薬剤説明テキスト、処方情報などを組み合わせるマルチモーダルな薬剤識別手法が提案されている。Heo らの手法は、画像特徴と刻印文字を個別に抽出し、言語モデルで刻印文字を補正することで高精度な薬剤検索を実現している。一方で、複数の専用モジュールを組み合わせる必要があり、システム構成が複雑である。Rádli らの手法は、薬剤画像と薬剤説明テキストを組み合わせる点で本研究と関連するが、画像特徴抽出器とテキスト埋め込みを用いたメトリクス学習であり、薬剤名を直接生成する VLM 型の手法ではない。Menaha らの手法は、生成 AI を薬剤識別支援に用いる点で関連するが、商用モデルを用いたプロンプトベースの手法であり、薬剤画像に特化したファインチューニングを行うものではない。

これらを踏まえ、本研究ではオープンソースの VLM である Qwen3.5 (??節) を用い、薬剤画像とテキストプロンプトを入力として薬剤名を直接出力する手法を検討する。特に、LoRA[?] によるファインチューニングを行うことで、薬剤画像データに特化したモデルを構築し、ファインチューニング前のモデルおよび外部 API 型マルチモーダル AI との比較を通じて、その有効性を評価する。

表 1 に、先行研究の問題点と本研究での対応を整理して示す。

表 1 従来手法の問題点と本研究の対応

従来手法の問題点	該当研究	本研究での対応
YOLOv5・ResNet・RNN など複数の専用モジュール が必要でシステム構成が複雑	Heo ら [5]	単一薬剤識別では Qwen3.5 に画像とテキストプロンプトを統合して入力し、専用の特徴抽出器を個別に組み合わせない構成とする
画像特徴抽出器・テキスト 埋め込み・メトリクス学習 を個別に設計する必要がある 、エンドツーエンドの学習 ではない	Rádli ら [6]	基盤モデルの重みを固定し、注意機構の一部に追加した LoRA アダプタを薬剤画像データへ適応させる
商用クローズドソースモデル への依存および薬剤画像 の外部送信によるプライバシー 懸念	Menaha ら [8]	オープンソースモデルをローカル環境で動作させることで、画像を外部に送信しない構成を目指す
ゼロショットのみで薬剤画像 に特化した追加学習が行 われておらず、専門的な薬 剤識別への適応が不十分	Menaha ら [8]	薬剤画像と正解薬剤名のペアを用いて LoRA ファインチューニングを行い、識別精度を向上させる

3 提案手法

本章では、提案手法の概要と、課題・解決策・評価方法の対応関係を整理したうえで、手法の詳細を述べる。本研究の全体像を図 1 に示す。オープンソース VLM を LoRA で薬剤画像に特化させることを中核とし、単一薬剤識別・複数薬剤同時識別・軽量化の 3 つの軸で評価する。比較対象としてファインチューニング前のモデルおよび Gemini を用い、交差検証・統計検定・リーク監査・汎化評価などで結果の妥当性を検証する。

3.1 研究テーマの整理

本研究の課題、解決策、評価方法の対応を表 2 に示す。

表 2 研究テーマの課題・解決策・評価方法の対応

課題	解決策	評価方法
薬剤名が記載された外箱・薬袋が 失われた場合に、錠剤・PTP シー トの外観のみから薬剤を識別する 必要がある	オープンソース VLM (Qwen3.5-4B) を少数 の実画像にデータ拡張を施した小規模データ セットで LoRA ファインチューニングし、単 一モデルで薬剤鑑別を実現する	Top-1 Accuracy (学習・評価 データ分離) で Gemini のゼロ ショット識別と比較し、McNe- mar 検定で差の有意性を確認す る
従来手法は複数の専用モジュール を要するか、商用 API に依存しプ ライバシー懸念がある	オープンソースモデルをローカル環境で動作 させることで、薬剤画像を外部サービスに送 信しない構成を目指す	外部 API 不使用でのローカル 推論が可能かを動作確認する




図 1 本研究の全体像：オープンソース VLM の LoRA 特化を中核に，単一識別・複数薬剤・軽量化の 3 軸で評価し，交差検証等で妥当性を検証する

3.2 解決策の妥当性

提案手法の妥当性を以下の観点から検討する．

- **少数画像での LoRA 有効性**：単一薬剤（メインテート錠 2.5mg）を元画像 6 枚から 11 倍に拡張した 66 枚で学習し，評価用 22 枚すべてで正答した（Top-1 精度 100%）．少数の実画像でもデータ拡張との組み合わせにより LoRA が有効に機能することを予備実験で確認している．
- **多クラス拡張性**：41 種類の薬剤を対象とした単一モデルの LoRA ファインチューニングにおいても，拡張のない撮影元画像での 5 分割交差検証で全体 Top-1 精度 $98.6\% \pm 1.5\%$ を達成しており，薬剤数を増やした場合でも精度を維持できることを確認している（4 章参照）．
- **外部 API との比較根拠**：Gemini によるゼロショット識別との比較で特化学習の効果を検討する．拡張のない元画像での単一識別は Gemini と同等だが，回転・反転を含む拡張画像に対する頑健性（98.2% 対 82.3%）と，画像を外部に送らないローカル動作の点で優位である（4 章参照）．
- **複数薬剤への拡張可能性**：単剤識別用モデルを変更せず，素の基盤モデルによる薬剤位置の検出と領域ごとの単剤識別を組み合わせる 2 段構成（3.5 節）により，完全一致率 68.8% を得た．さらに，検出器を専用学習した合成画像 200 枚・1024px の条件では 96.0% に到達した．
- **残課題**：回転・反転への対策は学習データの拡張強化によって 99.8% まで改善した．一方，学習対象外の未知薬剤への対応は，ホワイトリスト方式の予備実験（?? 節）で未知薬剤 17 枚中 12 枚の保留にとどまっており，確信度に基づく保留機構の導入が必要である．また，実写の複数薬剤画像およびスマートフォン実機での検証は未実施である．

3.3 使用モデル：Qwen3.5

本研究では、画像とテキストを入力できるオープンソースの VLM として Qwen3.5 を使用する。Qwen3.5 は、Qwen-VL[?] に始まり Qwen3-VL[?] へと発展してきた Qwen シリーズ VLM と同系列のモデルであり、0.8B/2B/4B など複数のパラメータ規模で公開されている (??節)。Qwen3.5 を選定する理由は、外部 API に依存せずローカル環境で動作させられる可能性があり、LoRA などのパラメータ効率の高い手法によって追加学習が可能であるためである。また、同系列の VLM は画像中の文字読み取りとグラウンディングを学習しており [?], PTP シートの印字を重要な手がかりとする薬剤鑑別と親和性が高い。

VLM は画像とテキストプロンプトを同時に入力できるため、薬剤画像に対する質問応答形式で薬剤名を出力するタスクを構成できる。本研究では、この特性を利用し、薬剤画像から薬剤名を出力するように Qwen3.5 を LoRA によりファインチューニングする。

3.4 提案手法：Qwen3.5 の LoRA ファインチューニング

本研究では、薬剤画像とテキストプロンプトを入力し、正解薬剤名を出力するように Qwen3.5 を LoRA によりファインチューニングする。学習データは、薬剤ごとに分類された画像フォルダから作成する。各サブフォルダ名を薬剤名ラベルとし、フォルダ内の画像を入力画像として用いる。

入力プロンプトは「この錠剤は何という薬ですか？薬剤名だけで答えてください。」とし、モデルが正解薬剤名のみを出力するように学習させる。これにより、薬剤画像に対する質問応答形式の薬剤鑑別モデルを構築する。

3.4.1 LoRA による追加学習

LoRA (Low-Rank Adaptation) [?] は、事前学習済みモデルの重みをそのまま固定し、小さな追加パラメータ（低ランク行列）だけを学習するパラメータ効率の高いファインチューニング手法である (??節)。モデル全体を学習し直す場合に比べて学習対象のパラメータ数が大幅に少なくて済むため、少ない計算資源でも追加学習が可能になる。本研究では、追加学習の大きさを決めるランクを $r = 8$ 、スケーリング係数を $\alpha = 16$ とし、モデル内部のアテンション機構の間合せ射影 (q_proj) と値射影 (v_proj) に LoRA を適用する。この適用対象の選択は、Hu ら [?] が注意機構のクエリ射影 W_q と値射影 W_v への適用を採用した構成に対応する。

形式的には、事前学習済みの重み行列を $W_0 \in \mathbb{R}^{d \times k}$ とすると、LoRA は W_0 を固定したまま、低ランク行列の積による更新項 $\Delta W = BA$ ($B \in \mathbb{R}^{d \times r}$, $A \in \mathbb{R}^{r \times k}$, ランク $r \ll \min(d, k)$) だけを学習する [?]。入力 x に対する線形層の出力 h は次式で表される。

$$h = W_0 x + \Delta W x = W_0 x + \frac{\alpha}{r} B A x \quad (1)$$

学習対象を低ランク行列 A , B のみに限定するため、モデル全体を再学習する場合に比べてごく少数のパラメータ（本研究では $r = 8$ ）で薬剤画像へ適応できる。これが、少ない計算資源でも特化学習が可能となる理由である。なお、式 (1) の定式化および α/r によるスケーリングは Hu ら [?] に従っている。

学習では、薬剤画像と質問プロンプトを入力として与え、正解薬剤名を出力するようにモデルを訓練する。このとき、入力した質問プロンプトの部分は学習の対象とせず、モデルが答えるべき正解薬剤名の部分だけを学習させる。これにより、モデルは画像中の薬剤に対して薬剤名のみを答えるように学習される。

図 2 に、提案手法の処理フローを示す。




図2 提案手法の処理フロー：薬剤画像と質問文を Qwen3.5-4B に入力し、LoRA アダプタで薬剤画像に適応させたモデルが薬剤名を出力する

実際の入力画像と出力の対応を図3に示す。撮影した PTP シート画像を入力すると、特化モデルは薬剤名のみを応答として出力する。




図3 提案手法の実行例：PTP シートの薬剤画像（左）を入力すると、特化モデルが薬剤名（右）を出力する

強み

- 薬剤画像データに特化した追加学習により、ゼロショット識別よりも高い識別精度が期待できる。
- 外部 API に依存せず、適切な計算環境を用意すればローカル環境で推論できる。
- 画像と自然言語プロンプトを組み合わせた質問応答形式で薬剤名を出力できる。

課題

- ある程度の量と多様性を持つ学習データが必要である。
- 新たな薬剤クラスを追加する場合、再チューニングまたはデータベース検索との併用が必要となる。
- 包装込み画像を用いる場合、モデルが錠剤本体ではなく包装上の文字やデザインに依存する可能性がある。

3.5 複数薬剤同時識別への拡張：検出→単剤分類

実際の薬剤鑑別では、1枚の画像に複数の薬剤（複数の PTP シート）が写る場合がある。しかし、前節のモデルは「1枚に1薬剤」を答えるよう学習されているため、画像全体に対して「写っている薬をすべて答えよ」と質問しても、1薬剤のみを出力する傾向がある（この現象は4章の実験で定量的に示す）。

そこで本研究では、まず単剤識別用モデルを再学習せずに利用できる、複数薬剤識別の2段階構成パイプラインを提案する。基本的な考え方は、「複数薬剤の識別」を「薬剤位置の検出」と「領域ごとの単剤識別」に分解することである。入力画像に対する処理手順を以下に示す。

1. **検出**：VLM のグラウンディング能力（文章で指した物体が画像のどこにあるかを対応づける能力）[?] を用いて、画像中の各薬剤シートの位置を四角い枠（bounding box, 以下 bbox）で囲み、その座標を構造化テキスト（JSON 形式）で出力させる．検出プロンプトには「画像に写っているすべての薬剤（錠剤シート/PTP シート）の位置を検出し、各薬剤の bounding box を JSON で出力してください」を用いる．
2. **切り出し**：検出した各四角を、画像の幅・高さの 2% のマージンを付けて切り出し、1 薬剤ずつの部分画像にする．
3. **単剤識別**：切り出した各部分画像に対して、3.4 節の単剤識別モデル（学習済み LoRA）を適用し、薬剤名を 1 つずつ得る．
4. **統合**：すべての部分画像の識別結果をまとめ、その画像に写る薬剤名の集合として出力する．

以上の処理手順をアルゴリズム 1 に示す．単剤識別モデル自体には一切手を加えず、検出と切り出しを前段に追加するだけで複数薬剤に対応できる点が本方式の要点である．

アルゴリズム 1 検出→単剤分類による複数薬剤同時識別

入力：複数の薬剤が写った画像

出力：画像に写る薬剤名の一覧

- 1: 検出モデルで、画像に写るすべての薬剤の位置を四角い枠（bounding box）として検出する
 - 2: 空の「薬剤名の一覧」を用意する
 - 3: **for all** 検出した枠 **do**
 - 4: 枠を幅・高さの 2% ずつ広げる（切り出し時の余白）
 - 5: 広げた枠で画像を切り出し、1 薬剤だけが写る画像を作る
 - 6: 切り出した画像を単剤識別モデルに入力し、薬剤名を 1 つ得る
 - 7: 得られた薬剤名を一覧に追加する
 - 8: **end for**
 - 9: **return** 薬剤名の一覧
-

検出段階には 2 つの構成を用いる．第 1 の構成では、LoRA を無効化した基盤モデル（以下、「素のベースモデル」と呼ぶ）のゼロショット検出能力を用いる（再学習・追加データ不要）．第 2 の構成では、検出専用の LoRA アダプタを追加学習し、検出精度を高める（4 章で比較する）．後者では、1 つの基盤モデルに識別用 LoRA と検出用 LoRA の 2 つを搭載し、処理段階に応じてアダプタを切り替える．これは LoRA のアダプタ差し替えによるタスク切替の性質 [?] を利用した構成であり、モデル本体のメモリ使用量はほぼ単剤識別時と変わらない．

図 4 に複数薬剤同時識別の処理フローを示す．

複数薬剤画像の例を図 5 に示す．このように複数の PTP シートが並ぶ画像に対し、検出した各領域を 1 薬剤ずつ識別して結果を統合する．

この方式の利点は、(1) 高精度な単剤識別モデルを変更せずそのまま流用できること、(2) 写っている薬剤の枚数が未知でも検出された個数から自動的に決まること、(3) 検出段階のみを独立に改善できることである．




図4 複数薬剤同時識別の処理フロー：検出→切り出し→単剤識別→統合の2段階構成。検出（1）と単剤識別（3）は、同一の Qwen3.5-4B に検出用・識別用の LoRA アダプタを切り替えて実行する




図5 複数薬剤画像の例（2 薬剤）：このように複数の PTP シートが並ぶ画像に対し、検出→単剤分類により各領域を個別に識別して「メインテート錠，ウルソ錠」の集合を出力する

3.6 比較手法

提案手法の有効性を検証するため、以下の比較手法を設定する。

- **ファインチューニング前の Qwen3.5**：LoRA 適用前のモデルによるゼロショット識別。
- **Gemini (gemini-3.5-flash)**：外部 API 型マルチモーダル AI によるゼロショット識別。

また、提案手法の出力形式を確定するための予備実験（4 章）では、上記に加えて以下の方式も比較した。

- **詳細鑑別形式（方法 B）**：薬剤名だけでなく、色・形状・刻印などの鑑別理由を含む詳細な説明を出力するようにファインチューニングする方式。
- **RAG 型（薬剤データベース検索）**：薬剤情報を記述したデータベース（JSON 形式）を検索し、候補薬剤情報を回答に利用する方式。

3.7 使用データ

本研究では、研究用に撮影した薬剤画像を使用する。画像には、錠剤やカプセル本体に加え、PTP シートや包装上の印字が含まれる場合がある。これは、実際の薬剤鑑別において、錠剤本体の色や形状だけでなく、包装上の文字情報や印字も重要な手がかりとなるためである。

ただし、包装情報を含む画像を用いる場合、モデルが錠剤本体ではなく包装上の文字やデザインに依存して薬剤名を予測する可能性がある。本研究では、PTP シートや包装上の印字を含む画像をそのまま使用する。錠剤部分のみを切り出した画像との比較は今後の課題とする。

3.8 評価方法

評価においては、学習画像と評価画像が重複しないようにデータを分割する。具体的には、各薬剤クラスごとに拡張前の元画像単位で学習用と評価用に分け、同一画像および同一の元画像に由来する拡張画像が学習データと評価データの両方に含まれないようにする。これにより、単なる画像の記憶ではなく、薬剤画像に対する識別性能を評価する。評価では、入力画像に対してモデルが出力した薬剤名と正解薬剤名を比較し、識別精度を算出する。

3.8.1 単一薬剤識別の評価指標

主な評価指標として、正答率 (Top-1 Accuracy) を用いる。正答率は、評価画像のうちモデルが正しく薬剤名を答えられた画像の割合であり、次式で定義される。

$$\text{正答率} = \frac{\text{正しく識別できた画像数}}{\text{評価画像の総数}} \quad (2)$$

正解の判定は次のように行う。薬剤名は全角・半角や大文字・小文字といった表記のゆれを揃えたうえで、モデルの出力テキストの中に正解薬剤名が含まれていれば正解とみなす。なお、本研究の評価では製品名と用量の識別を主対象とし、メーカー単位の識別は別タスクとして扱う。そのため、後発医薬品のメーカー識別子（薬剤名末尾に鉤括弧で付される表記。例：「DSEP」）は正解薬剤名から除外して照合する（41 薬剤中で該当するのはロスバスタチン錠 2.5mg 「DSEP」のみ）。この扱いはファインチューニング前後の Qwen3.5・Gemini のすべてに統一して適用した。また、モデルに上位 3 候補を出力させる実験では、3 候補のいずれかに正解が含まれていれば正解とする Top-3 正答率を補助指標として用いる。

3.8.2 複数薬剤同時識別の評価指標

複数薬剤の同時識別では、1 枚の画像に写るすべての薬剤を当てる必要がある。そこで主な指標として、予測した薬剤が正解の薬剤と過不足なく一致した画像の割合である完全一致率を用いる。

$$\text{完全一致率} = \frac{\text{予測が正解と完全に一致した画像数}}{\text{評価画像の総数}} \quad (3)$$

完全一致率は、1 薬剤でも取りこぼしや余分な予測があれば不正解とする厳しい指標である。そこで補助指標として、部分的な正解にも部分点を与える F1 スコアも用いる。F1 スコアは、「予測した薬剤のうち正しかった割合（適合率）」と「正解の薬剤のうち予測できた割合（再現率）」をバランスよくまとめた指標であり、画像ごとに算出して全評価画像で平均する。

形式的には、画像 i におけるモデルの予測薬剤集合を P_i 、正解薬剤集合を G_i とすると、適合率・再現率・F1 スコアは次式で定義される。

$$\text{Precision}_i = \frac{|P_i \cap G_i|}{|P_i|}, \quad \text{Recall}_i = \frac{|P_i \cap G_i|}{|G_i|}, \quad F1_i = \frac{2 \text{Precision}_i \cdot \text{Recall}_i}{\text{Precision}_i + \text{Recall}_i} \quad (4)$$

画像ごとの F1 スコアを全評価画像で平均した値（マクロ F1 スコア）を報告する。

また、誤識別が生じた画像については、どの拡張種別・薬剤で失敗したかを確認し、傾向を把握する。

3.8.3 統計的検定

手法間の精度差が偶然によるものでないかを確認するため、同一の評価画像に対する対応のある比較には McNemar 検定を用い、主要な精度には二項比率の 95% 信頼区間 (Wilson 法) を付す (??節).

3.9 実験計画

本研究では、以下の手順で実験を進める.

1. 予備実験として、単一薬剤を対象に出力形式 (薬剤名のみ / 詳細鑑別) および RAG 型・Gemini との比較を行い、提案手法の出力形式を確定する.
2. 薬剤画像データセットを作成し、薬剤名ラベルを整理する.
3. 各薬剤クラスごとに、画像を学習用と評価用に分割する. この際、同一画像が学習データと評価データの両方に含まれないようにする.
4. ファインチューニング前の Qwen3.5 を用いて、薬剤画像に対するゼロショット識別を行う.
5. 薬剤画像と正解薬剤名のペアを用いて、Qwen3.5 を LoRA によりファインチューニングする.
6. ファインチューニング後のモデルを用いて同一条件で識別実験を行う.
7. Gemini (gemini-3.5-flash) と比較する.
8. 複数薬剤の同時識別を「検出→単剤分類」の 2 段構成 (3.5 節) で評価し、ファインチューニング前の Qwen3.5 および Gemini と同一の評価セットで比較する.
9. 検出器の専用学習 (検出用 LoRA) により複数薬剤同時識別の改善を図り、合成時の正解 bbox を用いた基準値と比較する.
10. スマートフォン搭載を見据え、4bit 量子化およびモデルサイズ (0.8B / 2B / 4B) による精度の変化を、単一・複数・混在の各評価セットで測定する.
11. 撮影環境への過学習やデータ分割への依存がないことを確認するため、Web 収集画像での汎化評価、学習・評価分割のリーク監査、および全 41 薬剤を対象とした 5 分割交差検証を行う.
12. 主要な比較 (ファインチューニング前後・Gemini) について、McNemar 検定と 95% 信頼区間により差の統計的有意性を確認する.
13. 学習・評価分割を固定し、データ拡張の倍率 ($\times 1 \sim \times 17$) のみを変えた対照実験により、データ拡張の寄与を分離して測定する.
14. 学習対象外の未知薬剤に対する誤断定を防ぐ保留機構の予備実験として、出力候補を学習済み薬剤名一覧と照合するホワイトリスト方式を評価する.

表 3 に実験スケジュールを示す.

表 3 実験スケジュール

フェーズ	期間	内容
先行研究・準備	4～5 月	先行研究調査（学術論文 4 本以上）、研究課題・解決策・評価方法の整理、薬剤画像撮影・データセット整備
予備実験	4～5 月	単一薬剤 LoRA 予備学習（手法比較）、全 41 薬剤拡張データセット学習
本実験	5～6 月	単一薬剤 3 者比較、複数薬剤同時識別（検出→単剤分類・検出器学習）、量子化・モデルサイズ比較
追加実験	6～7 月	Web 収集画像での汎化評価、回転・反転対策、モデルサイズ・量子化の拡張なし評価、few-shot 分析、リーク監査、5 分割交差検証、推論ベンチマーク、統計検定、拡張倍率の対照実験、未知薬剤保留の予備実験
今後の実験	7～9 月	実写の複数薬剤検証、確信度に基づく未知薬剤の保留機構、錠数・表裏の対照実験、スマートフォン実機評価
論文執筆・発表	10 月～	卒業論文執筆、発表準備・スライド作成

4 実験と結果

本章では、提案手法の有効性を検証するために実施した実験の内容と結果を述べる。本研究は予備実験（単一薬剤での方式検証）、本実験（41 薬剤での単一・複数識別の 3 者比較）、および追加実験（検出器の専用学習、軽量化評価）の順に進めた。第三者による追試を可能とするため、入力データの作成手順、処理方法、出力結果を、使用したパラメータとともに記述する。本章に示すすべての数値は、実験実行時に自動出力された結果ファイル（評価サマリー・学習ログ）に基づく。なお、以下ではファインチューニングを FT と略記する。

本章は実験数が多いため、どの節でどの実験を行い、何が分かったかを表??に一覧として示す。各実験の目的・条件・詳細な結果は対応する節を参照されたい。

4.1 実験環境

実験に使用した計算環境を表 4 に示す。学習・評価スクリプトは Python で実装し、Hugging Face Transformers および PEFT ライブラリを用いた。モデルの演算精度は bfloat16 である。

4.2 データセットの構築

4.2.1 元画像の撮影

近畿大学薬学部で取り扱われる薬剤を対象に、2026 年 4 月に薬剤画像を撮影した。各薬剤について、PTP シートの表面と裏面を含む 3～10 枚程度の画像をスマートフォンのカメラで撮影し、薬剤名でフォルダを分けて保存した。フォルダ名（正式な薬剤名・用量を含む）をそのまま正解ラベルとして用いる。混合薬である一包化薬は単剤識別の対象外として除外した。最終的なデータセットは 41 種類の薬剤、元画像合計 287 枚である。薬剤ごとの内訳を表 5 に示す。

表 4 本章の実験一覧（節・実験内容・主な結果）

節	実験	主な結果
??	予備実験（出力形式・方式の比較）	薬剤名のみ出力する FT が最速・最高精度（5/5）
4.6	拡張なし全薬剤学習（初期検討）	過学習の兆候を確認し、データ拡張を導入
4.7	単一薬剤識別の 3 者比較（拡張 814 枚）	FT 後 98.2%・Gemini 82.3%・FT 前 0.9%
??	外部画像での汎化（予備的検証）	別時期撮影の 1 薬剤で 99.7%
4.9	複数薬剤同時識別（合成 1,000 枚）	一括質問 $\approx 0\%$ $\rightarrow$ 検出 $\rightarrow$ 単剤分類で 68.8%
4.10	検出器の専用学習	最高 96.0%（1024px・標準 200 枚）
4.10	過検出抑制の追加検討（負の結果）	NMS は効果なし・該当なしゲートは -7.5pt 悪化
4.11	軽量化（モデルサイズ・量子化）	量子化 4B：単一 91.9%・複数 55.2%
4.12	Gemini の元画像 287 枚評価	99.0%（41 薬剤の候補一覧を提示）
4.13	Web 収集画像での汎化評価	別環境 136 枚で 96.3%
4.14	回転・反転への対策	拡張強化の再学習で 98.2% $\rightarrow$ 99.8%
4.15	学習枚数の感度分析（few-shot）	全枚数（5 $\sim$ 8 枚）で 98.7%
??	データ拡張倍率の対照実験	拡張なし 73.0% $\rightarrow$ 11 種拡張 97.3%
4.16	量子化・サイズの拡張なし評価	量子化 4B で 94.6%（74 枚）
4.17	リーク監査	学習・評価間に同一・酷似カットなし
4.18	5 分割交差検証	98.6% $\pm$ 1.5%（283/287）
??	評価時拡張の多数決（TTA）	98.6% のまま変化なし
??	統計検定	FT の効果は有意・Gemini とは同等（ $p=1.00$ ）
4.19	推論ベンチマーク	量子化 4B：VRAM 3.08GB・1.22 秒/枚
4.20	根拠説明文の生成可否	特化後モデルは説明文を生成せず
??	未知薬剤保留の予備実験	保留 70.6%・ホワイトリスト単独では不十分

表 5 実験環境

項目	内容
OS	Windows 11
GPU	NVIDIA GeForce RTX 4070 Ti SUPER（VRAM 16GB）
Python	3.10 以上（uv による仮想環境）
PyTorch	2.10.0（CUDA 13.0）
transformers	5.5.0
peft	0.18.1
qwen-vl-utils	0.0.14
外部 API	Gemini API（gemini-3.5-flash）

4.2.2 学習・評価分割

学習データと評価データの分離は、データ拡張を行う前の元画像単位で実施した。各薬剤フォルダごとに、画像ファイル名を辞書順に整列したうえで乱数シード 42 でシャッフルし、先頭 75% を学習用、残り 25% を評価用とした（評価用には最低 1 枚を保証）。シードを固定しているため、同一の元画像集合からは常に同一の分割が再現される。分割を元画像単位で行うため、同一の元画像に由来する拡張画像が学習データと評価データの両方に含まれることはない。この分割の結果、全 41 薬剤の合計で学習用の元画像は 213 枚、評価用は 74 枚となった。表 5 の「学習」「評価」列は、これらの元画像に 11 種拡張を適用した後の枚数（それぞれ

表 6 データセットの内訳 (41 薬剤). 学習・評価枚数は 11 種データ拡張適用後の枚数

薬剤名	元	学習	評価	薬剤名	元	学習	評価
メインテート錠 2.5mg	8	66	22	トラゼンタ錠 5mg	7	55	22
アルダクトンA錠 25mg	6	44	22	ノルバスク OD 錠 5mg	6	44	22
ウルソ錠 100mg	4	33	11	バイアスピリン錠 100mg	4	33	11
エソメプラゾールカプセル 20mg	7	55	22	バクタミン配合錠	6	44	22
エンレスト錠 100mg	9	77	22	パルモディア XR 錠 0.2mg	10	88	22
エンレスト錠 200mg	9	77	22	フェブリク錠 10mg	9	77	22
カロナール錠 500mg	6	44	22	フォシーガ錠 10mg	9	77	22
キャブピリン配合錠	9	77	22	フロセミド錠 20mg	6	44	22
クエン酸第一鉄 Na 錠 50mg	6	44	22	ブレドニン錠 5mg	6	44	22
ジャディアンス錠 10mg	6	44	22	プロマック D 錠 75mg	9	77	22
ジャスピア錠 50mg	9	77	22	ペオーバ錠 50mg	9	77	22
センノシド錠 12mg	9	77	22	ミヤBM錠	4	33	11
タケキャブ錠 10mg	7	55	22	ムコダイン錠 500mg	9	77	22
タケキャブ錠 20mg	4	33	11	メチコパール錠 500 μ g	4	33	11
タリジェ OD 錠 5mg	6	44	22	メトクロプラミド錠 5mg	4	33	11
ダイアート錠 30mg	10	88	22	メトグルコ錠 250mg	10	88	22
デエビゴ錠 5mg	10	88	22	ランソプラゾール OD 錠 15mg	4	33	11
リクシアナ OD 錠 30mg	9	77	22	レバミピド錠 100mg	6	44	22
レボチロキシン Na 錠 50 μ g	10	88	22	レボフロキサシン錠 500mg	3	22	11
ロスバスタチン錠 2.5mg 「DSEP」	6	44	22	ロキソプロフェンナトリウム錠 60mg	6	44	22
酸化マグネシウム錠 330mg	6	44	22	合計	287	2,343	814

$213 \times 11 = 2,343$ 枚, $74 \times 11 = 814$ 枚) である.

4.2.3 データ拡張

撮影枚数が限定的であることを補うために, 分割後の学習用・評価用それぞれの元画像に対して, 表 6 に示す 11 種類のデータ拡張を適用し, PNG 形式で保存した.

表 7 データ拡張の種類とパラメータ (1 枚の元画像から 11 枚を生成)

拡張名	種別	処理内容
orig	複製	元画像のコピー
rot $\pm$ 15	回転	± 15 度回転 (キャンバス拡張あり, 余白は RGB(128,128,128) で充填)
rot $\pm$ 30	回転	± 30 度回転 (同上)
flip_h	反転	水平 (左右) 反転
bright0.7 / 1.3	明度	明度を 0.7 倍 / 1.3 倍に変更
contrast0.7 / 1.3	コントラスト	コントラストを 0.7 倍 / 1.3 倍に変更
noise	ノイズ	平均 0・標準偏差 10 のガウシアンノイズを加算 (画素値は 0~255 にクリップ)

この結果, 学習用 2,343 枚 (元 213 枚 $\times$ 11), 評価用 814 枚 (元 74 枚 $\times$ 11) のデータセットを構築した.

4.2.4 拡張なし評価画像

本研究では, 単一薬剤識別の精度を, 人工的な変形を含まない撮影元画像で評価することを基本とする. 提案手法は, 単一分割の評価用元画像 74 枚で 100% (4.7 節), 全 41 薬剤の 5 分割交差検証で $98.6\% \pm 1.5\%$ (4.18 節) を得た. 評価用元画像 74 枚では, 0.8B/2B/4B の非量子化および 4bit 量子化 (計 6 条件) を同一画像で比較した (4.16 節). 一方, 11 種の拡張を施した評価画像 814 枚は, 回転・反転・明度変化等の画像変形に対する頑健性を分析する目的, およびモデル間・手法間を共通の条件で比較する目的で用いる. 拡張画像は実際の撮影画像ではないため, これらの数値は実環境での精度そのものではなく, 頑健性および相対比較の指標として解釈する. また, 学習枚数の感度分析では 33 薬剤の拡張なし評価画像 79 枚を全条件で共通して

用い（4.15 節），Gemini の元画像評価では撮影画像 287 枚を拡張せずに用いた（4.12 節）．このように，本研究では実験目的に応じて拡張あり評価と拡張なし評価を区別した．以上のデータの作成と使い分けの全体構成を図 6 に示す．




図 6 評価データの全体構成：287 枚の撮影元画像を元画像単位で学習/評価に分割し，目的に応じて拡張なし・拡張あり・合成画像を使い分ける．Web 収集画像は学習に用いない別環境データである

4.3 学習設定

基盤モデルとして Qwen3.5-4B を用い，3.4 節で述べた LoRA ファインチューニングを行った．学習に用いたハイパーパラメータを表 7 に示す．

表 8 LoRA ファインチューニングの設定

パラメータ	値
基盤モデル	Qwen/Qwen3.5-4B
LoRA rank r	8
LoRA alpha α	16
target modules	q-proj, v-proj
LoRA dropout	0.05
エポック数	5
最適化手法	AdamW
学習率	2e-4（固定）
バッチサイズ	1
勾配チェックポイント	有効
演算精度	bfloat16
画像入力ピクセル数	最小 256 × 256，最大 768 × 768

学習サンプルは「ユーザ発話＝薬剤画像＋質問文，アシスタント応答＝正解薬剤名（フォルダ名）＋文末トークン」のチャット形式で構成し，3.4 節で述べたとおり質問プロンプト部分は学習の対象とせず，応答部分（正解薬剤名）のみを学習させた．各エポックで学習サンプルの順序をシャッフルした．41 薬剤・2,343 枚での学習に要した時間は 498 分 50 秒（約 8.3 時間）であり，エポックごとの平均損失は表 8 のとおり単調に

減少した。

表 9 全薬剤学習における損失推移（学習 2,343 枚）

エポック	平均損失
1	0.2470
2	0.0258
3	0.0133
4	0.0058
5	0.0006

4.4 評価手順

評価時には学習時と同一の質問文「この錠剤は何という薬ですか？薬剤名だけで教えてください。」でモデルに推論を実行させ、表記のゆれ（全角・半角、大文字・小文字）を揃えたうえで、正解薬剤名（フォルダ名）が回答テキストに含まれていれば正解と判定した。Top-3 評価では、ビームサーチ（ビーム幅 3）により 3 候補を生成させた。

比較手法の評価条件は次のとおりである。ファインチューニング前の Qwen3.5-4B は、LoRA を適用しない同一の基盤モデルに同一の質問文・同一の評価画像で推論させた。Gemini は `gemini-3.5-flash` を API 経由で使い、プロンプトには「PTP シートに印刷された文字を読み、製品名と用量（mg/μg）を必ず両方教えてください」を使用した。API のレート制限対策として 1 リクエストごとに 1 秒の待機を挟み、レート超過エラー（429）発生時には再試行した。正解判定は Qwen 側と同一の正規化・部分一致判定である。

4.5 予備実験（単一薬剤メインテート錠）

本実験に先立ち、単一薬剤「メインテート錠 2.5mg」のみを対象として、(1) 出力形式・方式の比較、(2) 少数画像＋データ拡張での LoRA 学習の有効性確認を行った。

4.5.1 出力形式・方式の比較

提案手法の出力形式を確定するため、以下の 4 方式をテスト画像 5 枚（メインテート錠 2.5mg）で比較した（2026 年 4 月 26 日実施）。

- **方法 A（薬剤名のみ FT）**：画像に対して薬剤名のみを出力するよう LoRA 学習する方式（3.4 節の提案手法）。
- **方法 B（詳細鑑別 FT）**：薬剤名に加えて色・形状・刻印などの鑑別理由を含む詳細な説明を出力するよう LoRA 学習する方式。
- **RAG 型**：薬剤情報データベース（JSON 形式の薬剤 DB）を検索し、候補薬剤情報を回答に利用する方式。
- **Gemini**：外部 API によるゼロショット識別（当時は `gemini-2.5-flash` を使用）。

結果を表 9 に示す。

方法 A と RAG 型がともに 5/5 で正答したが、推論時間は方法 A が 0.8 秒/枚と約 30 倍高速であったた

表 10 出力形式・方式の比較（テスト画像 5 枚・メインテート錠 2.5mg）

方式	成功数	平均時間/枚	備考
方法 A（薬剤名のみ FT）	5 / 5	0.8 秒	最も高速かつ正確
方法 B（詳細鑑別 FT）	3 / 5	37.4 秒	説明的だが遅く不安定
RAG 型（薬剤 DB 検索）	5 / 5	24.4 秒	正確だが検索処理で低速
Gemini（ゼロショット）	0 / 5	3.4 秒	全問不正解

め、以降の全実験では方法 A（薬剤名のみを出力）を採用した。なお、RAG 型は新規薬剤の追加に再学習が不要という利点があり、全薬剤規模での比較は今後の課題とする（5 章）。

4.5.2 拡張データセットでの学習と評価

次に、少数の元画像とデータ拡張の組み合わせで LoRA 学習が機能するかを確認した。元画像 6 枚を 11 種拡張した 66 枚で学習し、元画像 2 枚を 11 種拡張した 22 枚で評価した。学習に要した時間は 15 分 18 秒であり、エポックごとの平均損失は表 10 のとおりであった。

表 11 単一薬剤での学習損失推移

エポック	平均損失
1	0.6757
2	0.0002
3	0.0001
4	0.0001
5	0.0001

2 エポック目以降にはほぼ完全に収束し、評価用 22 枚すべてで正解薬剤名を出力した（Top-1 精度 100%）。明度、コントラスト、回転、水平反転、ノイズの全拡張パターンに対して正答した。同一の 22 枚に対する Gemini（gemini-2.5-flash）のゼロショット識別は 0/22 であった（表 11）。ただし Gemini 側の失敗には無料枠の API リクエスト数上限超過によるエラー応答 6 件が含まれるため、この予備実験の比較は参考値であり、本実験（4.7 節）にて全薬剤・新プロンプトでの再評価を行った。

表 12 メインテート錠 2.5mg における LoRA と Gemini の比較（予備実験・参考値）

指標	LoRA	Gemini 2.5 Flash
成功数	22 / 22	0 / 22
成功率	100.0%	0.0%
平均推論時間	1.1 秒	14.0 秒

4.6 初期検討：データ拡張なしでの全薬剤学習

データ拡張を導入する前の初期検討として、元画像 287 枚のみ（拡張なし）を用いた全薬剤の LoRA 学習を行った（2026 年 5 月 12 日頃実施）。これは学習・評価の分離を行わず全元画像を学習に投入した予備的な検

討であり、過学習の挙動を確認することを目的とする。学習設定は本実験と同一（LoRA rank 8・alpha 16, target modules q_proj・v_proj, 5 エポック, 学習率 2e-4）である。

学習損失は初期 3.88 から最終約 0.001 までほぼゼロに低下した。学習枚数が 287 枚と少ないにもかかわらず損失がほぼゼロまで落ちる挙動は、学習データを丸暗記する過学習の兆候であり、未学習画像への汎化は期待できないと判断した。このモデルに対する定量評価は実施せず、撮影枚数の不足を補う対策として 4.2 節の 11 種類のデータ拡張を導入した。すなわち本検討は、提案手法においてデータ拡張が必要である根拠を与えた通過点である。次節の標準的な単一薬剤評価と、これを基礎とする複数薬剤・軽量化評価では、拡張あり（学習 2,343 枚）のモデルを用いる。後半の追加実験では、各節に記載した条件で再学習または再評価を行う。

4.7 単一薬剤識別の結果（本実験）

単一薬剤識別の精度の主指標は、人工的な変形を含まない撮影元画像での評価である。提案手法は、評価用元画像 74 枚で 100%（表 15）、全 41 薬剤の 5 分割交差検証で 98.6%±1.5%（4.18 節）を達成した。本節ではさらに、回転・反転等の画像変形に対する頑健性を分析し、あわせてファインチューニング前のモデルおよび Gemini と共通の条件で比較するため、評価用元画像に 11 種拡張を施した 814 枚を用いた結果を示す。3 者を同一画像・同一の正解判定基準で比較した結果を表 12 および図??に示す（入力プロンプトは各モデルの応答特性に合わせており、完全に同一ではない）。

表 13 単一薬剤識別の 3 者比較（拡張画像 814 枚・画像変形への頑健性と相対比較）

手法	Top-1 精度	成功数
ファインチューニング後 Qwen3.5-4B（提案手法）	98.2%	799 / 814
Gemini (gemini-3.5-flash・ゼロショット)	82.3%	670 / 814
ファインチューニング前 Qwen3.5-4B（ゼロショット）	0.9%	7 / 814




図 7 単一薬剤識別の 3 者比較（拡張画像 814 枚）：薬剤画像に特化したファインチューニングにより、FT 前 0.9% から 98.2% へ向上し、Gemini (82.3%) を上回った

提案手法は 98.2% を達成し、41 薬剤中 29 薬剤で 100% の正答であった。3 者の差の統計的評価（95% 信頼区間および McNemar 検定）は??節に示す。提案手法の薬剤別の成功率を表 13 に示す。

ファインチューニング前のモデルは 0.9%（7/814）であり、正答した 7 枚はすべてレバミピド錠 100mg であった（同薬剤のみ 31.8%，他の 40 薬剤は 0%）。レバミピドのみ正答できた理由として、事前学習データに

表 14 提案手法（ファインチューニング後 4B）の薬剤別 Top-1 成功率（成功数／評価枚数）

薬剤名	成功／枚数	成功率	薬剤名	成功／枚数	成功率
メインテート錠 2.5mg	22/22	100.0%	バルモディア XR 錠 0.2mg	20/22	90.9%
アルダクトン A 錠 25mg	21/22	95.5%	フェブリク錠 10mg	22/22	100.0%
ウルソ錠 100mg	11/11	100.0%	フォシーガ錠 10mg	22/22	100.0%
エソメプラゾールカプセル 20mg	21/22	95.5%	フロセミド錠 20mg	21/22	95.5%
エンレスト錠 100mg	21/22	95.5%	ブレドニン錠 5mg	22/22	100.0%
エンレスト錠 200mg	22/22	100.0%	プロマック D 錠 75mg	22/22	100.0%
カロナール錠 500mg	22/22	100.0%	ベオーバ錠 50mg	22/22	100.0%
キャブピリン配合錠	22/22	100.0%	ミヤBM錠	11/11	100.0%
クエン酸第一鉄 Na 錠 50mg	22/22	100.0%	ムコダイン錠 500mg	21/22	95.5%
ジャディアンス錠 10mg	22/22	100.0%	メチコパール錠 500μg	11/11	100.0%
ジャヌビア錠 50mg	20/22	90.9%	メトクロプラミド錠 5mg	11/11	100.0%
センノシド錠 12mg	22/22	100.0%	メトグルコ錠 250mg	22/22	100.0%
タケキャブ錠 10mg	22/22	100.0%	ランソプラゾール OD 錠 15mg	11/11	100.0%
タケキャブ錠 20mg	11/11	100.0%	リクシアナ OD 錠 30mg	21/22	95.5%
タリージェ OD 錠 5mg	21/22	95.5%	レバミピド錠 100mg	22/22	100.0%
ダイアート錠 30mg	22/22	100.0%	レボチロキシシン Na 錠 50μg	22/22	100.0%
デエビゴ錠 5mg	22/22	100.0%	レボフロキサシン錠 500mg	10/11	90.9%
トラゼンタ錠 5mg	22/22	100.0%	ロキソプロフェンナトリウム錠 60mg	22/22	100.0%
ノルバスク OD 錠 5mg	20/22	90.9%	ロスバスタチン錠 2.5mg 「DSEP」	21/22	95.5%
バイアスピリン錠 100mg	11/11	100.0%	酸化マグネシウム錠 330mg	22/22	100.0%
バクトラミン配合錠	22/22	100.0%	全体	799/814	98.2%

薬剤名や外観情報が含まれていた可能性が考えられるが、本実験から原因を特定することはできない。この 97.3 ポイントの差が、薬剤画像に特化した追加学習による効果の大きさを表している。

Gemini は 82.3% であり、提案手法が 15.9 ポイント上回った。Gemini は薬剤ごとの精度差が大きく、提案手法がほぼ完全に識別できる薬剤であっても、Gemini は大きく精度を落とすことがあった（表 14）。ただし、この差は主として拡張画像に対する頑健性の違いを反映している。拡張のない元画像 287 枚での比較では、提案手法（98.6%）と Gemini（99.0%）は同等であった（4.18 節）。

表 15 Gemini の正答率が低かった薬剤と提案手法との比較（同一評価画像）

薬剤名	Gemini	提案手法（FT 後 4B）
バルモディア XR 錠 0.2mg	4.5%	90.9%
ジャヌビア錠 50mg	18.2%	90.9%
メチコパール錠 500μg	36.4%	100.0%
エンレスト錠 200mg	45.5%	100.0%
カロナール錠 500mg	45.5%	100.0%
ロキソプロフェンナトリウム錠 60mg	50.0%	100.0%

なお、Gemini の評価は当初「薬剤名のみを日本語で答える」旧プロンプトで実施しており、このときの正答率は 44.0%（学習用拡張データ 1,338 枚を対象とした途中中断時点の参考値）であった。プロンプトを「PTP シートの印字を読み、製品名と用量を必ず両方答える」形式（4.4 節）に変更し、評価用 814 枚で再評価した結果が 82.3% である。外部 API の性能はプロンプト設計に強く依存することも確認された。

また、提案手法について評価条件を変えた結果を表 15 に示す。

表 16 提案手法（ファインチューニング後 4B）の評価条件別の結果

評価条件	評価画像	精度
撮影＋拡張あり（標準）	814 枚	Top-1 98.2%
拡張なし（元画像のみ）	74 枚	Top-1 100.0%
Top-3 評価（ビーム幅 3）	814 枚	Top-3 99.9%（Top-1 98.3%）

拡張なしの元画像のみでは 100% (74/74) であり、98.2% における失敗 15 枚はすべて拡張によって人工的に変形させた画像に由来する。また、上位 3 候補を提示する Top-3 評価では 99.9% (813/814) に達した。Top-1 で誤る場合でも、候補提示によって人による確認を支援できる可能性がある。

誤識別 15 枚は表 13 に示した 12 薬剤で発生した (各薬剤 1~2 枚)。この 15 枚を拡張種別ごとに集計したものを表 16 に示す。

表 17 誤識別画像の拡張種別内訳 (提案手法・15 枚)

拡張種別	失敗枚数
回転 +30 度	4
回転 -30 度	4
水平反転	4
回転 -15 度	2
明度 1.3 倍	1
元画像, 回転 +15 度, 明度 0.7 倍, コントラスト 0.7・1.3 倍, ノイズ	0
合計	15

誤識別の大部分は回転 (± 30 度, -15 度) と水平反転の合計 14 枚であり、文字方向や錠剤シートの上下左右が大きく変化する拡張に対してモデルが脆弱であることが分かった。一方で、明度・コントラスト・ノイズなどの輝度系の変化に対する失敗は 1 件のみであり、色や明るさの揺らぎに対しては頑健であった。また、同一の元画像が複数の拡張で同時に失敗するケースが 3 例観察され (ジャヌビア錠 50mg, ノルバスク OD 錠 5mg, パルモディア XR 錠 0.2mg の各 1 枚)、これらは元画像自体の判別が難しく、撮影品質に起因する可能性がある。誤識別の出力内容は無関係な単語ではなくほぼすべて別の薬剤名であり、回転や反転で文字が読みにくくなった結果、近い見た目の別薬剤に誤判定していると考えられる。

4.8 外部画像での汎化 (予備的検証)

評価画像が学習画像と同一の撮影環境であることによる過大評価の可能性を確認するため、データセット (4.2 節) とは別の時期に撮影したレバミピド錠 100mg の画像を、回転・明度の拡張を施して 390 枚とし、提案手法 (同一の学習済み LoRA・同一の評価手順) で評価した (2026 年 5 月 21 日実施)。結果は 99.7% (389/390, 失敗 1 枚) であり、少なくとも本薬剤については撮影時期が異なっても高精度を維持した。本検証は 1 薬剤のみの予備的なものであるが、全薬剤を対象とした別環境画像 (Web 収集画像) での汎化評価は 4.13 節で実施し、96.3% を確認している。

4.9 複数薬剤同時識別の結果

4.9.1 評価データの作成

実際に複数の PTP シートを同時に並べて撮影した画像は本研究では用意していない。そのため、1 枚に複数の薬剤が写る評価画像は、単一薬剤の評価用画像 (学習に未使用の 814 枚) を合成して作成した。この 814 枚には拡張画像が含まれるため、合成画像中の個々の薬剤にも拡張が反映される点に留意する (拡張のない実写の複数薬剤画像での検証は今後の課題。5 章)。合成手順は次のとおりである。(1) 各薬剤画像から、画素値の局所標準偏差に基づくテクスチャ検出により薬剤 (PTP シート) 部分の領域を自動的に切り出す。(2) 切

り出した薬剤画像を高さ 512px に揃え、異なる薬剤 2 枚または 3 枚を余白なしで横に連結して 1 枚のタイル画像とする。(3) 全 41 薬剤が均等に登場するよう、各画像の主役となる薬剤を順番に均等に割り当て (ラウンドロビン)、残りの 1~2 薬剤をランダムに選択する (乱数シード 42 で固定)。この方法で 2 薬剤 500 枚 + 3 薬剤 500 枚の合計 1,000 枚を生成した (各薬剤は各グループに 12~13 回ずつ登場)。各合成画像に写る薬剤の集合は正解ラベルファイル (labels.json) として保存し、採点に用いた。合成には評価用画像のみを使用しているため、学習データのリークはない。

4.9.2 一括質問方式の失敗

まず、合成画像全体をモデルに 1 回提示し「写っている薬をすべて JSON リストで答えよ」と質問する一括質問方式を試みた。この検証は、学習用画像から合成した 2,050 枚の予備セットで実施した。表 17 に示すとおり、プロンプトの工夫 (必ず複数答えるよう指示、薬剤の個数を提示、領域順の列挙指示、高解像度化) のいずれを加えても、完全一致は 2,050 枚中最大でも 1 枚であり、完全一致率はほぼ 0% であった。

表 18 一括質問方式の結果 (ファインチューニング後 4B・学習用画像から合成した 2,050 枚での予備検証)

方式	プロンプトの工夫	完全一致率
基準	すべて JSON で答えよ	≈0% (1/2,050)
工夫 1	「必ず複数答えよ」と指示	≈0% (1/2,050)
工夫 2	写っている個数 n を提示	≈0% (1/2,050)
工夫 3	「領域ごとに左から順に」と指示	0% (0/2,050)
工夫 4	個数提示+高解像度入力	≈0% (1/2,050)

失敗の原因は、モデルが「1 枚に 1 薬剤」を答えるよう学習されているため、複数の薬剤が写っていても 1 薬剤しか出力しないことであった。

4.9.3 検出→単剤分類方式の結果と 3 者比較

次に、3.5 節の 2 段階構成 (検出→単剤分類) を適用した。検出には LoRA を無効化した素のベースモデルのゼロショット検出 (検出プロンプトは 3.5 節、入力最大 1280 × 1280 ピクセル) を用い、検出された各領域をマージン 2% 付きで切り出して単剤識別した。

まず先行検証として、学習用画像から同じ手順で合成した生成画像 2,050 枚 (各薬剤が 2 薬剤 25 枚 + 3 薬剤 25 枚の計 50 回登場) で本方式を評価し、完全一致率 69.6%・F1 85.2% を得た。ただしこの 2,050 枚は学習に使用した画像を合成元とするため、独立した評価データに比べて性能を過大評価する可能性がある。そこで本評価では、学習に未使用の評価用画像から合成した前述の 1,000 枚を用いた。同一の 1,000 枚で、Gemini およびファインチューニング前の Qwen3.5-4B とも比較した。Gemini は一括質問方式 (プロンプト「この画像に写っているすべての薬を薬剤名と用量を含めて JSON リストで教えてください」) で評価した。したがって、提案手法との比較は同一画像・同一判定基準によるシステム全体の比較であり、モデル単体またはファインチューニングの効果だけを分離した比較ではない。ファインチューニング前の Qwen3.5-4B も同様に一括質問方式 (「この画像に写っているすべての薬を JSON リストで教えてください」) である。結果を表 18 に示す。

提案手法の完全一致率は 68.8% (2 薬剤 75.6%, 3 薬剤 62.0%) であり、一括質問方式の Gemini は 50.6% (2 薬剤 60.4%, 3 薬剤 40.8%) であった。これは処理方式を含むシステム全体の比較である。ファインチューニング前のモデルは完全一致 0% (1 薬剤以上正解した画像でも 3.3%) であった。同じ拡張あり条件で、単剤

表 19 複数薬剤同時識別の 3 者比較 (同一の合成評価画像 1,000 枚)

手法	完全一致率	Recall	Precision	F1
FT 後 4B (検出→単剤分類・提案)	68.8% (688/1000)	85.5%	86.3%	85.6%
Gemini (一括質問)	50.6% (506/1000)	—	—	—
FT 前 4B (一括質問)	0.0% (0/1000)	—	—	—

識別が 98.2% であるのに対し複数同時識別が 68.8% に留まることから、性能低下の主因は検出・切り出し段階にあると考えられた。この仮説は次節の実験で検証する。

4.10 検出器の専用学習による改善

4.10.1 評価セットと正解 bbox 基準値による診断

本節の実験では、評価用 814 枚 (学習に未使用) から各薬剤の正解 bounding box 付きで再合成した評価セットを用いた。構成は、標準セット 200 枚 (2 薬剤 100 枚 + 3 薬剤 100 枚) と、評価用 814 枚を 1 枚ずつ使い切る全画像使用セット 320 枚 (2 薬剤 146 枚 + 3 薬剤 174 枚) の 2 種類である。

検出段階の改善余地を定量化するため、合成時に保存した正解 bounding box で切り出して単剤識別する「正解 bbox 基準値」を測定した。この値は合成時の矩形を用いた比較基準であり、理論上の上限値ではない。あわせて合成タイル画像の解像度 (タイル高さ) の影響も調べた。結果を表 19 に示す。

表 20 合成解像度別の正解 bbox 基準値と実機値 (素のベース検出)

タイル高さ	正解 bbox 基準	実機 (素のベース検出)
512px	80.0%	—
768px	92.0%	81.5% (200 枚)
1024px	93.5%	—

正解 bbox 基準値は、解像度を 512px から 768px へ変更すると 80.0% から 92.0% へ上昇した。768px・標準 200 枚における実機値は 81.5% であった。一方、68.8% は 512px で作成した別の 1,000 枚評価セットによる値であり、81.5% との直接比較はできない。これらの結果から、入力解像度と検出精度の双方が複数識別の性能に影響することが示唆された。

4.10.2 検出器 LoRA の学習

検出精度を高めるため、検出専用の LoRA アダプタを追加学習した。学習データは、学習用分割の画像 (評価用合成画像とは元画像レベルで分離しリークを防止) から、実写に近い条件 (薬剤間のすきま、背景余白約 6%、大きさ・位置のばらつき) を加えて合成した複数薬剤画像 500 枚 (2 薬剤 200 枚・3 薬剤 200 枚・4 薬剤 100 枚) である。教師信号は、各薬剤の bounding box を 0~1000 に正規化した座標で記述するグラウディング形式 JSON ([{"bbox_2d": [x1,y1,x2,y2], "label": "薬剤"}])。座標の正規化は Qwen-VL 系列の表現 [?] に準拠) であり、検出プロンプトは推論時 (3.5 節) と同一とした。学習設定は LoRA rank 8・alpha 16、画像解像度 1024px、3 エポックで、平均損失は 0.181 → 0.134 → 0.119 と単調に減少した (所要約 80 分)。

4.10.3 検出器差し替え後の再評価

学習した検出器 LoRA を検出段に差し替え、同一の合成画像で「正解 bbox 基準」「旧検出（素のベース）」「新検出（学習した検出器）」を比較した。1 つの基盤モデルに識別 LoRA と検出 LoRA の 2 つを搭載し、処理段階に応じてアダプタを切り替えた。結果を表 20 に示す。

表 21 検出器学習の効果（完全一致率、括弧内は F1）

方式	768px・標準 200 枚	768px・全部 320 枚	1024px・標準 200 枚
正解 bbox 基準	92.0% (96.8%)	91.6% (96.9%)	93.5% (97.3%)
旧検出（素のベース）	81.5% (90.8%)	77.8% (90.4%)	85.5% (93.4%)
新検出（学習した検出器）	91.0% (96.2%)	88.8% (96.3%)	96.0% (98.4%)
改善（新－旧）	+9.5pt	+10.9pt	+10.5pt

検出器の専用学習により完全一致率は 9.5～10.9 ポイント改善した。768px 条件では、正解 bbox 基準との差の約 80～90% が縮小した。新検出（学習した検出器）の薬剤数別の内訳を表 21 に示す。

表 22 新検出（学習した検出器）の薬剤数別の完全一致率

条件	2 薬剤	3 薬剤
768px・標準 200 枚	92.0% (92/100)	90.0% (90/100)
768px・全部 320 枚	93.8% (137/146)	84.5% (147/174)
1024px・標準 200 枚	97.0% (97/100)	95.0% (95/100)

特に 1024px 設定では全体 96.0%（2 薬剤 97.0%，3 薬剤 95.0%）に達し、本研究の複数薬剤同時識別における最高値となった。1024px において、新検出（96.0%）は正解 bbox 基準値（93.5%）を上回った。これは、正解 bbox 基準値が理論上の上限ではなく、合成時のタイル全体を矩形として使用した比較値であるためである。学習した検出器が出力する bounding box は薬剤領域により密着し、切り出し品質が高かった。1024px・標準合成画像 200 枚で新検出が誤った 8 枚は、記録上すべて識別段階の取り違いであり、うち 5 枚はロスバスタチン錠 2.5mg「DSEP」をクエン酸第一鉄 Na 錠 50mg と誤認した。この評価セットでは検出誤りは観察されなかったが、実写画像を含む他の条件での検証は必要である。

4.10.4 過検出抑制の追加検討（負の結果）

検出器学習後に残る誤りを過検出（同一薬剤への重複した枠や、背景を薬剤とする誤検出）とみなし、その抑制を 2 方式で試みた（768px・標準 200 枚。スクリプト・結果は windows/複数薬剤_検出強化/）。第 1 に、重なり率（IoU）が 0.5 を超える枠を 1 つにまとめる重複除去（NMS）を適用したが、除去対象となる重複が 0 個であり、完全一致率は 91.0% のまま変化しなかった。第 2 に、切り出した枠が薬剤か否かを判定する「該当なしゲート」用 LoRA を学習し、該当なしと判定された枠を捨てる方式を試したが、正しい薬剤の枠まで捨ててしまい、完全一致率は 91.0% から 83.5% へ 7.5 ポイント悪化した（ゲートの学習損失が 2 エポック目ではほぼ 0 となる過学習を確認した）。これらは負の結果であるが、学習した検出器の時点で重複型の過検出は既に生じておらず、残る誤りの主因は識別段階の取り違いであることを裏付けるものであった。本研究では過検出抑制の後処理は採用しない。

複数薬剤同時識別の到達点の推移を図??にまとめる。一括質問方式のほぼ 0% から、検出→単剤分類への分解で 68.8%，検出器の専用学習と入力解像度の向上で 96.0% まで段階的に改善した。




図 8 複数薬剤同時識別の到達点の推移。一括質問はほぼ 0%（最大 1/2,050），検出→単剤分類は合成 1,000 枚で 68.8%，検出器学習 + 1024px は標準合成 200 枚で 96.0%。評価セットが異なるため厳密な同一条件の比較ではない

4.11 軽量化の評価（量子化・モデルサイズ）

量子化とは，モデル内部の数値表現の精度を落としてメモリ使用量を減らす圧縮技術である．スマートフォン等の端末搭載を見据え，（1）学習済み 4B モデルの 4bit 量子化（NF4 形式＋二重量子化．再学習は行わず，学習済み LoRA をそのまま量子化モデルに適用），（2）モデルサイズの縮小（0.8B / 2B，いずれも 4B と同一の学習データ・同一の LoRA 設定で学習）による精度の変化を測定した．

評価は 3 条件で行った．単一薬剤は評価用 814 枚（4.7 節と同一），複数薬剤は合成評価画像 1,000 枚（4.9 節と同一・検出→単剤分類方式）である．混在評価は，薬剤数が事前に分からない実運用を模擬するため，単一薬剤の評価画像から 100 枚と複数薬剤の合成画像から 100 枚を抽出・シャッフルした計 200 枚に対し，検出→単剤分類方式で薬剤数を自動判定させて評価した．結果を表 22～24 に示す．なお，本節の単一薬剤の数値（表 22）は拡張あり 814 枚での相対比較であり，拡張のない元画像での単一薬剤精度の主指標は 4.16 節（量子化を含む）および交差検証（4.18 節）に示す．複数薬剤・混在は実写の複数薬剤画像がないため合成画像で評価しており，これらの数値は相対比較の指標として解釈する．

表 23 モデルサイズ・量子化と単一薬剤識別精度（Top-1，拡張あり 814 枚・相対比較）

モデル	非量子化	4bit 量子化	量子化での低下
0.8B	87.3% (711/814)	74.3% (605/814)	−13.0pt
2B	87.2% (710/814)	83.9% (683/814)	−3.3pt
4B	98.2% (799/814)	91.9% (748/814)	−6.3pt

表 24 モデルサイズ・量子化と複数薬剤同時識別精度（完全一致率，括弧内は F1，1,000 枚）

モデル	非量子化	4bit 量子化
0.8B	12.7% (54.1%)	4.6% (33.9%)
2B	30.0% (67.6%)	12.9% (51.7%)
4B	68.8% (85.6%)	55.2% (76.7%)

表 25 単一・複数混在評価（完全一致率，括弧内は F1，単一 100 枚＋複数 100 枚）

モデル	非量子化（単一／複数の内訳）	4bit 量子化（単一／複数の内訳）
0.8B	38.0%・F1 62.7% (66%／10%)	26.5%・F1 42.4% (48%／5%)
2B	48.5%・F1 68.3% (68%／29%)	40.5%・F1 62.2% (71%／10%)
4B	68.0%・F1 80.3% (67%／69%)	70.0%・F1 80.4% (72%／68%)

単一薬剤識別ではモデルサイズによる差が比較的小さい（0.8B でも 87.3%）のに対し，複数薬剤同時識別では 0.8B 12.7%，2B 30.0%，4B 68.8% とサイズの影響が極めて大きい．量子化の影響も複数識別の方が大きかった（4B で単一 −6.3pt，複数 −13.6pt）．複数識別の完全一致率は，2〜3 薬剤のすべてを正しく検出・分類した場合のみ成功となるため，各領域で生じた誤りの影響を受けやすい．また，量子化による精度低下は薬剤間で一様ではなく，量子化 4B の単一識別ではレバミピド錠 100mg（27.3%），メチコバル錠 500 μ g・ロスバスタチン錠 2.5mg「DSEP」（各 54.5%）など，特定の薬剤に低下が集中した．量子化 4B の複数識別の内訳は 2 薬剤 63.8%・3 薬剤 46.6%（Recall 76.8%・Precision 77.6%）であった．混在評価では 4B のみが単一・複数で均等な精度を示し（67%／69%），量子化しても全体精度がほぼ低下しなかった（68.0% → 70.0%，各 100 枚での誤差範囲）．量子化 4B の複数識別 55.2% は，一括質問方式で評価した Gemini の 50.6% を数値上は上回った．ただし両者は処理方式が異なるため，モデル単体の優劣を示す比較ではない．端末搭載の候補としては，実験した 6 条件の中で量子化 4B が精度とメモリ使用量のバランスに優れていた．なお，本節の複数識別の値は，いずれも素のベースモデルによるゼロショット検出（4.9 節）を用いた構成で測定したものであり，4.10 節で専用学習した検出器（最高 96.0%）とは検出構成が異なる．量子化と検出器の専用学習を組み合わせた評価は今後の課題である．なお混在評価は各 100 枚の軽量版であり，数ポイントの差は誤差として傾向の確認に用いる．

4.12 Gemini による拡張前の元画像 287 枚の評価

4.7 節の Gemini 評価は撮影＋拡張を施した 814 枚を対象としていた．本節では，拡張による人工的な変形を含まない**撮影元画像そのもの**に対する Gemini の識別性能を確認するため，`drugs.json`（表裏・錠数ラベル付き）と照合できた拡張前の元画像 287 枚のみを対象に再評価した（2026 年 6 月 24 日実施）．

■入力・条件

- 対象画像：元画像_260409 撮影/ のうち `drugs.json` とファイル名で照合できた 287 枚（41 薬剤）．内訳は表 212 枚／裏 75 枚，1 錠 39 枚／2〜3 錠 102 枚／4 錠以上 146 枚．
- モデル：gemini-3.5-flash．送信前処理は最大 589,824 ピクセル（768×768 相当）に縮小し JPEG quality=90 で送信．レート制限対策として 1 リクエストごとに 1 秒待機．
- プロンプト：41 薬剤の候補一覧を提示し，「最も近い薬剤名を 1 つだけ，薬剤名のみ」で回答させた．
- 判定：正解薬剤名からメーカー記号を除外し，薬剤名部分と用量が回答に含まれれば正解（4.7 節と同ルール）．
- スクリプト・結果：windows/Gemini 元画像_3.5_flash 評価/，サマリーは結果/_summary.md，全入出力は結果/_入力出力.md．

■結果 全体正答率は **99.0% (284/287)** であり、拡張前の実写真だけであれば Gemini 3.5 Flash もほぼ全て識別できた。表裏・錠数別の内訳を表 25 に示す。失敗はすべて表側の 3 枚に集中した (表 26)。

表 26 Gemini (拡張前の元画像 287 枚) の表裏・錠数別正答率

区分	正解/枚数	正答率	区分	正解/枚数	正答率
全体	284/287	99.0%	表 ×1 錠	29/30	96.7%
表	209/212	98.6%	表 ×2~3 錠	71/73	97.3%
裏	75/75	100.0%	表 ×4 錠以上	109/109	100.0%
1 錠	38/39	97.4%	裏 ×1 錠	9/9	100.0%
2~3 錠	100/102	98.0%	裏 ×2~3 錠	29/29	100.0%
4 錠以上	146/146	100.0%	裏 ×4 錠以上	37/37	100.0%

表 27 Gemini が失敗した 3 枚 (拡張前の元画像)

正解	画像	表裏	錠数	Gemini 回答
デエビゴ錠 5mg	IMG_0095.png	表	1	タケキャブ錠 10mg
メチコバル錠 500 μ g	IMG_0044.png	表	2	タケキャブ錠 20mg
メチコバル錠 500 μ g	IMG_0045.png	表	2	メトクロプラミド錠 5mg

薬剤別では 39 薬剤が 100% で、失敗が出たのはデエビゴ錠 5mg (9/10) とメチコバル錠 500 μ g (2/4) の 2 薬剤のみであった。4.7 節の Gemini (拡張あり) は 82.3%, 本節の Gemini (拡張なし) は 99.0% であった。ただし、本節では 41 薬剤の候補一覧を提示しており、4.7 節とはプロンプト条件も異なる。したがって、この差を回転・反転等の拡張変形だけに帰属することはできない。同一プロンプトで拡張の有無だけを変えた対照実験が必要である。

4.13 Web 収集画像での汎化評価

本研究の評価画像 (4.7 節) は学習画像と同一の撮影環境で取得したものが中心であり、撮影環境に依存した過大評価 (同環境への過学習) の懸念がある。この懸念を検証するため、Web から収集した、自前撮影とは出典および撮影条件が異なる画像で提案手法 (FT 後 4B) を評価した。

■入力・条件

- 対象画像：41 薬剤について公式サイト・添付文書等から収集した実画像、計 136 枚 (拡張なし・1 薬剤あたり数枚)。学習にも自前撮影画像にも一切用いていない別環境画像である。
- モデル・プロンプト：4.7 節と同一 (学習済み単剤識別 LoRA・同一質問文)。
- 判定：薬剤名を「ブランド名+用量」に分解し、順不同で両方が回答に含まれれば正解。
- スクリプト・結果：windows/ネット画像での評価/ (1.augment.py / 2.evaluate.py / 3.evaluate_gemini.py), サイズ・量子化比較は windows/モデル横断_学習と評価/結果_ネット画像/。

■結果 別環境の 136 枚で **96.3% (131/136)** を達成し、自前撮影 (拡張あり 814 枚) の 98.2% に近い精度を維持した (表 27)。同じ 136 枚をモデルサイズ・量子化を変えて評価した結果を表 28 に示す。小型モデルでも単一識別の Web 収集画像では高い (0.8B でも 92.6%)。

表 28 自前撮影画像と Web 収集画像の比較 (FT 後 4B)

評価画像	正答率
自前撮影 (拡張なし・評価用 74 枚)	100.0% (74/74)
自前撮影 (拡張あり 814 枚)	98.2% (799/814)
Web 収集画像 (別環境・136 枚)	96.3% (131/136)

表 29 Web 収集画像のモデルサイズ・量子化別正答率 (FT 後・136 枚)

モデル	量子化	正答率
4B	なし	96.3% (131/136)
4B	4bit	89.7% (122/136)
2B	なし	97.1% (132/136)
2B	4bit	94.9% (129/136)
0.8B	なし	92.6% (126/136)
0.8B	4bit	88.2% (120/136)

なお 2B 非量子化 97.1% と 4B 96.3% の差は 1 枚 (132/136 と 131/136) で誤差の範囲であり、外した薬剤も両者で異なるため 2B が 4B より優れているとは言えない。さらに、実環境では薬剤が画像内に小さく写る場合があるため、Web 収集画像を縮小し、被写体の画像内占有率を低下させた条件で 4B を評価した (表 29)。被写体を小さくするほど正答率は低下した。学習画像が薬剤を大きく写した画像を中心としていることが一因と考えられるが、原因を確認するにはズーム率のみを変えた対照実験が必要である。

表 30 Web 収集画像のズーム率別正答率 (FT 後 4B・136 枚)

ズーム率	正答率
1.00 (元)	96.3% (131/136)
0.75	95.6% (130/136)
0.60	92.6% (126/136)
0.45	84.6% (115/136)

本結果は、提案手法が自前撮影とは異なる出典・条件の画像にも一定程度汎化することを示している。ただし、Web 画像は公式サイト等の比較的明瞭な画像であり、実際の医療現場における多様な撮影条件を網羅するものではない。

4.14 回転・反転への対策

4.7 節 (表 16) に示したように、提案手法の誤識別はその大部分が回転・水平反転に由来していた。この向きの崩れへの対策として、(a) 学習データに大角度回転・反転を加えて再学習する方式と、(b) 推論前に向きを補正する前処理方式の 2 案を、いずれも標準評価 (814 枚) で同一条件で検証した。結果を表 30 に示す。

■(a) 拡張強化による再学習 学習データに $\pm 45/\pm 90/180$ 度回転および上下反転を加えた画像 1,278 枚を追加し、同一の LoRA 設定で再学習した (評価時の前処理はなし)。スクリプトは windows/回転前処理/a1_

拡張強化データ生成.py・a2_train_拡張強化.py・a3_eval_拡張強化.py. 結果は 99.8% (812/814) で、ベースライン 98.2% から +1.6 ポイント改善した (改善 14 枚・悪化 1 枚, McNemar 検定で $p=0.001$ と有意). 拡張種別の内訳では, 回転 -30 度 ($70 \rightarrow 73$), 回転 $+30$ 度 ($70 \rightarrow 74$), 水平反転 ($70 \rightarrow 74$) など, 標準評価セットにおける従来の弱点が大幅に改善した.

■(b) 向き補正前処理 (再学習なし) 推論前に画像の傾きを推定し, $|\text{傾き}| \geq 5.0^\circ$ の画像のみ水平に回転補正してから入力する方式 (windows/回転前処理/向き補正.py・2_eval_向き補正.py). 結果は 98.5% (802/814) で, ベースラインから +0.4 ポイントにとどまった (改善 9 枚・悪化 6 枚, McNemar 検定で $p=0.61$ と有意でない). 前処理は回転は補正できても水平反転は戻せないため改善が小さい.

表 31 回転・反転対策の効果 (標準評価 814 枚)

条件	Top-1 精度	差
ベースライン (対策なし・従来の最高値)	98.2% (799/814)	—
(b) 向き補正前処理 (再学習なし)	98.5% (802/814)	+0.4pt
(a) 拡張強化による再学習	99.8% (812/814)	+1.6pt

学習側に大角度回転・反転を加えて再学習する (a) が有効であり, 標準評価セットでは向きの崩れへの脆弱性が大幅に改善した.

4.15 学習枚数の感度分析 (few-shot 曲線) と表裏・錠数の効果

1 薬剤あたりの撮影枚数を定めるため, 学習に用いる元画像枚数を変化させ, 識別精度への影響を検証した. あわせて, PTP シートの表裏および画像に写る錠数が精度に与える影響を分析した.

4.15.1 実験条件

対象は元画像を 6 枚以上確保できた 33 薬剤とし, 元画像が 3~4 枚の 8 薬剤は除外した. 各薬剤の画像を乱数シード 42 で学習用 75% と評価用 25% に分割し, 表裏の偏りを抑えるため層化した. 学習には 1 薬剤あたり $N = 1, 2, 4$ 枚, または学習用画像の全枚数を用いた. 各条件で 11 種のデータ拡張を行い, 同一設定で LoRA を 5 エポック学習した. 評価には全条件で共通する拡張なしの実画像 79 枚を用い, ブランド名と用量の双方が回答に含まれる場合を正解とした. なお, $N = 5, 6, 7$ の学習も実施したが, 必要枚数を確保できる薬剤がそれぞれ 20, 16, 8 薬剤に減少するため, 33 薬剤を固定した主比較には含まなかった.

4.15.2 学習枚数の比較

33 薬剤を固定した結果を表 31 および図 7 に示す.

表 32 学習枚数 N と正答率 (33 薬剤・クラス数一定)

N (1 薬剤あたりの学習元画像数)	正解/評価枚数	Top-1 正答率
1	53/79	67.1%
2	69/79	87.3%
4	72/79	91.1%
全枚数 (5~8 枚)	78/79	98.7%




図9 1 薬剤あたりの学習元画像枚数と Top-1 正答率 (33 薬剤. 横軸の「全部」は 5~8 枚)

$N = 1$ から $N = 2$ に増やすと正答率は 20.2 ポイント上昇した. $N = 4$ では 91.1%, 全枚数を用いた条件では 98.7% に達した. 一方, $N = 5, 6, 7$ ではいずれも 100% であったが, 薬剤数が減少し分類問題が容易になっているため, 学習枚数のみの効果とは解釈できない.

4.15.3 表裏および錠数の分析

$N = 1, 2, 4$ および全枚数の 4 条件における評価結果をプールし, 表裏および錠数別に集計した. 結果を表 32 に示す.

表 33 評価画像の表裏・錠数別正答率 (33 薬剤・延べ 316 件)

観点	条件	正解/延べ評価数	Top-1 正答率
表裏	表	184/216	85.2%
	裏	88/100	88.0%
錠数	1 錠	43/52	82.7%
	2 錠	56/64	87.5%
	3 錠	36/44	81.8%
	4 錠	32/40	80.0%
	5~8 錠	57/64	89.1%
	9 錠	3/4	75.0%
	シート全体	45/48	93.8%

表面と裏面の正答率はそれぞれ 85.2% と 88.0% であり, 面そのものによる差は小さかった. 錠数別ではシート全体が 93.8% で最も高く, 1 錠のみの画像は 82.7% であった. 1 錠画像では薬剤名や用量の印字が画角外となる例があり, 識別に利用できる文字情報が少ないことが精度低下の一因と考えられる. ただし, 9 錠の評価は延べ 4 件に限られるため, 75.0% という値から一般的な傾向を判断することはできない.

さらに, $N = 1, 2, 4$ の 3 条件について, 評価画像と同じ面または錠数が学習画像に含まれていたかを集計した結果を表 33 に示す.

学習画像に評価面が含まれない場合は 6.5 ポイント, 評価時と同じ錠数が含まれない場合は 11.1 ポイント

表 34 学習画像との面・錠数の一致による正答率 (延べ 237 件)

観点	学習画像に同じ条件	正解/延べ評価数	Top-1 正答率
表裏	あり	175/212	82.5%
	なし	19/25	76.0%
錠数	あり	79/89	88.8%
	なし	115/148	77.7%

低下した。したがって、撮影時には表裏の両面を含め、1 錠、複数錠およびシート全体の画像を確保する必要がある。学習枚数は 1 薬剤あたり 5 枚以上が一つの目安となるが、本実験では同一の 33 薬剤で 5 枚と 6 枚を直接比較していないため、両者の差については結論づけられない。なお、表 32 および表 33 は同一の評価画像 79 枚を複数の学習条件で評価した延べ件数であり、各行を独立標本とみなした統計検定は行っていない。

4.16 データ拡張倍率の対照実験

4.6 節では、データ拡張なしの学習が過学習の兆候を示したことからデータ拡張を導入した。しかし、その検討は学習・評価の分離を行っていないため、データ拡張の寄与を定量的に分離するには、他の条件を固定して拡張倍率のみを変えた対照実験が必要である。そこで、学習・評価分割 (学習用元画像 213 枚・評価用 74 枚、4.2 節と同一) を固定し、1 枚の元画像から生成する拡張枚数のみを $\times 1$ (拡張なし) $\sim \times 17$ に変えて、同一設定 (LoRA rank 8・alpha 16, 5 エポック, 学習率 $2e-4$ 。ただし本実験では学習バッチサイズを 2 に統一) でそれぞれ独立に LoRA を学習した (スクリプト・生ログは `windows/拡張枚数_対照実験/`)。拡張の並びは先頭 11 種が表 6 と同一であり、 $\times 17$ では回転 ± 45 度および強い明暗変化などの 6 種を追加した。評価は全条件共通の、拡張なしの評価用元画像 74 枚である。結果を表??に示す。

表 35 データ拡張倍率と Top-1 正答率 (41 薬剤・拡張なし評価用元画像 74 枚)

拡張倍率	学習枚数	正解/評価枚数	Top-1 正答率
$\times 1$ (拡張なし)	213	54/74	73.0%
$\times 3$	639	65/74	87.8%
$\times 5$	1,065	67/74	90.5%
$\times 7$	1,491	71/74	95.9%
$\times 11$ (本研究の標準)	2,343	72/74	97.3%
$\times 17$	3,621	74/74	100.0%

拡張なしの 73.0% に対し、データ拡張により精度は単調に向上し、 $\times 7$ でほぼ天井 (95.9%) に達した後、 $\times 11$ で 97.3%、 $\times 17$ で 100% となった。拡張を増やしすぎることによる精度低下は観察されなかった。この結果は、本研究の 11 種データ拡張が精度向上に大きく寄与していることを、学習・評価分割を固定した対照実験として裏付けるものである。ただし本実験は単一 seed・単一分割であり、評価 74 枚では上位水準間の 1 $\sim$ 2 枚の差は誤差の範囲であるため、統計的に明確なのは「拡張なしと拡張あり」の差である。

さらに、 $\times 17$ 拡張について 4.18 節と同一の fold 分割で 5 分割交差検証を行った結果は $99.3\% \pm 0.9\%$ (285/287) であり、 $\times 11$ の 98.6% (283/287) を数値上は上回った。しかし、正誤が食い違った画像は 6 枚 ($\times 17$ のみ正解 4 枚・ $\times 11$ のみ正解 2 枚) にとどまり、McNemar 検定 (正確二項) では $p=0.6875$ と有意差

はなかった。なお、この比較では学習バッチサイズも異なる（×11 は 7, ×17 は 2）ため、拡張倍率のみの純粋な比較ではない。以上から、×17 に増やす明確な利点は確認されず、本研究では現行の 11 種拡張を妥当な設定と判断した。

4.17 量子化・モデルサイズの実画像（拡張なし）評価

評価に拡張画像を用いない方針（4.2 節）に従い、モデルサイズと量子化の影響は、拡張のない撮影元画像で評価することを基本とする。4.11 節の比較（拡張あり 814 枚・相対比較）に対し、本節では拡張なしの元画像 74 枚で、非量子化と 4bit 量子化の各サイズを評価した結果を表 34 に示す（スクリプトは windows/モデル横断_学習と評価/の評価_非量子化_拡張なし.py・評価_量子化_拡張なし.py, 結果は結果_非量子化_拡張なし/・結果_量子化_拡張なし/）。

表 36 モデルサイズ・量子化別の単一薬剤識別精度（拡張なし元画像 74 枚）

モデル	非量子化	4bit 量子化	量子化での低下
0.8B	91.9% (68/74)	82.4% (61/74)	−9.5pt
2B	94.6% (70/74)	93.2% (69/74)	−1.4pt
4B	100% (74/74)	94.6% (70/74)	−5.4pt

非量子化ではサイズが大きいほど精度が高く（0.8B 91.9% < 2B 94.6% < 4B 100%）、拡張のない実写画像でもモデルサイズの効果が確認できる。4bit 量子化はいずれのサイズでも精度を下げたが、低下量はサイズで一様ではなく、2B −1.4 ポイント、4B −5.4 ポイントに対し、最も軽い 0.8B では −9.5 ポイントと大きかった。拡張なし元画像でも、量子化による精度低下は小型モデルほど大きい傾向が見られた。

4.18 データ分割の妥当性検証（リーク監査）

98.2% という高精度が、連続撮影による「ほぼ同一カット」が学習側と評価側に分かれて入ったこと（データリーク）による見かけの精度でないかを、画像類似度で監査した。

■入力・処理

- 対象：学習側の元画像 213 枚と評価側の元画像 74 枚（いずれも拡張前の無加工コピー*.orig.png）。同一薬剤内の学習 × 評価ペア 403 組を比較した。
- 指標：MD5（ファイル内容の完全一致）、pHash（DCT ベースの知覚ハッシュのハミング距離）、SSIM（構造的類似度）。scipy/OpenCV を使わず numpy+PIL で実装。
- スクリプト・結果：windows/リーク監査/1_リーク監査.py, 結果/リーク監査_結果.md。

■結果 MD5 完全一致は 0 件、pHash ハミング距離が 5 以下（ほぼ同一の疑い）のペアは 0 件、SSIM が 0.97 以上のペアも 0 件であった。設定した閾値の範囲では、学習側と評価側に同一・酷似カットの跨ぎは検出されなかった。この結果は完全一致画像や極めて類似した画像によるデータリークがないことを支持するが、あらゆる類似性や記憶の影響を否定するものではない。

4.19 5 分割交差検証による頑健性の確認

4.7 節の 98.2% は、1 通りの 75% / 25% 分割（4.2 節）による評価値である。分割の取り方に依存した偶然の高精度でないことを確認するため、41 薬剤すべてを対象に 5 分割交差検証を行った。

■入力・条件

- 対象：41 薬剤の撮影元画像 287 枚。各元画像がちょうど 1 回だけテストに用いられるよう、5 つの fold に分割した。
- 学習：各 fold で、テスト以外の元画像に 11 種拡張を施し、一から LoRA を学習した（FT 設定は 3.4 節・表 7 と同一。ただし学習バッチサイズのみ 7 とした）。fold ごとに独立に学習する。
- テスト：拡張なしの元画像のみ（各 fold 57~58 枚、計 287 枚）。判定は 4.7 節と同一。
- スクリプト・結果：windows/41 薬剤_5fold 交差検証/, サマリーは結果/_交差検証サマリー.md。

なお、本交差検証に先立ち、5 薬剤を対象とするパイロット実行により、分割・学習・評価の一連の手順が正しく動作することを確認したうえで全 41 薬剤に適用した。

■結果 プール正解率は 98.6% (283/287)、fold 平均は 98.6%±1.5% であった（表 35）。最も精度の低い fold でも 96.5% であり、分割の取り方に依存せず安定して高い精度が得られた。これは 4.7 節の単一分割 98.2% が、特定の分割に偏った結果ではないことを支持する。

表 37 5 分割交差検証の fold 別 Top-1 精度（テストは拡張なし元画像 287 枚）

fold	成功/枚数	Top-1
1	58/58	100.0%
2	58/58	100.0%
3	56/57	98.2%
4	55/57	96.5%
5	56/57	98.2%
プール (fold 平均 98.6%±1.5%)	283/287	98.6%

表裏別では表 98.6% (209/212)・裏 98.7% (74/75) とほぼ差がなく、錠数別では 1 錠が 94.9% (37/39) と最も低かった（表 ×1 錠 93.3%）。これは 4.15 節で観察された「1 錠が弱点」という傾向と整合する。誤りは 287 枚中 4 枚（カロナール錠 500mg・タケキャブ錠 10mg・デエビゴ錠 5mg・ロスバスタチン錠 2.5mg 「DSEP」各 1 枚）であった。

■Gemini との同一画像での直接比較 本交差検証のテストは拡張なしの元画像 287 枚であり、4.12 節の Gemini 評価（同じ 287 枚で 99.0%）と画像単位で対応づけられる。両者を突き合わせた結果を表 36 に示す。提案手法 98.6% (283/287) と Gemini 99.0% (284/287) の差はわずか 1 枚であり、280 枚は両者とも正解、どちらも不正解の画像は 0 枚であった。取りこぼす画像は互いに異なり（提案手法のみ正解 3 枚・Gemini のみ正解 4 枚）、両者は相補的であった。この正誤の食い違いに対する McNemar 検定は $p=1.00$ であり、両者の差は統計的に有意でない（??節）。なお、同じ 287 枚に対するファインチューニング前の Qwen3.5-4B（ゼロショット）は 1.0% (3/287) であった。

表 38 同一の元画像 287 枚における提案手法（5 分割 FT）と Gemini の正誤対応

区分	枚数
両者とも正解	280
提案手法のみ正解	3
Gemini のみ正解	4
両者とも不正解	0

すなわち、拡張のない実写の元画像では、ローカルで動作する提案手法（98.6%）と外部 API である Gemini（99.0%）は同等の精度であった。4.7 節で提案手法が Gemini（82.3%）を 15.9 ポイント上回ったのは、主として回転・反転を含む拡張画像に対する頑健性の差によるものと考えられる（4.12 節・4.14 節）。以上から、提案手法の利点は、画像を外部に送信せずローカルで完結しながら、拡張のない実写画像では Gemini と同等の精度を保ち、回転・反転を含む劣化画像に対してより頑健である点にあると整理できる。

4.20 評価時拡張の多数決（TTA）の検討

推論時の頑健化策として、評価画像 1 枚を学習時と同じ 11 種の加工で水増しし、それぞれをモデルに回答させて多数決を最終回答とする Test-Time Augmentation（以下、TTA）を検討した。モデル・分割・正解判定は 4.18 節の 5 分割交差検証と同一である（スクリプトは windows/41 薬剤_5fold 交差検証/7_TTA 多数決評価.py）。多数決の数え方は、学習対象 41 薬剤に該当しない回答も 1 票と数える方式と、該当しない回答を除外する方式の 2 通りを試した。

結果は、いずれの方式も元画像 1 枚のみで回答した場合と同一の 98.6%（283/287）であり、改善も悪化もなかった（単発推論と正誤が入れ替わった画像は 0 枚）。11 枚の回答が完全には一致しなかった画像は 287 枚中 29 枚あったが、いずれも多数決の結果は単発推論と同じであった。誤りが残った 4 枚は交差検証の誤り 4 枚と同一で、すべて外観の似た薬剤どうしの取り違いであり、画像の水増しでは解消しなかった。また、1 枚あたり 11 回の推論を要するため、処理時間は 1 枚あたり約 24 秒であった。以上から、モデルは学習時のデータ拡張により既に画像の揺らぎへ頑健であり、TTA による精度向上は見込めないと判断した。一方、11 枚の回答のそろい具合は入力に対する確信度の指標として利用できる可能性があり、未知薬剤の保留機構（?? 節・5 章）を構成する材料の候補となる。

4.21 主要な比較の統計検定（McNemar 検定と 95% 信頼区間）

主要な比較の差が偶然によるものでないかを確認するため、同一の評価画像に対する対応のある比較として McNemar 検定を行い、主要な精度に二項比率の 95% 信頼区間（Wilson 法）を付した（スクリプト・結果は windows/統計検定/）。

■拡張のない元画像 287 枚での 3 者比較 4.18 節の交差検証テスト（提案手法：283/287）、4.12 節の Gemini 評価（284/287）、および同一 287 枚に対するファインチューニング前 4B のゼロショット評価（3/287）を画像単位で対応づけ、McNemar 検定（連続性補正あり）を行った。結果を表??に示す。

ファインチューニング前後の差（98.6% 対 1.0%）および Gemini とファインチューニング前の差は極めて有意（ $p < 0.001$ ）である一方、提案手法と Gemini の差は $p = 1.00$ であり、拡張のない元画像では両者は統計

表 39 拡張のない元画像 287 枚における McNemar 検定（連続性補正あり）

比較ペア	片方のみ正解（前者/後者）	χ^2	p 値	判定
FT 後 4B vs FT 前 4B	280 / 0	278.00	2.0×10^{-62}	FT 後が有意に高い
Gemini vs FT 前 4B	281 / 0	279.00	1.2×10^{-62}	Gemini が有意に高い
FT 後 4B vs Gemini	3 / 4	0.00	1.00	有意差なし

的に同等であった（ただし Gemini 側は 41 薬剤の候補一覧を提示する条件である。4.12 節）。

■拡張画像 814 枚での 3 者比較 4.7 節の単一薬剤 3 者比較（表 12）について、Wilson 法による 95% 信頼区間は、提案手法 98.2% [97.0%, 98.9%]、Gemini 82.3% [79.5%, 84.8%]、ファインチューニング前 0.9% [0.4%, 1.8%] であり、3 者の区間は互いに重ならない。同一画像での対応のある比較（McNemar 検定、正確二項・両側）でも、提案手法と Gemini の差（提案手法のみ正解 138 枚・Gemini のみ正解 9 枚）、および提案手法とファインチューニング前の差（提案手法のみ正解 792 枚・ファインチューニング前のみ正解 0 枚）は、いずれも $p < 10^{-15}$ で有意であった。また、回転・反転対策の拡張強化による改善（98.2% → 99.8%。4.14 節）も McNemar 検定で有意（ $p=0.001$ ）であった。

4.22 推論ベンチマーク（メモリ・速度）

端末搭載の可否を判断するため、精度に加えてモデルが使用するメモリ（VRAM）と 1 枚あたりの推論時間を 6 条件で計測した（RTX 4070 Ti SUPER・同一 20 枚）。結果を表 37 に示す（スクリプトは windows/推論ベンチマーク/）。

表 40 モデルサイズ・量子化別の精度・メモリ・速度

条件	単一 Top-1（拡張あり）	複数完全一致	モデル VRAM(GB)	推論 (秒/枚)
0.8B 非量子化	87.3%	12.7%	1.59	0.81
0.8B 4bit	74.3%	4.6%	0.78	0.93
2B 非量子化	87.2%	30.0%	4.12	0.88
2B 4bit	83.9%	12.9%	1.79	1.00
4B 非量子化	98.2%	68.8%	8.46	1.00
4B 4bit	91.9%	55.2%	3.08	1.22

量子化 4B は GPU 上で計測したモデル VRAM を 8.46GB から 3.08GB へ（約 1/2.7）削減できた。ただし、この値にはスマートフォンの OS や実行環境が使用するメモリは含まれず、GPU VRAM とスマートフォンの共有 RAM を直接比較することもできないため、搭載可否は実機で検証する必要がある。推論時間はどの条件も 0.8~1.2 秒/枚であり、本実験で用いた GPU 実装では量子化による高速化は確認できなかった。速度は量子化カーネルや端末向けランタイムの実装にも依存する。

4.23 根拠説明文の生成可否

モデルが薬剤名の出力根拠を文章として説明できるかを確認した。なお、生成された説明文はモデル内部の推論過程そのものを直接示すものではない。出力トークン数の上限を通常の 32 から 1024 に拡大した。そのうえで、思考を促す／強制する 2 種類のプロンプト（「どこに注目したかを順を追って説明し、最後に薬剤名を答える」、および「文字・色・形・刻印などの根拠を 3 つ以上述べてから答える（いきなり薬剤名だけを答え

るのは禁止))」を、自前撮影画像と Web 収集画像の双方で試した (windows/思考過程の可視化/).

いずれのプロンプトでも、出力は薬剤名だけ (例:「2.5mg メインテート錠」) で、根拠説明文は生成されなかった. 現行モデルは「薬剤名だけを短く答える」形式で学習されており、今回試したプロンプトだけでは説明文を生成させることができなかった. 参考として、追加学習前のモデルは同じプロンプトで長い説明文を出力したが、印字を読み違えて誤答する場合があった. ただし、説明文の生成はモデル内部の判断根拠が忠実に可視化されたことを意味しない.

4.24 未知薬剤に対する保留の予備実験 (ホワイトリスト方式)

本研究のモデルは 41 薬剤で学習されているため、学習対象外 (未知) の薬剤画像を入力しても、学習済みのいずれかの薬剤名を生成してしまう可能性がある. 医療用途では、判別できない画像に誤った薬剤名を断定することが最も危険である. そこで、誤断定を保留する仕組みの予備実験として、ホワイトリスト方式を評価した (スクリプト・結果は windows/誤出力対策_ホワイトリスト/).

■方式 ビームサーチで Top-3 候補を生成し、順位の高い候補から順に、学習済み 41 薬剤名の一覧 (ホワイトリスト) と照合する. 最初に一致した候補を薬剤名として出力し、3 候補すべてがリスト外の場合は薬剤名を出力せず「学習していない薬剤です」と保留する. 薬剤名一覧は実際の学習に用いた fold の学習データから取得し、照合には 4.7 節と同一の正規化を適用した.

■入力・条件

- 未知薬剤: 製薬会社の公式製品情報等から収集した、学習済み 41 薬剤と正式名が重複しない 12 薬剤・17 枚の PTP 画像. モデルは 5 分割交差検証 (4.18 節) の fold 1 の LoRA を評価前に固定して用いた. 全 12 薬剤が fold 1 の学習済み薬剤に含まれないことを推論前に確認した.
- 既知薬剤の誤識別: 5 分割交差検証で誤識別された 4 枚. 各画像をテストに含む fold の LoRA を用い、学習データとの重複がないことを機械的に確認した.

■結果 未知薬剤 17 枚のうち 12 枚 (70.6%) は「学習していない薬剤です」と保留できた. 一方、残る 5 枚 (29.4%) ではモデルが学習済み薬剤名 (クエン酸第一鉄 Na 錠 50mg で 2 枚など) をそのまま生成したため、誤答がホワイトリストを通過した. また、既知薬剤の誤識別 4 枚はいずれも別の学習済み薬剤名を出力しており、ホワイトリストでは防げなかった (うち 2 枚は Top-2 に正解を含んでいたが、正解を知らない実運用では Top-1 より下位の候補を選ぶ根拠がない).

■考察 ホワイトリスト方式は、リスト外の崩れた出力や無関係な文字列を止める第一段階としては機能するが、未知薬剤を既知薬剤名として出力する誤りと、既知薬剤同士の取り違えには効果がない. 誤断定を保留するには、出力文字列の照合ではなく、生成スコアや候補間の一致度など、モデルの確信度に基づく保留機構 (確信度ゲート) の導入が必要である (5 章).

4.25 考察

本章の実験結果から、以下の知見が得られた.

第一に、薬剤画像に特化した LoRA ファインチューニングは、本評価条件において大きな改善を示した. 回

転・反転等を施した同一の拡張画像 814 枚に対して、ファインチューニング前 0.9% に対しファインチューニング後 98.2% (差 97.3 ポイント) であり、画像変形への頑健性において汎用大規模モデルである Gemini (82.3%) を上回った。1 薬剤あたり元画像 3~10 枚という少数データでも、11 種のデータ拡張との組み合わせにより、本評価セットで高い精度に到達した。学習・評価分割を固定し拡張倍率のみを変えた対照実験 (?? 節) では、拡張なしの 73.0% に対し 11 種拡張で 97.3% であり、データ拡張が精度向上に大きく寄与することが確認された。一方、 $\times 17$ への増強は McNemar 検定で有意な改善を示さず、現行の 11 種拡張が妥当な設定であった。

第二に、複数薬剤の同時識別は、まず問題を「検出→単剤分類」に分解することで実現できた。一括質問方式は本実験で試したプロンプトではほぼ 0% であったが、単剤識別用モデルを変更しない 2 段階構成により、合成画像 1,000 枚で 68.8% に達した。さらに検出器の専用学習と入力解像度の向上により、標準合成画像 200 枚・1024px の条件で 96.0% まで改善した。この 200 枚では、検出器学習後に残った 8 件は記録上すべて識別段階の取り違えであり、検出誤りは観察されなかった。ただし、実写の複数薬剤画像を含む他条件への一般化は未確認である。

第三に、軽量化のトレードオフが定量化された。単一識別では、拡張のない元画像 74 枚での評価で小型・量子化モデルも一定の精度を示し (量子化 2B で 93.2%, 量子化 4B で 94.6%), 複数識別 (拡張あり合成画像) では 4B が検証したモデル中で最も高かった。量子化 4B は端末搭載の候補となるが、実機でのメモリ使用量と速度は未検証である。

第四に、本研究の評価の妥当性を補強する検証を行った。撮影環境への過学習の懸念に対しては、自前撮影とは出典および撮影条件が異なる Web 収集画像 136 枚で 96.3% を得た (4.13 節)。また、学習・評価分割のリーク監査では、設定した閾値の範囲で同一・酷似カットの跨ぎは検出されなかった (4.17 節)。これらは異なる画像条件への一定の汎化と、明白なデータリークがないことを支持する結果である。さらに、41 薬剤の 5 分割交差検証では $98.6\% \pm 1.5\%$ (プール 283/287) が得られ、単一分割の 98.2% が特定の分割に偏った結果でないことを支持した (4.18 節)。同じ拡張なしの元画像 287 枚での直接比較では、提案手法 (98.6%) と外部 API の Gemini (99.0%) は同等であり、4.7 節で Gemini を上回ったのは、主として回転・反転を含む拡張画像に対する頑健性の差によるものと考えられる。統計検定 (?? 節) でも、ファインチューニング前後の差は極めて有意 ($p < 0.001$) である一方、拡張のない元画像での提案手法と Gemini の差は有意でない (McNemar 検定, $p = 1.00$) ことが確認された。また誤識別の主因であった回転・反転への脆弱性は、学習データへの大角度回転・反転の追加により、標準評価セットで 98.2% から 99.8% へ改善した (4.14 節)。

最後に本実験の限界を述べる。複数薬剤の評価は合成画像によるものであり、実際に複数の PTP シートを並べて撮影した実写画像での検証は今後必要である。また、同名・別用量の取り違えは未解決である。学習外 (未知) 薬剤への安全な対応についても、ホワイトリスト方式の予備実験 (?? 節) では未知薬剤の約 7 割を保留できたにとどまり、確信度に基づく保留機構の導入が必要な未解決の課題として残る (5 章)。

5 結論・今後の課題

5.1 結論

本研究では、オープンソースの VLM である Qwen3.5-4B を薬剤画像で LoRA ファインチューニングし、薬剤画像とテキストプロンプトから薬剤名を直接出力する薬剤鑑別手法を提案・評価した。得られた主な結論は以下のとおりである。

1. **特化学習の有効性**：41 薬剤の単一薬剤識別において、提案手法は、人工的な変形を含まない撮影元画像を主指標とする評価で高い精度を達成した（評価用元画像 74 枚で 100%，全 41 薬剤の 5 分割交差検証で $98.6\% \pm 1.5\%$ ）。ファインチューニング前のモデル（拡張あり 814 枚で 0.9%）から大きく向上し、回転・反転を含む拡張画像 814 枚に対しても 98.2% と高い頑健性を示した。外部 API 型マルチモーダル AI の Gemini は拡張画像 814 枚で 82.3% であり、画像変形への頑健性で提案手法が上回った（拡張のない元画像では両者は統計的に同等。McNemar 検定で $p=1.00$ 。4.18 節・??節）。
2. **複数薬剤同時識別の実現**：単剤識別用に学習したモデルを変更せず、「検出→単剤分類」の 2 段階構成により、合成画像 1,000 枚で完全一致率 68.8% を得た。一括質問方式の Gemini は 50.6% であったが、処理方式が異なるため、これはシステム全体の比較である。さらに検出器 LoRA の専用学習と入力解像度の向上により、標準合成画像 200 枚・1024px の条件で 96.0% まで改善した。
3. **軽量化のトレードオフ**：モデルサイズ（0.8B/2B/4B）と 4bit 量子化の影響を単一・複数・混在の 3 条件で定量化した。複数識別では 4B が検証したモデル中で最も高く、量子化 4B（拡張なし元画像での単一 94.6%・拡張あり合成画像での複数 55.2%）は端末搭載の候補となった。実際の搭載可否はスマートフォン実機での検証を要する。
4. **ローカル動作**：以上の全評価は Gemini 比較を除きローカル環境（単一 GPU）で完結しており、薬剤画像を外部サービスへ送信しない薬剤鑑別システムの実現可能性を示した。
5. **汎化性能と妥当性の確認**：自前撮影とは出典および撮影条件が異なる Web 収集画像 136 枚で 96.3% を得た（4.13 節）。学習・評価分割のリーク監査では、設定した閾値の範囲で同一・酷似カットの跨ぎは検出されなかった（4.17 節）。41 薬剤の 5 分割交差検証でも $98.6\% \pm 1.5\%$ が得られ、単一分割の 98.2% が特定の分割に依存しないことを確認した（4.18 節）。主要な比較には McNemar 検定と 95% 信頼区間による統計的裏付けを付した（??節）。なお、同一の拡張なし元画像 287 枚での直接比較では提案手法（98.6%）と Gemini（99.0%）が統計的に同等（ $p=1.00$ ）であり、提案手法の優位性はローカル動作と、回転・反転を含む劣化画像への頑健性にある。また、回転・反転への脆弱性は、学習データへの大角度回転・反転の追加により、標準評価 814 枚で 98.2% から 99.8% へ有意に改善した（4.14 節）。
6. **データ拡張の寄与の分離と未知薬剤対応の予備検証**：学習・評価分割を固定し拡張倍率のみを変えた対照実験により、拡張なし 73.0% に対し 11 種拡張で 97.3% と、データ拡張の寄与を分離して確認した（ $\times 17$ への増強は有意差なし。??節）。また、学習対象外の未知薬剤に対するホワイトリスト方式の予備実験では、未知薬剤 17 枚中 12 枚（70.6%）の保留にとどまり、確信度に基づく保留機構の必要性を明らかにした（??節）。

5.2 今後の課題

本研究の対象は 41 薬剤の PTP シートであり，複数薬剤の評価も主として合成画像に基づいている．今後は，以下の検証が必要である．

- 学習対象外の薬剤や判別困難な画像を保留できる仕組みを確立する．ホワイトリスト方式の予備実験（??節）では未知薬剤への誤断定を完全には防げなかったため，生成スコア，Top-1 候補と Top-2 候補の確信度差，複数候補・複数拡張間の回答一致度などモデルの確信度を用いた保留機構（確信度ゲート）を導入し，誤った薬剤名を断定しない仕組みを検証する．
- 複数の PTP シートを実際に並べて撮影し，薬剤数，配置，照明および背景が変化した条件で検出・識別性能を検証する．
- 同名別用量やメーカー違いの識別を強化するとともに，裸錠，カプセルおよび一包化薬へ対象を拡張する．
- 量子化モデルと専用検出器を組み合わせ，スマートフォン実機で精度，推論時間およびメモリ使用量を評価する．

謝辞

本研究の遂行にあたり，多大なご指導とご助言を賜った森山真光准教授に，心より感謝申し上げます．また，本研究で用いた薬剤画像の撮影にご協力いただくとともに，薬剤鑑別に関する貴重なご助言を賜った共同研究者である近畿大学病院薬剤部の皆様，ならびに木村裕一教授に深く感謝申し上げます．

参考文献

- [1] World Health Organization, “Medication Without Harm,” <https://www.who.int/initiatives/medication-without-harm>, 2017, 2026 年 6 月 2 日閲覧.
- [2] 日本医療機能評価機構, “薬局ヒヤリ・ハット事例収集・分析事業 2024 年年報,” https://www.yakkyoku-hiyari.jcqh.or.jp/pdf/year_report_2024.pdf, 2025, 2026 年 6 月 27 日閲覧.
- [3] 日本医療機能評価機構, “薬局ヒヤリ・ハット事例収集・分析事業 第 34 回報告書: 内服薬の取り違いに関する事例—外観の類似に関連した事例—,” https://www.yakkyoku-hiyari.jcqh.or.jp/pdf/report_34.pdf, 2026, 2026 年 6 月 27 日閲覧.
- [4] 末次王卓, 金澤直子, 正門佳法, 天達菜緒, 副田雪乃, 屋地慶子, 寺菌英之, “AI 画像解析錠剤識別システムの使用による持参薬錠剤一包化鑑別作業の効率化と薬剤助手へのタスク・シフト／タスク・シェアに関する評価,” 医療薬学, Vol. 52, No. 5, pp. 273–281, 2026. <https://doi.org/10.5649/jjphcs.52.273>.
- [5] Junyeong Heo, Youjin Kang, SangKeun Lee, Dong-Hwa Jeong, and Kang-Min Kim, “An Accurate Deep Learning-Based System for Automatic Pill Identification: Model Development and Validation,” *Journal of Medical Internet Research*, Vol. 25, p. e41043, 2023. <https://doi.org/10.2196/41043>.
- [6] Richárd Rádli, Zsolt Vörösházi, and László Czúni, “Metric-based pill recognition with the help of textual and visual cues,” *IET Image Processing*, Vol. 18, No. 14, pp. 4623–4638, 2024. <https://doi.org/10.1049/ipr2.13273>.
- [7] Richárd Rádli, Zsolt Vörösházi, and László Czúni, “Word and Image Embeddings in Pill Recognition,” in *Proceedings of the 19th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications (VISIGRAPP 2024)*, Vol. 4: VISAPP, pp. 729–736, 2024. <https://doi.org/10.5220/0012460800003660>.
- [8] R. Menaha, R. Abilaash, P. N. Mohanram, A. Unnikrishnan, and S. Sukumar, “Drug Pills Identification System using Google Gemini LLM: A Generative AI approach,” in *2024 International Conference on Emerging Research in Computational Science (ICERCS)*, pp. 1–5, 2024. <https://doi.org/10.1109/ICERCS63125.2024.10895371>.
- [9] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen, “LoRA: Low-Rank Adaptation of Large Language Models,” in *Proceedings of the 10th International Conference on Learning Representations (ICLR)*, 2022. <https://arxiv.org/abs/2106.09685>.
- [10] Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou, “Qwen-VL: A Versatile Vision-Language Model for Understanding, Localization, Text Reading, and Beyond,” arXiv preprint arXiv:2308.12966, 2023. <https://arxiv.org/abs/2308.12966>.
- [11] Qwen Team, “Qwen3-VL Technical Report,” arXiv preprint arXiv:2511.21631, 2025. <https://arxiv.org/abs/2511.21631>.