

収集画像を用いたPTP包装識別

近畿大学 B4／呉竹 權人／2026年9月10日

1. 学術的な問い

フルシートの表面1枚と裏面1枚だけを元に、画像拡張を加えて学習しても実写を識別できるか

薬剤の取り違いは医療安全上の重要な課題です。外観や名称の類似が誤認の一因となっています。本研究の目的は、PTP包装の写真から薬剤名を識別することです。従来は薬剤ごとに、残存錠数や向きを変えた学習用写真を個別に撮影する必要がありました。本研究では、1薬剤につきフルシートの表面1枚と裏面1枚だけを元にRTI・部分画像を作り、画像拡張を加えた学習だけで、視覚言語モデルをLoRAで追加学習します。

問いは三つあります。①フルシートの表面1枚と裏面1枚だけを元に、画像拡張を加えて学習しても実写を識別できるか。②学習薬剤数を増やしても精度を保てるか。③未学習薬剤への誤回答を抑えられるか、です。

卒業研究報告書「260930.pdf」を提示し、研究内容、評価結果、研究計画の順に報告します。

2. 研究がわかる数式や図

学習と推論を分け、回答する前に信頼ゲートを通す

図1に研究全体の構成を示します。学習側ではRTIと部分画像を用意し、画像と薬剤名の対応を学習します。推論側では写真から薬剤名を生成し、信頼ゲートで回答するか保留するかを判定します。




図1 学習から回答判定までの全体構成を示す。

単剤識別、複数薬剤識別、信頼ゲートは、異なる評価集合で測定します。正解判定では、薬剤名をNFKC正規化・小文字化・記号除去したうえで、完全一致するか、期待する薬剤名が出力に含まれていれば正解とします。

元画像からRTIを作り、全体・部分画像を取り出す

図2に元画像からRTIを作る手順を示します。表裏を分離し、背景除去と向き・大きさの調整を行います。裏面を左、表面を右へ配置し、448×448画素のRTIを作成します。

① 表裏の元画像を用意する

② 背景除去・向き・大きさを整える

③ 裏を左、表を右に並べる



例：メインテート錠2.5mg。RTIは切り出しの基準にも使う。最高精度条件ではRTIそのものは学習しない。

図2 保存画像からのRTI作成手順を示す。

RTIを基準として、全体画像と1錠・1/2・1/4の部分画像を作成します。後述の3seed比較では全体＋部分画像を学習し、RTIそのものは学習しませんでした。

LoRAで、学習済みモデルを薬剤識別に合わせる

LoRAは、元の重みを固定したまま必要な変化だけを小さく付け足し、その分だけを学習する手法です。視覚言語モデルQwen3.5-4Bの重みは固定し、図2で準備した学習画像を使って付け足した小さな部分だけを調整します。これにより、PTP包装の写真から薬剤名を生成できるようになります。

LoRAで、学習済みモデルを薬剤識別に合わせる

元の重みは固定し、収集画像と正解の薬剤名で「追加部分」だけを学習する。




図2補足 対象の重みの概念図。回答時は、学習済みのLoRAを使い、重みを更新しない。

図2補足 灰色は固定する元の重み、青色は追加学習する調整分である。

付け足す部分の重みは、次の式で表せます。

$$W = W_0 + (\alpha / r)BA$$

モデル全体を更新するよりも少ない計算量で薬剤識別に適応できます。対象名や実装の出典は[補足資料](#)に示します。

条件DのLoRA重みでは、視覚エンコーダには付かず言語モデル部のみに付いており、学習パラメータの割合は全体の0.4656%でした。ただしこれは学習後の重みを事後に開いて調べた結果であり、由来を示す記録もないため、卒論記載の条件Dの最終重みと同一とは断定できません。

複数薬剤は候補領域を切り出し、一枚ずつ識別する

図3に複数薬剤の処理手順を示します。候補枠は、**OpenCVによる「Cannyエッジ検出+モルフォロジー処理+輪郭抽出」**で作成します。画像の明暗の境目を探し、近くの境目をまとめて枠で囲む仕組みです。

- 1. 境目を探す：** グレースケール化とガウシアンぼかしで細かなノイズを減らします。Cannyエッジ検出により、包装や印字の明暗の境目を線として取り出します。
- 2. 線を領域へまとめる：** クロージングと膨張というモルフォロジー処理で、途切れた線や近い線をつなぎます。長い縦横線を除いた補助画像からも候補を作成します。
- 3. 枠で囲む：** 輪郭抽出（findContours）で線のまとまりを探します。外接矩形（boundingRect）で囲み、面積・縦横比・輪郭の密度などで候補を絞り込みます。
- 4. 重複を減らす：** 面積・輪郭の詰まり具合・エッジ密度から候補の強さを計算します。強い順に残し、既存の枠と大きく重なる候補を除きます。最終的に最大10候補を識別へ回します。


実装はtraining_preprocess.pyのforeground_maskと、detect_top10_regions.pyのdetect_top_candidatesです。この段階では薬剤名も正解の薬剤数も使いません。

複数薬剤の識別：候補抽出 → 画像の整形 → 1枚ずつ識別

① 入力：3薬剤を並べた合成画像



② 画像処理で候補枠を抽出する



前景の輪郭をまとめる → 重複する枠を減らす → 前景の強さで最大10候補を残す

③ 候補ごとに背景除去・向き補正を行い、黒背景448×448画素に整える



候補1



候補2



候補3



候補4：余分な検出

④ 各画像を視覚言語モデル+LoRAへ入力し、薬剤名を生成する。

図3 複数薬剤の入力・候補枠・整形後の4枚を示す。

各候補の背景を除去し、向きと大きさを整えます。黒背景448×448画素の画像を1枚ずつ視覚言語モデルへ渡し、薬剤名を識別します。**この写真は3薬剤から4候補を検出した実例であり、候補4には余分な背景が含まれます。**正しく3枚に分離できた例ではありません。

評価では、余分な予測を許す「全候補包含」と、薬剤数Nが既知として上位N候補を残す「個数既知Top-N」を区別します。候補の順位は画像処理の強さによるものであり、薬剤名の正解確率ではありません。

3. 評価結果となる数値のサマリ

ver1～ver9の単剤結果と条件の比較

基本条件ver1では、RTI+分画画像457枚を回転12種+明るさ5種で7,769枚へ拡張しました。4bit QLoRA (r8/ α 16)、5epoch、実効バッチ16、学習率0.0002、448×448画素、seed 42を使用しています。

図4に基本条件ver1の学習前画像を示します。この薬剤では、表裏を並べたRTI 1枚と、表裏を対にした分画画像10枚を用いました。41薬剤全体では457枚となります。各画像に回転12種と明るさ5種を別々に適用し、合計17種へ増やしました。



図4 基本条件ver1に使った一薬剤の全11枚を示す。

表1 実写41薬剤287枚の単剤Top-1精度（各条件はseed 42の単発結果）

条件	主な変更	正解数／287枚	精度
ver1	RTI+分画画像を使用	259/287	90.24%
ver2	表裏全体と固定部分画像を追加	255/287	88.85%
ver3	位置・大きさの違う部分画像を追加	281/287	97.91%
ver4 C	BF16・r16へ変更	283/287	98.61%
ver4 D	ぼけ・遠近変化などを追加	280/287	97.56%
ver5 B	PTPの部分画像を追加	281/287	97.91%
ver6	LoRAをr32へ拡大	286/287	99.65%
ver7	中央画像・空間条件を追加	284/287	98.95%
ver8	単剤用と複数用の2経路化	286/287	99.65%
ver9	低解像度画像を追加	286/287	99.65%

単発結果ではver6系が99.65%でしたが、3seed平均とは分けて扱っています。

ver1～ver9の複数薬剤結果（同じ800枚での比較）

複数用モデルも各条件のseed 42で比較しました。評価は隙間なし合成800枚（2・3・5・8薬剤を各200枚）であり、単剤287枚とは別のデータセットです。

表2 ver1～ver9の複数薬剤結果を示す。


条件	全候補に正解を含む（余分な予測を許す）	薬剤数既知Top-N（残した薬剤がすべて一致する）
ver1	495/800（61.88%）	439/800（54.88%）
ver2	278/800（34.75%）	252/800（31.50%）
ver3	366/800（45.75%）	326/800（40.75%）
ver4 C	690/800（86.25%）	600/800（75.00%）
ver4 D	610/800（76.25%）	532/800（66.50%）
ver5 B	790/800（98.75%）	681/800（85.13%）
ver6	699/800（87.38%）	600/800（75.00%）
ver7	711/800（88.88%）	599/800（74.88%）
ver8	790/800（98.75%）	682/800（85.25%）
ver9	709/800（88.63%）	609/800（76.13%）

最高の個数既知Top-Nはver8の85.25%でした。ただし、この合成画像の評価を実写複数薬剤の性能とはみなせません。

高精度条件における学習画像と拡張手法

図5にメインテート錠2.5mgの学習画像を示します。今回の実験81・82の比較では、41薬剤・r32/ α 64・回転12種＋明るさ5種の条件が、3seed平均98.84%で最も高くなりました。

① 元画像からRTIを作る




RTIを表・裏に分ける
RTI自体は学習対象外である

② 全体・部分画像30枚を学習に使う



全体2枚 + 1/2区画4枚 + 1/4区画8枚 + 1錠区画16枚

③ 各画像に17種の拡張を行う



回転：0～330°を30°刻みで12種
明るさ：0.8・0.9・1.0・1.1・1.2倍の5種

例：メインテート錠2.5mg。右側は表面全体で示した拡張見本であり、同じ17種を各基画像に適用する。

図5 元画像・RTI・学習用30枚・拡張17種を示す。

メインテート錠2.5mgでは全体2枚、1/2区画4枚、1/4区画8枚、1錠区画16枚を用いました。回転0〜330°を30°刻みで12種、明るさ0.8〜1.2倍を0.1刻みで5種としています。RTI自体は学習対象から除外しました。

その後の3seed比較では、41薬剤条件で98.84%でした

実験81・82の比較では、全体＋部分画像、回転12種＋明るさ5種、BF16、r32/α64で学習した実験82の41薬剤条件が最も高くなりました。

表3 実写41薬剤287枚の単剤Top-1精度を示す。

seed 42	seed 43	seed 44	3seed平均 ± 標本SD
286/287 (99.65%)	284/287 (98.95%)	281/287 (97.91%)	98.84% ± 0.88pt

学習条件は5epoch、実効バッチ128、学習率0.0002、448×448画素です。SDの単位はptであり、同じ287枚を3回評価しました。

実行環境はH100、CUDA 12.8、Python 3.13.5、PyTorch 2.11.0+cu128、Transformers 5.14.1、PEFT 0.19.1です。なお、基本条件ver1の学習にはRTX 4070 Ti SUPERを使用しました。

100薬剤までの全段階における各seedと平均の推移

共通条件は全体＋部分画像（RTIなし）、BF16、5epoch、学習率0.0002、実効バッチ128、448×448画素です。評価は全段階で一貫して同じ実写41薬剤287枚としました。

図6に41〜100薬剤の全7段階を示します。プロットした点は各seed、線は3seed平均、誤差棒は標本SDを表します。実験81と82はLoRA容量と拡張内容が異なるため、分けて表示しています。

41 → 100薬剤：同じ実写41薬剤287枚で評価した




図6 学習薬剤数ごとの各seedと3seed平均を示す。

実験81は撮影変動も加える17種・r16/α32で学習し、実験82は回転12種＋明るさ5種・r32/α64で学習しました。
100薬剤では実験81の96.40% ± 2.64ptが高くなりました。
なお、実験80は実験81の100薬剤条件と同じrunです。100薬剤全体の実写性能はまだ評価していません。

信頼ゲートによる三つの確認と保留判定

図7に信頼ゲートの判定手順を示します。ここでは、実験82の41薬剤モデル3seedへ既存の閾値を再調整せず適用しました。




図7 登録名、回答一致、スコアの順に確認する手順を示す。

閾値は、調整用データで決めた値を3seedへ共通に適用

「調整用で値を決める→値を固定する→別の画像で評価する」という順序で設定しました。

元の信頼ゲートでは、調整用 既知139枚・未知67枚のデータを使いました。回答を残せる割合と、誤回答を止められるかを確認し、次の条件を最終評価の前に固定しています。

- 登録名を確認：
元画像の第1候補と、TTAの最多回答がともに学習済み41薬剤名の一覧に入ることとしました。
- 回答の安定性を確認：
回転や明るさなどを変えた11通りの画像で識別するTTAを使いました。同じ薬剤名への一致率を
0.90以上（11回中10回以上の一致に相当）としました。
- 生成スコアを確認：第1候補の生成スコアを **-0.02以上** としました。値が0に近いほどモデルがその名前を生成しやすいことを示しますが、正解確率を意味する値ではありません。
- 候補間の差を確認：第1候補と第2候補の生成スコア差（margin）を **0.12以上** とし、候補間の差が小さい回答を保留としました。

元の実験では、値をJSONへ保存してから、別の既知148枚・未知58枚で評価しました。**今回の表4の3seed評価では、この既存値をそのまま使っており、実験82のモデルや各seedに合わせた閾値の再調整は行っていません。**

また、TTAの最多回答と元画像の第1候補が同じであることは必須条件にしませんでした。

記録から確認できたのは調整用データでの設定と事前固定であり、この数値が最適であるという保証はありません。

表4 ゲート専用の既知148枚・未知58枚での結果を示す。

指標	seed 42	seed 43	seed 44	3seed平均 ± SD
既知の回答率	94.59%	88.51%	89.19%	90.77% ± 3.33pt
既知の回答時正解率	100%	100%	100%	100% ± 0.00pt
未知の保留率	81.03%	94.83%	79.31%	85.06% ± 8.50pt
未知への誤回答数／58枚	11件	3件	12件	8.67件 ± 4.93件

既知の回答には誤りはありませんでしたが、未知への誤回答は残りました。閾値の再検討と、新たな写真での検証が必要と考えています。

4. 研究計画

9月に手法を検証し、10・11月に薬剤部で撮影する

表5 月ごとの研究計画を示す。[研究計画書 \(README.md\)](#)にも同じ内容を示す。

時期	内容
9月 (9/15～)	手法を検証する。LoRA・RTI・部分画像の効果を分けて確かめる。Gemini 3.8 Flashとの比較を行う。撮影の日程を薬剤部・指導教員と調整する。
10月・11月	薬剤部で撮影する（追加薬剤・未学習薬剤・複数薬剤）。学習画像と対象薬剤をN薬剤まで増やし、拡張方法と学習条件を調整する。信頼ゲートを検証する。未学習薬剤への誤回答と保留を評価する。
12月	最終調整（できていないことをする）。
1月（～1/20）	発表準備。

複数薬剤はおまけ程度の位置づけとし、主目的は単剤の識別精度向上と未学習薬剤への誤回答対策です。

結論として、フルシート表裏各1枚から生成・拡張した学習画像による単剤識別は3seed平均98.84%を得ました。100薬剤学習では96.40%が高く、複数薬剤では個数既知条件で85.25%を得ました。この構成は実現できた一方、追加薬剤の実写性能と未知薬剤への誤回答防止は課題として残っています。