

卒業研究報告書

題目

収集画像から生成した RTI・部分画像を用いた
マルチモーダル LLM による PTP 包装識別

指導教員

森山 真光 准教授

報告者

23-1-211-0009

呉竹 權人

近畿大学情報学部情報学科

令和 8 年 9 月 30 日提出

概要

薬剤の取り違い防止には、外観が類似する PTP 包装を正確に識別する必要がある。撮影画像だけを学習元とする場合、残存錠数や切り出し範囲を変えた学習用写真を薬剤ごとに個別に撮影する必要がある。本研究では、1 クラスにつきフルシートの表面画像 1 枚と裏面画像 1 枚を学習元とし、そこから学習集合を構成する方法を検討した。表裏を結合した Re-oriented Two-sided Image (RTI) と複数サイズの部分画像を生成し、41 クラスを対象としてマルチモーダル LLM である Qwen3.5-4B を LoRA で追加学習した。本研究の目的は、この構成で 41 クラスの PTP 包装識別性能を評価することである。評価には、大学病院内部開発評価画像 287 枚を用いた。

本報告書で主結果として扱う ver4 条件 D は、内部開発評価画像 287 枚中 280 枚を正しく識別し、単剤 Top-1 精度 97.56% であった。同条件の合成複数薬剤画像 400 枚では、画像単位完全一致率 82.75%、領域ラベル一致率 95.83% であった。さらに、隙間のない元写真タイルによる探索的な複数薬剤評価 800 枚では、薬剤数を知らせず最大 10 候補を残す方式の正解薬剤包含率が最高 790/800 (98.75%)、薬剤数を既知とする Top-N 方式が最高 682/800 (85.25%) であった。これは固定 400 枚の黒い隙間評価とは別の評価である。結果確認後の探索的追試 ver6 は 286/287 (99.65%) を示したが、条件 C との対応比較で有意差は認められなかった。

本報告書では、ver4 条件 C のアダプタに対して、信頼できない入力への回答を保留する信頼ゲートの予備評価を行った。最終評価集合（既知 148 枚・未知 58 枚）では、未知薬剤 58 枚中 8 枚 (13.79%) に既知薬剤名を回答し、危険通過を 0 件にはできなかった。また、学習に用いる薬剤の種類数を 41 薬剤から 100 薬剤まで段階的に増やし、全段階で同一の実写 41 薬剤 287 枚（単剤 Top-1）を評価したところ、精度は学習薬剤数に対して単調に変化しなかった。研究内で単剤評価が最も高かった実験 82 番 41 薬剤条件（3seed 平均 98.84% ± 0.88pt）に対して、信頼ゲート ver2 の凍結しきい値を再校正せずに適用したところ、未知薬剤への危険通過は seed によって 3 件から 12 件まで変動した。

以上より、本研究は 41 クラスを対象とした識別を実行できることを確認した。一方、新しい薬剤への一般化、他方式に対する優越性、実用性および未知薬剤に対する安全性は確認していない。評価に用いた 287 枚は条件検討に反復使用しており、条件を決めた後に新しく撮影した写真での確認は行っていない。学習元をフルシートの表裏 2 枚に限定できる構成としたが、収集、撮影および前処理を含む総作業時間は比較しておらず、作業負担の削減量も確認していない。今後の課題は、対象とする薬剤の数を増やすことと、学習対象外の薬剤に対して誤った薬剤名を答えない仕組みを整えることである。

目次

1	序論	1
1.1	研究背景	1
1.2	研究課題	1
1.3	研究目的と提案	1
1.4	本報告書の構成	3
2	関連研究・関連技術	4
2.1	薬剤画像の認識	4
2.2	Vision-Language Model とマルチモーダル LLM	5
2.3	LoRA と QLoRA	5
2.4	画像拡張の関連技術	6
2.5	未知入力の見出しと選択的分類	6
2.6	本研究の位置付け	6
3	提案手法	8
3.1	処理の全体像	8
3.2	収集画像の由来監査	9
3.3	RTI と部分画像の生成	9
3.4	画像拡張	12
3.5	LoRA 学習	13
3.6	評価方法	14
4	実験結果・考察	21
4.1	実験環境とデータ監査結果	21
4.2	初期実画像方式と収集画像学習への移行	22
4.3	収集画像学習 ver1 から ver3	24
4.4	収集画像学習 ver4 (ver4 条件 A から D の比較)	25
4.5	収集画像学習 ver5	28
4.6	収集画像学習 ver6 (LoRA 容量の探索的追試)	28
4.7	ver6 の単剤評価	29
4.8	追加学習していない Qwen3.5-4B との比較	30
4.9	Gemini 3.5 Flash との対応比較	31
4.10	ver6 の合成複数薬剤画像評価	32
4.11	収集画像学習 ver7 (探索的追加実験)	33
4.12	収集画像学習 ver8・ver9 の単剤評価	33
4.13	黒い区切りのない合成画像による予備評価	34
4.14	ver4 条件 C の信頼ゲート評価	37
4.15	学習薬剤数の段階増加 (41 から 100 薬剤)	38
4.16	最高精度モデル (実験 82 番 41 薬剤条件) への信頼ゲート適用	40
4.17	隙間のない合成複数薬剤画像: 最大 10 候補と Top-N 評価	41
4.18	総合考察	42
4.19	妥当性の限界	43
5	結論・今後の課題	44
5.1	結論	44
5.2	今後の課題	44

謝辭	46
参考文献	47

1 序論

1.1 研究背景

薬剤の取り違いや誤服用は、患者の健康被害につながる医療安全上の課題である。世界保健機関（World Health Organization : WHO）は、投薬に関連する回避可能な健康被害の削減を国際的な目標としている [1]。国内でも、調剤時の薬剤取り違いが継続して報告されている [2]。外観が類似した内服薬の取り違いも分析対象となっている [3]。

医療現場では、外箱や薬袋がない状態で薬剤を鑑別する場合がある。この場合、錠剤の形状、刻印、色、PTP（Press Through Package）包装上の印字などを手掛かりとする。末次らは、AI 画像解析錠剤識別システムを持参薬の一包化鑑別に導入し、作業時間の短縮とタスク・シフトの可能性を報告している [4]。この報告は、薬剤識別の自動化が薬剤師の負担軽減に寄与し得ることを示している。

1.2 研究課題

画像認識モデルを新しい薬剤へ対応させるには、薬剤ごとの学習画像が必要である。薬剤画像の認識に関する先行研究は、いずれも学習用の薬剤画像データセットを構築したうえで手法を評価している [5, 6, 7]。撮影画像だけを学習元とする場合、残存錠数、切り出し範囲および向きを変えた学習用写真を薬剤ごとに個別に撮影する必要がある。学習画像が不足する場合の一般的な対処としては、幾何変換や色変換によって学習画像の多様性を高める画像拡張が用いられる [8]。そこで本研究では、1 クラスにつきフルシートの表面 1 枚と裏面 1 枚を学習元とし、そこから派生画像を生成する構成を検討する。この構成では、残存錠数や切り出し範囲を変えた学習用写真を個別に撮影する必要がない。ただし、収集画像の取得、出典確認、撮影、背景除去、ラベル確認および前処理に要する時間は方式間で比較していない。このため、総作業時間または総作業負担の削減量は本研究の評価対象ではない。本研究で直接検証するのは、1 クラスにつきフルシートの表面 1 枚と裏面 1 枚だけを学習元とし、そこから派生画像（RTI・部分画像）を生成して画像拡張を適用した学習集合により、大学病院薬剤部で撮影した実写の内部開発評価画像について、あらかじめ定めた 41 クラスの中から薬剤名を正しく答えられるかどうかである。

PTP 包装には、錠剤本体だけでなく、薬剤名、含量、識別コードなどの文字情報が含まれる。一方、表面と裏面では得られる情報が異なる。片面だけを学習すると、撮影面が変わった場合に識別根拠が不足する。また、フルシートだけを学習すると、切り分けられた PTP 包装や一部だけが写る画像へ対応しにくい。

1.3 研究目的と提案

本研究の目的は、1 クラス当たりフルシートの表面画像 1 枚と裏面画像 1 枚から RTI および部分画像を生成して学習集合を構成し、41 クラスの PTP 包装識別性能を評価することである。モデルは、あらかじめ定めた 41 クラスの中から薬剤名を答える。

評価には、大学病院内部開発評価画像 287 枚を用いる。本報告書では、この 287 枚を内部開発評価画像と呼ぶ。内部開発評価画像は、収集画像から構成した ver1 から ver9 の LoRA 学習集合には含めていない。一方、同じ 287 枚を条件検討に反復使用し、研究初期の実画像方式では一部を学習にも用いた。そのため、条件決定後に初めて使用する独立最終評価集合ではない。

本報告書では、画像と質問文を入力し、薬剤名を文字列として生成する Qwen3.5-4B を、マルチモーダル LLM として扱う。視覚言語モデル（Vision-Language Model : VLM）との関係は 2.2 節で述べる。提案手法は、表裏のフルシート収集画像を正規化する。次に、表裏を結合した RTI と複数の大きさの部分画像を生成する。これらの画像に各実験条件で定めた撮影変動を適用し、マルチモーダル LLM を LoRA で追加学習する。評価では、収集画像学習に使用していない、大学病院内部開発評価画像を用いる。主指標は単剤 Top-1 精度と Wilson 法による 95% 信頼区間とする。加えて、誤分類の組合せを列挙する。

本研究で直接評価するのは、単剤 Top-1 精度、合成複数薬剤画像の画像単位完全一致率と領域ラベル一致率、ならびに条件間の画像別正誤対応である。あわせて、追加学習していない Qwen3.5-4B や Gemini 保存予測との比較、ver4 条件 C の信頼ゲートによる予備評価、学習薬剤数を 41 から 100 へ段階的に増やした際の既知 41 薬剤の精度、および実験 82 番 41 薬剤条件への凍結しきい値適用を評価する。一方、新しい薬剤への一般化、臨床利用の可能性、総作業時間の削減量、RTI と部分画像の個別寄与、実写複数薬剤の実用性能、および未知薬剤に対する安全性の確立は、直接評価していない。

本報告書では、検証課題を次の 5 つに分ける。

1. 本報告書で主結果として扱う ver4 条件 D が、内部開発評価画像でどの程度の識別性能を示すか。
2. ver4 条件 C から LoRA ランクを増やした ver6 で観測値がどう変化するか（探索的追試）。
3. 合成複数薬剤画像および黒い区切りのない予備画像で、検出と識別がどこまで成立するか（探索的副次評価）。
4. ver4 条件 C に適用した信頼ゲートが、未知薬剤への回答を安全に保留できるか（探索的安全性評価）。
5. 追加学習していない Qwen3.5-4B、保存済み Gemini 3.5 Flash 予測と LoRA 条件の正誤対応がどう異なるか（探索的比較）。

本研究の課題、解決策、評価方法の関係を表 1 に示す。課題に対し、少数の収集画像を複数の学習画像に変換する。その結果を、学習元とは撮影条件の異なる大学病院薬剤部の写真で評価する。

表 1 研究テーマの課題、解決策、評価方法

項目	内容
課題	薬剤数を増やす際に、残存錠数や切り出し範囲を変えた学習用写真を薬剤ごとに個別に撮影する必要がある。
解決策	1 クラスにつきフルシートの表面 1 枚と裏面 1 枚から RTI と部分画像を生成し、画像拡張を用いてマルチモーダル LLM を LoRA 学習する。
評価方法	大学病院内部開発評価画像 287 枚について、単剤 Top-1 精度、Wilson 法による 95% 信頼区間、誤分類一覧を示す。合成複数薬剤画像は副次評価とし、学習薬剤数の段階増加と信頼ゲートの予備評価も記述する。

本研究は、あらかじめ定めた 41 クラスの中から薬剤名を答える識別を対象とする。錠剤そのものを対象とする鑑別全般や、41 クラス以外の薬剤が入力される場合の識別は対象としない。診断、処方、服薬指示には用いず、医療従事者による確認を伴わない臨床利用も対象としない。また、未知薬剤に対する信頼ゲートは予備評価であり、安全性が確立した機構として扱わない。

1.4 本報告書の構成

第2章では、薬剤識別、VLM およびマルチモーダル LLM, LoRA, 画像拡張, 未知入力の保留に関する研究を整理する。第3章では、収集画像から学習データを生成する手法と評価方法を示す。第4章では、初期実画像方式から収集画像学習 ver5 に至る経緯, および本報告書で主結果として扱う ver4 条件 D の結果を示す。続いて, ver6・ver7 の探索的追試と ver8・ver9 の単剤評価, 追加学習していない Qwen3.5-4B および Gemini 3.5 Flash との比較, 合成複数薬剤評価, 条件 C に適用した信頼ゲートの補足結果, ならびに実画像に基づく誤分類分析を示す。さらに 4.15 節で, 学習薬剤数を 41 から 100 へ段階的に増やしたときの既知 41 薬剤の結果と, 4.16 節で実験 82 番 41 薬剤条件への信頼ゲート適用結果を示す。第5章では, 得られた結論と今後の課題を述べる。

2 関連研究・関連技術

2.1 薬剤画像の認識

Heo らは、錠剤の刻印、形状、色、剤形を認識し、薬剤データベースを検索する手法を提案している [5]。同手法は、刻印検出、外観特徴の認識、文字列補正、候補検索を組み合わせる。識別モデルの学習に含まれない薬剤でも、データベースに外観特徴と薬剤情報が登録されていれば検索候補にできる。一方、データベースにも未登録の薬剤を同定できることを意味するものではなく、複数の専用モデルを構成する必要もある。刻印が不鮮明な場合には、検索に用いる情報が不足する可能性がある。

Rádli らは、薬剤画像の特徴と薬剤説明文の単語埋め込みを組み合わせている [6]。さらに、視覚的手掛かりとテキスト情報を用いるメトリクス学習を提案している [7]。Rádli らは、薬剤ごとに異なる説明文の意味情報と画像特徴を学習に用いている。一方、本研究のテキスト入力、全画像に共通するタスク指示であり、薬剤固有の説明情報を与えるものではない。本研究は、画像と共通質問文を単一のマルチモーダル LLM へ入力し、対象クラス名を文字列として生成する点で異なる。

薬剤画像認識に関する手法は数多く提案されており、Nguyen らは、データセット、前処理、特徴抽出および識別手法の観点から整理している [9]。このうち、1 クラス当たりの学習画像が少ない設定は低ショット認識として扱われている。Usuyama らは、4,902 種類の錠剤の表裏に対応する 9,804 クラス、約 13,000 枚から成る公開ベンチマーク ePillID を構築した [10]。同ベンチマークでは、大半のクラスについて統制された環境で撮影した参照画像が片面 1 枚しか存在せず、これに対して撮影条件の異なる実利用画像を識別する。Usuyama らは、CNN の後段に双線形変換層を置く多頭メトリクス学習によって、この低ショット設定へ対処している。Ling らは、実環境で撮影した 196 クラス・8,649 枚の CURE データセットを構築し、領域分割用のネットワークと複数系列の特徴を統合する識別器を、2 段階の学習手順で訓練している [11]。

これらの研究は、1 クラス当たりの参照画像が少ないという点で本研究と近い。一方、いずれも識別対象は錠剤本体であり、参照画像も撮影されたものである。また、学習した埋め込み空間で参照画像と照合する方式であるため、識別できるのは参照画像が登録されたクラスに限られる。本研究は、識別対象を PTP 包装とし、参照画像を撮影せずに収集画像から複数の派生画像を生成する点で異なる。さらに、埋め込みの照合ではなく、マルチモーダル LLM がクラス名を文字列として生成する点でも異なる。

Menaha らは、Google Gemini を用いた薬剤識別支援システムを提案している [12]。生成 AI を薬剤画像へ適用する点は本研究と近い。ただし、同研究は外部サービスを用いるプロンプト型の手法である。本研究は、重みを取得可能なモデルを薬剤画像で追加学習する。ただし、本研究では学習と推論をいずれも GPU 計算機上で実行しており、端末上での動作は評価していない。

Han らは、専用の撮影装置を用いて PTP 包装の表面と裏面を同時に撮影する手法を提案した [13]。向きと大きさを正規化した両面画像である RTI を作成し、畳み込みニューラルネットワーク (Convolutional Neural Network: CNN) に入力して識別を行う。原論文の比較実験では、表面、裏面および RTI を同じ識別器群へ入力し、RTI で高い F1 値を報告した。本研究は、この両面統合という着想を RTI として採用する。一方、Han らは上下 2 台のカメラを備えた専用装置を前提とし、包装全体の外形が得られることを想定している。本研究は、専用装置を用いず、収集画像と部分的な PTP 包装画像も対象とする点で異なる。Han らは各片面を 448×224 画素に正規化し、左右結合後の RTI を 448×448 画素としたうえで、識別器入力を 224×224 画素に変換した。本研究は左右結合後の画像を 448×448 画素に直接リサイズするため、結合前の縦横比を保持し

ていない。

2.2 Vision-Language Model とマルチモーダル LLM

画像とテキストを同一モデルで扱う手法は、一般に視覚言語モデル（Vision-Language Model : VLM）と呼ばれる。本報告書では、このうち大規模言語モデルを基盤とし、画像と質問文を入力して文字列を生成するものをマルチモーダル LLM と呼ぶ。関連研究の一般名称としては VLM を用い、本研究が追加学習する対象を指す場合はマルチモーダル LLM を用いる。

Bai らは、画像とテキストを統合して扱う Qwen-VL を提案している [14]。Qwen-VL は、視覚的質問応答、画像中の文字読み取り、物体位置の理解を扱う。Qwen3-VL では、視覚理解と文書理解がさらに拡張されている [15]。

この Qwen-VL 系列を含め、マルチモーダル LLM は共通する 3 つの部分から構成される [14, 15]。第一に、入力画像を小領域に分割して特徴ベクトルの列に変換する視覚エンコーダである。第二に、視覚エンコーダの出力を言語モデルのトークン表現空間へと写像する射影部である。第三に、射影した視覚トークンと質問文のトークンを連結して受け取り、次のトークンを逐次予測して文字列を生成する大規模言語モデルのデコーダである。この構成により、画像中の文字と外観の双方を同一の系列として扱い、分類ラベルの番号ではなく薬剤名という文字列を出力できる。PTP 包装では、文字情報と外観情報の双方が識別手掛かりとなるため、両者を同一モデルで扱えるマルチモーダル LLM を採用する。なお、LoRA による追加学習の対象は、本研究ではこれら 3 部分のうち線形射影層に限る。その具体的な対象モジュールは第 3 章で述べる。

本研究では、Qwen3.5-4B の特定のリビジョンを用いる [16]。入力画像に「この錠剤は何という薬ですか？ 薬剤名だけで教えてください。」という質問を与える。出力は薬剤クラス名と同じ規則で正規化し、第 3 章に示す文字列一致規則で評価する。

2.3 LoRA と QLoRA

LoRA（Low-Rank Adaptation）は、事前学習済みモデルの重みを固定し、低ランク行列を追加学習する方法である [17]。元の重み行列を $W_0 \in \mathbb{R}^{d \times k}$ とすると、学習後の変換は式 (1) で表す。

$$h = \left(W_0 + \frac{\alpha}{r} BA \right) x, \quad A \in \mathbb{R}^{r \times k}, \quad B \in \mathbb{R}^{d \times r} \quad (1)$$

ここで、 $x \in \mathbb{R}^k$ は入力、 $h \in \mathbb{R}^d$ は出力、 r はランク、 α は更新量の倍率を調整する係数である。 r を大きくすると学習可能パラメータ数が増え、 α/r が 1 回の更新で元の重みに加える変化の大きさを定める。学習対象は、アテンション層および MLP 層の線形射影のうち任意の部分集合を選べる。条件 D の最終 LoRA 重みを事後に開いて調べたところ、付加箇所は視覚エンコーダには存在せず言語モデル部の線形射影のみであり、学習パラメータの割合は全体の 0.4656% であった。ただし、この数値は学習後の重みを事後に調べた結果であり、作成過程の記録がないため、条件 D の学習時点の設定と同一であると断定はできない。

QLoRA（Quantized LoRA）は、事前学習済みモデルを 4 ビットに量子化し、LoRA を学習する方法である [18]。必要な GPU メモリを削減できる一方で、量子化が対象課題の性能に与える影響を確認する必要がある。本研究で用いる r 、 α 、学習対象層および量子化の有無は、条件ごとに第 3 章で示す。

2.4 画像拡張の関連技術

画像拡張は、幾何変換や色変換によって学習画像の多様性を高める方法である [8]。PTP 包装の撮影では、向きと照明が変化する。このため本研究では、回転、明度、コントラスト、ガンマ、台形歪み、ぼけおよびセンサノイズを組み合わせた提示条件を用いる。いずれも薬剤クラスを維持したまま、撮影時の向き、明るさ、形状および画質の変動を模擬することを目的とする。条件ごとに用いる提示条件の具体的な内訳は第 3 章で示す。

2.5 未知入力検出と選択的分類

Hendrycks らは、最大予測確率を用いて誤分類と分布外入力を検出する基準を示している [19]。同時に、分布外入力に対して高い確信度を出力する場合があることも指摘している。薬剤鑑別では、未知薬剤を既知薬剤として回答すると危険な誤回答になり得る。

その後、分布外入力の検出手法は数多く提案されている。Yang らは、これらを分布外検出、オープンセット認識および異常検知を含む枠組みとして整理している [20]。たとえば Liu らは、出力のログジットから求めるエネルギー値が、最大予測確率より分布内と分布外を分離しやすいことを示している [21]。一方、本研究の信頼ゲートは、最大予測確率と同様にモデル自身の出力だけを信号とする素朴な構成である。これらの手法は適用していないため、本研究の危険通過率は、現在の分布外検出手法で到達できる水準を示すものではない。

選択的分類は、確信できない入力への回答を保留し、回答率と誤り率を調整する考え方である [22]。本研究では、この考え方に基づく保留機構を信頼ゲートと呼ぶ。ver4 条件 C に信頼ゲートを適用した評価は、探索的追試 ver6 とは異なるアダプタを用いており、目的と生成方法も異なるため、安全性に関する補足評価として扱う。

2.6 本研究の位置付け

先行研究では、刻印などの専用特徴を認識する方法、画像と説明文を埋め込み空間で照合する方法、外部生成 AI を用いる方法が提案されている。本研究は、収集画像から複数サイズの部分画像を生成し、マルチモーダル LLM を追加学習する。学習画像とは撮影条件が異なり、収集画像学習には使用していない内部開発評価画像を用いる点に特徴がある。また、未知薬剤を安全に保留する問題を、識別精度とは分けて扱う。関連研究と本研究の相違を表 2 に示す。

表 2 (a) から、本研究は専用装置を用いず、収集画像と共通質問文をマルチモーダル LLM に入力する点で先行研究と異なる。表 2 (b) から、未知薬剤への対応は予備評価にとどまり、安全な保留を実証したものではない。また、薬剤固有の説明文を利用する Rádlí らの方式と、本研究の全画像に共通する質問文は役割が異なる。

表 2 関連研究と本研究の位置付け

(a) 対象・入力・手法

研究	対象	主な入力	手法	専用装置
Heo ら [5]	錠剤	錠剤画像	刻印・外観認識とデータベース検索	不要
Rádli ら [6, 7]	錠剤	薬剤画像と薬剤固有の説明文	画像特徴と単語埋め込みによるメトリクス学習	不要
Usuyama ら [10]	錠剤	片面 1 枚の参照画像と実利用画像	双線形変換層を用いる多頭メトリクス学習	不要
Ling ら [11]	錠剤	実環境で撮影した少数枚	領域分割と複数系列特徴の統合, 2 段階学習	不要
Menaha ら [12]	錠剤	薬剤画像とプロンプト	外部サービスの Gemini による生成	不要
Han ら [13]	PTP 包装	専用装置で撮影した表裏	RTI と CNN	必要
本研究	PTP 包装	PTP 包装の表裏・部分画像と共通質問文	RTI・部分画像と Qwen3.5-4B (マルチモーダル LLM) の LoRA 追加学習	不要

(b) 未知薬剤への対応と本研究との差

研究	未知薬剤への対応	本研究との主な違い
Heo ら [5]	データベース検索	本研究はマルチモーダル LLM を追加学習し, 41 クラスの薬剤名を直接生成する.
Rádli ら [6, 7]	原論文で評価なし	薬剤固有の説明文ではなく, 共通質問文を単一のマルチモーダル LLM へ入力する.
Usuyama ら [10], Ling ら [11]	参照画像が未登録のクラスは識別対象外	参照画像を撮影せず, 収集画像から派生画像を生成する. 照合ではなくクラス名の文字列を生成する.
Menaha ら [12]	評価なし	重みを取得可能な基盤モデルに LoRA 追加学習を行う.
Han ら [13]	評価なし	専用装置を用いず, 収集画像から RTI と部分画像を生成する.
本研究	信頼ゲートを予備評価	41 クラスに限定し, モデル固定後の新規評価と安全な未知薬剤保留は未完了である.

3 提案手法

3.1 処理の全体像

図 1 に、提案手法の処理を UML のアクティビティ図として示す。図は「学習側」と「評価側」の 2 つのスィムレーンに分け、処理の主体と責務の境界を明示する。黒丸は開始ノード、二重丸は終了ノード、角丸の矩形はアクション、太い横棒はフォークノードおよびジョインノードである。実線の矢印は制御フロー、破線の矢印はオブジェクトフローを表す。

学習側では、収集した表裏の PTP 包装画像を取得して由来を監査し、背景除去と向きの正規化を行う。続いてフォークノードで制御を分岐させ、RTI の生成と面別部分画像の生成を並行して実行する。両者はジョインノードで合流し、各実験条件で定めた提示条件による画像拡張を適用したうえで、マルチモーダル LLM を LoRA で追加学習する。評価側では、収集画像学習に使用していない内部開発評価画像を入力とし、背景除去と 448×448 画素への正規化を行う。学習側で得た学習済み LoRA アダプタはオブジェクトフローとして評価側へ渡され、薬剤名の生成に用いられる。生成した薬剤名を正解ラベルと照合し、Top-1 精度と 95% 信頼区間を算出して処理を終了する。




図 1 提案手法の処理を示す UML アクティビティ図 (スィムレーンで学習側と評価側を分離)

この構成は、第 2 章で挙げた先行研究の制約へ対応させて定めた。Heo らは刻印検出、外観認識、文字列補正および候補検索を別々のモデルとして構成する必要がある、刻印が不鮮明な場合は検索に用いる情報が不足

する [5]。これに対し本手法は、画像と共通質問文を単一のマルチモーダル LLM へ入力し、包装上の印字と外観を同一のトークン列として扱うため、刻印以外の印字も手掛かりとして利用できる。Rádli らは薬剤ごとに異なる説明文の意味情報を学習に用いる [6, 7] のに対し、本手法はテキスト入力を全画像共通のタスク指示に限るため、薬剤を追加する際に薬剤固有のテキスト資源を整備する必要がない。Usuyama らおよび Ling らは参照画像を撮影して登録する方式であり、登録がないクラスは識別対象外となる [10, 11]。これに対し本手法は、1 クラス当たりフルシート表裏各 1 枚の収集画像から、残存錠数と切り出し範囲の異なる派生画像を生成して学習集合を構成する。Han らは上下 2 台のカメラを備えた専用装置を前提とする [13] のに対し、本手法は専用装置を用いずに両面統合画像を生成し、同時に部分画像を生成することで、包装の一部のみが写る画像にも対応させる。Menaha らは外部サービスへ画像を送信するプロンプト型の構成である [12] のに対し、本手法は重みを取得可能な基盤モデルへ LoRA で追加学習する。ただし、本章が示すのは各制約へ対応させた設計であり、対応が実際に有効であったかは第 4 章の結果によって判断する。

3.2 収集画像の由来監査

薬剤ごとに、PTP 包装の表面と裏面を確認できる画像を収集画像として整理する。採用前に、薬剤名、含量、面の種別、フルシートであるかを目視確認する。箱だけが写る画像、複数薬剤が混在する画像、極端に低解像度の画像は除外する。監査項目には、掲載ページ URL、画像 URL、取得日、表裏の判定を用いる。

由来監査では、現存する収集画像を現行の収集記録と照合する。直接照合できない画像については、削除前の収集記録まで探索し、掲載ページ URL や取得日時から出典記録または出典候補を特定する。あわせて、収集画像と内部開発評価画像 287 枚に同一の画像が含まれていないことを確認する。本監査は、保存ファイルと記録行の同一性を確認するものである。掲載ページの現在の内容、薬剤ラベルの医学的妥当性、利用条件および再配布可否を判定する権利監査ではない。このため、「出典候補を確認済み」と「加工履歴まで完全に再現可能」を区別する。収集画像は 41 クラス・42 ファイルであり、1 クラスだけが表面と裏面の 2 ファイルへ分かれる。監査結果は 4.1.2 節に示す。以後、本報告書では、実験管理上の保存名である「Web 画像学習」を必要な場合だけ引用し、この学習集合自体は「収集画像」と呼ぶ。


3.3 RTI と部分画像の生成

Han らは、PTP 包装の各片面を 448×224 画素に向き補正し、左右に結合した 448×448 画素の画像を Re-oriented Two-sided Image (RTI) と呼んだ [13]。本研究では、この構成に基づく画像を RTI と呼ぶ。ただし、本研究は結合後の画像を 448×448 画素へ直接リサイズし、結合前の縦横比を保持しない。図 2 に、表面画像と裏面画像から RTI を作成する手順を示す。まず、薬剤 d ごとにフルシートの表面画像 $I_{d,f}$ 1 枚と裏面画像 $I_{d,b}$ 1 枚を用意し、両画像から背景を除去する。PTP 包装の凸包を抽出し、透視変換によって表裏の向きと大きさをそろえる。正規化関数を $T(\cdot)$ 、左右結合を $\parallel$ とすると、背景除去後に正規化した画像から作る薬剤 d の RTI は式 (2) で表す。

$$I_d^{\text{RTI}} = \text{Resize}_{448 \times 448} (T(I_{d,b}) \parallel T(I_{d,f})) \quad (2)$$

RTI では、裏面を左、表面を右へ配置する。両面を同一画像内に含めることで、片面だけでは不足する文字と外観を同時に提示する。図中の「最高精度条件では RTI そのものは学習しない」という注記は、RTI を生成しないという意味ではない。RTI の生成と、生成した RTI を学習へ含めるかどうかは別であり、後者は実

験条件に依存する。



例：メインテート錠2.5mg。RTIは切り出しの基準にも使う。最高精度条件ではRTIそのものは学習しない。

図2 保存画像の表面・裏面から RTI を作成する手順（メインテート錠 2.5mg の例）



図3 収集元画像および保存済み派生基画像の例（エンレスト錠 200mg）。内部開発評価画像ではない。

(a) 収集元の表面，(b) 収集元の裏面，(c) 正規化後の表面，(d) 正規化後の裏面，(e) RTI（左：裏面，右：表面），(f) 1錠区画，(g) 縦2分割，(h) 縦4分割である。(a) (b) の出典：ノバルティス ファーマ株式会社の製品資料 [23]。(c) から (h) は著者が保存済み実験データから再配置した。

図3は，図2の手順を実際の保存画像へ適用した結果である。(c) から (h) は再生成せず，ver6 の train_manifest.csv が指す保存済み基画像を用いる。収集元画像の掲載ページと，同社の利用規約^{*1}を確認

^{*1} ノバルティス ファーマ株式会社：利用規約，<https://www.novartis.com/jp-ja/terms-use>，最終閲覧日：2026年8月8日。
なお，2026年7月27日に確認した医療関係者向けサイトの利用条件 PDF は，2026年7月28日の再アクセスで HTTP 403

認している。同条件が引用その他の法令上認められる範囲を示していることを踏まえ、本図は手法を説明する非営利の学術目的の範囲に限り、出典を明示して掲載する。公開リポジトリ等へ二次配布する場合は、公開時点の条件と必要な許諾を改めて確認する。

各薬剤では、RTI を 1 枚生成する。この 1 枚は RTI 生成処理で作る基画像として数えたものであり、学習へ含めることを意味しない。RTI を学習へ含めるかどうかは実験条件ごとに定め、最高精度条件では RTI 自体を学習から除外する。さらに各面から、フルシート 1 枚、1 錠区画 8 枚、縦 2 分割画像 2 枚、縦 4 分割画像 4 枚を生成する。1 錠区画は、画像から錠剤セルを自動検出して得るものではない。各面の前景外接矩形へ薬剤ごとに定めた固定格子を当て、格子区画に対応する部分画像を左上から行優先で最大 8 枚生成する。本実装ではクラス間の基画像数をそろえるため上限を 8 枚に固定するが、上限値の妥当性を比較する実験は行っていない。格子の列数と行数は通常の薬剤で 2×5 、メチコバル錠 $500\mu\text{g}$ で 3×7 、レボフロキサシン錠 500mg で 1×5 とする。縦 2 分割画像と縦 4 分割画像は、前景外接矩形を高さ方向へ等分した水平帯である。したがって、この 1 錠区画の切り出しは既知の PTP 配列に基づく固定規則であり、任意の包装に対する一般的な錠剤セル検出器ではない。通常の薬剤で生成する基画像数 N_d は式 (3) より 31 枚となる。

$$N_d = 1 + 2(1 + 8 + 2 + 4) = 31 \quad (3)$$

レボフロキサシン錠 500mg は、PTP 包装に含まれる錠剤セル数の制約により 1 錠区画を 5 枚とし、式 (4) の 25 枚となる。41 クラスについて、クラスごとに 1 組の収集元画像から派生させた基画像は、式 (5) の合計 1,265 枚となる。

$$N_d^{\text{LVFX}} = 1 + 2(1 + 5 + 2 + 4) = 25 \quad (4)$$

$$N_{\text{base}} = 40 \times 31 + 1 \times 25 = 1,265 \quad (5)$$

アルゴリズム 1 に、基画像生成の手順を示す。

が返されたため、現在閲覧できる利用規約のページを挙げる。

アルゴリズム 1 収集画像からの基画像生成

入力: 薬剤 d の表面画像 $I_{d,f}$, 裏面画像 $I_{d,b}$

出力: 基画像集合 $\mathcal{D}_d$

- 1: $\mathcal{D}_d \leftarrow \emptyset$
 - 2: 表裏画像から背景を除去し, PTP 包装の凸包を抽出する
 - 3: 透視変換により, 表裏画像の向きと大きさを正規化する
 - 4: 裏面を左, 表面を右へ配置して RTI を生成する
 - 5: 生成した RTI を $\mathcal{D}_d$ へ追加する
 - 6: 正規化した表裏フルシートを $\mathcal{D}_d$ へ追加する
 - 7: **for** 面 $s \in \{f, b\}$ **do**
 - 8: $T(I_{d,s})$ の前景外接矩形へ薬剤 d に対応する固定格子を設定する
 - 9: 格子区画に対応する部分画像を, 左上から行優先で最大 8 枚生成する
 - 10: 前景外接矩形を高さ方向へ 2 等分し, 水平帯を 2 枚生成する
 - 11: 前景外接矩形を高さ方向へ 4 等分し, 水平帯を 4 枚生成する
 - 12: 生成画像を $\mathcal{D}_d$ へ追加する
 - 13: **end for**
 - 14: 各画像を 448×448 の黒背景へ配置する
 - 15: **return** $\mathcal{D}_d$
-

3.4 画像拡張

主条件 D では, 撮影時の変動を模擬する重複のない 17 提示条件を用いる. 内訳は, 無変換 1 条件, ± 15 度, ± 30 度, 90 度および 180 度の回転 6 条件である. これに, 明度 0.7 倍と 1.3 倍, コントラスト 0.7 倍と 1.3 倍, ガンマ 0.7 と 1.4, 左右の台形歪み, ぼけおよびセンサノイズを各条件として加える. 主条件 D では, BF16 LoRA, ランク 16, スケーリング係数 32, q-proj, k-proj, v-proj, o-proj, gate-proj, up-proj, down-proj を対象とし, 5 エポックおよび乱数シード 42 を用いる.

探索的 ver6 は ver4 条件 C を基準とする. ver4 条件 C と ver6 では, 回転 12 条件と明度 5 条件からなる提示条件 $\mathcal{A}_C$ を式 (6) で定義する. 回転は 0 度から 330 度まで 30 度刻みとし, 明度倍率は 0.8, 0.9, 1.0, 1.1, 1.2 とする. 回転と明度変化は別の提示条件として用いるため, 提示数は 17 となる. 0 度回転 R_0 と明度倍率 1.0 の $B_{1.0}$ は画素値が同一だが, 実装では別レコードとして 1 回ずつ提示する.

$$\mathcal{A}_C = (R_0, R_{30}, \dots, R_{330}, B_{0.8}, B_{0.9}, B_{1.0}, B_{1.1}, B_{1.2}) \quad (6)$$

図 4 に, 主条件 D の 17 提示条件のうち, 回転 6 条件から 4 条件と, 無変換および明度 2 条件を抜粋して模式的に示す. 主条件 D では重複する提示条件を設けないため, 画素値を変えない条件は無変換 1 条件だけであり, 回転 0 度および明度倍率 1.0 を別条件として重ねて数えていない.

1 エポック当たりの提示数は $1,265 \times 17 = 21,505$ 枚である. 5 エポックの延べ提示数 N_{exposure} は式 (7) の $107,525$ 枚となる.

$$N_{\text{exposure}} = 1,265 \times 17 \times 5 = 107,525 \quad (7)$$




図4 主条件 D で基画像へ適用する提示条件の模式図（上段：回転 6 条件のうち 4 条件，下段：無変換 1 条件と明度 2 条件）

3.5 LoRA 学習

基盤モデルには，2.2 節で述べたマルチモーダル LLM を用いる．本報告書の実験で用いる具体的なモデルとそのリビジョンは，4.1 節に示す．画像サイズは 448×448 とし，質問文と正解薬剤名を学習ペアとする．主条件 D ではモデル重みを BF16 で読み込み，LoRA ランク 16，スケーリング係数 32，ドロップアウト率 0.05 とする．LoRA の対象モジュール名は，q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj である．保存設定はこれらの接尾辞を記録しているが，視覚部とテキスト部のどちらへ何個適用されたかを分離した一覧は保存していないため，本報告書ではその内訳を断定しない．主条件 D では撮影変動対応 17 条件を用いる．探索的 ver6 では， $\alpha/r = 2.0$ を保ったまま LoRA ランクを 32，スケーリング係数を 64 へ同時に増加させる．学習可能パラメータ数は 21,233,664 から 42,467,328 へ約 2 倍となる．ver6 の学習対象層，基画像，提示条件，エポック数，実効バッチサイズおよび乱数シードは ver4 条件 C と同じとする．主条件 D と探索的 ver6 の設定を表 3 に示す．

表 3 主条件 D と探索的 ver6 の学習設定

項目	主条件 D	探索的 ver6
LoRA ランク	16	32
スケーリング係数	32	64
LoRA 対象	q/k/v/o 射影 + gate/up/down 射影	ver4 条件 C と同じ
画像拡張	撮影変動対応の重複しない 17 条件	ver4 条件 C と同じ回転 12 条件 + 明度 5 条件
エポック数／乱数シード	5 / 42	5 / 42
位置付け	報告上の主条件	結果確認後の探索的追試

学習率は 2.0×10^{-4} ，実効バッチサイズは 128，エポック数は 5 とする．乱数シードは 42 に固定する．最適化には PyTorch の AdamW を用いる．AdamW の学習率は 2.0×10^{-4} ， $\beta_1 = 0.9$ ， $\beta_2 = 0.999$ ， $\epsilon = 10^{-8}$ ，weight decay は 0.01 とする．実装が対応する環境では fused=True を指定する．学習率スケジューラは用いない．損失は質問文をマスクし，回答文字列と終端トークンの部分だけで計算する．自由生成評価では貪欲法を用い，最大生成長を 32 トークン，反復ペナルティを 1.1 とする．

3.6 評価方法

3.6.1 単剤評価に用いた画像

単剤評価には、大学病院薬剤部で撮影した 41 クラスの画像、計 287 枚を用いる。撮影場所および撮影記録は 4.1 節に示す。本報告書では、この 287 枚を内部開発評価画像と呼ぶ。内部開発評価画像は、収集画像から構成した ver1 から ver9 の LoRA 学習集合には含めていない。一方、同じ 287 枚を条件検討へ反復使用し、研究初期の実画像方式では一部を学習にも用いた。そのため、条件決定後に初めて使用する独立最終評価集合ではない。内訳は表面 212 枚、裏面 75 枚である。フルシート 29 枚と、錠剤が 1 錠から 9 錠まで残った部分シート 258 枚を含む。学習元の収集画像とは出典と撮影条件が異なる。1 クラス当たりの枚数は 3 枚から 10 枚であり、クラス間で偏りがある。



図5 内部開発評価画像の元画像と保存済みモデル入力の対応例。(a)(b) IMG_0256 (表面フルシート), (c)(d) IMG_0258 (裏面フルシート), (e)(f) IMG_0027 (表面・1錠), (g)(h) IMG_0236 (表面・4錠)である。各組の左が撮影元画像、右が背景除去・向き補正・448画素正方形化後のモデル入力である。画像は近畿大学病院薬剤部で撮影され、著者が保存済み評価データから再配置した。

図5では、元画像内の包装占有率や向きが異なっても、モデル入力では包装が黒背景の448画素正方形へ正規化されることを確認できる。撮影元287枚はすべてPNG形式・3024×4032画素である。一方、EXIFの撮影日時、端末メーカーおよび端末型番は287枚すべてで欠落している。したがって、撮影端末、距離、照明、撮影セッションを画像の記録から復元できない。

文字列 s に NFKC 正規化と小文字化を適用する。続いて、空白、読点、句点、中点、コロンのハイフン、アンダースコア、スラッシュ、バックスラッシュ、丸括弧、角括弧、かぎ括弧、二重かぎ括弧を除去する。この関数を $g(s)$ とする。保存済み評価実装の一致判定 $M(a, b)$ は、 $g(a) = g(b)$ 、または $g(a)$ が $g(b)$ の部分文字列である場合に真となる。画像 x_i に対するモデルの Top-1 出力を $\hat{y}_i$ 、記録済み正解ラベルを y_i とする。Top-1 精度は式 (8) で求める。

$$\text{Accuracy} = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(M(y_i, \hat{y}_i)) \quad (8)$$

この実装は正規化後の完全一致より緩い．このため本報告書では，実装規則を開示したうえで，保存済み予測を $g(y_i) = g(\hat{y}_i)$ の完全一致でも再集計し，両判定の正解数を比較する．再集計の結果は 4.1.2 節に示す．Wilson 区間，マクロ平均およびブートストラップ区間は，両判定の正解数が一致することを確認したうえで，保存済み判定に基づく集計値として示す．

クラス間の枚数の偏りを考慮するため，クラス別正解率のマクロ平均も式 (9) で求める．ここで D はクラス集合， n_d はクラス d の画像数である．

$$\text{MacroAccuracy} = \frac{1}{|D|} \sum_{d \in D} \frac{1}{n_d} \sum_{i: y_i = d} \mathbf{1}(M(y_i, \hat{y}_i)) \quad (9)$$

保存済み予測の薬剤別不確実性を補足するため，41 クラスをクラスタとして復元抽出するブートストラップも用いる．各反復では 41 クラスを復元抽出し，抽出したクラス別正解率の平均を求める．乱数シードを 260727 に固定して 10,000 回反復し，2.5 および 97.5 パーセンタイルを薬剤をクラスタとするブートストラップ 95% 区間とする．これは 41 クラスの分布に対する記述的な区間であり，新しい薬剤への一般化を示す区間ではない．

二項比率の 95% 信頼区間には Wilson 区間を用いる．観測比率を $\hat{p}$ ，標本数を n ， $z = 1.96$ とすると，区間は式 (10) で表す．

$$\text{CI}_{95\%} = \frac{\hat{p} + \frac{z^2}{2n} \pm z \sqrt{\frac{\hat{p}(1-\hat{p})}{n} + \frac{z^2}{4n^2}}}{1 + \frac{z^2}{n}} \quad (10)$$

同じ画像に対する 2 方式の正誤を比較する場合は，対応のある二値データとして McNemar 検定を用いる．方式 A のみが正解した画像数を b ，方式 B のみが正解した画像数を c とする．帰無仮説の下で不一致対の各方向は確率 1/2 で生じるため，両側の正確 p 値は式 (11) で求める．

$$p_{\text{exact}} = \min \left\{ 1, 2 \sum_{k=0}^{\min(b,c)} \binom{b+c}{k} \left(\frac{1}{2} \right)^{b+c} \right\} \quad (11)$$

本研究では両側 $p < 0.05$ を有意差の基準とする．ただし，有意差が認められない結果は，2 方式の統計的同等性を示すものではない．不一致対がない場合，すなわち $b + c = 0$ の場合も，式 (11) の正確両側 p 値は 1 となる．正確 McNemar 検定は，各画像対の不一致方向が画像対間で独立であることを仮定する．本評価集合には同じクラスに属する複数画像が含まれ，独立した撮影セッションを識別する情報も保存されていない．したがって，この独立性は確認できない．本報告書の p 値は保存済み 287 画像内の探索的な記述値として示し，薬剤または撮影条件の母集団に対する確率的推論には用いない．

本評価では 5 分割交差検証を用いない．学習元は薬剤ごとに 1 組の収集画像であり，評価対象は内部開発評価画像である．派生画像だけを分割すると，同一の収集元画像に由来する画像が学習用分割と検証用分割に混入する．また，評価画像だけを 5 分割してもモデルを再学習しないため，同じ予測を分割集計するだけになる．各薬剤について 5 組以上の独立した収集元画像がないため，元画像単位のグループ化交差検証を構成できない．このため，全 287 枚の点推定を主な集計値とし，Wilson 区間は画像単位の独立性を仮定した参考値として併記する．

3.6.2 追加学習していない Qwen3.5-4B との比較

追加学習前の基準として、LoRA を適用していない Qwen3.5-4B の保存済み予測 287 件を再集計する。この実行では素画像を入力し、プロンプトは「この錠剤は何という薬ですか？薬剤名だけで教えてください。」である。保存時の判定は、正規化した正解薬剤名が生成文に含まれる場合を成功とするものである。本報告書ではこれを再現するとともに、式 (8) より厳しい $g(y_i) = g(\hat{y}_i)$ の完全一致でも再集計する。3 系列の予測は、薬剤名と画像ファイル名を結合した識別子で単剤マニフェストへ結合し、287 件すべてを一意に対応させる。

追加学習していない側と LoRA を適用した側では、入力の前処理、入力画像サイズ、実行環境および出力の制御が異なる。したがって、これは保存済みの実行同士の比較であり、LoRA の有無だけを変えた比較ではない。

3.6.3 外部サービスとの対応比較

外部サービスとの比較には、2026 年 6 月 24 日に保存したモデル文字列 `gemini-3.5-flash` の予測を用いる [24]。Gemini 側では元画像を最大 589,824 画素へ縮小し、JPEG 品質 90 へ変換する。プロンプトには、学習対象と同じ 41 クラスの候補一覧を与える。Gemini と ver6 は、薬剤名と画像ファイル名を結合した識別子で対応付ける。さらに、元画像と正解ラベルの一致を確認する。正誤は保存済み予測と正解ラベルの完全一致で再集計する。モデルリビジョン、温度、乱数シードが記録されていないため、API へ再問い合わせせず、保存済み CSV を一次資料とする。

3.6.4 合成複数薬剤画像

複数薬剤評価には、元写真を黒い隙間で区切り、薬剤数が 2, 3, 5, 8 の合成複数薬剤画像を各 100 枚用いる。この合成複数薬剤画像 400 枚は、収集画像学習 ver1 から ver9 まで共通である。ただし、ver1 から ver3 は評価時に領域を検出し、ver4 以降は同じ 400 枚から生成した固定評価キャッシュの 1,800 領域を用いる。画像中の連結領域を検出し、各領域を単剤モデルへ入力する。領域分割では、画素の最大 RGB 値が 18 を超える領域を前景とし、 7×7 の形態学的クロージングを 2 回適用した後、外側輪郭を抽出する。さらに、画像全体に対する外接矩形の面積比が 2.5% 以上で、短辺が 100 画素以上の領域だけを識別対象とする。したがって、この領域分割は、薬剤間に黒い隙間があり、包装同士が接触しない配置を前提とする連結領域分割であり、一般的な物体検出器ではない。画像 i について、保存順の正解薬剤ラベル列を Y_i 、予測ラベル列を $\hat{Y}_i$ とする。保存済み実装では、 $\hat{Y}_i$ の予測を順に調べ、一致判定 M が真となる未対応の正解ラベルのうち先頭の要素へ貪欲に一対一対応付けする。対応できた個数を c_i^{greedy} とする。部分文字列一致を許す M では、この個数は一般に保存順へ依存し得る。合成複数薬剤画像の総数を N_{multi} とする。画像単位完全一致率は式 (12) で求める。

$$\text{ExactMatch} = \frac{1}{N_{\text{multi}}} \sum_{i=1}^{N_{\text{multi}}} \mathbf{1}(c_i^{\text{greedy}} = |Y_i| = |\hat{Y}_i|) \quad (12)$$

領域ラベル一致率は式 (13) で求める。

$$\text{RegionLabelMatch} = \frac{\sum_{i=1}^{N_{\text{multi}}} c_i^{\text{greedy}}}{\sum_{i=1}^{N_{\text{multi}}} |Y_i|} \quad (13)$$

この指標は正解ラベルに対する対応率であり、過検出を分母へ含めない。過検出は、画像単位完全一致率と検出領域数によって別途評価する。また、本指標は画像内ラベル列を保存順に貪欲対応した一致数であり、検

出領域の物理的位置ごとの正誤率ではない。保存済み予測を正規化後の厳密一致で再集計すると対応候補は同一ラベルだけとなり、保存順への依存はなくなる。このため、合成複数薬剤の集計についても厳密一致で再集計し、保存済み集計値と比較する。再集計の結果は 4.1.2 節に示す。これらの評価画像は合成複数薬剤画像であり、薬剤同士の重なりや実背景を含まない。したがって、実画像における複数薬剤識別性能とは区別する。図 6 に評価入力例を示す。




図 6 評価入力の構成を示す模式図（左：単剤，右：合成複数薬剤）



図 7 固定 400 枚に含まれる合成複数薬剤画像の実例。(a) 2 薬剤, ID 2 薬剤_0001, (b) 5 薬剤, ID 5 薬剤_0001, (c) 8 薬剤, ID 8 薬剤_0001 である。評価用の単剤実写真を黒い隙間で区切って合成した画像であり、実写の複数薬剤配置ではない。包装同士の接触, 重なり, 複雑な背景を含まない。著者が保存済み評価画像を再配置した。

図 7 に、模式図 6 に対応する実際の入力を示す。

3.6.5 信頼ゲート

ver4 条件 C のモデルへ、信頼できない入力に対する回答を保留する信頼ゲートを適用する。これは初期の予備評価である。本報告書では、ver4 条件 C のアダプタに対するこの予備評価のみを扱う。既知薬剤には内部開発評価画像 287 枚を用い、保存済み記録ラベル単位で校正集合 139 枚と最終評価集合 148 枚に事前分割する。未知薬剤には、学習対象の 41 件の保存済み記録ラベルに含まれない薬剤の収集画像 125 枚を用い、薬剤ラベル単位で校正集合 67 枚と最終評価集合 58 枚に事前分割する。既知薬剤と未知薬剤のいずれも、校正集合と最終評価集合の薬剤ラベルに重複はない。全評価画像について、学習画像と同一の画像が含まれていないことを確認する。ただし、この確認は、再圧縮や切り出しを経た近い画像が混入していないことまでは保証しない。

信頼ゲート専用の正規化関数 $h(s)$ は、まず大文字と小文字を区別せずに<think>...</think>区間を除去する。次に、Unicode NFKC を適用し、前後の空白を除去して小文字化する。先頭が「薬剤名は」「これは」「回答は」のいずれかであれば、該当する接頭句を 1 つだけ除去する。末尾が「です」「になります」のいずれかであれば、該当する接尾句を 1 つだけ除去する。最後に、空白と保存実装で列挙した句読点・区切り記号を除去する。学習対象の保存済み記録ラベル集合を W_{raw} とし、信頼ゲートで照合する既知集合を $W = \{h(w) \mid w \in W_{\text{raw}}\}$ とする。

Top-3 ビーム探索で得た候補を系列スコアの降順に並べ、 $s_1 \geq s_2 \geq s_3$ とする。 s_k は、第 k 候補について生成処理が返す長さ調整済み系列スコアである。 s_k は反復ペナルティを含む生成設定に依存するため、モデル固有の校正済み確率とは扱わない。候補間マージン m を式 (14) で定義する。

$$m = s_1 - s_2 \quad (14)$$

11 視点の TTA 出力を $\hat{y}^{(1)}, \dots, \hat{y}^{(11)}$ 、各出力の信頼ゲート専用正規化結果を $\tilde{y}^{(j)} = h(\hat{y}^{(j)})$ とする。正規化後の最頻値を v とすると、TTA 多数決一致率 a は式 (15) で表す。同数首位がある場合は、保存実装に従い、11 視点の列で最初に現れた候補の正規化値を v とする。

$$a = \frac{1}{11} \sum_{j=1}^{11} \mathbf{1}(\tilde{y}^{(j)} = v) \quad (15)$$

信頼ゲートは 3 段階で構成する。第 1 段階では、モデル出力へ h を適用し、既知集合 W との厳密一致を確認する。第 2 段階では、元画像、回転、左右反転、明度、コントラスト、ノイズからなる 11 視点のテスト時拡張 (Test-Time Augmentation : TTA) を用いる。多数決結果が既知薬剤名であることを確認する。さらに、多数決結果が Top-1 予測と一致し、一致率がしきい値以上であることを確認する。第 3 段階では、Top-3 ビーム探索の第 1 候補系列スコア s_1 と候補間マージン m をしきい値と比較する。アルゴリズム 2 に判定順序を示す。

アルゴリズム 2 信頼ゲートによる回答と保留の判定

入力: 画像 x , 学習済みモデル f_θ , 正規化関数 h , 既知集合 W , しきい値 τ_s , τ_m , τ_a

出力: h で正規化したクラス名または保留

```

1:  $f_\theta$  の Top-3 ビーム探索により候補  $\hat{y}_1, \hat{y}_2, \hat{y}_3$  と  $s_1 \geq s_2 \geq s_3$  の系列スコアを得る
2:  $\tilde{y}_1 \leftarrow h(\hat{y}_1)$ 
3: if  $\tilde{y}_1 \notin W$  then
4:   return 保留
5: end if
6: 11 視点の TTA 出力へ  $h$  を適用し、多数決  $v$  と一致率  $a$  を求める
7: if  $v \notin W$ , または  $v \neq \tilde{y}_1$ , または  $a < \tau_a$  then
8:   return 保留
9: end if
10: if  $s_1 < \tau_s$ , または  $s_1 - s_2 < \tau_m$  then
11:   return 保留
12: end if
13: return  $\tilde{y}_1$ 

```

回答するには、既知薬剤名集合への所属、Top-1 と TTA 多数決の一致、TTA 一致率、系列スコア、候補間マージンの全条件を満たす必要がある。いずれか 1 条件でも満たさない場合は、アルゴリズム 2 の順序で保留する。しきい値は校正集合だけで決定し、最終評価集合の推論前に固定する。未知薬剤に対して既知薬剤名を回答することを、以下では危険通過と呼ぶ。既知薬剤の誤回答を 0 件、未知薬剤の危険通過を 67 枚中 3 枚

以下とする制約下で、既知薬剤への正しい回答数を最大化する。固定後は最終評価集合の結果を見て変更しない。指標には、既知薬剤への回答率、回答した既知薬剤の正解率、未知薬剤の保留率を用い、各比率に Wilson 法による 95% 信頼区間を付す。なお、信頼ゲートでは信頼信号を得るため Top-3 ビーム探索を用いるため、単剤評価の貪欲法による生成とは生成方法が異なる。

3.6.6 隙間のない合成複数薬剤画像による最大 10 候補評価

固定 400 枚の黒い隙間を含む合成複数薬剤評価とは別に、薬剤数が未知の複数薬剤入力に対する探索的評価を行った。元写真を縦横比を保って 768×1024 画素へリサイズし、タイル間隔と外周余白を 0 画素として連結した。薬剤数は 2, 3, 5, 8 の 4 条件、各 200 枚、計 800 枚である。1 薬剤の画像も各 200 枚生成したが、Top10 本番の主集計には含めなかった。

検出器には薬剤数、配置、薬剤名および生成位置を入力せず、画像から得た前景強度で候補を順位付けし、1 画像につき最大 10 領域を選択する。この方式を「薬剤数未知・全候補包含」と呼ぶ。抽出した候補を単剤モデルへ入力し、余分な予測を許したうえで、正解薬剤がすべて含まれる画像を成功とした。

候補領域の抽出は、OpenCV による Canny エッジ検出、モルフォロジー処理および輪郭抽出を組み合わせて行う。手順は次のとおりである。(1) グレースケール化とガウシアンぼかしで細かなノイズを減らしたうえで、Canny エッジ検出により包装や印字の明暗の境目を線として取り出す。(2) クロージングと膨張のモルフォロジー処理で、途切れた線や近い線をつなぐ。長い縦横線を除いた補助画像からも候補を作る。(3) 輪郭抽出 (findContours) で線のまとまりを探し、外接矩形 (boundingRect) で囲んだうえで、面積、縦横比および輪郭の密度で候補を絞る。(4) 面積、輪郭の詰まり具合およびエッジ密度から候補の強さを計算し、強い順に残しつつ、既存の枠と大きく重なる候補を除いて重複を減らす。実装は training_preprocess.py の foreground_mask と、detect_top10_regions.py の detect_top_candidates である。この段階では薬剤名も正解の薬剤数も使わない。図 8 に、入力・候補枠・整形後の例を示す。

同じ保存済み候補 1 位から 10 位までの推論結果から、薬剤数 N を既知と仮定して候補 1 位から N 位だけを残す Top- N 評価も行った。 N は検出前や薬剤名推論時には与えず、実行後の再評価にだけ使用した。Top- N では余分な予測を認めず、残した予測と正解薬剤を 1 対 1 に対応させ、すべて一致した画像を成功とした。


本評価は隙間のないタイル合成画像によるものであり、薬剤が自由な位置、向きおよび重なりで置かれる実環境の複数薬剤画像性能を示すものではない。

複数薬剤の識別：候補抽出 → 画像の整形 → 1枚ずつ識別

① 入力：3薬剤を並べた合成画像



② 画像処理で候補枠を抽出する



前景の輪郭をまとめる → 重複する枠を減らす → 前景の強さで最大10候補を残す

③ 候補ごとに背景除去・向き補正を行い、黒背景448×448画素に整える



候補1



候補2



候補3



候補4：余分な検出

④ 各画像を視覚言語モデル+LoRAへ入力し、薬剤名を生成する。

図8 隙間のない複数薬剤画像における候補抽出と整形の実例。入力画像，候補枠の重畳表示，黒背景448×448画素へ整形した候補の順に示す。この写真は3薬剤の入力から4候補を検出した実例であり，候補には余分な背景を含むものがある。正しく3枚へ分離できた例として示すものではなく，候補抽出の処理過程を説明するための1事例である。評価集合全体（2・3・5・8薬剤各200枚，計800枚）における成功率は表21に示す。

4 実験結果・考察

4.1 実験環境とデータ監査結果

4.1.1 実験環境と撮影記録

主条件 D と探索的 ver6 の実験環境を表 4 に示した．両条件の学習には NVIDIA H100 を 1 台使用した．モデルリビジョンを固定し，実行時の Python および主要ライブラリの版を記録した．乱数シードは 42 としたが，速度を優先して CUDA の決定論的アルゴリズムを無効にした．このため，ビット単位で同一の再現は保証されなかった．本研究は人を対象とする実験ではなく，被験者を用いず，PTP 包装画像を評価対象とした．評価画像は PTP 包装だけを写した画像であり，患者を識別できる情報は含まれていなかった．

表 4 主条件 D および探索的 ver6 の実験環境

項目	主条件 D	探索的 ver6
GPU	NVIDIA H100, VRAM 93.096 GiB, 1 台	同左
OS / Python	Linux 6.8.0, glibc 2.39 / Python 3.13.5	同左
主要ライブラリ	PyTorch 2.11.0, CUDA 12.8, cuDNN 9.19, Transformers 5.14.1, PEFT 0.19.1	同左
基盤モデル	Qwen/Qwen3.5-4B, リビジョン 851bf6e806efd8d0a36b00ddf55e13ccb7b8cd0a	
LoRA	ランク 16, 係数 32, BF16	ランク 32, 係数 64, BF16
学習対象層	q, k, v, o 射影および gate, up, down 射影	同左
学習可能パラメータ数	21,233,664	42,467,328
画像拡張	撮影変動対応 17 条件	ver4 条件 C と同じ回転 12 条件 + 明度 5 条件
バッチ	マイクロバッチ 16, 勾配累積 8, 実効バッチ 128	同左
エポック数／乱数シード	5 / 42	5 / 42

内部開発評価画像の撮影条件として確認できた事項を表 5 に示した．端末，距離，角度，照明および背景の値は保存記録から確認できなかったため，推測で補わなかった．

図 9 に ver6 の学習損失を示す．最終ログに記録された学習損失は 2.8×10^{-5} であった．4 エポック以降はおおむね 1×10^{-5} 台で推移したが，最終ログ点は直前の区間より高い値を示した．ver4 条件 C の最終損失は 1.3×10^{-5} であったが，学習損失の大小だけで評価精度を比較することはできなかった．独立した検証集合の損失を測定していないため，過学習の有無および 5 エポックが最適であったかは判断できなかった．

4.1.2 データおよび監査結果

3.2 節の手順による収集画像の由来監査の結果は，次のとおりである．収集画像は 41 クラス・42 ファイルから構成される．32 ファイルは現行の収集記録と直接照合できた．残る 10 ファイルは，削除前の収集記録か

表 5 内部開発評価画像の撮影・前処理記録

項目	確認結果
撮影場所	近畿大学病院薬剤部
撮影日	元画像ディレクトリ名は 2026 年 4 月 9 日撮影を示したが、PNG 内に独立した撮影日時を確認できなかった。
撮影端末・セッション数	PNG 内に機種情報がなく、撮影セッション ID も保存されていなかった。
元画像解像度	評価マニフェスト 287 枚はすべて $3,024 \times 4,032$ 画素であった。
距離・角度・照明・背景	数値または条件を記録していなかった。
表裏の記録	保存台帳と評価マニフェストに表裏を記録し、表 212 枚、裏 75 枚であった。
フル／部分シート	フルシート 29 枚、1 錠から 9 錠の部分シート 258 枚であった。
背景除去	色しきい値と形態学的処理で前景マスクを作成し、外側輪郭の凸包を透視変換した後、 448×448 画素の黒背景へ配置した。




図 9 ver6 の学習損失（縦軸は対数目盛）

ら出典記録または出典候補を確認した。一方、この 10 ファイルについては、元画像から現存画像までの加工の履歴をたどれなかった。また、収集画像と内部開発評価画像 287 枚に同一の画像は含まれていなかった。

3.6.1 節および 3.6.4 節の判定規則に関する再集計の結果は、次のとおりであった。保存済み予測を正規化後の完全一致で再集計しても、単剤の正解数は ver4 条件 D, ver4 条件 C, ver6, ver7 でそれぞれ 280, 283, 286, 284 であり、保存済み集計値と変わらなかった。合成複数薬剤画像でも、画像単位完全一致はそれぞれ 331, 356, 374, 380、領域ラベル一致数はそれぞれ 1,725, 1,752, 1,773, 1,780 であり、保存済み集計値と変わらなかった。両判定の正解数が一致したため、以降の Wilson 区間、マクロ平均およびブートストラップ区間は保存済み判定に基づく集計値として示した。

4.2 初期実画像方式と収集画像学習への移行

研究初期には、近畿大学病院薬剤部で撮影した 41 クラスに属する 287 枚を学習元と評価用に分ける方式を用いた。乱数シード 42 で元画像単位に分割し、213 枚を学習用、74 枚を評価用とした。学習用画像に 11 提示条件の拡張を適用し、Qwen3.5-4B を LoRA で追加学習した。拡張していない評価用元画像 74 枚では、74

枚すべてで正解した。同じ 74 枚から生成した回転・明度変化を含む 814 枚では 799/814 枚、98.2% であった。なお、後者の 814 枚は独立して撮影した 814 枚ではなく、74 枚から生成した派生画像である。

単一分割への依存を確認するため、同じ 287 枚を元画像単位で 5 分割し、各分割を 1 回ずつ評価用とする交差検証も行った。分割別の Top-1 精度は、58/58 枚、58/58 枚、56/57 枚、55/57 枚、56/57 枚であり、順に 100.0%、100.0%、98.2%、96.5%、98.2% であった。全分割を統合すると 283/287 枚、98.6% であり、分割別精度の平均と標準偏差は 98.6% $\pm$ 1.5% であった。これは初期実画像方式の内部検証であり、後述する収集画像学習モデルの外部評価ではない。

実画像を学習元とする方式について、1 薬剤当たりの学習元画像数も比較した。1 薬剤当たりの学習元画像数を変えた比較と、1 元画像当たりの提示条件数を変えた比較の結果を、表 6 にまとめて示した。前者は 6 枚以上の元画像を持つ 33 薬剤を対象として同じ 79 枚を評価したものであり、後者は学習元 213 枚と評価用元画像 74 枚を固定したものである。

表 6 初期実画像方式における学習元画像数および提示条件数と Top-1 精度

比較	水準	学習画像数	Top-1 精度
1 薬剤当たりの学習元画像数 (対象 33 薬剤, 固定評価 79 枚)	1 枚	363	67.1%
	2 枚	726	87.3%
	4 枚	1,452	91.1%
	利用可能な全画像 (5–8 枚)	1,947	98.7%
1 元画像当たりの提示条件数 (学習元 213 枚, 固定評価 74 枚)	1 条件	213	73.0% (54/74)
	3 条件	639	87.8% (65/74)
	5 条件	1,065	90.5% (67/74)
	7 条件	1,491	95.9% (71/74)
	11 条件	2,343	97.3% (72/74)
	17 条件	3,621	100.0% (74/74)

表 6 の上段では、同一の 33 薬剤と固定評価 79 枚を用いた比較において、学習元画像数の増加に伴って精度が上昇した。1 薬剤当たり 1 枚では 67.1% にとどまり、4 枚で 91.1%、利用可能な全画像で 98.7% であった。ただし、乱数シード 42 による 1 回の比較であり、薬剤ごとの画像数にも差があるため、必要撮影枚数を確定する結果ではなかった。薬剤を追加するたびに、複数の学習用実画像を撮影して整理する必要がある。この撮影・整理負担が、対象薬剤数を増やすうえでの課題となった。本研究が収集画像を学習元とする方式へ移行した動機は、この上段の結果にある。

下段の単一分割では提示条件数の増加に伴って観測精度が上昇した。一方、各提示条件数での実験は 1 回だけであり、評価枚数も 74 枚であった。また、17 提示条件には同一画素となる 0 度回転と明度倍率 1.0 が含まれる。したがって、17 提示条件が一般に最適であることや、精度差が提示条件数だけに起因することは示さなかった。

以上から、少数の元画像から複数の見え方を生成するという方針は維持することとした。そのうえで、残存錠数や切り出し範囲を変えた学習用写真を個別に撮影せずに済むよう、フルシート表裏の収集画像を学習元とする方式へ移行した。

4.3 収集画像学習 ver1 から ver3

実験管理上の保存名は「Web 画像学習」であるが、本報告書では出典監査の完了状況を考慮し、一般名称として「収集画像学習」を用いる。収集画像学習 ver1 から ver3 では、同じ評価画像 287 枚と合成複数薬剤画像 400 枚を用いながら、基画像の構成を段階的に変更した。結果を表 7 に示した。

表 7 収集画像学習 ver1 から ver3 の入力と評価結果

実験	基画像数	17 種類 提示後	量子化	LoRA	GPU / 実効バッチ	単剤 Top-1	画像単位 完全一致
ver1	457	7,769	4 ビット	r8, q/v	RTX 4070 Ti SU- PER / 16	259/287 (90.24%)	245/400 (61.25%)
ver2	451	7,667	4 ビット	r8, q/v	RTX 4070 Ti SU- PER / 16	255/287 (88.85%)	252/400 (63.00%)
ver3	1,265	21,505	4 ビット	r8, q/v	H100 / 128	281/287 (97.91%)	371/400 (92.75%)

ver1 では、RTI 41 枚と 1 錠区画 416 枚を基画像とし、4 ビット QLoRA で学習した。評価画像 287 枚は学習に用いておらず、その 287 枚に対する単剤 Top-1 精度は 90.24% であった。この結果から、収集画像を学習元とする方針には一定の見込みがあると考えた。一方、初期実画像方式より精度が低く、部分画像の空間的多様性が課題として残った。図 10 に、ver1 が 1 薬剤あたりに用いた基画像 11 枚（RTI 1 枚、表裏を対にした分画画像 10 枚）と、回転 12 種・明るさ 5 種による拡張後 17 種の例を示す。



図 10 ver1 が 1 薬剤あたりに用いた学習画像の全 11 枚（RTI 1 枚、分画画像 10 枚）と、回転 12 種・明るさ 5 種の拡張適用例。41 薬剤全体では基画像 457 枚、拡張後 7,769 枚であった。評価は内部開発評価画像 287 枚、単剤 Top-1（表 7 の ver1 行と同一の数値）であり、seed は 42 の単発結果である。

ver2 では、各薬剤について RTI を 1 枚生成した。さらに、面別にフルシートを各 1 枚、1 錠区画を各 2 枚、上半分を各 1 枚、上 1 / 4 区画を各 1 枚生成し、式 (16) の合計 11 枚とした。

$$N_d^{\text{ver2}} = 1 + 2(1 + 2 + 1 + 1) = 11 \quad (16)$$

1 錠区画画像は同じ位置を重複して用いており、包装内の異なる位置を網羅していなかった。ver1 から単剤

Top-1 は 1.39 パーセントポイント低下し、画像単位完全一致率は 1.75 パーセントポイント上昇した。ただし、基画像の構成も異なるため、一つの変更だけの効果とは解釈しなかった。

ver3 では、異なる錠剤セル、縦 2 分割画像、縦 4 分割画像を加え、通常の薬剤については基画像を 31 枚生成した。基画像数は 1,265 枚、17 種類の提示条件適用後は 21,505 枚であり、単剤 Top-1 は 97.91% へ上昇した。ただし、ver2 から ver3 では基画像構成、画像枚数、使用 GPU、実効バッチが同時に変化した。したがって、改善を部分画像の位置追加だけに帰属できなかった。また、同じ 287 枚を ver1 以降の条件検討に反復使用したため、ver1 から ver3 の評価はいずれも内部開発評価であった。

4.4 収集画像学習 ver4 (ver4 条件 A から D の比較)

表 8 に ver4 条件 A から D の設定と結果を示した。評価画像、エポック数、乱数シードは全条件で共通とした。ver4 条件 A は ver3 の設定を基準として 4 ビット QLoRA を再構成した条件であるが、ver3 本番実行の再現結果とは扱わない。ver4 条件 A は ver3 と同じ基画像 1,265 枚、同じ 17 提示条件、同じ 4 ビット量子化を用いたが、単剤 Top-1 は ver3 の 97.91% に対して 94.77% であった。ver3 と ver4 条件 A では、同一条件を意図しても実行環境と実装が完全には一致しなかった。したがって、ver4 条件 A は ver3 の再現結果ではなく、ver4 条件 B から D と比較するための基準として用いた。ver4 条件 B では量子化を行わなかったほか、勾配チェックポイントとマイクロバッチ構成も変更した。ver4 条件 C は LoRA のランク、スケール係数、対象層を同時に増やした。ver4 条件 D は ver4 条件 C の画像拡張を撮影変動対応の重複しない 17 条件へ置き換えた。手元の設計資料では ver4 条件 D が主条件とされていたが、第三者が検証できる形で事前に登録した条件ではなかった。このため、本報告書では ver4 条件 D を主結果として扱いつつ、事前登録済みの条件とは扱わなかった。

表 8 ver4 条件 A から D の設定と評価結果

条件	主な設定	単剤 Top-1	画像単位 完全一致	領域ラベル 一致
A	4 ビット QLoRA, ランク 8・係数 16, q/v 射影, ver3 の 17 提示条件	272/287 (94.77%)	307/400 (76.75%)	1,696/1,800 (94.22%)
B	BF16 LoRA, ランク 8・係数 16, q/v 射影, ver3 の 17 提示条件	276/287 (96.17%)	320/400 (80.00%)	1,714/1,800 (95.22%)
C	BF16 LoRA, ランク 16・係数 32, q/k/v/o + gate/up/down, ver3 の 17 提示条件	283/287 (98.61%)	356/400 (89.00%)	1,752/1,800 (97.33%)
D	BF16 LoRA, ランク 16・係数 32, q/k/v/o + gate/up/down, 撮影変動対応 17 提示条件	280/287 (97.56%)	331/400 (82.75%)	1,725/1,800 (95.83%)

図 11 に各条件の正解率を示した。本報告書で主結果として扱う ver4 条件 D は、単剤 Top-1 が 280/287 (97.56%)、画像単位完全一致率が 331/400 (82.75%)、領域ラベル一致率が 1,725/1,800 (95.83%) であった。単剤 Top-1 の Wilson 法による 95% 信頼区間は、画像単位の参考値として 95.05% から 98.81% であった。保存済み予測から求めた薬剤別正解率のマクロ平均は 96.82% であり、薬剤をクラスタとするブートストラップ 95% 区間は 94.24% から 98.98% であった。薬剤別正解率の最低値は 75.00% であり、該当するクラスはタケキャブ錠 20mg, ミヤ BM 錠, メトクロプラミド錠 5mg であった。




図 11 ver4 条件 A から D の評価結果 (3 指標)

保存済み予測を面，シート種別および残存錠数で層別に再集計した結果を表 9 に示した。再集計では新しい推論を行わず，ver4 条件 D の保存済み予測だけを入力とした。保存時の判定と 3.6.1 節の正規化後の厳密一致は 287 件すべてで一致し，層別の分母は面が表 212 枚・裏 75 枚，シート種別がフルシート 29 枚・部分シート 258 枚であった。

表 9 主条件 D の層別正解率 (分母は評価画像 287 枚の内訳)

層	区分	正解数／枚数	正解率
面	表	205/212	96.70%
	裏	75/75	100.00%
シート種別	フルシート	29/29	100.00%
	部分シート	251/258	97.29%
残存錠数	1 錠	37/39	94.87%
	2 錠	60/60	100.00%
	3 錠	40/42	95.24%
	4 錠	42/44	95.45%
	5 錠	33/33	100.00%
	6 錠	15/16	93.75%
	7 錠	15/15	100.00%
	8 錠	6/6	100.00%
	9 錠	3/3	100.00%
全体	全画像	280/287	97.56%

裏面 75 枚とフルシート 29 枚は，いずれも誤分類が 0 件であった。一方，表面は 205/212 枚であり，誤分類 7 件はすべて表面に生じた。ただし，残存錠数別の分母は 3 枚から 60 枚までと偏りが大きく，錠数と正解率の関係を確定的に解釈できなかった。

表 10 と図 12 に 7 件の内訳と代表 4 件を示した。7 件はすべて表面であり，残存錠数は 1 錠 2 件，3 錠 2 件，4 錠 2 件，6 錠 1 件の内訳であった。正解側ではムコダイン錠 500mg が 2 件，ほか 5 薬剤が各 1 件であ

表 10 主条件 D の誤分類 7 件（評価画像 287 枚）

画像 ID	正解薬剤	ver4 条件 D の予測	面	錠数
IMG_0020	レバミピド錠 100mg	プレドニン錠 5mg	表	1
IMG_0027	カロナール錠 500mg	デエビゴ錠 5mg	表	1
IMG_0039	ミヤ BM 錠	メチコパール錠 500 μ g	表	3
IMG_0047	タケキャブ錠 20mg	ジャディアンス錠 10mg	表	3
IMG_0079	メトクロプラミド錠 5mg	デエビゴ錠 5mg	表	4
IMG_0236	ムコダイン錠 500mg	レボチロキシン Na 錠 50 μ g	表	4
IMG_0238	ムコダイン錠 500mg	デエビゴ錠 5mg	表	6



図 12 主条件 D の代表的な誤分類モデル入力。(a) IMG_0027: カロナール錠 500mg→ デエビゴ錠 5mg, (b) IMG_0047: タケキャブ錠 20mg→ ジャディアンス錠 10mg, (c) IMG_0236: ムコダイン錠 500mg→ レボチロキシン Na 錠 50 μ g, (d) IMG_0020: レバミピド錠 100mg→ プレドニン錠 5mg である。著者が保存済みモデル入力を再配置した。

る。予測先ではデエビゴ錠 5mg が 3 件、ほか 4 薬剤が各 1 件であり、41 クラス外文字列はなかった。ただし、誤分類が 7 件と少なく、包装の向き、錠数または印字が原因であるとは断定できなかった。ver4 条件 C は、ver4 の 4 条件の中では、単剤 Top-1、画像単位完全一致率、領域ラベル一致率の 3 指標のすべてで最も高かった。ver4 条件 C は ver4 条件 B に対し、単剤 Top-1 が 2.44 パーセントポイント、画像単位完全一致率が 9.00 パーセントポイント上昇した。ただし、ver4 条件 C は全条件の結果を確認した後に選んだ探索的な最良条件である。このため、ver4 条件 C を事前に選んだ独立な確認実験の結果とは扱わなかった。

4.5 収集画像学習 ver5

ver5 では、ver4 条件 D を基準とし、全 41 クラスへ表面中央の縦 2 分割画像と縦 4 分割画像を各 1 枚追加した。基画像は 1,265 枚から 1,347 枚へ増加した。ver4 条件 C を基準とした後継実験ではなかった。結果は次のとおりであった。基準の ver5-1 は基画像 1,265 枚で、単剤 Top-1 が 280/287 (97.56%)、画像単位完全一致が 331/400 (82.75%)、領域ラベル一致が 1,725/1,800 (95.83%) であった。基画像を 1,347 枚へ増やして 5 エポック学習した ver5-2 は、281/287 (97.91%)、348/400 (87.00%)、1,745/1,800 (96.94%) であった。延べ提示数を ver5-1 へそろえた ver5-3 は、281/287 (97.91%)、356/400 (89.00%)、1,755/1,800 (97.50%) であった。

単剤 Top-1 は、追加前の ver5-1 に対して ver5-2、ver5-3 とも 1 枚の増加であった。薬剤をクラスタとしたブートストラップ 95% 区間は -2.02 から +2.57 パーセントポイント、McNemar 検定の p 値は 1.00 であり、単剤精度の明確な改善は確認されなかった。合成複数薬剤画像では ver5-2、ver5-3 が ver5-1 を上回ったが、黒背景のタイル合成複数薬剤画像に限られる結果であった。ver5-3 が ver4 条件 C と同じ 89.00% を示しても、基準条件と学習画像が異なるため、同一モデルまたは再現結果とは扱わなかった。

4.6 収集画像学習 ver6 (LoRA 容量の探索的追試)

ver6 は、ver4 条件 C と同じ評価画像 287 枚ならびに合成複数薬剤画像 400 枚・1,800 領域で評価した。評価入力の一覧が両条件で同一であることを確認したため、同じ評価集合に対する結果として比較した。

ver6 では、ver4 条件 C から LoRA のランク r を 16 から 32 へ増やし、 $\alpha/r = 2.0$ を保つため、スケーリング係数 α も 32 から 64 へ比例変更した。これに伴い、学習可能パラメータ数は 21,233,664 から 42,467,328 へ約 2 倍となった。モデル重みのデータ型である BF16、学習対象層および基画像 1,265 枚は、ver4 条件 C と同一であった。17 種類の提示条件、5 エポック、延べ提示画像数 107,525 枚、実効バッチサイズ 128 および乱数シード 42 も同一であった。変更の主眼は LoRA 容量に置いた。ただし、 r と α の 2 設定値を変更したため、容量増加の因果効果だけを証明する設計ではなかった。

表 11 ver4 条件 C、ver6 および ver7 の評価結果 (評価集合は同一)

条件	主な設定と変更点	単剤 Top-1	画像単位 完全一致	領域ラベル 一致
ver4 条件 C	ランク 16, 係数 32, 学習可能 21,233,664 パラメータ	283/287 (98.61%)	356/400 (89.00%)	1,752/1,800 (97.33%)
ver6	ランク 32, 係数 64, 学習可能 42,467,328 パラメータ	286/287 (99.65%)	374/400 (93.50%)	1,773/1,800 (98.50%)
ver7	ランク 16, 係数 32. 基画像 1,347 枚, 延 べ提示 114,495 枚, 41 候補から選択する 推論	284/287 (98.95%)	380/400 (95.00%)	1,780/1,800 (98.89%)

ver7 の詳細は 4.11 節に示す。3 条件はいずれも乱数シード 42 による 1 回の学習である。

ver4 条件 C と ver6 の評価結果を表 11 に示した。同表には ver7 の結果も併記し、探索的追試の 3 条件を同

一の評価集合で比較できるようにした。単剤予測の対応は、両条件とも正解 282 枚、ver4 条件 C だけ正解 1 枚、ver6 だけ正解 4 枚、両条件とも誤り 0 枚であった。McNemar 検定（正確法）は両側 $p = 0.375$ であり、ver4 条件 C に対する有意な改善は確認されなかった。ver6 は収集画像学習の探索条件内で単剤 Top-1 の最高観測値を示したため、探索的追試として詳述した。ただし、ver6 は全条件の結果を確認した後に選択した条件である。実行前の主条件は ver4 条件 D であった。また、乱数シード 42 による 1 回の観測だけであったため、LoRA 容量増加の効果と再現性は確認できなかった。

4.7 ver6 の単剤評価

ver6 は、内部開発評価画像 287 枚中 286 枚を正しく識別した。単剤 Top-1 精度は 99.65% であり、画像単位 of 参考値として算出した Wilson 法による 95% 信頼区間は 98.05% から 99.94% であった。同一薬剤内の画像は相互に独立とは限らないため、この区間を 287 個の独立標本に基づく外部性能の区間とは解釈しなかった。薬剤別正解率のマクロ平均は 99.73% であった。表面は 211/212 枚、99.53%、裏面は 75/75 枚、100.00%、フルシートは 29/29 枚、100.00% である。錠数別では、残存錠数が 4 錠の画像だけが 44 枚中 43 枚であり、ほかはすべて 100.00% であった。

ver4 条件 C で誤分類した 4 件について、ver6 では表 12 のとおり 4 件すべてを正しく識別した。そのうち、ver4 条件 C がムコダイン錠 500mg に対して生成した「ケコダイン錠 500mg」は学習対象の 41 クラスに存在しない文字列であったが、ver6 ではこの文字列を生成しなかった。

表 12 ver4 条件 C の誤分類 4 件に対する ver6 の予測

画像 ID	正解薬剤	面	錠数	ver4 条件 C の予測	ver6 の予測
IMG_0027	コロナール錠 500mg	表	1	デエビゴ錠 5mg	コロナール錠 500mg (正解)
IMG_0234	ムコダイン錠 500mg	表	4	ケコダイン錠 500mg	ムコダイン錠 500mg (正解)
IMG_0238	ムコダイン錠 500mg	表	6	デエビゴ錠 5mg	ムコダイン錠 500mg (正解)
IMG_0042	メチコパール錠 500 μ g	表	5	メトクロプラミド錠 5mg	メチコパール錠 500 μ g (正解)

図 13 に、ver4 条件 C から ver6 で正誤が変化した 4 件を示した。ver4 条件 C の 4 件を ver6 が正解した一方、ver6 は ver4 条件 C が正解した IMG_0236 を誤分類した。改善方向は一律ではなく、単一乱数シードのため再現性を確認していない。ムコダイン錠 500mg で複数の変化が観測されたが、事例数が少なく原因は特定できなかった。また、「ケコダイン錠 500mg」は 41 クラス外の生成文字列であった。

一方、ver6 は ver4 条件 C が正解していた別の 1 件を誤分類した。ver6 の誤分類は 287 枚中 1 枚であり、画像 ID は IMG_0236、正解薬剤はムコダイン錠 500mg、予測薬剤はレボフロキサシン錠 500mg、面は表、残存錠数は 4 錠であった。いずれも 41 クラスに含まれる薬剤名であり、クラス外の文字列は生成しなかった。ムコダイン錠 500mg は、ver4 条件 C と ver6 の双方で誤分類が集中した薬剤である。ただし、ver6 の誤分類は計 1 件だけであり、原因を統計的に特定できるだけの事例数はなかった。

なお、初期実画像方式の保存済み条件のうち、17 種拡張・640 画素・実効バッチ 8 の 5 分割交差検証は 286/287 (99.65%) であり、ver6 と同数であった。また、17 種拡張・実効バッチ 2 の保存済み条件は 285/287 (99.30%) であった。以下の画像別対応比較は 11 種提示条件の 283/287 を対象としたものであり、初期実画像方式の最良保存条件に対する ver6 の優越を示すものではない。初期実画像方式の 11 種拡張による 5 分割交差検証は 283/287 枚、ver6 は 286/287 枚を正しく識別した。ただし、両者は学習元と評価設計が異なるため、以下は同一画像に対する予測の探索的な参考比較である。方式間の優越性を検定する確認的比較ではなかった。画像識別子を正規化して 287 件すべてを一意に対応させた結果、両方式とも正解が 282 枚、ver6 の



図 13 ver4 条件 C と ver6 で正誤が変化した保存済みモデル入力。(a) IMG_0236 : 正解ムコダイン錠 500mg, ver4 条件 C は正解, ver6 はレボフロキサシン錠 500mg, (b) IMG_0234 : 正解ムコダイン錠 500mg, ver4 条件 C はケコダイン錠 500mg, ver6 は正解, (c) IMG_0027 : 正解カロナル錠 500mg, ver4 条件 C はデエビゴ錠 5mg, ver6 は正解, (d) IMG_0042 : 正解メチコバル錠 500 μ g, ver4 条件 C はメトクロプラミド錠 5mg, ver6 は正解である。著者が保存済みモデル入力を再配置した。

み正解が 4 枚, 初期実画像方式のみ正解が 1 枚, 両方式とも誤分類が 0 枚であった。不一致対は 4 対 1 であり, McNemar 検定 (正確法) による両側 p 値は $p = 0.375$ であった。有意差は認められず, ver6 の優越を証明した結果ではなかった。両方式とも誤分類した画像が 0 枚であったことから, この 287 枚には, 学習元の違いにかかわらず識別できない画像は含まれていなかった。

収集画像を学習元とした ver6 は, 学習には使用していない薬剤部の写真 287 枚で 99.65% を得た。この結果から, RTI, 部分画像, 画像拡張および LoRA 設定を組み合わせた構成で, 41 クラスの識別を実行できることを探索的に確認した。ただし, 新しい薬剤へ同程度の性能で拡張できることまでは示さなかった。

4.8 追加学習していない Qwen3.5-4B との比較

LoRA を適用していない Qwen3.5-4B の保存済み予測を 287 件すべて再集計した。追加学習していない Qwen3.5-4B は, 41 クラスの薬剤名をそのままの形では出力できなかった。保存時の包含判定では 3/287

(1.05%, Wilson 95% 信頼区間 0.36–3.03%) であった。一方、本報告書の厳密一致では 0/287 (0.00%, Wilson 95% 信頼区間 0.00–1.32%) であった。保存時に成功とされた 3 件も薬剤名を含む説明文であり、要求した薬剤名だけの出力形式には一致しなかった。同一 287 画像に対する 3 系列の集計を表 13 に示した。

表 13 追加学習していない Qwen3.5-4B, ver4 条件 D, ver6 の同一 287 画像による比較

保存系列	厳密一致	Top-1 精度	Wilson 95% 信頼区間
追加学習していない Qwen3.5-4B	0/287	0.00%	0.00–1.32%
ver4 条件 D	280/287	97.56%	95.05–98.81%
探索的 ver6	286/287	99.65%	98.05–99.94%

追加学習していない側と LoRA を適用した側では、入力の前処理、入力画像サイズ、実行環境および出力の制御が異なる。このため、観測された差は LoRA の有無だけを変更した比較ではなく、保存済みの実行全体の差であった。LoRA だけの効果は確認しておらず、観測された差を LoRA の有無だけの効果とは解釈しない。入力条件をそろえた再比較は本報告書の対象外であり、今後の課題とする。

正誤が異なった画像は ver4 条件 D に対して 280 件、ver6 に対して 286 件であり、すべて一方向へ偏った。このため、McNemar 検定の p 値は画像別の対応を記述する参考値であり、モデルの優越性を示す根拠としては用いない。

4.9 Gemini 3.5 Flash との対応比較

保存済みの Gemini 3.5 Flash による予測と ver6 の予測を、同じ評価画像 287 枚について対応付けた。薬剤名と画像ファイル名を結合した識別子は 287 件すべてで一意に一致し、元画像と正解ラベルの不一致もなかった。ただし、過去に Gemini API へ送信した JPEG 変換後のバイト列は保存されておらず、実際の送信入力そのものは検証できなかった。

Gemini 3.5 Flash は 284/287 枚 (98.95%), ver6 は 286/287 枚 (99.65%) を正しく識別した。差は ver6 が 0.70 パーセントポイント高かった。

画像別の正誤対応は、両方式とも正解が 283 枚、ver6 のみ正解が 3 枚、Gemini のみ正解が 1 枚、両方式とも誤分類が 0 枚であった。すなわち不一致対の内訳は、ver6 のみ正解が 3 件、Gemini のみ正解が 1 件である。式 (11) による正確 McNemar 検定の両側 p 値は 0.625 であり、有意差は認められなかった。ただし、不一致対は 4 件だけであり、検出力は低かった。この結果は、両方式の統計的同等性を示すものではなかった。また、両方式とも誤分類した画像が 0 枚であったことは、一方が誤る画像はもう一方が正解していることを意味する。すなわち、287 枚のうちいずれの方式でも識別できない画像は存在しなかった。

正誤が異なった 4 枚の内訳を表 14 に示した。

表 14 Gemini 3.5 Flash と ver6 で正誤が異なった画像

画像 ID	Gemini 3.5 Flash の予測	ver6 の予測
IMG_0095	タケキャブ錠 10mg (誤り)	デエビゴ錠 5mg (正解)
IMG_0236	ムコダイン錠 500mg (正解)	レボフロキサシン錠 500mg (誤り)
IMG_0044	タケキャブ錠 20mg (誤り)	メチコパール錠 500 μ g (正解)
IMG_0045	メトクロプラミド錠 5mg (誤り)	メチコパール錠 500 μ g (正解)

Gemini の保存実験では、元画像を最大 589,824 画素へ縮小し、JPEG 品質 90 へ変換したうえで、41 クラスの候補一覧をプロンプトへ与えていた。一方、ver6 では背景除去後の 448 画素正方形画像を用いた。入力前処理、プロンプト、推論方式が異なるため、本比較は各保存済みパイプライン全体の探索的参考比較とし

た。また、Gemini のモデルリビジョン、温度、乱数シードは記録されておらず、API 再実行による完全な再現はできなかった。

4.10 ver6 の合成複数薬剤画像評価

ver6 は、合成複数薬剤画像 400 枚中 374 枚を画像単位完全一致で識別した。画像単位完全一致率は 93.50% であり、参考値として算出した Wilson 法による 95% 信頼区間は 90.65% から 95.53% であった。検出された領域数は、正解領域数と同じ 1,800 件であった。保存順の貪欲な一対一対応では、正解ラベル 1,800 件中 1,773 件が予測ラベルと対応した。厳密一致による再集計でも、これらの件数は変わらなかった。領域ラベル一致率は 98.50% であり、独立性を仮定した参考値として算出した Wilson 法による 95% 信頼区間は 97.83% から 98.97% であった。400 枚は、単剤実写真を黒い間隔を空けてタイル状に配置して作成した。ただし、各領域がどの単剤写真に由来するかは記録されていない。このため、使用した元写真の総数、除外画像、元写真ごとの再利用回数は再集計できなかった。単剤実写真を再利用した合成評価であるため、単剤評価から独立に取得した検証とは扱わなかった。領域ラベル一致率 98.50% は、単剤 Top-1 精度 99.65% とは異なる独立標本に対する外部評価ではなかった。両者の差は、タイル合成と領域抽出という処理を経たことによる劣化を含んでいた。また、元写真の対応記録がないため、1,800 領域を独立標本として扱わなかった。

図 14 に薬剤数別の完全一致率を示した。2 薬剤では 96.00%、3 薬剤では 95.00%、5 薬剤では 93.00%、8 薬剤では 90.00% であった。画像内の薬剤数が増えるにつれて、完全一致率は低下した。画像単位完全一致は、画像内のすべての領域が正しく識別された場合にのみ成立する指標である。したがって、1 画像当たりの領域数が増えるほど、完全一致の成立条件は厳しくなる。ただし、各薬剤数の評価枚数は 100 枚であり、薬剤数間の差の有意性は検定していない。




図 14 ver6 における薬剤数別の完全一致率

本評価では、薬剤部で撮影した元写真を黒い隙間で区切って格子状に配置した合成複数薬剤画像を用いた。薬剤の重なり、影、手やトレイの写り込み、反射、複雑な背景を含まなかった。したがって、93.50% を薬剤部で撮影する実画像の性能として解釈できなかった。複数薬剤の実用性能を判断するには、実際の撮影条件による独立評価が必要であった。

4.11 収集画像学習 ver7（探索的追加実験）

ver7 は、ver6 および ver4 条件 C と同じ評価画像 287 枚ならびに合成複数薬剤画像 400 枚・1,800 領域で評価した。ver7 では、ver4 条件 C から次の 3 点を同時に変更した。

1. 表面中央の縦 2 分割画像と縦 4 分割画像を 41 クラスへ各 1 枚追加し、基画像を 1,265 枚から 1,347 枚へ増やした。
2. 延べ提示画像数を 107,525 枚から 114,495 枚へ増やした。
3. 推論を自由生成から、学習マニフェスト由来の 41 候補の中で平均トークン対数尤度が最大のものを選ぶ方式へ変更した。

LoRA はランク 16、スケーリング係数 32 であり、ver4 条件 C と同一であった。したがって、ver6 との比較では、画像追加、延べ提示画像数、推論方式に加え、LoRA のランクと係数も異なった。なお、ver7 の来歴記録には基画像数 1,265 枚という変更前の値が残る一方、設定、学習マニフェストおよび実ファイルは 1,347 枚で一致した。このため、来歴記録は更新漏れのある補助資料として扱い、基画像数の根拠には用いない。

ver7 の評価結果は、ver4 条件 C および ver6 とあわせて表 11 へ示した。ver7 は画像単位完全一致 380/400 (95.00%)、領域ラベル一致 1,780/1,800 (98.89%) であり、複数薬剤の 2 指標では ver6 を上回った。一方、単剤 Top-1 は 284/287 (98.95%) であり、ver6 を下回った。41 候補から選ぶ推論による正解数の増加は認められず、同じアダプタによる自由生成の予測と完全に一致した。ver4 条件 C からは 3 要因、ver6 からは LoRA 容量を含む 4 要因が異なるため、結果の変化を個別要因へ帰属できなかった。ver6 は単剤 Top-1、ver7 は合成複数薬剤の 2 指標で高い値を示しており、探索的追試の中でも単一の条件がすべての指標で最良とはならなかった。ver6、ver7 とともに乱数シード 42 による 1 回の学習結果であり、条件間の差の再現性は確認しなかった。

4.12 収集画像学習 ver8・ver9 の単剤評価

ver8 と ver9 は、単剤経路と複数薬剤経路を分けた 2 経路パッケージとして保存されている。本節では、本報告書の主指標である単剤側だけを扱う。

両条件とも、BF16 LoRA、ランク 32、スケーリング係数 64、学習対象層は q, k, v, o 射影および gate, up, down 射影であり、学習可能パラメータ数は 42,467,328 であった。基画像は 1,347 枚であり、延べ提示画像数は ver6 と同じ 107,525 枚へ固定した。エポック数 5、学習率 2.0×10^{-4} 、実効バッチサイズ 128、乱数シード 42 は、ver6 と同一であった。ver9 は ver8 に対し、17 提示条件のうち明度倍率 1.0 の条件を、複数領域の解像度劣化を模擬する条件へ置き換えた点だけが異なる。

ここで注意すべき点がある。保存された 2 経路パッケージの単剤経路は、新たに学習した ver8・ver9 のアダプタではなく、保存済み ver6 アダプタをそのまま用いる設定であった。実際、パッケージの単剤経路の予測は、画像 ID、正解薬剤、予測薬剤および正誤の 4 項目について、ver6 の保存済み予測 287 件と不一致 0 件で完全に一致した。したがって、パッケージとしての単剤結果は ver6 の結果の再掲であり、ver6 を上回る単剤性能を示すものではなかった。

一方、ver8・ver9 のアダプタ自身を同じ評価画像 287 枚へ適用した診断値は、いずれも 286/287 (99.65%) であった。この値は ver6 と同数であるが、誤分類した画像は条件ごとに異なった。ver8 は IMG_0130 (正解 エンレスト錠 200mg、表、残存 4 錠) をフロセミド錠 200mg と予測した。この予測文字列は、フロセミド錠

20mg とは含量が異なり、学習対象の 41 クラスには存在しなかった。ver9 は IMG_0236（正解ムコダイン錠 500mg、表、残存 4 錠）をレボフロキサシン錠 500mg と予測し、これは ver6 が誤分類した画像および予測先と同一であった。

保存済みの昇格判定では、単剤性能の維持を示す項目だけが真であり、ver6 および ver7 の複数薬剤性能を上回る項目と、総合的な昇格の可否を示す項目はいずれも偽であった。したがって、ver8 と ver9 は性能退行のない候補条件であり、採用条件として昇格したものではなかった。

収集画像学習 ver1 から ver9 までの単剤 Top-1 精度を表 15 にまとめた。すべて同じ評価画像 287 枚に対する値であった。

表 15 収集画像学習 ver1 から ver9 の単剤 Top-1 精度（評価はいずれも同じ 287 枚）

条件	主な設定・変更点	基画像数	単剤 Top-1
ver1	RTI と 1 錠区画、4 ビット QLoRA、ランク 8、q/v 射影	457	259/287 (90.24%)
ver2	表裏を分離し、面別の部分画像を追加	451	255/287 (88.85%)
ver3	異なる錠剤セル、縦 2 分割・縦 4 分割を追加	1,265	281/287 (97.91%)
ver4 条件 A	ver3 設定を基準に 4 ビット QLoRA を再構成	1,265	272/287 (94.77%)
ver4 条件 B	BF16 LoRA へ変更（量子化等を同時に変更）	1,265	276/287 (96.17%)
ver4 条件 C	ランク 16・係数 32、学習対象層を拡大	1,265	283/287 (98.61%)
ver4 条件 D	撮影変動対応の重複しない 17 提示条件（主条件）	1,265	280/287 (97.56%)
ver5-1	ver4 条件 D を基準とする再実行	1,265	280/287 (97.56%)
ver5-2	表面中央の縦 2 分割・縦 4 分割画像を追加	1,347	281/287 (97.91%)
ver5-3	総提示数を ver5-1 へ一致させた条件	1,347	281/287 (97.91%)
ver6	ランク 32・係数 64 へ増加（探索的追試）	1,265	286/287 (99.65%)
ver7	基画像 1,347 枚、41 候補から選ぶ推論へ変更	1,347	284/287 (98.95%)
ver8*	2 経路構成、ランク 32、延べ提示数を ver6 へ固定	1,347	286/287 (99.65%)
ver9*	ver8 の明度 1.0 条件を解像度劣化条件へ置換	1,347	286/287 (99.65%)

* ver8・ver9 の値は各アダプタ自身を単剤評価した診断値である。2 経路パッケージの単剤経路は保存済み ver6 アダプタを用いるため、パッケージとしての単剤結果は ver6 と同一である。

表 15 では、ver6、ver8 および ver9 が 286/287 で同数の最高観測値であった。したがって、収集画像学習の探索条件の中で、ver6 だけが単独の最高条件ではなかった。ただし、ver8 と ver9 はいずれも ver6 と同じランク 32・係数 64 を用いており、基画像数と提示条件だけが異なる派生条件である。また、各条件は乱数シード 42 による 1 回の学習結果であり、同一の 287 枚を反復使用した評価であった。このため、286/287 という同数の観測から、条件間の優劣および再現性を判断することはできなかった。

4.13 黒い区切りのない合成画像による予備評価

4.13.1 ver3 入力素材を用いた領域抽出だけの評価

黒い隙間への依存を切り分ける追試として、収集画像学習 ver3 で保存した 448 × 448 の背景除去済み Qwen 入力素材を、継ぎ目のない共通背景へ非接触で配置した。5 薬剤、6 薬剤、8 薬剤を各 3 枚、合計 9 枚生成し、正解薬剤数や正解外接矩形を処理へ与えずに領域を抽出した。図 15 に 5 薬剤画像の入力と検出結果

の構成を模式的に示した。




図 15 黒い区切りのない合成画像に対する領域抽出の模式図

採採用正解領域 57 件に対して 57 領域を抽出し、領域の重なり率（Intersection over Union : IoU）0.25 以上で 57 件すべてが対応した。個数と全領域が一致した画像は 9/9 枚であった。図 16 に、本節の保存済み 9 枚のうち 8 薬剤_gapless_01 の入力と検出結果を示した。

図 16 は、模式図 15 の後段に対応する実出力であった。包装同士が離れ、背景色が一様であるため、前景マスクの連結成分が包装単位で分離した。ただし、これは色の安定した共通背景上で包装同士を離れた合成複数薬剤画像による領域抽出だけの確認であり、Qwen による薬剤名推論は実施しなかった。したがって、この 9/9 を ver4 条件 C の複数薬剤完全一致率 89.00% と置き換えることはできなかった。また、実際の机上背景、接触、重なり、影を含む自然画像での検出性能も示さなかった。

4.13.2 元写真タイルを用いた ver6・ver7 の検出後識別

これとは別に、評価用の元写真を背景除くせず、余白と間隔を 0 画素としてタイル配置した合成画像を用いた。薬剤数が 5, 6, 8 の画像を各 3 枚、合計 9 枚生成し、正解薬剤数を検出器へ与えずに領域検出と薬剤名推論を行った。入力には、元写真全体を縦横比を保って各タイルへ縮小した画像を用いた。この条件は、固定 400 枚の黒背景キャッシュとは異なっていた。結果を表 16 に示した。

表 16 黒い区切りのない未知個数画像 9 枚に対する探索的評価

条件	薬剤名と個数の完全一致	薬剤名の種類の完全一致	期待ラベル数	検出数	対応した正解ラベル
ver6	2/9 (22.22%)	2/9 (22.22%)	57	66	55/57 (96.49%)
ver7	2/9 (22.22%)	3/9 (33.33%)	57	66	55/57 (96.49%)

「薬剤名と個数の完全一致」は、画像ごとに薬剤名とその個数がすべて一致した画像数を 9 枚中の比率で示した。「薬剤名の種類の完全一致」は、個数を無視して薬剤名の種類だけが一致した画像数を 9 枚中の比率で示した。「対応した正解ラベル」は、画像内の予測と正解を薬剤名と個数で照合できた個数を、期待 57 領域に対する比率で示した。この値は、検出枠の位置の正しさを測る指標ではない。両条件とも期待領域数 57 件に対して 66 領域を検出し、検出数は期待数を 9 件上回った。領域検出は薬剤名の推論とは独立に行うため、検出数は両条件で等しい。対応した正解ラベル数もいずれも 55 件であったが、薬剤名の種類の完全一致は ver6 が 2/9, ver7 が 3/9 であり、識別結果そのものは同一ではなかった。過検出の例を図 17 に示した。

正解ラベル 55 件がいずれかの予測と対応しても、検出数とラベル多重集合の双方が一致した画像は 2/9 枚




図 16 共通背景・非接触配置における入力と領域抽出結果の実例 (8 薬剤_gapless_01)。(a)は採点用期待領域 8 件の入力, (b)は保存済みの検出枠である。検出器へ正解薬剤数, 正解外接矩形および薬剤名は与えておらず, 8 領域を検出して IoU 0.25 以上で 8 件すべてが対応した。入力は ver3 の背景除去済み 448×448 素材を共通背景上へ非接触配置した合成画像であり, 実写の自然配置画像ではない。著者が保存済み入力と検出結果を再配置した。



図 17 元写真タイルにおける入力と検出結果の過検出例 (5 薬剤_flush_02). (a) は採点用期待領域 5 件の入力, (b) は保存済みの検出枠である. 検出器へ正解薬剤数, 配置, 薬剤名およびタイル寸法は与えておらず, 8 領域を検出して 3 件を過検出した. 過検出した 3 件は, いずれも左端タイルの元写真の周辺部に写り込んだ被写体に対応した. 入力は背景除去を行わない元写真を余白・間隔 0 画素でタイル配置した合成画像であり, 実写の自然配置画像ではない. 著者が保存済み入力と検出結果を再配置した.

にとどまった. これは 9 枚だけの合成画像による探索的評価であり, 固定 400 枚の結果と直接比較できなかった. また, 元写真を接触させたタイル境界は含むが, 包装同士の重なり, 任意の机上配置, 手やトレーの写り込みを含む自然画像ではなかった.

4.14 ver4 条件 C の信頼ゲート評価

本節は ver4 条件 C のアダプタに対する初期の予備評価である. 本節で決定したしきい値は, 他のモデルへ流用できるかどうかを判断する基準としても用いた. ver4 条件 C のモデルに対し, 校正集合だけで決定した信頼ゲートを最終評価集合へ適用した. 系列スコアのしきい値は $\tau_s = -0.0112$, 候補間マージンのしきい値は $\tau_m = 0.2827$ とした. 11 視点の TTA 多数決一致率のしきい値は $\tau_a = 7/11$ とし, 第 1 候補と TTA 多数決の薬剤名一致を必須とした. 本文では有効数字を 3 桁へそろえて示し, 実験で用いた値は保存済み設定に小数第 9 位まで記録している. これらのしきい値は, 最終評価集合の推論開始前に固定した.

表 17 に校正集合と最終評価集合の結果を示した. 校正集合では, 既知薬剤 139 枚中 137 枚に回答し, 誤回答は 0 件であった. 未知薬剤 67 枚では 64 枚を保留し, 危険通過は 3 件であった. 最終評価集合では, 既知薬剤 148 枚に対するゲート適用前の第 1 候補正解は 145 枚であった. ゲート適用後は 134 枚に回答し, 回答した 134 枚はすべて正解であった. ゲートは適用前の誤回答 3 枚をすべて保留したが, 適用前に正しかった 11 枚も保留した.

最終評価集合における既知薬剤への回答率は 90.54% であり, Wilson 法による 95% 信頼区間は 84.75%

表 17 ver4 条件 C の信頼ゲートにおける校正集合と最終評価集合の結果

評価段階	既知薬剤への回答	既知誤回答	未知薬剤の保留	危険通過
校正集合	137/139	0	64/67	3
最終評価集合	134/148	0	50/58	8

から 94.28% であった。回答した既知薬剤の正解率は 100.00% であり、Wilson 法による 95% 信頼区間は 97.21% から 100.00% であった。一方、未知薬剤の保留率は 86.21% であり、Wilson 法による 95% 信頼区間は 75.07% から 92.84% であった。既知薬剤と未知薬剤のいずれにも、同一製品に由来する複数画像が含まれていた。そのため、これらは画像単位の参考区間であり、製品単位で独立な外部性能の区間ではなかった。未知薬剤 58 枚中 8 枚 (13.79%) に既知薬剤名を回答した。危険通過は校正集合の 3/67 (4.48%) から最終評価集合の 8/58 (13.79%) へ悪化し、校正集合で観測された水準は再現されなかった。

表 18 に、信頼ゲートを通過した未知薬剤と、誤って回答した既知薬剤との組合せを示した。アラセプリル錠 25mg とアテノロール錠 25mg は、いずれもアルダクトン A 錠 25mg として各 2 枚が通過した。そのほか 4 薬剤で各 1 枚が通過した。

表 18 信頼ゲートを通過した未知薬剤と誤って回答した既知薬剤との組合せ

未知薬剤	回答した既知薬剤	枚数
アラセプリル錠 25mg 「日医工」	アルダクトン A 錠 25mg	2
アテノロール錠 25mg 「NIG」	アルダクトン A 錠 25mg	2
アテノロール錠 50mg 「NIG」	ムコダイン錠 500mg	1
アロプリノール錠 100mg 「NIG」	プロマック D 錠 75mg	1
エゼチミブ錠 10mg 「日医工」	エソメブラゾールカプセル 20mg	1
プレガバリンカプセル 150mg 「日医工」	プレドニン錠 5mg	1

危険通過 8 件の元画像パスとモデル入力パスは最終評価マニフェストから一意に復元できた。ただし、未知薬剤は外部 Web 収集画像であり、各画像の本文転載条件までは確認できなかったため、指示書の掲載条件に従って実画像図は掲載しなかった。また、既知側と未知側で取得条件が異なり、外観だけから誤り原因を断定できなかった。

今回の最終評価集合では、厳密な薬剤名照合、TTA、系列スコア、候補間マージンだけでは、未知薬剤の危険通過を十分に防止できなかった。また、既知薬剤は内部開発評価画像、未知薬剤は収集画像であり、画像の取得条件および被写体の占有範囲が異なった。したがって、本評価は信頼ゲートの予備評価であり、実画像の未知薬剤を安全に検出できることを示す外部評価ではなかった。信頼ゲートは完成していないと判断した。

4.15 学習薬剤数の段階増加 (41 から 100 薬剤)

学習に用いる薬剤の種類数を 41 薬剤から 100 薬剤まで段階的に増やし、全段階で同一の実写 41 薬剤 287 枚 (単剤 Top-1) を評価した。LoRA 容量と画像拡張の異なる 2 系列を実施した。第一系列 (以下、実験 81 番) は LoRA rank16/alpha32, 画像拡張 acquisition_17 (無変換 1 種, 回転 6 種, 明るさ 2 種, コントラスト 2 種, ガンマ 2 種, 台形歪み 2 種, ぼかし 1 種, ノイズ 1 種の計 17 種) を用いた。第二系列 (以下、実験 82 番) は LoRA rank32/alpha64, 画像拡張 v3_17 (回転 12 種, 明るさ 5 種の計 17 種) を用いた。いずれも 41, 50, 60, 70, 80, 90, 100 薬剤の 7 水準について、学習薬剤数の増加にあわせて基画像数と総学習提示数

も増加させ、seed 42, 43, 44 の 3seed で学習・評価した。

図 18 に、実験 82 番 41 薬剤条件（3seed 平均 98.84% ± 0.88pt, 実写 41 薬剤 287 枚）が 1 薬剤あたりに用いた学習画像の全体像を示す。




図 18 実験 82 番 41 薬剤条件（メインテート錠 2.5mg の例）が用いた元画像，RTI，学習用画像 30 枚（全体 2 枚，1/2 区画 4 枚，1/4 区画 8 枚，1 錠区画 16 枚）と，回転 0～330 度を 30 度刻みで 12 種，明るさ 0.8～1.2 倍を 0.1 刻みで 5 種とした拡張 17 種の例。RTI 自体は学習から除外した。評価は実写 41 薬剤 287 枚，単剤 Top-1，3seed (42, 43, 44) 平均 98.84% ± 0.88pt（表 19 の 41 薬剤・実験 82 番の値と同一）である。

学習薬剤数を 100 薬剤まで増やしても，追加した薬剤（42 番目以降）の実写評価画像は存在しない。したがって本実験が測っているのは，100 薬剤を識別できるかではなく，学習に投入する薬剤クラス数を増やしたとき，もともと学習していた 41 薬剤の識別精度がどう変化するかである。「100 種類に対応できるようになった」とは言えず，言えるのは「学習対象を増やしても既知 41 薬剤の性能が大きくは崩れない場合がある」までである。

表 19 に，2 系列それぞれの学習薬剤数と 3seed 平均精度を示した。± は seed 間の標本標準偏差であり，同一の 287 枚を 3 回評価した値の変動を表す。3seed 合計 861 件は，独立な 861 枚に対する信頼区間ではない。

いずれの系列も，学習薬剤数に対して精度が単調に変化しなかった。実験 81 番系列は 41 薬剤 97.33% から 100 薬剤 96.40% へ -0.93pt 変化し，80 薬剤で標本標準偏差 9.57pt の大きな崩れ（seed 44 が 80.49%）を挟んで 90 薬剤で 98.03% まで持ち直した。実験 82 番系列は 41 薬剤 98.84% から 100 薬剤 94.89% へ -3.95pt 変化し，60 薬剤で一度落ち込んだ（seed 44 が 93.38%）のち持ち直し，90 薬剤から 100 薬剤にかけて右肩下がりとなった。崩れが生じる薬剤数の段階は系列によって異なり，「100 薬剤で必ず崩れる」といった共通の法則は確認できなかった。

この 2 系列は，LoRA 容量（rank/alpha）と画像拡張セット（acquisition_17 と v3_17）が同時に異なる。ま

表 19 学習薬剤数を 41 から 100 へ段階的に増やしたときの実写 41 薬剤 287 枚の 3seed 平均精度

学習薬剤数	実験 81 番 (rank16/alpha32・acquisition_17)	実験 82 番 (rank32/alpha64・v3_17)
41	97.33% ± 1.22pt	98.84% ± 0.88pt
50	97.79% ± 0.20pt	98.61% ± 0.70pt
60	97.68% ± 0.40pt	96.40% ± 2.64pt
70	95.59% ± 1.61pt	97.91% ± 0.70pt
80	91.52% ± 9.57pt	98.37% ± 0.73pt
90	98.03% ± 0.40pt	96.98% ± 1.22pt
100	96.40% ± 2.64pt	94.89% ± 0.80pt

± は seed 42, 43, 44 間の標本標準偏差. 評価はすべて実写 41 薬剤 287 枚, 単剤 Top-1.

41 → 100薬剤: 同じ実写41薬剤287枚で評価した




図 19 学習薬剤数を 41 から 100 まで 7 水準で段階的に増やしたときの, 実験 81 番 (rank16/alpha32・acquisition_17) と実験 82 番 (rank32/alpha64・v3_17) それぞれ 3seed (42, 43, 44) の実写 41 薬剤 287 枚単剤 Top-1 精度. 表 19 と同一の数値を図示した. 評価は全段階を通じて常に既知の実写 41 薬剤 287 枚のままであり, 42 番目以降として追加学習した薬剤の実写評価データは存在しない. そのため本図は「100 薬剤に対応できた」ことを示すものではなく, 学習対象を増やしたときに既存 41 薬剤の性能がどう変化したかを示す.

た, 学習薬剤数の増加にあわせて基画像数 (1,224 枚から 2,994 枚) と総学習提示数 (107,525 件から 262,990 件) も同時に増加している. したがって, 表 19 の精度変化を学習薬剤数だけの効果に帰属することはできない. LoRA 容量と拡張セットを分離した比較は本報告書では扱わない.

4.16 最高精度モデル (実験 82 番 41 薬剤条件) への信頼ゲート適用

研究内で単剤評価が最も高かったモデルは, 4.15 節の実験 82 番 41 薬剤条件 (3seed 平均 98.84% ± 0.88pt) である. このモデルには, これまで信頼ゲートを一度も適用していなかった. そこで, 実験 82 番 41 薬剤条件の 3seed (42, 43, 44) の保存済み LoRA へ, 4.14 節の信頼ゲート ver2 で校正集合 (既知 139 枚・未知 67 枚) を用いて事前に固定したしきい値を再校正せずそのまま適用した. 用いたしきい値は, 系列スコア

$\tau_s = -0.02$, 候補間マージン $\tau_m = 0.12$, TTA 多数決一致率 $\tau_a = 0.90$ であり, 第 1 候補と TTA 多数決の薬剤名一致は必須としなかった. これらは 4.14 節で ver4 条件 C のために決定したしきい値とは異なる, 信頼ゲート ver2 の凍結値である.

評価集合は信頼ゲート final (既知 148 枚・未知 58 枚) であり, 4.14 節と同一の画像・同一の `sample_id` を用いた. 実写 41 薬剤 287 枚, 隙間なし合成 800 枚, 合成複数薬剤 400 枚などの他の評価集合とは混同していない.

表 20 に 3seed の結果を示した.

表 20 実験 82 番 41 薬剤条件への信頼ゲート適用結果 (既知 148 枚, 未知 58 枚, しきい値は再校正なし)

指標	seed 42	seed 43	seed 44	3seed 平均 $\pm$ SD
既知の回答率	94.59%	88.51%	89.19%	90.77% $\pm$ 3.33pt
既知の回答時正解率	100.00%	100.00%	100.00%	100.00% $\pm$ 0.00pt
未知の保留率	81.03%	94.83%	79.31%	85.06% $\pm$ 8.50pt
未知への危険通過 (/58)	11	3	12	8.67 $\pm$ 4.93

既知薬剤への回答は 3seed とも誤回答が 0 件であり, 回答時正解率は 100% を維持した. 一方, 未知薬剤への危険通過は seed によって 3 件から 12 件まで振れた (標準標準偏差 4.93). seed 43 だけが 3 件と少なく, seed 42・44 は 11 件・12 件と多かった.

この結果は, 信頼ゲート ver2 で決定したしきい値が, モデルが変わるとそのまま適用できない可能性を示す. 実験 82 番の結果からも, 信頼ゲートのしきい値はモデル間・seed 間で流用できないことが確認された. 本節の適用対象は実験 82 番の 41 薬剤条件 (rank32/alpha64・v3.17) の 3seed であり, 4.15 節の 100 薬剤条件には適用していない. また, 信頼ゲート ver2 のしきい値は, 本節とは異なるモデル・学習データで校正されたものであり, 実験 82 番にとって最適であることは確認していない.

4.17 隙間のない合成複数薬剤画像：最大 10 候補と Top-N 評価

固定 400 枚の評価とは別に, 薬剤数 2, 3, 5, 8 の隙間のない元写真タイルを各 200 枚, 合計 800 枚用いた. 1 薬剤 200 枚は生成したが, 薬剤数が複数となる 2, 3, 5, 8 薬剤の 800 枚を Top10 本番の評価対象とした. 入力タイルは 768 $\times$ 1024 画素, タイル間隔と外周余白は 0 画素で, 合成前の背景除去は行っていない.

薬剤数を検出器へ渡さず, 前景強度の高い候補を順位付けして最大 10 領域まで残した. 800 枚から抽出された候補は 4,336 領域であり, 期待薬剤ラベル数 3,600 に対して, 14 アダプタで 60,704 回の単剤推論を行った.

薬剤数未知の全候補包含では余分な予測を許し, 正解薬剤がすべて別々の予測として含まれる画像を成功とした. 一方, 既知個数 Top-N では, 実行後に正解薬剤数 N を用いて候補 1 位から N 位を残し, 予測と正解薬剤の集合が 1 対 1 で完全一致した画像だけを成功とした. 結果の最高値と ver4 条件 D の値を表 21 に示す.

表 21 隙間のない合成複数薬剤画像 800 枚に対する最大 10 候補方式と既知個数 Top-N 方式

方式	最高条件	最高結果 (800 枚)	ver4 条件 D
薬剤数未知・全候補包含	ver5 B, ver5 C, ver8	790/800 (98.75%)	76.25%
薬剤数既知・Top-N	ver8	682/800 (85.25%)	66.50%

全候補包含の最高条件は同率であった. 同方式は余分な予測を許すため, 790/800 は画像完全一致率ではなく, 正解薬剤包含率である. 正解薬剤単位では 3,589/3,600 を認識した.

全候補包含方式では、ver5 B, ver5 C および ver8 が同率で 790/800 (98.75%) となった。薬剤数を正しく当てることよりも正解薬剤を取りこぼさないことを優先する方式であり、過検出を罰していない。Top-N 方式は全条件で全候補包含方式を下回り、最高は ver8 の 682/800 (85.25%) であった。候補の強度順位が薬剤領域の完全性や単剤モデルの識別しやすさを直接表さないため、正しい候補が N 位より後ろに残ることが低下の主因と考えられた。

この 800 枚の評価は、黒い隙間を設けた固定 400 枚の評価と画像構成および採点規則が異なる。したがって、表 8 の画像単位完全一致率 82.75% や領域ラベル一致率 95.83% と直接比較せず、隙間のない画像に対する探索的な副次評価として扱う。

4.18 総合考察

条件比較では、4 ビット量子化、勾配チェックポイント、マイクロバッチ構成を同時に変更した条件 B が条件 A を上回った。さらに、LoRA のランク、スケール係数、適用層を同時に変更した条件 C が条件 B を上回った。各比較で複数要因を同時に変更したため、BF16 化または追加学習対象層の拡大だけの効果とは解釈できなかった。ver6 は、 $\alpha/r = 2.0$ を保ったままランク r を 2 倍にし、それに伴って α を比例変更した。学習可能パラメータ数は 21,233,664 から 42,467,328 へ約 2 倍となり、単剤 Top-1 は 283/287 (98.61%) から 286/287 (99.65%) へ増加した。対応比較の McNemar 検定は両側 $p = 0.375$ であった。ランク増加と性能変化を同時に観測したが、乱数シード 42 による 1 回の学習であったため、LoRA 容量増加の効果と再現性は確認できなかった。

本報告書で主結果として扱う ver4 条件 D の単剤 Top-1 は 97.56% であり、ver6 の 99.65% は収集画像学習の探索条件内で全条件の結果確認後に得た最高観測値である。ただし、ver8 および ver9 のアダプタも同じ 286/287 (99.65%) であり、ver6 は収集画像学習内でも単独の最高条件ではない。さらに、初期実画像方式の保存済み最良条件 E12b も 286/287 (99.65%) であった。ver8 と ver9 の 2 経路パッケージの単剤経路は保存済み ver6 アダプタを用いる設定であり、ver6 を上回る単剤性能を示すものではなかった。ver7 では、画像単位完全一致率が 95.00%、領域ラベル一致率が 98.89% となり、両指標で ver6 を上回った。一方、単剤 Top-1 は 98.95% であった。したがって、ver6 を確認的な主結果または全指標で最良の条件とは扱わなかった。次の評価では、主条件を事前に固定し、新しく撮影した画像だけで確認する必要がある。

Gemini 3.5 Flash との対応比較では、ver6 が 0.70 パーセントポイント高かった。しかし、正確 McNemar 検定の両側 p 値は 0.625 であり、有意差は認められなかった。不一致対は 4 件だけであり、方式間の統計的同等性を示す結果でもなかった。また、入力前処理、プロンプト、推論方式が異なるため、差をモデル本体だけへ帰属できなかった。

追加学習していない Qwen3.5-4B は、41 クラスの薬剤名をそのままの形では出力できなかった。保存時の包含判定では 3/287、厳密一致では 0/287 であった。ver4 条件 D および ver6 との差は大きかったが、追加学習していない側は素画像、LoRA を適用した条件は前処理後の画像を用いた。また、追加学習していない側のモデルリビジョンと実行環境の記録は残っていなかった。したがって、本比較は追加学習の必要性を検討する参照情報にはなるが、LoRA だけの因果効果または提案手法の優越性を示す対照実験とは扱えなかった。

ver6 の評価画像 287 枚では誤分類が 1 件となった。一方、複数薬剤では領域ラベル一致率が 98.50% であっても、8 薬剤の完全一致率は 90.00% まで低下した。画像単位完全一致では、領域ごとの誤りが画像全体の不一致として反映される。したがって、複数薬剤では単剤モデルの改善に加え、検出結果の検証と保留機構が必要であった。

ver4 条件 C の信頼ゲートは、既知薬剤の誤回答 3 件をすべて保留し、回答した 134 件はすべて正解であった。一方で、正しく識別できていた 11 件も保留し、未知薬剤 8 件を危険通過させた。未知薬剤保留率は、校正集合の 64/67 (95.52%) から最終評価集合の 50/58 (86.21%) へ低下した。このことから、生成系列スコアと TTA 一致率は、外観が類似する未知薬剤に対して十分な安全指標ではなかった。この結果は ver4 条件 C のアダプタに対する予備評価であり、ver6 の信頼ゲート性能を示すものではなかった。PTP 包装の印字を光学文字認識 (Optical Character Recognition : OCR) で読み取り、薬剤名と含量を候補と照合するなど、モデル出力とは独立した根拠を導入する必要があると考えた。

4.19 妥当性の限界

本実験の限界を、データ、評価設計、統計、再現性、比較対象および実運用の 6 区分に整理した。

1. **データ**：評価対象は 41 クラスに限られた。収集画像 42 枚のうち 32 枚は現行の収集記録と直接照合でき、残る 10 枚も削除前の収集記録から出典候補を確認した。ただし、その 10 枚は元画像から現存画像までの加工の履歴をたどれなかった。
2. **評価設計**：評価 287 枚は収集画像学習 ver1 から ver9 の LoRA 学習には使用していないが、研究初期の実画像方式では一部を学習へ使用した。同じ 287 枚を収集画像学習の条件検討に反復使用し、条件選択後の新規評価専用集合を設けなかった。ver6、ver8 および ver9 はいずれも結果確認後に得た条件である。合成複数薬剤画像は単剤写真を再利用し、黒い隙間を含む固定 400 枚の評価も、隙間のない 800 枚の Top10 評価も、実写複数薬剤の性能を示さなかった。後者は元写真をタイル状に連結した探索的评价であり、実環境の自由な位置、向き、接触、重なりおよび背景を含まない。
3. **統計**：ver1 から ver9 の各条件は依然として乱数シード 42 による 1 回の学習であり、これらの条件間の差については学習のばらつきを評価していない。McNemar 検定では画像対間の独立性を確認できず、薬剤または撮影元をクラスタとする方式差の区間推定は行わなかった。1,265 枚の基画像と 1,800 領域は相関を含むため、独立標本として扱わなかった。
4. **再現性**：CUDA の決定論的アルゴリズムを無効にしており、実行コードのバージョンも実行記録に残っていなかった。合成複数薬剤画像の記録には各領域の元写真の対応がなく、再利用回数を再集計できなかった。収集画像と実行結果の一部はバージョン管理の対象外であり、報告書のディレクトリだけでは再学習できなかった。
5. **比較対象**：追加学習していない Qwen3.5-4B の保存結果は再集計したが、素画像を入力した実験であり、LoRA を適用した条件と入力の前処理をそろえていなかった。同じ入力による OCR と薬剤辞書の照合や、単純な画像分類器も評価していない。Gemini との比較も入力の前処理と推論方式が異なり、提案構成の優越性を示す比較ではなかった。
6. **実運用**：収集画像の整理と実画像の撮影に要した工数を測定しなかった。信頼ゲートは ver4 条件 C の予備評価と実験 82 番への適用のいずれでも危険通過を 0 件にできなかった。既知側と未知側の取得条件も異なったため、安全な保留、新しい薬剤への一般化および臨床利用可能性を示さなかった。端末上の動作、速度、メモリ、発熱および消費電力も評価していない。

5 結論・今後の課題

5.1 結論

本研究では、収集した PTP 包装のフルシート表面・裏面画像から RTI と部分画像を生成し、Qwen3.5-4B を LoRA で追加学習したうえで、収集画像学習 ver1 から ver9 には使用していない近畿大学病院薬剤部で撮影した写真 287 枚を用いて、41 クラスの Top-1 識別性能を評価した。なお、研究初期の実画像方式では、この 287 枚の一部を学習にも用いた。

主結果として扱う ver4 条件 D は 287 枚中 280 枚を正しく識別し、Top-1 精度 97.56% を得た。同条件の合成複数薬剤画像 400 枚では、画像単位完全一致率 82.75%，領域ラベル一致率 95.83% であった。隙間のない元写真タイルを用いた探索的評価 800 枚では、薬剤数を知らせず最大 10 候補を残す全候補包含方式の最高が 790/800 (98.75%)，薬剤数を既知と仮定する Top-N 方式の最高が 682/800 (85.25%) であった。これは余分な予測を許す包含率と既知個数の画像完全一致率であり、固定 400 枚の黒い隙間評価とは別の指標である。結果を確認した後の探索的な追試では、ver6 が 286/287，ver7 が 284/287 であり、ver8・ver9 のアダプタも ver6 と同じ 286/287 であった。ただし、これらはいずれも結果を見た後に選んだ条件であり、確認的な主結果として扱わなかった。ver6 と ver4 条件 C の対応比較でも有意差は認められなかった。Gemini 3.5 Flash の保存予測は 284/287 であった。

未知薬剤への対応については、ver4 条件 C の予備評価で危険通過が 8/58 観測され、実験 82 番 41 薬剤条件へしきい値を再校正せず適用した場合は、危険通過が seed によって 3 件から 12 件まで振れた。いずれの適用でも危険通過を 0 件にできなかった。

以上より、フルシートの表面 1 枚と裏面 1 枚を学習元とし、RTI と部分画像を自動生成する構成で、41 クラスの PTP 包装を識別できることを確認した。残存錠数や切り出し範囲ごとに学習用写真を個別に撮影する必要はなくなったが、収集、撮影および前処理を含む総作業時間は比較しなかったため、作業負担の削減量は確認できなかった。また、評価に用いた 287 枚は条件検討へ反復使用しており、条件を決めた後に新しく撮影した写真での確認は行わなかった。このため、新しく撮影した写真による確認、実際に撮影した複数薬剤画像の評価、および未知薬剤への回答を安全に保留する仕組みは、いずれも今後の課題である。

5.2 今後の課題

今後は、対象とする薬剤の数を増やすとともに、学習対象外の薬剤に対して誤った薬剤名を答えない仕組みを整える必要がある。

薬剤の数を増やす際は、学習用の写真と評価用の写真を薬剤部で別々に撮影し、評価用の写真は学習にはいっさい使わずに識別性能を確認する。その際は、モデル、前処理、しきい値および採点規則を撮影前に固定する。新しい評価では、複数の乱数シードによる平均、標本標準偏差および最小値を報告する。

間違った薬剤を答えないようにするには、41 クラス以外の薬剤が入力された場合に回答を保留する仕組みが必要である。本研究の信頼ゲートは、厳密な薬剤名照合、TTA 一致率、系列スコアおよび候補間マージンから構成されるが、これらはいずれもモデル自身の出力から得た信号である。外観が類似する未知薬剤に対しては、これらが同時に高い値を示し得るため、危険通過を 0 件にできなかった。このため、PTP 包装の印字を OCR で読み取り、モデルが答えた薬剤名および含量と一致しない場合は回答を保留する方法を検討する。あわせて、既知薬剤と未知薬剤を同じ端末、背景、距離および照明で撮影し、取得条件の違いによる交絡を取

り除いたうえで危険通過率を測定する。

RTI および部分画像については，生成規則と評価条件を事前に固定し，それぞれの有効性を検証できる実験設計を改めて行うことが今後の課題である。

謝辞

本研究の遂行にあたり，多大なご指導とご助言を賜った森山真光准教授に，心より感謝申し上げます．また，本研究で用いた薬剤画像の撮影にご協力いただくとともに，薬剤鑑別に関する貴重なお助言を賜った共同研究者である近畿大学病院薬剤部の皆様，ならびに木村裕一教授に深く感謝申し上げます．

参考文献

- [1] World Health Organization. Medication Without Harm.
<https://www.who.int/initiatives/medication-without-harm>, 2017. 最終閲覧日：2026 年 7 月 25 日.
- [2] 日本医療機能評価機構. 薬局ヒヤリ・ハット事例収集・分析事業 2024 年年報.
https://www.yakkyoku-hiyari.jcqh.or.jp/pdf/year_report_2024.pdf, 2025. 最終閲覧日：2026 年 7 月 25 日.
- [3] 日本医療機能評価機構. 薬局ヒヤリ・ハット事例収集・分析事業 第 34 回報告書：内服薬の取り違えに関する事例—外観の類似に関連した事例—.
https://www.yakkyoku-hiyari.jcqh.or.jp/pdf/report_2025_2_T001.pdf, 2026. 最終閲覧日：2026 年 8 月 8 日.
- [4] 末次王卓, 金澤直子, 正門佳法, 天達菜緒, 副田雪乃, 屋地慶子, 寺蘭英之. AI 画像解析錠剤識別システムの使用による持参薬錠剤一包化鑑別作業の効率化と薬剤助手へのタスク・シフト／タスク・シェアに関する評価. 医療薬学, Vol. 52, No. 5, pp. 273–281, 2026. <https://doi.org/10.5649/jjphcs.52.273>, 最終閲覧日：2026 年 7 月 25 日.
- [5] Junyeong Heo, Youjin Kang, SangKeun Lee, Dong-Hwa Jeong, and Kang-Min Kim. An accurate deep learning-based system for automatic pill identification: Model development and validation. *Journal of Medical Internet Research*, Vol. 25, p. e41043, 2023.
<https://doi.org/10.2196/41043>, 最終閲覧日：2026 年 7 月 25 日.
- [6] Richárd Rádli, Zsolt Vörösházi, and László Czúni. Word and image embeddings in pill recognition. In *Proceedings of the 19th International Joint Conference on Computer Vision, Imaging and Computer Graphics Theory and Applications*, pp. 729–736, 2024.
<https://doi.org/10.5220/0012460800003660>, 最終閲覧日：2026 年 7 月 25 日.
- [7] Richárd Rádli, Zsolt Vörösházi, and László Czúni. Metric-based pill recognition with the help of textual and visual cues. *IET Image Processing*, Vol. 18, No. 14, pp. 4623–4638, 2024.
<https://doi.org/10.1049/ipr2.13273>, 最終閲覧日：2026 年 7 月 25 日.
- [8] Connor Shorten and Taghi M. Khoshgoftaar. A survey on image data augmentation for deep learning. *Journal of Big Data*, Vol. 6, No. 1, p. 60, 2019.
<https://doi.org/10.1186/s40537-019-0197-0>, 最終閲覧日：2026 年 7 月 25 日.
- [9] Linh Nguyen Thi My, Viet-Tuan Le, Tham Vo, and Vinh Truong Hoang. A comprehensive review of pill image recognition. *Computers, Materials & Continua*, Vol. 82, No. 3, pp. 3693–3740, 2025.
<https://doi.org/10.32604/cmc.2025.060793>, 最終閲覧日：2026 年 8 月 10 日.
- [10] Naoto Usuyama, Natalia Larios Delgado, Amanda K. Hall, and Jessica Lundin. ePillID dataset: A low-shot fine-grained benchmark for pill identification. In *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pp. 3971–3977, 2020.
<https://doi.org/10.1109/CVPRW50498.2020.00463>, 最終閲覧日：2026 年 8 月 10 日.
- [11] Suiyi Ling, Andreas Pastor, Jing Li, Zhaohui Che, Junle Wang, Jieun Kim, and Patrick Le Callet. Few-shot pill recognition. In *2020 IEEE/CVF Conference on Computer Vision and Pattern*

- Recognition (CVPR)*, pp. 9786–9795, 2020. <https://doi.org/10.1109/CVPR42600.2020.00981>, 最終閲覧日：2026 年 8 月 10 日.
- [12] R. Menaha, R. Abilaash, P. N. Mohanram, Akash Unnikrishnan, and S. Sukumar. Drug pills identification system using Google Gemini LLM: A generative AI approach. In *2024 International Conference on Emerging Research in Computational Science (ICERCS)*, pp. 1–5, 2024. <https://doi.org/10.1109/ICERCS63125.2024.10895371>, 最終閲覧日：2026 年 7 月 25 日.
- [13] Yun Han, Sheng-Luen Chung, Qiang Xiao, Jing-Syuan Wang, and Shun-Feng Su. Pharmaceutical blister package identification based on induced deep learning. *IEEE Access*, Vol. 9, pp. 101344–101356, 2021. <https://doi.org/10.1109/ACCESS.2021.3097181>, 最終閲覧日：2026 年 7 月 26 日.
- [14] Jinze Bai, Shuai Bai, Shusheng Yang, Shijie Wang, Sinan Tan, Peng Wang, Junyang Lin, Chang Zhou, and Jingren Zhou. Qwen-VL: A versatile vision-language model for understanding, localization, text reading, and beyond. <https://arxiv.org/abs/2308.12966>, 2023. arXiv:2308.12966, 最終閲覧日：2026 年 7 月 25 日.
- [15] Shuai Bai, Yuxuan Cai, Ruizhe Chen, Keqin Chen, Xionghui Chen, Zesen Cheng, Lianghao Deng, Wei Ding, Chang Gao, Chunjiang Ge, Wenbin Ge, Zhifang Guo, Qidong Huang, Jie Huang, Fei Huang, Binyuan Hui, Shutong Jiang, Zhaohai Li, Mingsheng Li, Mei Li, Kaixin Li, Zicheng Lin, Junyang Lin, Xuejing Liu, Jiawei Liu, Chenglong Liu, Yang Liu, Dayiheng Liu, Shixuan Liu, Dunjie Lu, Ruilin Luo, Chenxu Lv, Rui Men, Lingchen Meng, Xuancheng Ren, Xingzhang Ren, Sibao Song, Yuchong Sun, Jun Tang, Jianhong Tu, Jianqiang Wan, Peng Wang, Pengfei Wang, Qiuyue Wang, Yuxuan Wang, Tianbao Xie, Yiheng Xu, Haiyang Xu, Jin Xu, Zhibo Yang, Mingkun Yang, Jianxin Yang, An Yang, Bowen Yu, Fei Zhang, Hang Zhang, Xi Zhang, Bo Zheng, Humen Zhong, Jingren Zhou, Fan Zhou, Jing Zhou, Yuanzhi Zhu, and Ke Zhu. Qwen3-VL technical report. <https://arxiv.org/abs/2511.21631>, 2025. arXiv:2511.21631, 最終閲覧日：2026 年 7 月 25 日.
- [16] Qwen Team. Qwen3.5-4B model card. <https://huggingface.co/Qwen/Qwen3.5-4B>, 2026. 使用リビジョン：851bf6e806efd8d0a36b00ddf55e13ccb7b8cd0a, 最終閲覧日：2026 年 7 月 27 日.
- [17] Edward J. Hu, Yelong Shen, Phillip Wallis, Zeyuan Allen-Zhu, Yuanzhi Li, Shean Wang, Lu Wang, and Weizhu Chen. LoRA: Low-rank adaptation of large language models. In *Proceedings of the 10th International Conference on Learning Representations*, 2022. 著者版：<https://arxiv.org/abs/2106.09685>, 最終閲覧日：2026 年 7 月 25 日.
- [18] Tim Dettmers, Artidoro Pagnoni, Ari Holtzman, and Luke Zettlemoyer. QLoRA: Efficient finetuning of quantized LLMs. In *Advances in Neural Information Processing Systems 36*, pp. 10088–10115, 2023. <https://doi.org/10.52202/075280-0441>, 最終閲覧日：2026 年 8 月 11 日.
- [19] Dan Hendrycks and Kevin Gimpel. A baseline for detecting misclassified and out-of-distribution examples in neural networks. In *Proceedings of the 5th International Conference on Learning Representations*, 2017. <https://openreview.net/forum?id=Hkg4TI9x1>, 最終閲覧日：2026 年 8 月 11 日.
- [20] Jingkang Yang, Kaiyang Zhou, Yixuan Li, and Ziwei Liu. Generalized out-of-distribution detection: A survey. *International Journal of Computer Vision*, Vol. 132, No. 12, pp. 5635–5662,

2024. <https://doi.org/10.1007/s11263-024-02117-4>, 最終閲覧日 : 2026 年 8 月 8 日.
- [21] Weitang Liu, Xiaoyun Wang, John D. Owens, and Yixuan Li. Energy-based out-of-distribution detection. In *Advances in Neural Information Processing Systems 33*, 2020. 著者版 : <https://arxiv.org/abs/2010.03759>, 最終閲覧日 : 2026 年 8 月 8 日.
- [22] Yonatan Geifman and Ran El-Yaniv. Selective classification for deep neural networks. In *Advances in Neural Information Processing Systems 30*, pp. 4878–4887, 2017. <https://proceedings.neurips.cc/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html>, 最終閲覧日 : 2026 年 8 月 11 日.
- [23] ノバルティスファーマ株式会社. エンレスト 製品基本情報 (電子添文等) . <https://www.pro.novartis.com/jp-ja/products/entresto/document>, 2026. 医療関係者向けサイト, 最終閲覧日 : 2026 年 7 月 28 日.
- [24] Google. Gemini 3.5 Flash. <https://ai.google.dev/gemini-api/docs/models/gemini-3.5-flash>, 2026. モデル ID : gemini-3.5-flash, 保存予測作成日 : 2026 年 6 月 24 日, 最終閲覧日 : 2026 年 7 月 27 日.