

卒業研究報告書

題目

収集画像から生成した RTI・部分画像を用いた
マルチモーダル LLM による PTP 包装識別

指導教員

森山 真光 准教授

報告者

23-1-211-0009

呉竹 權人

近畿大学情報学部情報学科

令和 8 年 10 月 6 日提出

概要

薬剤の取り違えは、患者の健康被害につながるおそれがある。PTP 包装を画像から識別する従来研究には、250 薬剤について計 36,000 枚を撮影した例がある [1]。本研究では、Web から集めた各薬剤の表裏各 1 枚の収集画像から、全体画像、表裏を結合した RTI、部分画像を作る。それらの組合せと画像拡張を変え、視覚言語モデルを LoRA で追加学習する。目的は、少ない収集画像から、実写画像の薬剤名を識別することである。

主結果の条件では RTI を学習に含めず、全体画像と部分画像を用いた。41 薬剤の実写 287 枚に対し、3 回の学習の平均正解率は 99.54%，標本標準偏差は 0.53 ポイントであった。各回の正解数は 287 枚中 286 枚、287 枚中 287 枚、287 枚中 284 枚であった。これらの画像は、このモデルの学習には使わなかった。この条件は同じ画像で 8 条件を比較して選んだため、高めにしている可能性がある（第 4.5.1 節）。

同じ画像と同じ短文プロンプトを与えた Gemini 3.8 Flash は、287 枚中 238 枚に正解した。提案手法は学習の 3 回とも有意に高い正解率を示した。一方、41 薬剤の候補一覧を与えた Gemini の 283 枚とは有意差がなかった。この結果から、今回の 41 薬剤では、少ない元画像で学習したモデルによって実写を識別する目的をおおむね達成した。

複数薬剤については、実写から作った合成画像 800 枚を評価した。主結果のモデルでは、最大 10 候補にすべての正解薬剤が含まれた画像は、3 回とも 790 枚であった。正解の薬剤数だけ候補を残す方式では、平均正解率は 85.00% であった。未知薬剤への回答を保留する仕組みは別の 2 条件で評価したが、未知 58 枚中 4 枚と 2 枚で誤回答が残った。また、学習薬剤数を 100 まで増やしても、評価したのは既知 41 薬剤であり、100 薬剤全体の識別性能は確認しなかった。

固定 800 枚の推論は研究室の GPU で実行でき、画像を外部サービスへ送らずに使える点にも意義があると考えた。今後の課題は、学習薬剤数を増やしても正解率を保つこと、部分画像の内容と学習量の効果を分けて確かめること、未知薬剤への回答保留と実写の複数薬剤画像の識別であった。

目次

1	序論	1
1.1	研究背景	1
1.2	研究課題と目的	1
2	関連研究・関連技術	2
2.1	薬剤画像の認識	2
2.2	マルチモーダル LLM	3
2.3	LoRA	3
2.4	未知入力 の 保 留	3
3	収集画像からの薬剤名識別と評価方法	4
3.1	処理の全体像	4
3.2	学習画像の生成	4
3.3	画像拡張	7
3.4	LoRA 学習	7
3.5	評価方法	7
4	実験結果・考察	11
4.1	実験環境と評価データ	11
4.2	初期実画像方式と収集画像学習への移行	12
4.3	収集画像学習 ver1 から ver9	12
4.4	追加学習していない Qwen3.5-4B と の 比 較	15
4.5	主結果 r16.a128 の選定と追加検証	15
4.6	信頼ゲートの評価	17
4.7	学習薬剤数の段階増加（41 から 100 薬剤）	18
4.8	隙間のない合成複数薬剤画像	19
4.9	総合考察	20
4.10	評価範囲と注意点	22
5	結論・今後の課題	23
5.1	結論	23
5.2	今後の課題	23
	謝辞	24
	参考文献	25

1 序論

薬剤の取り違いや用量の誤りは、患者に重い健康被害を与えるおそれがある [2]. PTP 包装を画像から識別する従来研究では、250 薬剤について計 36,000 枚を撮影している [1]. そこで本研究は、各薬剤の表裏各 1 枚の収集画像から、実写画像の薬剤名を識別することを目指す。収集画像から表裏を結合した画像 (RTI) と部分画像を作り、画像拡張と視覚言語モデルの LoRA 追加学習を組み合わせる。

1.1 研究背景

薬剤の取り違いや誤服用は、患者の健康被害につながる。世界保健機関 (World Health Organization : WHO) は、投薬に関連する回避可能な健康被害の削減を国際的な目標としている [2]. 医療現場では、外箱や薬袋がない状態で薬剤を鑑別する場合がある。この場合、錠剤の形状、刻印、色、PTP (Press Through Package) 包装上の印字などを手掛かりとする。末次らは、AI 画像解析錠剤識別システムを持参薬の鑑別に導入し、作業時間の短縮とタスク・シフトの可能性を報告している [3].

1.2 研究課題と目的

薬剤画像の認識に関する先行研究は、学習用の薬剤画像データセットを構築して手法を評価している [4, 5]. Han らの PTP 包装識別では、多数の画像を撮影している。同研究は、時間と人手の制約も挙げている [1]. 学習画像が不足する場合は、幾何変換や色変換によって学習画像の多様性を高める画像拡張が用いられる [6]. そこで本研究は、1 薬剤につきフルシートの表面 1 枚と裏面 1 枚を学習元とし、そこから派生画像を生成する構成を検討する。この構成では、残存錠数や切り出し範囲を変えた学習用写真を個別に撮影する必要がない。収集画像の取得から前処理までに要する時間は方式間で比較しておらず、総作業時間の削減量は評価対象としない。

本研究では、単剤の薬剤名識別の正解率を求め、追加学習していないモデルや外部サービスと比較する。さらに、複数の薬剤が写る合成画像の識別、未知薬剤への回答保留、学習薬剤数を増やした場合の正解率も調べる。新しい薬剤への一般化、臨床利用、実写の複数薬剤画像に対する性能、および RTI と部分画像の個別の寄与は、評価の対象外とする。

2 関連研究・関連技術

2.1 薬剤画像の認識

Heo らは、錠剤の刻印、形状、色を認識し、薬剤データベースを検索する手法を提案している [4]。この手法は、刻印検出、外観認識、候補検索など複数の専用モデルを組み合わせる。Usuyama らは、約 13,000 枚から成る公開データセット ePillID を構築している [5]。同ベンチマークでは、大半のクラスで参照画像が片面 1 枚しかなく、撮影条件の異なる実利用画像を識別する。Usuyama らは、メトリクス学習によってこのような少数の参照画像からの識別に取り組んでいる。

これらの研究は、1 クラス当たりの参照画像が少ない点で本研究と近い。一方、識別対象は錠剤本体である。また、参照画像と照合する方式であるため、識別できるのは参照画像が登録されたクラスに限られる。本研究は、識別対象を PTP 包装とし、収集した表裏画像から派生画像を生成して追加学習する。さらに、マルチモーダル LLM がクラス名を文字列として生成する点も異なる。

Menaha らは、錠剤や包装の画像を入力し、Google Gemini を用いた薬剤識別支援システムを提案している [7]。この手法は外部サービスを用いるプロンプト型であり、本研究は重みを取得可能なモデルを追加学習する点で異なる。

Han らは、専用の撮影装置を用いて PTP 包装の表面と裏面を同時に撮影する手法を提案している [1]。向きと大きさを正規化した両面画像である RTI を作成し、畳み込みニューラルネットワークへ入力して識別する。本研究は、この両面統合の着想を RTI として採用する。Han らは、専用装置による包装全体の撮影を前提とする。本研究は、専用装置を用いず、部分的な PTP 包装画像も対象とする。また、本研究は左右結合後の画像を 448×448 画素の正方形へリサイズするため、結合前の縦横比を保持しない。

表 1 に、関連研究と本研究の相違を示す。本研究は、収集した PTP 包装画像から派生画像を生成し、マルチモーダル LLM を追加学習する点に特徴がある。また、未知薬剤への対応は予備評価にとどまり、安全な保留を実証したものではない。

表 1 関連研究と本研究の位置付け

研究	対象	主な入力	手法	専用装置
Heo ら [4]	錠剤	錠剤画像	刻印・外観認識とデータベース検索	不要
Usuyama ら [5]	錠剤	片面 1 枚の参照画像と実利用画像	画像の特徴の近さを学習する手法	不要
Menaha ら [7]	錠剤・包装	錠剤・包装画像とプロンプト	外部サービスの Gemini による生成	不要
Han ら [1]	PTP 包装	専用装置で撮影した表裏	RTI と CNN	必要
本研究	PTP 包装	PTP 包装の表裏・部分画像と共通プロンプト	RTI・部分画像と Qwen3.5-4B（マルチモーダル LLM）の LoRA 追加学習	不要

2.2 マルチモーダル LLM

画像とテキストを同一モデルで扱うモデルは、視覚言語モデル (Vision-Language Model : VLM) と呼ばれる。本報告書では、大規模言語モデルを基盤とし、画像とプロンプトを入力して文字列を生成するものをマルチモーダル LLM と呼ぶ。Bai らは、画像とテキストを統合して扱う Qwen-VL を提案している [8]。マルチモーダル LLM は、視覚エンコーダ、射影部、言語モデルのデコーダから構成される。視覚エンコーダは入力画像を特徴ベクトルの列に変換し、射影部はその出力を言語モデルの表現空間へ写像する。デコーダは文字列を逐次生成する。この構成により、分類ラベルの番号ではなく薬剤名という文字列を出力できる。PTP 包装では、文字情報と外観情報の双方が識別の手掛かりとなる。そのため、両者を同一モデルで扱えるマルチモーダル LLM を採用する。

本研究では、Qwen3.5-4B の特定のリビジョンを用いる [9]。入力画像に「この錠剤は何という薬ですか？ 薬剤名だけで教えてください。」というプロンプトを与え、出力を薬剤クラス名と照合する。

2.3 LoRA

LoRA (Low-Rank Adaptation) は、事前学習済みモデルの重みを固定し、低ランク行列だけを追加学習する手法である [10]。元の重み行列を $W_0 \in \mathbb{R}^{d \times k}$ とすると、学習後の変換は式 (1) で表す。

$$h = \left(W_0 + \frac{\alpha}{r} BA \right) x, \quad A \in \mathbb{R}^{r \times k}, \quad B \in \mathbb{R}^{d \times r} \quad (1)$$

ここで、 $x \in \mathbb{R}^k$ は入力、 $h \in \mathbb{R}^d$ は出力、 r はランク、 α はスケーリング係数 (以下、係数) であり、更新量の倍率を調整する。 r を大きくすると学習可能パラメータ数が増え、 α/r が元の重みに加える変化の大きさを定める。本研究で用いる r 、 α および学習対象層は、第 3 章と第 4 章で示す。

2.4 未知入力の保留

選択的分類は、確信できない入力への回答を保留し、回答率と誤り率を調整する考え方である [11]。薬剤鑑別では、未知薬剤を既知薬剤として回答すると危険な誤回答になり得る。本研究では、この考え方に基づく保留機構を信頼ゲートと呼ぶ。信頼ゲートは、モデル自身の出力だけを信号とする簡単な構成であり、分布外入力の検出手法は適用していない。そのため、未知薬剤を検出する他の手法との優劣までは扱わない。

3 収集画像からの薬剤名識別と評価方法

3.1 処理の全体像

図 1 に、提案手法の処理を UML のアクティビティ図として示す。図は学習側と評価側の 2 つの区画に分ける。学習側では、Web から収集した表裏の PTP 包装画像から背景を除去し、向きと大きさをそろえる。続いて、RTI と各面の部分画像を作り、各実験条件で定めた画像拡張を適用する。主結果の条件では、RTI を学習に含めず、全体画像と部分画像を用いる。そのうえで、マルチモーダル LLM を LoRA で追加学習する。評価側では、学習に使用していない実写の評価画像を 448×448 画素へ正規化して入力する。学習済み LoRA を使って薬剤名を生成し、正解ラベルと照合して正解率を算出する。学習時は画像と共通のプロンプトを入力し、正解薬剤名を回答として与える。識別時は、同じプロンプトと画像を入力し、正解名を与えない。




図 1 提案手法の処理を示す UML アクティビティ図 (学習側と評価側を区画で分離)

3.2 学習画像の生成

薬剤ごとに、PTP 包装の表面と裏面を確認できるフルシート画像を Web から集め、これを収集画像と呼ぶ。採用前に、薬剤名、含量、面の種別、フルシートであることを目視で確認する。収集画像と内部開発評価画像 287 枚に、同じ画像は含まれていない。

Han らは、向きを補正した表裏の画像を左右に結合した画像を RTI と呼んでいる [1]. 図 2 に、表面画像と裏面画像から RTI を作成する手順を示す. 薬剤 d のフルシートの表面画像を $I_{d,f}$, 裏面画像を $I_{d,b}$ とする. 両画像から背景を除去し, PTP 包装の凸包を抽出する. 次に, 透視変換によって向きと大きさをそろえる. 正規化関数を $T(\cdot)$, 左右結合を $\parallel$ とすると, 薬剤 d の RTI は式 (2) で表す.

$$I_d^{\text{RTI}} = \text{Resize}_{448 \times 448} (T(I_{d,b}) \parallel T(I_{d,f})) \quad (2)$$

RTI では, 裏面を左, 表面を右へ配置する. RTI は切り出しの基準にも使う. RTI を学習へ含めるかどうかは実験条件ごとに定め, 単剤の主結果 r16_a128 では RTI そのものを学習から除外する.





図 2 収集画像の表面・裏面から RTI を作成する手順 (メインテート錠 2.5mg の例). 単剤の主結果 r16_a128 では RTI そのものは学習しない. 田辺ファーマの製剤写真を用いて作成した [12].

各面から, フルシート 1 枚, 1 錠区画 8 枚, 縦 2 分割画像 2 枚, 縦 4 分割画像 4 枚を生成し, これらを基画像と呼ぶ. 1 錠区画は, 各面の前景外接矩形へ薬剤ごとに定めた固定格子を当て, 左上から行優先で最大 8 枚を切り出したものである. 縦 2 分割画像と縦 4 分割画像は, 前景外接矩形を高さ方向へ等分した水平帯である. この切り出しは既知の PTP 配列に基づく固定規則であり, 任意の包装に対する一般的な錠剤セル検出器ではない. 通常の薬剤で生成する基画像数 N_d は, RTI を含めて式 (3) の 31 枚となる. レボフロキサシン錠 500mg は, 錠剤セル数の制約により 1 錠区画を各面 5 枚とし, 25 枚となる. 41 薬剤の基画像は, 式 (4) の合計 1,265 枚である. RTI を除くと 1,224 枚となる.

$$N_d = 1 + 2(1 + 8 + 2 + 4) = 31 \quad (3)$$

$$N_{\text{base}} = 40 \times 31 + 1 \times 25 = 1,265 \quad (4)$$

図 3 に, RTI を除いた 1 薬剤分の学習用画像 30 枚の例を示す. 30 枚は, 各面のフルシート 1 枚, 縦 2 分割画像 2 枚, 縦 4 分割画像 4 枚, 1 錠区画 8 枚を, 表裏の 2 面分あわせたものである. RTI は単剤の主結果の条件で学習に含めないため, この例から除いた. アルゴリズム 1 に, 基画像生成の手順を示す.



③ 学習用画像30枚 (全体2・1/2区画4・1/4区画8・1錠区画16)




図3 収集画像, RTI, 学習用画像 30 枚の例 (メインテート錠 2.5mg, 全体 (フルシート) 2 枚, 1/2 区画 (縦 2 分割) 4 枚, 1/4 区画 (縦 4 分割) 8 枚, 1 錠区画 16 枚). RTI 自体は学習から除外した. 田辺ファーマの製剤写真を用いて作成した [12].

アルゴリズム 1 収集画像からの基画像生成

入力: 薬剤 d の表面画像 $I_{d,f}$, 裏面画像 $I_{d,b}$

出力: 基画像集合 $\mathcal{D}_d$

- 1: $\mathcal{D}_d \leftarrow \emptyset$
- 2: 表裏画像から背景を除去し, PTP 包装の凸包を抽出する
- 3: 透視変換により, 表裏画像の向きと大きさを正規化する
- 4: 裏面を左, 表面を右へ配置して RTI を生成する
- 5: 生成した RTI を $\mathcal{D}_d$ へ追加する
- 6: 正規化した表裏フルシートを $\mathcal{D}_d$ へ追加する
- 7: **for** 面 $s \in \{f, b\}$ **do**
- 8: $T(I_{d,s})$ の前景外接矩形へ薬剤 d に対応する固定格子を設定する
- 9: 格子区画に対応する部分画像を, 左上から行優先で最大 8 枚生成する
- 10: 前景外接矩形を高さ方向へ 2 等分し, 水平帯を 2 枚生成する
- 11: 前景外接矩形を高さ方向へ 4 等分し, 水平帯を 4 枚生成する
- 12: 生成画像を $\mathcal{D}_d$ へ追加する
- 13: **end for**
- 14: 各画像を 448×448 の黒背景へ配置する
- 15: **return** $\mathcal{D}_d$

3.3 画像拡張

本報告書では、2種類の画像拡張セット（各17種）を用いる。単剤の主結果 r16_a128 は、回転12条件と明度5条件からなる v3_17 を用いる。回転は0度から330度まで30度刻みとし、明度倍率は0.8, 0.9, 1.0, 1.1, 1.2とする。回転と明度変化は別々に適用するため、拡張数は式(5)の17となる。0度回転と明度倍率1.0は画素値が同一だが、別レコードとして1回ずつ提示する。

$$\mathcal{A}_{v3} = (R_0, R_{30}, \dots, R_{330}, B_{0.8}, B_{0.9}, B_{1.0}, B_{1.1}, B_{1.2}) \quad (5)$$

ver4 条件 D は、r16_a128 を主結果とする前に主結果としていた条件であり、旧主結果と呼ぶ（ver 名は、第4.3節の図6に示す収集画像学習の各版を指す）。旧主結果は、撮影時の変動を模擬する別の17種（acquisition_17）を用いる。内訳は、無変換1条件、回転6条件、明度2条件、コントラスト2条件、ガンマ2条件、台形歪み2条件、ぼかし1条件、ノイズ1条件である。ver4 条件 D では、1エポック当たりの総提示数が $1,265 \times 17 = 21,505$ 枚、5エポックで107,525枚となる。

3.4 LoRA 学習

基盤モデルには、第2.2節の Qwen3.5-4B を用いる。画像サイズは 448×448 画素とし、プロンプトと正解薬剤名を学習ペアとする。モデル重みは BF16 で読み込み、LoRA のドロップアウト率は0.05とする。一方、ver1 から ver4 条件 A では、モデルを4ビットに量子化して学習する QLoRA を用いる¹。LoRA の対象は、q_proj, k_proj, v_proj, o_proj, gate_proj, up_proj, down_proj である。学習率は 2.0×10^{-4} 、実効バッチサイズは128とし、最適化には AdamW を用いる。損失は、プロンプトをマスクし、回答文字列と終端トークンの部分だけで計算する。推論では貪欲法を用い、最大生成長を32トークンとする。

単剤の主結果 r16_a128 は、ランク16、係数128、v3_17 を用い、乱数シード（以下、シード）42, 43, 44 の3回学習する。総提示数は、RTI を含む ver4 条件 D と同じ107,525枚（1,265枚 $\times$ 17種 $\times$ 5エポック）に固定する。r16_a128 の基画像は1,224枚であり、1エポック当たりの提示数は $1,224 \times 17 = 20,808$ 枚であるため、実効エポック数は約5.17となる。旧主結果 ver4 条件 D は、ランク16、係数32、acquisition_17、5エポック、シード42の1回学習である。両者は、RTIの有無、画像拡張セットおよび係数が異なる。

3.5 評価方法

3.5.1 単剤評価

単剤評価には、41薬剤の実写画像287枚を用いる。撮影は近畿大学病院薬剤部（以下、大学病院薬剤部）で行った。本報告書では、学習条件の比較にも使用したこの287枚を、内部開発評価画像と呼ぶ。内部開発評価画像は、収集画像から構成した LoRA 学習集合には含めていない。一方、同じ287枚を条件検討に反復使用しており、研究初期の実画像方式では一部を学習にも用いた。そのため、条件決定後に初めて使用する独立最終評価集合ではない。内訳は表面212枚、裏面75枚であり、フルシート29枚と、錠剤が1錠から9錠まで残った部分シート258枚を含む。1クラス当たりの枚数は3枚から10枚であり、クラス間で偏りがある。学習元の収集画像とは撮影条件が異なる。図4に、撮影元画像と、背景除去・向き補正・448画素正方形化後の

¹ ver1 は RTI と 1 錠区画を基画像とした最初の版、ver4 条件 A は ver3 の設定を基準に学習を再構成した条件である。

モデル入力の対応例を示す．各列の上段が撮影元画像，下段がモデル入力である．撮影元画像内の包装の占有率や向きが異なっても，モデル入力では包装が黒背景の正方形へ正規化される．




図4 内部開発評価画像の撮影元画像（上段）とモデル入力（下段）の対応例．(a) (b) は表面フルシート，(c) (d) は裏面フルシート，(e) (f) は表面1錠，(g) (h) は表面4錠である．大学病院薬剤部で撮影した画像を，著者が保存済みデータから再配置した．

文字列 s に NFKC 正規化と小文字化を適用し，空白と記号を除去した結果を $g(s)$ とする．一致判定 $M(a, b)$ は， $g(a) = g(b)$ ，または $g(a)$ が $g(b)$ の部分文字列である場合に真とする．画像 x_i に対してモデルが生成した回答を $\hat{y}_i$ ，正解ラベルを y_i として，正解率は式 (6) で求める．

$$\text{Accuracy} = \frac{1}{n} \sum_{i=1}^n \mathbf{1}(M(y_i, \hat{y}_i)) \quad (6)$$

ここで， $n = 287$ は評価画像数， $\mathbf{1}$ は判定が真なら1，偽なら0となる関数である．百分率では式 (6) の値を100倍する．この判定は，正規化後の文字列が正解名と全く同じ場合だけを正解とする採点（完全一致採点）より緩い．そこで，保存済みの予測を完全一致採点でも数え直し，正解数の違いを確認する．結果は第4.1節に示す．

同じ画像に対する2つの条件の正誤を比較する場合は，対応のある二値データとして McNemar 検定を用いる．一方の条件だけが正解した画像の枚数を使い，両側の正確検定で比較する．学習を3回行った条件では，各回の結果をそれぞれ比較する．比較が1つの場合は， $p < 0.05$ を有意の基準とする．複数の比較を行うと，

偶然の差を有意と判断しやすくなる。そのため、有意水準を $0.05 \div \text{比較数}$ に厳しくする（Bonferroni 補正）。3 回の学習を比較する場合は、3 回すべてで補正後の有意水準を下回った場合だけ有意とする。有意差が認められない結果は、2 条件が同等であることを示すものではない。また、同じ薬剤の写真が複数あるため、287 枚の 1 枚 1 枚が互いに無関係とは言えない。そのため、検定結果は今回の 287 枚についての比較として扱い、他の薬剤や撮影条件でも同じ差が出るとは判断しない。

3.5.2 比較実験

追加学習前の基準として、LoRA を適用していない Qwen3.5-4B を、ver4 条件 D と同じ 287 枚、入力形式、プロンプト、生成条件で評価する。プロンプトに候補一覧は含めず、採点は正解薬剤名が出力に含まれていれば正解とする包含採点とする。比較対象は ver4 条件 D であり、単剤の主結果 r16_a128 と LoRA なしの直接比較は行っていない。

外部サービスとの比較には、Gemini 3.8 Flash の短文条件、Gemini 3.8 Flash の候補一覧付き条件、および Gemini 3.5 Flash の短文条件を用いる。短文条件では、Qwen と同じ画像と同じプロンプトを入力し、候補を与えない。候補一覧付き条件では、41 薬剤の一覧から 1 つを選ばせる。Qwen の評価と同じ前処理済み 448×448 画素の画像を入力する。温度 0、最大出力トークン 4096 で、287 枚を各 1 回評価した保存予測を用いる。採点は、r16_a128 と同じ包含採点とする。

3.5.3 信頼ゲート

信頼ゲートは、モデルが生成した薬剤名を、次の 3 段階で確認し、1 つでも満たさなければ回答を保留する。第 1 段階では、出力が学習した 41 薬剤の名前と一致することを確認する。第 2 段階では、回転、反転、明度などを加えた 11 視点のテスト時拡張を行う。多数決の結果が Top-1 と一致し、一致率がしきい値以上であることを確認する。第 3 段階では、Top-3 ビーム探索の第 1 候補の系列スコアと、第 1 候補と第 2 候補の差がしきい値以上であることを確認する。図 5 に、判定の順序を示す。




図 5 信頼ゲートによる回答と保留の判定手順。登録名と照合する第 1 段階、変形しても回答が一致するか確かめる第 2 段階、スコアと候補間の差を確認する第 3 段階の順に判定し、1 つでも不成立であれば判定を保留する。しきい値はモデルごとに校正集合で決める。

既知薬剤には内部開発評価画像 287 枚を用い、記録ラベル単位で校正集合 139 枚と最終評価集合 148 枚に事前分割する。未知薬剤には、学習した 41 薬剤に含まれない薬剤の収集画像 125 枚を用い、薬剤ラベル単位で校正集合 67 枚と最終評価集合 58 枚に事前分割する。未知薬剤に対して既知薬剤名を回答することを、危険通過と呼ぶ。しきい値は校正集合だけで決め、最終評価集合の推論前に固定する。決め方は、既知薬剤の誤回答を 0 件、未知薬剤の危険通過を 67 枚中 3 枚以下とする制約下で、既知薬剤への正しい回答数を最大にす

ることである。信頼ゲートは、ver4 条件 D（ランク 16・係数 32）と ver6（ランク 32・係数 64）へ適用し、しきい値の流用を調べる比較には ver4 条件 C（ランク 16・係数 32）も用いる。主結果 r16_a128 への適用は扱わない。

3.5.4 隙間のない合成複数薬剤画像

薬剤数が未知の複数薬剤入力に対する予備的な評価として、隙間のない撮影元画像のタイル（固定 800 枚）を用いる。撮影元画像を 768×1024 画素へ縦横比を保ってリサイズし、タイル間隔と外周余白を 0 画素として連結する。薬剤数は 2, 3, 5, 8 の 4 条件、各 200 枚、計 800 枚である。検出器には薬剤数、配置および薬剤名を入力しない。Canny エッジ検出と輪郭抽出で候補領域を作り、前景強度の高い順に最大 10 領域を残す。各領域を黒背景 448×448 画素へ整形して単剤モデルへ入力する。

最大 10 候補が正解薬剤をすべて含めば、余分な予測を許して画像を成功とする方式を Top-10 方式と呼ぶ。Top-10 方式は過検出を罰しない。同じ推論結果から、正解薬剤数 N を既知として候補 1 位から N 位だけを残し、正解薬剤と 1 対 1 で完全一致した画像を成功とする方式を Top-N 方式と呼ぶ。Top-N 方式は、評価時点でのみ既知となる N を用いるため、薬剤数が未知の実運用での性能を示すものではない。本評価は、タイル合成画像によるものであり、薬剤が自由な位置や向き、重なりで置かれる実環境の性能を示すものではない。

4 実験結果・考察

4.1 実験環境と評価データ

実験環境を表 2 に示す．表 2 の 2 条件の学習には，NVIDIA H100 を 1 台ずつ使用した．固定 800 枚に対する r16_a128 の評価は，NVIDIA GeForce RTX 4070 Ti SUPER (VRAM 15.992 GiB) で推論のみを行った．モデルリビジョンとシードは固定したが，速度を優先して計算の再現性を確保する設定にできなかった．そのため，学習をやり直しても全く同じ結果になるとは限らない．固定 800 枚の推論には，Python 3.12.14, PyTorch 2.11.0+cu128, Transformers 5.14.1, PEFT 0.19.1, CUDA 12.8 を用いた．本研究は人を対象とする実験ではなく，被験者は用いなかった．評価画像は PTP 包装だけを写した画像であり，患者を識別できる情報は含まれなかった．

表 2 学習の実験環境と設定

項目	ver4 条件 D	r16_a128
GPU	NVIDIA H100, VRAM 93.096 GiB, 1 台	同左
OS / Python	Linux 6.8.0, glibc 2.39 / Python 3.13.5	Linux 6.8.0, glibc 2.39 / Python 3.12.3
主要ライブラリ	PyTorch 2.11.0, CUDA 12.8, cuDNN 9.19, Transformers 5.14.1, PEFT 0.19.1	PyTorch 2.11.0+cu128, Transformers 5.14.1, PEFT 0.19.1
基盤モデル	Qwen/Qwen3.5-4B, リビジョン 851bf6e806efd8d0a36b00ddf55e13ccb7b8cd0a	
LoRA	ランク 16, 係数 32, BF16	ランク 16, 係数 128, BF16
画像拡張	acquisition_17	v3_17
基画像数／総提示数	1,265 枚／ 107,525 枚	1,224 枚／ 107,525 枚
エポック数	5 (実効 5.00)	総提示数を固定 (実効約 5.17)
バッチ	マイクロバッチ 16, 勾配累積 8, 実効 128	実効 128
シード	42	42, 43, 44

内部開発評価画像は 41 薬剤・287 枚からなり，1 薬剤当たり 3～10 枚（平均 7 枚）を含んだ．撮影場所は大学病院薬剤部で，撮影元画像はすべて 3,024×4,032 画素の PNG 形式で保存されていた．撮影元画像のディレクトリ名は 2026 年 4 月 9 日撮影を示した．ただし，撮影端末，距離，角度，照明および背景は保存記録から確認できなかったため，推測で補わなかった．

学習元の収集画像は，各薬剤の表面 1 枚と裏面 1 枚，計 82 枚とした．

評価の判定規則について，保存済み予測を完全一致採点で数え直した．その結果，単剤の正解数は，ver4 条件 D, ver4 条件 C, ver6, ver7 で，287 枚中それぞれ 280 枚，283 枚，286 枚，284 枚となった．これらは，包含判定の集計値と変わらなかった²．

² ver4 条件 C は BF16 LoRA でランク 16・係数 32，全射影層を学習対象とした条件である．ver7 は ver6 を基に基画像を 1,347 枚へ増やし，41 候補から選ぶ推論へ変えた条件である．

4.2 初期実画像方式と収集画像学習への移行

研究初期には、撮影した 287 枚を撮影画像単位で 213 枚の学習用と 74 枚の評価用に分け、Qwen3.5-4B を LoRA で追加学習した。評価用の 74 枚では 74 枚すべてで正解した。同じ 287 枚を 5 分割する交差検証では、全分割を統合して 283/287 (98.6%) となった。1 薬剤当たりの学習元画像数を変えた比較では、6 枚以上の撮影画像を持つ 33 薬剤の固定評価 79 枚に対し、1 枚で 67.1%，2 枚で 87.3%，4 枚で 91.1%，利用可能な全画像（5～8 枚）で 98.7% であった。いずれもシード 42 の 1 回の比較であり、必要撮影枚数を確定する結果ではなかった。薬剤を追加するたびに複数の学習用実画像を撮影する負担が、対象薬剤数を増やすうえでの課題となった。そこで、フルシート表裏の収集画像を学習元とする方式へ移行した。

4.3 収集画像学習 ver1 から ver9

収集画像学習では、いずれも同じ内部開発評価画像 287 枚を評価し、基画像の構成と学習設定を段階的に変更した。図 6 に、各版の関係と単剤正解率を示す。シード 42 の 1 回の学習による値であった。内部開発評価画像は学習に用いなかったが、条件検討に繰り返し使用した。




図 6 収集画像学習 ver1 から ver9 の関係（箱は上から版名，単剤正解数，基画像数を，矢印は基にした版と変更点を表す。評価は同じ内部開発評価画像 287 枚，各 1 回学習である。色付きの箱は旧主結果 ver4 条件 D であり，* は各アダプタ自身を単剤評価した診断値である）

図 6 のとおり，ver1 から ver4 条件 C までは，基画像の構成と学習設定を 1 段階ずつ変更した。ver4 条件 C からは，画像拡張を変えた ver4 条件 D と，LoRA の容量を増やした ver6 の 2 つへ分かれた。ver5 は，ver4

条件 D を再実行した条件 (ver5-1), 表面中央の縦 2 分割・縦 4 分割画像を加えた条件 (ver5-2), ver5-2 の総提示数を ver5-1 と同数にそろえた条件 (ver5-3) の 3 条件であった。ver7 から ver9 は, ver6 を基に, 基画像を 1,347 枚へ増やした。

ver1 は 90.24% を示した。ver2 では, 同じ位置の 1 錠区画を重複して用いており, 88.85% へ低下した。ver3 では, 異なる錠剤セル, 縦 2 分割画像および縦 4 分割画像を加えて基画像を 1,265 枚とした。その結果, 97.91% へ上昇した。ver2 から ver3 では基画像の構成, 画像枚数, 使用 GPU および実効バッチが同時に変化したため, 改善を部分画像の追加だけに分けて説明できなかった。

ver4 条件 A から D は, 量子化, LoRA のランクと係数, 学習対象層, 画像拡張を変更して比較した。条件 A は ver3 と同じ設定を意図したが, 94.77% にとどまった。ver3 の結果は再現されなかった。条件 C は 98.61% と最も高く, 条件 D は 97.56% となった。各比較では複数の要因を同時に変更したため, BF16 化や学習対象層の拡大だけの効果とは解釈できなかった。ver4 条件 D は, 実験の開始前に主結果として定めた設定であり, 本報告書では旧主結果として扱った。

ver4 条件 D の保存済み予測を, 面, シート種別および残存錠数で層別に数え直した結果を表 3 に示す。裏面 75 枚とフルシート 29 枚では誤分類が生じず, 誤分類 7 件はすべて表面に生じた。ただし, 残存錠数別の分母は 3 枚から 60 枚までばらついており, 錠数と正解率の関係を確定的には解釈できなかった。

表 3 ver4 条件 D の層別正解率 (分母は内部開発評価画像 287 枚の内訳)

層	区分	正解数/枚数	正解率
面	表	205/212	96.70%
	裏	75/75	100.00%
シート種別	フルシート	29/29	100.00%
	部分シート	251/258	97.29%
残存錠数	1 錠	37/39	94.87%
	2 錠	60/60	100.00%
	3 錠	40/42	95.24%
	4 錠	42/44	95.45%
	5 錠	33/33	100.00%
	6 錠	15/16	93.75%
	7 錠	15/15	100.00%
	8 錠	6/6	100.00%
	9 錠	3/3	100.00%
全体	全画像	280/287	97.56%

表 4 に誤分類 7 件の内訳を示す。正解側ではムコダイン錠 500mg が 2 件, ほかに 5 薬剤が各 1 件となった。予測先ではデエビゴ錠 5mg が 3 件, ほかに 4 薬剤が各 1 件であり, 41 薬剤外の文字列はなかった。図 7 に, 代表的な 4 件のモデル入力を示す。誤分類数が少なく, 包装の向き, 錠数または印字が原因であるとは断定できなかった。

ver5 では, 表面中央の縦 2 分割画像と縦 4 分割画像を追加しても, 281/287 を示した。追加前の 280/287 に対する正確 McNemar 検定は $p = 1.00$ となった。ver6 は, ver4 条件 C からランクを 16 から 32 へ, 係数を 32 から 64 へ増やした。正解は, ver4 条件 C のみが 1 枚, ver6 のみが 4 枚であり, 正確 McNemar 検定は $p = 3.75 \times 10^{-1}$ で有意差はなかった。ver6 の誤分類 1 件 (IMG_0236) は, ver4 条件 C が正解していた画像であり, 改善の向きは一様ではなかった。ver7, ver8 および ver9 も 286/287 以下であり, ver6 を上回らなかった。ver8・ver9 は, ver6 と同じ 286/287 であるが, 誤分類した画像は条件ごとに異なった。ver6, ver8

表 4 ver4 条件 D の誤分類 7 件（内部開発評価画像 287 枚）

画像 ID	正解薬剤	ver4 条件 D の予測	面	錠数
IMG_0020	レバミピド錠 100mg	プレドニン錠 5mg	表	1
IMG_0027	カロナール錠 500mg	デエビゴ錠 5mg	表	1
IMG_0039	ミヤ BM 錠	メチコパール錠 500 μ g	表	3
IMG_0047	タケキャブ錠 20mg	ジャディアンス錠 10mg	表	3
IMG_0079	メトクロプラミド錠 5mg	デエビゴ錠 5mg	表	4
IMG_0236	ムコダイン錠 500mg	レボチロキシン Na 錠 50 μ g	表	4
IMG_0238	ムコダイン錠 500mg	デエビゴ錠 5mg	表	6




図 7 ver4 条件 D の代表的な誤分類モデル入力. (a) IMG_0027 : カロナール錠 500mg→ デエビゴ錠 5mg, (b) IMG_0047 : タケキャブ錠 20mg→ ジャディアンス錠 10mg, (c) IMG_0236 : ムコダイン錠 500mg→ レボチロキシン Na 錠 50 μ g, (d) IMG_0020 : レバミピド錠 100mg→ プレドニン錠 5mg である. 著者が保存済みモデル入力を再配置した.

および ver9 は、結果を確認した後に選んだ条件であり、結果を見てから選んだ最高値として扱った。いずれもシード 42 の 1 回の学習であり、286/287 という同数の観測から、条件間の優劣と再現性は判断できなかった。

ver1 から ver9 で正解率が上がった理由には、部分画像の追加と学習枚数の差が関係した可能性がある。これらは同時に変わっており、それぞれの効果は分けて確かめなかった。

4.4 追加学習していない Qwen3.5-4B との比較

LoRA を適用していない Qwen3.5-4B を、ver4 条件 D と同じ 287 枚、入力形式、プロンプト、生成条件で評価した。結果を表 5 に示す。LoRA なしは 3/287 (1.05%)、ver4 条件 D は 280/287 (97.56%) に達した。正規化後の出力が正解薬剤名と完全一致した画像は、LoRA なしが 0/287、ver4 条件 D が 280/287 となった。同じ画像で比べると、LoRA なしだけが正解した画像は 0 枚、ver4 条件 D だけが正解した画像は 277 枚となった。正確 McNemar 検定 (両側) の p 値は 8.24×10^{-84} となった。この比較は 1 つであり、有意水準は 0.05 とした。

表 5 追加学習していない Qwen3.5-4B と ver4 条件 D の比較 (内部開発評価画像 287 枚、候補一覧なし、包含採点、各 1 回)

モデル	正解数	正解率	完全一致
追加学習していない Qwen3.5-4B	3/287	1.05%	0/287
ver4 条件 D (LoRA あり)	280/287	97.56%	280/287

LoRA なしで正解となった 3 枚も、出力文の中に正解薬剤名が含まれていたものであり、薬剤名だけを答えた出力は 0 枚であった。今回の条件では、LoRA で追加学習したモデルの正解率が高かった。LoRA による追加学習で、対象薬剤の特徴を学べたためと考えられる。ただし、この点を確認する実験は行っていない。比較対象は ver4 条件 D であり、単剤の主結果 r16_a128 と LoRA なしの直接比較は行わなかった。また、LoRA なしの出力形式も異なったため、正解数だけでは誤りの原因を判断できなかった。LoRA なしは 1 回の評価、ver4 条件 D はシード 42 の 1 回学習であり、287 枚は内部開発評価画像であった。このため、新しく撮影した画像で 97.56% を再現した証拠ではない。

4.5 主結果 r16_a128 の選定と追加検証

4.5.1 LoRA 容量の系統比較と主結果の選定

ver6 の結果は、ランク 32・係数 64・シード 42 の 1 回の観測による。複数の設定と複数回の学習による系統的な比較は行っていなかった。そこで、画像拡張セットを v3_17 に固定し、LoRA のランク 8 から 64、係数 8 から 128 の 8 条件を設定した。基画像は 1,224 枚、総提示数は 107,525 枚、学習率は 0.0002、実効バッチは 128、計算精度は BF16 とした。各条件をシード 42、43、44 の 3 回ずつ比較した。6 条件は新たに学習し、残る 2 条件は設定が一致する既存の結果を用いた。結果を表 6 に示す。

8 条件のうち、3 回の学習の平均が最も高かったのは r16_a128 で、 $99.54\% \pm 0.53\text{pt}$ を示した。内訳は、シード 42 が 286/287 (99.65%)、43 が 287/287 (100.00%)、44 が 284/287 (98.95%) であった。シード 43 の 287/287 は、保存済みの予測ファイルの確認と、別プロセスでの再推論の両方で再現した。

8 条件のうち、ランクや係数を段階的に変えた比較と、主結果の条件との比較を合わせた 14 組について、正確 McNemar 検定を学習の各回で行った。比較は 14 組なので、有意水準を $0.05 \div 14 \approx 0.0036$ とした。3 回の学習すべてで補正後の有意水準を下回った組はなかった。r16_a64 から r16_a128 の 1 組も、どのシードも

表 6 v3.17 拡張・LoRA ランクと係数の系統比較（内部開発評価画像 287 枚の単剤正解率，3 回の学習）

条件	ランク	係数	シード 42	シード 43	シード 44	平均 ± 標本標準偏差
r08_a16	8	16	98.61%	97.91%	98.26%	98.26%±0.35pt
r16_a08	16	8	98.61%	97.91%	98.26%	98.26%±0.35pt
r16_a16	16	16	98.95%	97.91%	99.30%	98.72%±0.73pt
r16_a32	16	32	99.65%	98.95%	98.26%	98.95%±0.70pt
r16_a64	16	64	97.91%	98.26%	98.61%	98.26%±0.35pt
r16_a128	16	128	99.65%	100.00%	98.95%	99.54%±0.53pt
r32_a64	32	64	99.65%	98.95%	97.91%	98.84%±0.88pt
r64_a128	64	128	97.56%	99.30%	98.95%	98.61%±0.92pt

r16_a32・r32_a64 は他パッケージの一次資料からの参照値であり，本節での新規学習ではない。

有意水準に届かなかった ($p = 6.25 \times 10^{-2}$, 6.25×10^{-2} , 1.00). したがって，ver6 で見られた数値上の正解率の上昇は，統計的に有意な LoRA 容量の効果としては確認できなかった。

8 条件のうち平均の正解率が最も高かったため，r16_a128 を単剤の主結果とした．この値は 8 条件すべての結果を確認した後に選んだものであり，結果を見て条件を選んだ影響が残った．したがって，ランク 16・係数 128 が最良の設定とは言えなかった。

4.5.2 r16_a128 と旧主結果 ver4 条件 D の直接検定

r16_a128 と旧主結果 ver4 条件 D は，同じ 41 薬剤の収集画像を学習元としたが，学習の設定が異なった．そこで，同じ 287 枚について，保存済みの予測ファイルから正誤を数え直して対応比較を行った．r16_a128 の各シードを，同じ ver4 条件 D（1 回学習）と比較し，シードごとに正確 McNemar 検定を行った．比較は 1 つであり，有意水準は 0.05 とした．3 回の学習すべてで有意となった場合だけ，有意とした．結果を表 7 に示す．

表 7 r16_a128 と旧主結果 ver4 条件 D の直接検定（内部開発評価画像 287 枚の単剤正解率，ver4 条件 D は 1 回学習）

r16_a128 のシード	r16_a128	ver4 条件 D	r16_a128 のみ正解	ver4 条件 D のみ正解	p
シード 42	286/287	280/287	7	1	7.03×10^{-2}
シード 43	287/287	280/287	7	0	1.56×10^{-2}
シード 44	284/287	280/287	6	2	2.89×10^{-1}

r16_a128 は，3 回とも ver4 条件 D より正解数が多かった．しかし有意となったのはシード 43 ($p = 1.56 \times 10^{-2}$) だけで，シード 42 ($p = 7.03 \times 10^{-2}$) と 44 ($p = 2.89 \times 10^{-1}$) は有意でなかった．3 回とも有意とはならなかったため，r16_a128 が ver4 条件 D より高いとは一貫して言えなかった．両者は RTI の有無，画像拡張セットおよび LoRA の係数が同時に異なるため，差を特定の要因だけでは説明できなかった．また，ver4 条件 D 側は 1 回学習であり，学習のばらつきは検定に含めなかった．100 薬剤で比べた場合も，r16_a128 (96.75%) とランク 32・係数 64 系列 (94.89%) の間に有意差はなかった（第 4.7 節）．学習する薬剤の数がさらに増えれば，r16_a128 の設定の方が有利になる可能性もある．ただし，この点は確かめていない．

4.5.3 r16_a128 と Gemini の対応比較

r16_a128 と、保存済みの Gemini 3 条件との対応比較を行った。新規の学習と推論は行わず、保存済みの予測から正誤を数え直した。比較は 3 組なので、有意水準を $0.05 \div 3 \approx 0.017$ とした。結果を表 8 に示す。Gemini は温度 0 の単発評価であり、r16_a128 の 3 回の学習それぞれと同一の Gemini 結果を比較した。

表 8 r16_a128 と Gemini 3 条件の比較（内部開発評価画像 287 枚の単発正解率、 p は正確 McNemar 検定の両側の値）

条件	正解数 / 287	正解率	シード 42 p	シード 43 p	シード 44 p	判定
r16_a128（平均）	—	99.54%	—	—	—	—
Gemini 3.8 Flash 短文	238	82.93%	9.06×10^{-14}	3.55×10^{-15}	2.27×10^{-12}	3 回とも有意
Gemini 3.8 Flash 候補一覧	283	98.61%	3.75×10^{-1}	1.25×10^{-1}	1.00	有意差なし
Gemini 3.5 Flash 短文	156	54.36%	4.89×10^{-38}	7.35×10^{-40}	1.93×10^{-37}	3 回とも有意

短文の Gemini 2 条件に対しては、3 回の学習すべてで複数比較の補正後も、r16_a128 が有意に上回った。一方、41 薬剤の候補一覧を与えた Gemini 3.8 Flash（283/287、追加学習なし）とは、3 回とも統計的に区別できなかった。ただし、候補一覧付きの条件は 41 薬剤の中から選ぶ設定であり、候補なしの自由生成である r16_a128 とは入力条件が異なった。この非有意は、「候補があれば汎用モデルで十分」であることを意味しない。なお、保存済みの予測を完全一致採点で数え直すと、Gemini 3.8 Flash 短文は 238 から 178、3.5 Flash 短文は 156 から 123 となり、候補一覧付きは 283 のままであった。r16_a128 は 3 回とも変わらなかった。完全一致採点での検定は行わなかった。

4.6 信頼ゲートの評価

ver4 条件 D（ランク 16・係数 32）と ver6（ランク 32・係数 64）に、信頼ゲートを適用した。いずれもシード 42 の 1 回学習であり、しきい値は各モデルの校正集合で個別に決めた。表 9 に、最終評価集合（既知 148 枚・未知 58 枚）の結果を示す。

表 9 ver4 条件 D・ver6 の信頼ゲート最終評価集合の結果（既知 148 枚、未知 58 枚、各 1 回学習）

モデル	ゲート前既知正解数	既知で回答	回答中正解	既知保留	未知保留	未知への危険通過
ver4 条件 D	142/148	124/148	123/124	24/148	54/58	4/58
ver6	147/148	130/148	130/130	18/148	56/58	2/58

ver6 は、ver4 条件 D より既知回答数、回答中正解率および未知保留数のいずれも高かった。ただし、ver6 でも未知 58 枚中 2 枚（3.45%）へ危険通過し、どちらのモデルでも危険通過を 0 件にはできなかった。また、ver4 条件 C で校正したしきい値をそのまま ver4 条件 D・ver6 へ転送すると、危険通過はそれぞれ 10 件、9 件となった。モデルごとに校正し直すと、4 件と 2 件に減った。このことは、しきい値をモデル間でそのまま流用できないことを示した。どちらも 1 回学習であり、学習と校正のばらつきは検定しなかった。単剤の主結果 r16_a128 への適用は、本報告書では扱わず、今後の課題とした。

4.7 学習薬剤数の段階増加（41 から 100 薬剤）

学習に用いる薬剤の種類数を 41 薬剤から 100 薬剤まで段階的に増やし、全段階で同一の内部開発評価画像 287 枚を評価した。LoRA 容量と画像拡張の異なる 2 系列を実施した。ランク 16・係数 32 系列は、ランク 16・係数 32・acquisition_17 を用いた。ランク 32・係数 64 系列は、ランク 32・係数 64・v3_17 を用いた。いずれも 41, 50, 60, 70, 80, 90, 100 薬剤の 7 水準で、基画像数と総提示数を学習薬剤数に合わせて増やした。学習・評価は、シード 42, 43, 44 の 3 回で行った。結果を表 10 に示す。

表 10 学習薬剤数を 41 から 100 へ増やしたときの内部開発評価画像 287 枚の 3 回の学習の平均正解率（± は標本標準偏差）

学習薬剤数	ランク 16・係数 32 系列 (acquisition_17)	ランク 32・係数 64 系列 (v3_17)
41	97.33% ± 1.22pt	98.84% ± 0.88pt
50	97.79% ± 0.20pt	98.61% ± 0.70pt
60	97.68% ± 0.40pt	96.40% ± 2.64pt
70	95.59% ± 1.61pt	97.91% ± 0.70pt
80	91.52% ± 9.57pt	98.37% ± 0.73pt
90	98.03% ± 0.40pt	96.98% ± 1.22pt
100	96.40% ± 2.64pt	94.89% ± 0.80pt

追加した薬剤（42 番目以降）の評価画像は存在しなかった。したがって、本実験が測ったのは 100 薬剤を識別できるかではなく、学習薬剤数を増やしたときに、もともと学習していた 41 薬剤の正解率がどう変化するかであった。この結果から「100 種類に対応できた」とは判断できなかった。

いずれの系列も、正解率は学習薬剤数に対して単調に変化しなかった。ランク 16・係数 32 系列は、41 薬剤の 97.33% から 100 薬剤の 96.40% へ 0.93pt 低下し、80 薬剤では標本標準偏差が 9.57pt の大きな崩れ（シード 44 が 80.49%）があった。ランク 32・係数 64 系列は、41 薬剤の 98.84% から 100 薬剤の 94.89% へ 3.95pt 低下し、60 薬剤ではシード 44 が 93.38% まで落ち込んだ。図 8 に、表 10 の数値を図示する。横軸は学習薬剤数、縦軸は内部開発評価画像 287 枚の単剤正解率である。点は各シード、線は 3 回の学習の平均、誤差棒は標本標準偏差を表す。

崩れが生じる薬剤数は系列によって異なり、「100 薬剤で必ず崩れる」といった共通の法則は確認できなかった。2 系列は、LoRA 容量と画像拡張セットが同時に異なり、基画像数（1,224 枚から 2,994 枚）と総提示数（107,525 枚から 262,990 枚）も増加した。したがって、正解率の変化を学習薬剤数だけの効果に分けて説明できなかった。

主結果と同じ LoRA 容量・拡張セット（ランク 16・係数 128, v3_17）で、100 薬剤を学習した条件も評価した。基画像は 2,994 枚、総提示数は 262,990 枚とした。正解数は、シード 42 が 282/287 (98.26%)、43 が 273/287 (95.12%)、44 が 278/287 (96.86%) であり、3 回の学習の合計で 833/861 (96.75%) であった。41 薬剤の r16_a128（3 回の学習の平均 99.54%）より低かった。基画像数と総提示数も異なるため、差を学習薬剤数だけの効果に分けて説明できなかった。正確 McNemar 検定を用い、100 薬剤を学習した r16_a128 条件を 6 条件と比較した。比較対象は、41 薬剤の r16_a128、ランク 32・係数 64 系列とランク 16・係数 32 系列の 100 薬剤条件、および Gemini の 3 条件とした。比較は 6 組なので、有意水準を $0.05 \div 6 \approx 0.0083$ とした。100 薬剤を学習した条件と 41 薬剤の r16_a128 の比較は、シード 43 のみ有意であり ($p = 1.22 \times 10^{-4}$)、42 と 44 は有意でなかった ($p = 2.19 \times 10^{-1}$, 1.46×10^{-1})。100 薬剤を学習した条件の正解率は 3 回と




図8 学習薬剤数を41から100まで7水準で増やしたときの、ランク16・係数32系列（左）とランク32・係数64系列（右）の内部開発評価画像287枚単剤正解率（3回の学習）。

も41薬剤の条件より低かったが、3回とも有意とはならなかった。ランク32・係数64系列の100薬剤条件（94.89%）との比較でも、3回すべてで有意とはならなかった。設定によって結果がばらついたため、設定ごとに確かめる必要があると考えた。

4.8 隙間のない合成複数薬剤画像

薬剤数2, 3, 5, 8の隙間のない撮影元画像のタイルを各200枚、合計800枚用いた（固定800枚）。800枚から抽出された候補は4,336領域であり、期待薬剤ラベル数は3,600であった。結果の最高値、ver4条件Dの値およびr16_a128の値を、表11に示す。

表11 隙間のない合成複数薬剤画像800枚に対するTop-10方式とTop-N方式

方式	最高条件 (ver1~ver9)	最高結果 (800枚)	ver4 条件D	r16_a128 (3回の学習)
薬剤数未知・Top-10 方式	ver5-2, ver5-3, ver8	790/800 (98.75%)	76.25%	3回とも790/800 (98.750%)
薬剤数既知・Top-N 方式	ver8	682/800 (85.25%)	66.50%	学習3回の平均 85.000%±0.125pt

Top-10方式は余分な予測を許すため、790/800は画像完全一致率ではなく正解薬剤包含率である。r16_a128の値は、シード42, 43, 44の学習済みLoRAをRTX 4070 Ti SUPERで推論した結果であり、H100で推論した値とは推論に使用したGPUが異なる。

Top-10方式では、ver5-2, ver5-3およびver8が同率で790/800 (98.75%)となり、最も高かった。この

方式は、正解薬剤を取りこぼさないことを優先し、過検出を罰しなかった。Top-N 方式は、全条件で Top-10 方式を下回り、最高は ver8 の 682/800 (85.25%) にとどまった。候補の強度順位は、薬剤領域の完全性や識別しやすさを直接表さない。このため、正しい候補が N 位より後ろに残ることが低下の一因と考えられる。r16_a128 では、Top-10 方式が 3 回とも 790/800 (98.750%) であり、ver1 から ver9 の最高値と一致した。Top-N 方式は、シード 42, 43, 44 でそれぞれ 681/800, 680/800, 679/800 であり、ver8 の 682/800 を下回った。r16_a128 の Top-N 方式の画像正解率は、薬剤数が増えるほど低下し、2 薬剤の 96.500% から 8 薬剤の 64.333% まで下がった。Top-10 方式では、8 薬剤でも 95.000% を維持した。

図 9 に、固定 800 枚のうち 5 薬剤と 8 薬剤の各先頭 1 枚について、検出された候補枠と採点用の正解タイルを重ねて示す。検出器へは画像だけを与えた。2 枚は各薬剤数の先頭の画像であり、結果を見て選んだ画像ではない。薬剤名の予測には、r16_a128 のシード 42 を用いた。

5 薬剤の画像（同図 (a)）では 6 候補が検出され、5 候補が各タイルの薬剤と一致した。残る 1 候補は、正解薬剤に含まれない薬剤と予測された余分な検出となった。8 薬剤の画像（同図 (b)）では 10 候補が検出され、うち 8 候補が一致し、2 候補が余分となった。2 枚とも、余分な候補は順位 N より後ろであり、Top-10 方式と Top-N 方式のいずれでも成功と記録されていた。これに対し、余分な候補が正解薬剤の候補より上位に入った画像は、Top-N 方式では失敗と判定した。過検出の影響は画像によって異なった。

4.9 総合考察

本報告書が示した単剤正解率は、性質の異なる 3 つの区分に分かれた。表 12 に、その位置付けを示す。

表 12 本報告書が示す単剤正解率の位置付け（内部開発評価画像 287 枚）


位置付け	条件	単剤正解率	扱い
主結果	r16_a128 (3 回の学習)	99.54%±0.53pt	8 条件を比較し、3 回の平均が最も高かったため選んだ(第 4.5.1 節)。
旧主結果	ver4 条件 D	280/287 (97.56%)	実験の開始前に主結果として定めた設定の、1 回学習の観測値であった。
結果を見てから選んだ最高値	ver6, ver8, ver9	286/287 (99.65%)	結果を確認した後に選んだ条件であり、主結果とは別に扱った。

条件比較では、量子化、LoRA のランク、係数、学習対象層などを同時に変更しており、個別の要因の効果は分離できなかった。ver6 の 286/287 は、ver4 条件 C に対して有意でなかった。LoRA のランクと係数を変えた 8 条件の 14 組の比較でも、3 回の学習に共通する有意差は確認できなかった。100 薬剤の条件どうして比べても、r16_a128 (96.75%) とランク 32・係数 64 系列 (94.89%) の間に有意差はなかった。ランクを上げると学習に使えるパラメータ数が増えるため、意味はあると考えた。今回効果が見えなかったのは、学習した薬剤数が 41 と少なかったためかもしれない。この点は確かめていない。

単剤の主結果 r16_a128 は、99.54%±0.53pt (3 回の学習の平均) を示し、旧主結果 ver4 条件 D は 97.56% となった。両者の直接検定は、シードにより判定が割れた。LoRA なしでは 287 枚中 3 枚、追加学習した ver4 条件 D では 280 枚に正解した。候補一覧を与えた Gemini 3.8 Flash とは、有意差がなかった。候補を与えない Gemini の 2 条件は、3 回とも有意に上回った。固定 800 枚の推論は研究室の GPU (RTX 4070 Ti SUPER) で実行でき、外部のサービスにデータを送らずに使える点に意味があると考えた。

固定 800 枚では、薬剤数を仮定しない Top-10 方式の 98.75% に対し、薬剤数を既知とする Top-N 方式の


(a) 5薬剤 (count_05_case_001) 入力 3840×1024画素



5薬剤・検出候補6件 (番号は前景強度の順位)

- | | |
|-------------------------|------------------------------|
| 1 対応: 予測 クエン酸第一鉄Na錠50mg | 4 対応: 予測 エソメプラゾールカプセル20mg |
| 2 対応: 予測 メトグルコ錠250mg | 5 対応: 予測 ロスバスタチン錠2.5mg「DSEP」 |
| 3 対応: 予測 フロセミド錠20mg | 6 余分: 予測 メチコパール錠500μg |

(b) 8薬剤 (count_08_case_001) 入力 3072×2048画素



8薬剤・検出候補10件 (番号は前景強度の順位)

- | | |
|-------------------------|------------------------------|
| 1 対応: 予測 レバミピド錠100mg | 6 対応: 予測 酸化マグネシウム錠330mg |
| 2 対応: 予測 パルモディアXR錠0.2mg | 7 対応: 予測 デエビゴ錠5mg |
| 3 対応: 予測 ウルソ錠100mg | 8 対応: 予測 ロスバスタチン錠2.5mg「DSEP」 |
| 4 対応: 予測 メチコパール錠500μg | 9 余分: 予測 ジャディアンス錠10mg |
| 5 対応: 予測 プレドニン錠5mg | 10 余分: 予測 メチコパール錠500μg |

橙: 採点用の正解タイル (検出器には与えていない)

緑: 予測薬剤名が枠中心のタイルの正解薬剤名と一致

赤: 一致しない候補 (余分な検出)

図9 固定800枚における検出候補枠と正解タイルの実例。(a)は5薬剤, (b)は8薬剤の各先頭1枚である。橙色が採点用の正解タイル, 緑色が予測薬剤名と枠中心のタイルの正解薬剤名が一致した候補, 赤色が一致しなかった候補である。

最高は 85.25% にとどまった。画像単位の完全一致では、候補中の誤りが画像全体の不一致となる。複数薬剤では、薬剤の領域を切り出す処理の失敗と、正しい候補が N 位より後ろに残ることが、正解率を下げた原因と考えられるが、それぞれがどれだけ影響したかは分けて確かめなかった。

信頼ゲートは、どちらのモデルでも未知薬剤への危険通過を 0 件にできなかった。この点は、未知薬剤の種類を増やして確かめ、誤回答をさらに減らす必要があると考えた。

4.10 評価範囲と注意点

今回の評価の範囲と、結果を解釈する際の注意点を以下に示す。

1. 評価対象は 41 薬剤に限られた。
2. 評価に用いた 287 枚は条件検討に反復使用しており、条件を決めた後に別の写真で確認する評価は行わなかった。r16.a128 も 8 条件を同じ 287 枚で比較した後に選んだため、結果を見て条件を選んだ影響が残った。
3. 主結果は 3 回の学習（シード 42, 43, 44）で評価したが、ver1 から ver9, ver4 条件 D や信頼ゲートなど一部の比較は 1 回の学習であった。これらの比較では学習のばらつきを評価しなかった。複数比較の補正は、問いごとに 14 組, 3 組, 6 組の範囲で行った。
4. 固定 800 枚はタイル合成画像であり、実写の複数薬剤画像での性能は確かめなかった。また、信頼ゲートは ver4 条件 D と ver6 だけに適用し、既知側と未知側の撮影条件も異なった。
5. LoRA なしとの比較は ver4 条件 D との比較であり、Gemini の候補一覧付き条件とは入力条件が異なった。短文条件では同じ画像と同じプロンプトを用いた。
6. 速度を優先して計算の再現性を確保する設定にしなかったため、学習をやり直しても全く同じ結果になるとは限らない。収集画像の整理や撮影に要した時間と、スマートフォン上の動作は評価しなかった。

5 結論・今後の課題

5.1 結論

本研究では、1 薬剤当たりフルシートの表面画像 1 枚と裏面画像 1 枚から学習集合を構成し、41 薬剤の PTP 包装識別性能を評価することを目的とした。この目的に対し、Web から集めた表裏のフルシート画像から RTI と部分画像を生成し、画像拡張を適用して Qwen3.5-4B を LoRA で追加学習した。主結果の条件では RTI を学習に含めなかった。大学病院薬剤部で撮影した内部開発評価画像 287 枚を用いて、単剤正解率を評価した。

単剤の主結果 r16_a128 の正解率は、3 回の学習の平均で 99.54% であった。この条件は 8 条件を同じ 287 枚で比較して選んだため、高めにしている可能性がある（第 4.5.1 節）。LoRA なしの Qwen3.5-4B は 287 枚中 3 枚の正解であり、ver4 条件 D の 280 枚との間に有意な差があった。旧主結果 ver4 条件 D と r16_a128 の直接検定は、シードにより判定が割れた。Gemini の短文条件には 3 回とも有意に高く、候補一覧付きの条件とは有意差がなかった。固定 800 枚では、Top-10 方式が最高 790/800、Top-N 方式が最高 682/800 を示した。信頼ゲートでは、未知薬剤への危険通過を 0 件にできなかった。学習薬剤数を 41 から 100 へ増やしても、既知 41 薬剤の正解率は単調に変化しなかった。

目的は、41 薬剤の内部開発評価画像 287 枚について、少ない収集画像から実写の薬剤名を識別するという範囲でおおむね達成できた。ただし、条件の選択と評価に同じ 287 枚を用い、評価した薬剤も 41 種に限られた。また、実写の複数薬剤画像の識別と未知薬剤への回答保留は課題として残ったため、目的を達成できたのは今回の範囲に限られた。

LoRA による追加学習で正解率が上がったのは、対象薬剤の特徴を学べたためと考えられる。ランクや係数を変えても有意な差は見えず、100 薬剤で r16_a128 とランク 32・係数 64 系列を比べても有意差はなかった。この点には、学習した薬剤が 41 と少なかったことが関係した可能性があるが、確かめていない。複数薬剤で正解率が低かった点は、薬剤領域の切り出しの失敗と、正しい候補が N 位より後ろに残ることが原因と考えた。学習薬剤数を変えると結果がばらついたため、設定ごとに確かめる必要があると考えられる。

本研究では、専用の撮影機材を使わず、Web から集めた少ない収集画像でモデルを学習できた。固定 800 枚の推論は研究室の GPU で実行でき、外部へ画像を送らずに使える点に意義があると考えた。ただし、作業時間の削減は測定しなかった。

5.2 今後の課題

第一の課題は、学習する薬剤の数を増やしても正解率を保つことであった。追加した薬剤については、学習に使わない実写画像で評価する必要があると考えた。第二の課題は、部分画像の内容と学習量のどちらが結果に効いたかを調べることであった。学習量をそろえて画像の組合せを変える比較と、複数回の学習による確認が必要になる可能性がある。

その次に、未知薬剤への回答保留と、実写の複数薬剤画像での識別が課題となった。未知薬剤では、既知薬剤と同じ撮影条件で誤回答を減らせるかが未確認であった。

謝辞

本研究の遂行にあたり，多大なご指導とご助言を賜った森山真光准教授に，心より感謝する．また，本研究で用いた薬剤画像の撮影にご協力いただくとともに，薬剤鑑別に関する貴重なお助言を賜った共同研究者である近畿大学病院薬剤部の皆様，ならびに木村裕一教授に深く感謝する．

参考文献

- [1] Y. Han, S.-L. Chung, Q. Xiao, J.-S. Wang, and S.-F. Su. Pharmaceutical Blister Package Identification Based on Induced Deep Learning. *IEEE Access*, Vol. 9, pp. 101344–101356, 2021.
<https://doi.org/10.1109/ACCESS.2021.3097181>, 最終閲覧日：2026 年 7 月 26 日.
- [2] World Health Organization. Medication Without Harm: WHO Global Patient Safety Challenge.
<https://www.who.int/publications/i/item/WHO-HIS-SDS-2017.6>, 2017, 最終閲覧日：2026 年 10 月 4 日.
- [3] 末次 王卓, 金澤 直子, 正門 佳法, 天達 菜緒, 副田 雪乃, 屋地 慶子, and 寺菌 英之. AI 画像解析錠剤識別システムの使用による持参薬錠剤一包化鑑別作業の効率化と薬剤助手へのタスク・シフト／タスク・シェアに関する評価. *医療薬学*, Vol. 52, No. 5, pp. 273–281, 2026. <https://doi.org/10.5649/jjphcs.52.273>, 最終閲覧日：2026 年 7 月 25 日.
- [4] J. Heo, Y. Kang, S. Lee, D.-H. Jeong, and K.-M. Kim. An Accurate Deep Learning-Based System for Automatic Pill Identification: Model Development and Validation. *Journal of Medical Internet Research*, Vol. 25, pp. e41043, 2023.
<https://doi.org/10.2196/41043>, 最終閲覧日：2026 年 7 月 25 日.
- [5] N. Usuyama, N. L. Delgado, A. K. Hall, and J. Lundin. ePillID Dataset: A Low-Shot Fine-Grained Benchmark for Pill Identification. In *2020 IEEE/CVF Conference on Computer Vision and Pattern Recognition Workshops (CVPRW)*, pp. 3971–3977, 2020. <https://doi.org/10.1109/CVPRW50498.2020.00463>, 最終閲覧日：2026 年 8 月 10 日.
- [6] C. Shorten and T. M. Khoshgoftaar. A Survey on Image Data Augmentation for Deep Learning. *Journal of Big Data*, Vol. 6, No. 1, 2019. Article 60, <https://doi.org/10.1186/s40537-019-0197-0>, 最終閲覧日：2026 年 7 月 25 日.
- [7] R. Menaha, R. Abilaash, P. N. Mohanram, A. Unnikrishnan, and S. Sukumar. Drug Pills Identification System using Google Gemini LLM: A Generative AI Approach. In *2024 International Conference on Emerging Research in Computational Science (ICERCS)*, pp. 1–5, 2024. <https://doi.org/10.1109/ICERCS63125.2024.10895371>, 最終閲覧日：2026 年 7 月 25 日.
- [8] J. Bai, S. Bai, S. Yang, S. Wang, S. Tan, P. Wang, J. Lin, C. Zhou, and J. Zhou. Qwen-VL: A Versatile Vision-Language Model for Understanding, Localization, Text Reading, and Beyond.
<https://arxiv.org/abs/2308.12966>, 2023, arXiv:2308.12966, 最終閲覧日：2026 年 7 月 25 日.
- [9] Qwen Team. Qwen3.5-4B Model Card. <https://huggingface.co/Qwen/Qwen3.5-4B>, 2026, 使用リビジョン：851bf6e806efd8d0a36b00ddf55e13ccb7b8cd0a, 最終閲覧日：2026 年 7 月 27 日.
- [10] E. J. Hu, Y. Shen, P. Wallis, Z. Allen-Zhu, Y. Li, S. Wang, L. Wang, and W. Chen. LoRA: Low-Rank Adaptation of Large Language Models. In *Proceedings of the 10th International Conference on Learning Representations*, 2022. 著者版：<https://arxiv.org/abs/2106.09685>, 最終閲覧日：2026 年 7 月 25 日.
- [11] Y. Geifman and R. El-Yaniv. Selective Classification for Deep Neural Networks. In *Advances in Neural Information Processing Systems* 30, pp. 4878–4887, 2017.
<https://proceedings.neurips.cc/paper/2017/hash/4a8423d5e91fda00bb7e46540e2b0cf1-Abstract.html>, 最終閲覧日：2026 年 8 月 11 日.
- [12] 田辺ファーマ. 製剤写真 メインテート錠 2.5mg / 500 錠 (10 錠× 50) .
<https://medical.tanabe-pharma.com/di/product/mnt/photo/thumbnails/0000002350/>, 10 錠 PTP 写真, 最終閲覧日：2026 年 10 月 4 日.